한국어 합성데이터 기반 LLM-as-a-Judge의 평가자별 선호 누출 추정

GPT·Claude·Gemini가 만든 답으로 학습한 학생 모델을, 같은 세 모델이 평가할 때 자기 계열 학생을 더 좋게 보는가?

96.5%
서식을 지워도 답변만으로 생성 모델을 구별 (KLUE-RoBERTa, 우연 33.3%)

15 / 15
학생 15명 모두 자기 교사의 답에서 loss가 가장 낮음 (교차 loss)

+9.8%p
Gemini 평가자의 자기 계열 효과: 품질이 같은 상대를 이길 확률 (Holm p 0.003)

50%
첫 번째(A) 답을 1위로 뽑은 비율, GPT 평가자 (기대 33.3%)

목차

제목을 누르면 해당 위치로 이동한다. 각 절 제목 오른쪽의 "↑ 목차"를 누르면 여기로 돌아온다.

1 연구 배경

2 연구 질문

3 데이터

- 교사 답변 생성
- 교사에게 준 지시와 생성 조건
- 평가 데이터: "학생 15명 모두 끝까지 쓴 144개"란 무엇인가
- 데이터 구성
- 실제로 보낸 요청과 받은 답 (교사 생성 한 건)

4 LLM의 답변만으로 어떤 모델인지 구별할 수 있는가?

- 4.1 실험 설계 한눈에 보기
- 4.2 재료: 같은 질문에 대한 세 모델의 답
- 4.3 질문 단위 분할: 왜 질문으로 나누는가
- 4.4 분류기 ① 글자 n-gram TF-IDF + 다항 로지스틱 회귀
- 4.5 분류기 ② KLUE-RoBERTa 미세조정
- 4.6 통제 실험: 정규화로 "겉모양" 지우기
- 4.7 평가 지표: 정확도와 F1 점수
- 4.8 결과
- 4.9 세 교사의 스타일 프로필 자세히
- 4.10 분류 결과 더 깊이 보기: 평가자가 물어볼 만한 것

5 학생 모델 학습 (SFT)

- 5.1 학습 과정
- 5.1.1 학습 설정과 그 이유
- 5.1.2 학습 데이터 한 건은 실제로 이렇게 생겼다
- 5.2 loss와 perplexity란 무엇인가
- 5.3 학습이 잘 되었는가: val loss
- 5.4 학생이 자기 교사의 스타일을 흡수했는가: 교차 loss
- 5.5 학생 응답의 완결성
- 5.5.1 학생 답을 두 번 생성한 이유

6 LLM-as-a-Judge: 설계, 과정, 결과

6.1 설계
6.1.0 평가 설계를 이렇게 정한 이유
6.1.0-1 평가자에게 실제로 보낸 프롬프트와 받은 응답
6.1.0-2 프롬프트를 어떻게 조정했나
6.1.1 실제 평가 한 건 보기: 선호 누출은 판정에서 어떻게 보이나
6.1.2 반대 경우: 한 답만 핵심을 맞혔을 때 평가자는 어떻게 판정했나
6.1.3 평가자의 근거 문장에서 보이는 패턴
6.2 선호 편향을 재는 방법
(1) 1위 비율: "나머지 두 답보다 위에 놓았나?"
(2) 쌍대 승률: "상대 한 명과 붙었을 때 이겼나?"
(3) 두 지표로 알고 싶은 것: 선호 누출
(4) 통계를 몰라도 이해하는 분석의 논리: 요리 대회로 보기
(5) 그래서 본 연구가 쓴 방법: 세 평가자의 편향을 동시에 추정하는 통계 모형
(6) 우연이 아닌지 확인하는 두 도구: 부트스트랩과 Holm 보정
6.3 결과 ① 원자료: 평가자는 각 학생을 몇 번 1위·2위·3위로 놓았나 (최종 순위)
6.4 결과 ② 선호 누출 추정: 단순 계산과 세 통계 모형 (주 결과, 최종 순위)
6.4.1 길이 통제: 자기 계열 선호가 답 길이 때문은 아닌가
6.5 결과 ③ 다섯 번의 독립 학습(seed)에서도 반복되는가
6.6 결과 ④ 평가 기준별 분석 (ablation)
6.7 결과 ⑤ 위치 편향: 순서를 바꿔 넣은 설계가 필요했나

7 결과 해석

7.1 단순 계산에서 통계 모형으로: 무엇이 달라졌고 왜 달라졌나
7.2 가설 검정: 무엇을 검정했고 왜 "유의하다/유의하지 않다"고 판단했나
7.3 종합: 연구 질문에 대한 답과 근거
모델 성능과 누출: 성능이 높은 평가자일수록 편향이 적은가
한계

8 향후 연구 계획: 선호 누출을 어떻게 억제할 것인가

8.1 데이터 쪽 억제: 학습 데이터의 비율과 문체를 바꾸면 누출이 줄어드는가
8.2 다른 계열 평가자는 정말 공정한가: 외부 평가자로 검증
8.3 평가 쪽 억제: 평가 입력과 프롬프트를 바꾸면 누출이 줄어드는가
8.4 평가자나 학생이 커지면 누출이 저절로 사라지는가
8.5 실행 순서와 규모

9 초록

+ 부록. 예상 질문과 답

+ 참고문헌

1 연구 배경

↑ 목차

합성데이터 학습. 작은 모델을 학습시킬 사람이 쓴 데이터가 부족하면, GPT·Claude·Gemini 같은 큰 모델(교사)에게 답을 쓰게 해 그 답으로 작은 모델(학생)을 학습한다. 학생은 교사의 지식뿐 아니라 **말투, 형식, 어휘**까지 물려받는다.

LLM-as-a-Judge. 학생의 성능은 사람이 채점하기에 비싸서, 다시 큰 모델에게 채점을 맡긴다(Zheng et al., 2023). 평가가 빠르고 사람 판단과도 꽤 일치하지만, LLM 평가자에게는 **위치 편향**(먼저 나온 답 선호), **길이 편향**, **자기 선호**(자기 출력 선호; Panickssery et al., 2024) 같은 체계적 편향이 있다고 보고되었다.

선호 누출(preference leakage). 데이터를 만든 모델과 채점하는 모델이 같거나 관련되어 있으면, 평가자가 **자기 문체를 물려받은 학생**을 품질과 무관하게 더 좋게 볼 수 있다(Li et al., 2026). 이 현상은 영어 벤치마크에서 처음 보고되었다.

> **왜 중요한가.** 같은 계열의 모델로 데이터를 만들고 평가까지 하는 일은 흔하다. 누출이 있으면 "어느 학생 모델이 더 좋은가"라는 결론이 실제 품질이 아니라 **평가자와의 계보**로 정해질 수 있다. 한국어 합성데이터에서 이 현상이 나타나는지, 얼마나 큰지는 아직 확인되지 않았다.

2 연구 질문

↑ 목차

"LLM 평가자는 자기 모델이 만든 합성데이터로 학습한 모델의 답을 더 좋게 평가하는가?"

요즘 작은 모델은 큰 모델(GPT, Claude, Gemini)이 만든 답으로 학습시키고(합성데이터 학습), 그 성능도 큰 모델에게 채점을 맡긴다(LLM-as-a-Judge). 이때 데이터를 만든 모델과 채점하는 모델이 같으면, 채점 모델이 자기 문체를 물려받은 답을 좋게 보는 **선호 누출**이 생길 수 있다(Li et al., 2026). 이 연구는 한국어 질문에서 이 현상이 실제로 나타나는지, 얼마나 큰지 측정했다.

- **가설 H1:** 평가자는 품질이 같다면 자기 계열 학생을 더 높은 순위에 놓는다. → 6절(최종 순위)
- **가설 H2:** 이 선호는 평가 기준에 따라 크기가 다르다. → 6절(기준별 분석)
- **가설 H3:** 이 선호는 학습 무작위성(seed)에 따른 우연이 아니라 다섯 번의 반복 학습에서 모두 나타난다. → 6절(seed 반복)

전제 확인(앞선 단계): 세 교사의 답은 답만 보고도 97% 정확도로 구별되고(다항 로지스틱 97.2%, KLUE-RoBERTa 97.1%; 서식을 지운 텍스트에서도 92.1%, 96.5%), 학생 15명 모두 자기 교사의 문체를 물려받았다(교차 loss 15/15). 즉 평가자가 자기 계열 문체를 알아볼 수 있는 조건이다.

3 데이터

↑ 목차

① 원천
beomi/KoAlpaca-v1.1a 21,155개 (네이버 지식iN 질문 기반 한국어 지시 데이터)

② 추출
빈 질문·중복 제거 후 seed 42로 학습용 1,200개 + 평가용 400개 (서로 겹치지 않음)

③ 교사 생성
GPT·Claude·Gemini가 같은 시스템 프롬프트로 1,200개에 답

④ 학습 데이터
세 교사 모두 답한 1,199개 중 1,000개 학습 + 199개 검증

⑤ 평가 데이터
학생 15명이 평가 질문 400개에 답 → 모두 끝까지 쓴 144개 중 100개를 평가

교사 답변 생성

항목	GPT	Claude	Gemini
모델	gpt-5.6-terra	claude-sonnet-5-5	gemini-3.8-flash
추론 설정	effort medium	adaptive, effort medium	thinking medium
공통	같은 시스템 프롬프트(한국어, 600자 이내, 단정 금지 등), temperature 기본값, 출력 한도 4,096토큰		
실패	0	1 (안전 필터 거절 → 세 교사 모두에서 제외)	0

마크다운(굵게, 목록) 사용 여부는 일부러 지정하지 않아, 형식 차이도 모델 고유 스타일로 남겼다.

데이터 구성

용도	질문 수	설명
학생 학습	1,000	세 교사 답 각 1,000개, 같은 질문 id
학습 중 검증	199	학습에 안 쓴 질문. val loss, 교차 loss
분류 실험	1,199 × 3	질문 단위 70/15/15 분할 (train 839, val 179, test 181)
학생 응답	400	학습 질문과 겹치지 않는 평가 질문
LLM 평가	100	학생 15명 모두 끝까지 답한 144개 중 추첨

길이 검사: 학습 형식 전체를 Qwen3 토크나이저로 세면 최대 945토큰으로 1,024를 넘는 예제는 없어, 길이 때문에 빠진 질문은 없다.

교사에게 준 지시와 생성 조건

세 교사는 아래 조건을 모두 똑같이 맞추고 **모델만 바꿔** 답변을 생성했다. 그래야 세 교사의 답이 다른 이유를 "모델 고유의 스타일"로 돌릴 수 있다.

#	공통 시스템 프롬프트의 규칙	왜 이렇게 지시했나
1	한국어로 답한다. 전문용어는 영어를 함께 적을 수 있다	학생이 한국어 답변을 배우게 한다. 영어 병기 습관은 모델마다 남겨 둔다
2	되묻지 않고 바로 답한다. 모호하면 가장 일반적인 해석으로 답한다	모든 질문에 답변이 생겨 1,200개를 그대로 학습 데이터로 쓸 수 있다
3	600자 이내에서 완결되게 쓴다	학생 학습 길이(1,024토큰) 안에 들어오게 한다
4	AI라는 점, 모델 이름, 개발사를 언급하지 않는다	답변 속 이름표로 평가자가 출처를 알아채는 것을 막는다(블라인드 평가의 전제)
5	확실하지 않은 내용을 단정하지 않는다. 없는 출처·링크를 만들지 않는다	교사 답의 사실 오류를 줄인다
6	의료·법률·금융 질문은 일반 정보 + 필요하면 전문가 상담을 한 문장으로 권한다	민감 질문에서도 거절 대신 답을 얻는다

표 3-3. 세 교사가 함께 받은 시스템 프롬프트(`inference/prompt.py`). 학생 학습과 응답 생성에도 같은 시스템 프롬프트를 쓴다.

같게 맞춘 조건	내용
temperature	세 모델 모두 보내지 않음(각 제공사 기본값)
출력 한도	4,096토큰(사고 토큰 포함)
요청 방식	질문 1개당 요청 1개, 동시 8개, 서버 오류 시 최대 5회 재시도
형식 지시	마크다운(굵게, 목록) 사용 여부는 지시하지 않음 → 형식 차이도 모델 고유 스타일로 남김
제외 1건	Claude가 "윈도우 XP 로그인 비밀번호를 제거하는 방법"(id 9341)을 두 번 모두 거절 → 공정한 비교를 위해 세 교사 모두에서 제외 (1,200 → 1,199개)

표 3-4. 생성 조건과 제외 내역.

실제로 보낸 요청과 받은 답 (교사 생성 한 건)

LLM에게 일을 시킬 때는 보통 두 가지 글을 보낸다. **시스템 프롬프트**는 "너는 어떤 역할이고 어떤 규칙을 지켜라"라는 지시문이고, 모든 질문에 똑같이 붙는다. **사용자 메시지**는 매번 바뀌는 실제 질문이다. 모델은 둘을 함께 읽고 **답(assistant)**을 쓴다. 아래는 GPT 교사에게 실제로 보낸 요청과 받은 답이다.

system · 시스템 프롬프트 (세 교사 공통)

당신은 한국어 사용자의 질문에 답하는 어시스턴트입니다.
다음 규칙을 지켜 답변하십시오.

1. 한국어로 답합니다. 전문용어는 필요하면 영어를 함께 적을 수 있습니다.
2. 질문에 바로 답합니다. 되묻거나 추가 정보를 요청하지 않습니다. 질문이 모호하면 가장 일반적인 해석으로 답합니다.
3. 답변은 600자 이내에서 완결되게 작성합니다.
4. 자신이 AI라는 점, 모델 이름, 개발사를 언급하지 않습니다.
5. 확실하지 않은 내용을 단정하지 않습니다. 존재하지 않는 출처나 링크를 만들지 않습니다.
6. 의료, 법률, 금융처럼 전문가 확인이 필요한 질문에는 일반적인 정보를 제공하고, 필요하면 전문가 상담을 한 문장으로 권합니다.

user · 질문 (KoAlpaca 원문 그대로)

'오지랖이 넓다'란 무슨 뜻인가요?

assistant · GPT 교사의 실제 답

‘오지랖이 넓다’는 남의 일에 필요 이상으로 관심을 가지거나, 부탁받지 않았는데도 참견하는 성향을 뜻합니다. 대체로 부정적인 뉘앙스가 있습니다.

예: “그 사람은 남의 사생활까지 물어봐서 오지랖이 넓어.”
다만 상황에 따라 남을 잘 챙기고 적극적으로 돕는다는 뜻으로 가볍게 쓰이기도 합니다.

그림 3-1. 교사 생성 요청 한 건(질문 id 820). 같은 요청을 Claude와 Gemini에도 그대로 보냈고, 세 교사의 답은 표 4-1에서 나란히 비교한다. 이렇게 1,200개 질문마다 요청을 하나씩 보냈다(`inference/gen_gpt.py`, `gen_claude.py`, `gen_gemini.py`).

평가 데이터: "학생 15명 모두 끝까지 쓴 144개"란 무엇인가

"끝까지 쓴 답"(완전한 답)의 정의. 학생은 답을 다 쓰면 **끝 토큰**(<|im_end|>)을 스스로 내고 멈추도록 학습되었다(5.1). 생성 한도는 1,024토큰이다. 끝 토큰을 내고 1,024토큰 전에 멈춘 답을 "완전한 답", 끝 토큰 없이 1,024토큰에서 **강제로 잘린** 답을 "잘린 답"이라고 부른다.

- **전체:** 학생 15명 × 평가 질문 400개 = 답 6,000개 중 **502개(8.4%)가 잘린 답**이다. 502개 모두 끝 토큰을 내지 못해 1,024토큰에서 잘렸고, 빈 답은 없었다. 학생별 개수는 표 5-3에 있다(Claude 학생이 373개로 가장 많다).
- **144개:** 한 질문에 대해 학생 15명의 답이 **모두** 완전한 질문이다. 400개 중 144개다. 이 중 100개를 추첨(추첨 난수 42)해 LLM 평가에 썼다.
- **왜 "15명 모두"인가:** listwise 평가는 같은 질문에 대한 같은 seed의 학생 세 명을 나란히 비교한다. 한 명의 답만 잘려 있으면 평가자는 문체가 아니라 "잘렸다"는 이유로 그 답을 꼴찌로 놓을 것이다. 또 다섯 seed 모두에서 **같은 질문 100개**를 써야 seed 간 결과를 비교할 수 있다.

질문 하나에서 완전한 답을 쓴 학생 수 (15명 중)	15명	14명	13명	12명	11명	10명	9명	7명	합계
질문 수	**144**	121	73	37	11	8	4	2	400

표 3-1. 평가 질문 400개를 "완전한 답을 쓴 학생 수"로 나눈 것. 14명인 121개 질문은 15명 중 단 한 명이 잘려서 빠졌다.

교차 검증: 144개 모두 15명 전원의 답이 완전한지 다시 확인했고(위반 0건), 빠진 256개는 모두 적어도 한 학생의 답이 실제로 불완전했다(위반 0건). 100개 추첨에 쓴 난수 42는 추첨을 재현하기 위한 값으로, 학생 모델의 seed(42~46)와는 무관하다.

예시: 같은 질문에서 완전한 답과 잘린 답. 질문 "어른 펭귄과 새끼 펭귄의 털색깔이 다른 이유는 무엇인가요?"에 같은 GPT 교사 데이터로 학습한 두 학생이 답했다. 이 질문은 seed 45 학생 한 명이 잘려서 144개에서 빠졌다.

학생	답 (발췌)
GPT 학생 seed 42 완전한 답, 235토큰에서 끝 토큰을 내고 멈춤	어른 펭귄의 턔색은 **주성유전**이라서 새끼와 거의 같아집니다. … 다만 헤드카펫이나 얼굴 부분의 노랑/파랑 등은 서로 다른 유전자 때문에 달라질 수 있습니다. [끝]
GPT 학생 seed 45 잘린 답, 1,024토큰에서 강제 종료	어른 펭귄과 새끼 펭귄의 털색깔 차이는 주로 **생리구조** 때문입니다. … 새끼 펭귄은 아직 변하지 않았을 가능성이 큽니다.) ↵ ↵ ↵ (빈 줄) 유전적 요인이 더 큰 역할을 하는 경우도 있지만, 생리구조가 가장 크게 작용합니다.) ↵ ↵ ↵ 유전학자는 헤르페린(Herpesin), 세로닌 합성효소(SNase) 등을 연구해 …) ↵ ↵ ↵ 유전적 차이는 없더라도 어른 펭귄이 녹색·검란색이며, …) ↵ ↵ ↵ 유전학자는 헤르페린(Herpesin), 세로닌 합성효소(SNase) 등을 연구해 …) ↵ ↵ ↵ 유전적 차이는 없더라도 어른 펭귄이 녹색·검란색이며, 새끼 펭귄이 [1,024토큰에서 잘림]
GPT 학생 seed 44 다른 질문 "시력이 12면 어느 정도까지 보일까요?"의 잘린 답	… 다만 모든 면이 10배 더 잘 보이는 것은 아닙니다.) ↵ ↵ ↵ 유연성은 무엇이며, 유연성이란 말은 어떤 의미인가요? 유연성은 생물체가 특정 환경 변화에 대응하거나 …) ↵ ↵ ↵ 생명체 내부에서 에너지를 저장하는 장소는 어디인가요? … [스스로 새 질문을 지어내고 답하기를 반복하다 잘림]

표 3-2. 학생 답의 앞부분과 끝부분. ↵ = 줄바꿈. 두 학생 모두 내용은 사실과 다르다(0.6B 학생 답의 일반적 수준, 6.1 참고). 이 절의 관심은 내용이 아니라 **끝맺음**이다.

잘린 답의 두 가지 모양. 잘린 답 502개를 살펴보면, (1) 답을 다 쓴 자리에서 끝 토큰 대신 ")"와 빈 줄을 내고 계속 쓰는 경우가 431개(86%)이고, (2) 후반부에 **같은 문장 조각이 세 번 이상 되풀이되는** 반복 루프가 422개(84%)다(두 모양은 대부분 함께 나타난다). 나머지는 위 seed 44처럼 새 질문을 지어내 답을 이어 가는 경우다.

왜 0.6B 모델은 이렇게 끝맺지 못하고 반복하는가: 선행 연구

- **greedy 디코딩이 반복을 부른다.** 매 위치에서 확률이 가장 높은 토큰만 고르는 최대화 기반 디코딩(greedy, beam search)은 사람 글과 달리 같은 말을 되풀이하는 퇴화(degeneration)를 자주 일으킨다(Holtzman et al., 2020). 본 연구는 같은 입력에 항상 같은 답이 나오도록(결과가 무작위 추출 운에 좌우되지 않도록) greedy 디코딩을 썼다.
- **최대우도 학습 자체가 반복에 너무 높은 확률을 준다.** 다음 토큰의 우도를 최대화하는 표준 학습 목표로 학습한 모델은 반복과 흔한 단어가 들어간 문장에 사람 글보다 과도한 확률을 준다(Welleck et al., 2020).
- **반복은 스스로 강화된다.** 문장이 문맥에 한 번 반복되면, 반복 횟수가 늘수록 그 문장을 또 생성할 확률이 계속 커진다(self-reinforcement effect). 처음부터 확률이 높았던 문장일수록 이 효과가 강하다(Xu et al., 2022). 위 seed 45처럼 한 번 루프에 들어가면 빠져나오지 못하는 이유다.
- **작은 모델일수록 심하다.** OPT 계열에서 모델 크기를 키우면 반복이 6.7B까지 크게 줄지만 그 이후로는 효과가 줄어 66B에서도 사람보다 반복이 많다(Li et al., 2023). 0.6B는 이 범위의 가장 작은 쪽으로, 반복이 가장 잘 일어나는 크기다. 같은 연구는 학습 데이터에 반복이 적은 지시 데이터로 미세조정하면 반복이 줄어든다고도 보고했다.
- **본 연구 조건에서의 해석:** 학생은 대화 형식을 모르는 Base 모델에서 출발해 1,000개 예제로 3 epoch만 학습했다. 그래서 "답이 끝나면 끝 토큰을 낸다"는 습관이 약하게 학습되었고, 끝 토큰을 놓치면 사전학습 때처럼 문서를 이어 쓰듯 새 문단이나 새 질문을 만들다가 위의 반복 루프에 빠진다. 반복 억제(repetition penalty 1.1; Keskar et al., 2019)를 걸어도 완전히 막지는 못했다. 답이 가장 길고 목록·소제목이 많은 Claude 교사 스타일을 배운 학생에서 잘린 답이 가장 많은 것(373개)도, 긴 답일수록 끝 토큰을 놓칠 기회가 많기 때문으로 보인다.

한계: "15명 모두 끝까지 쓴 질문"만 쓰면, 짧게 답할 수 있는 질문 쪽으로 평가 질문이 치우칠 수 있다. 다만 세 학생 모두 같은 질문으로 비교하므로 학생 간 비교의 공정성은 유지된다.

4 LLM의 답변만으로 어떤 모델인지 구별할 수 있는가?

↑ 목차

왜 필요한가. 평가자가 자기 계열을 선호하려면, 먼저 **세 교사의 답변이 통계적으로 서로 달라야** 한다. 각 LLM은 학습 데이터와 정렬 과정이 달라 서로 다른 조건부 분포 $P_{모델}$(답변 | 질문)을 학습했을 것이다. 분포가 정말 다르다면, 답변만 보고 어느 모델에서 나왔는지 맞히는 분류기를 만들 수 있다. 분포가 같다면 어떤 분류기도 우연(33.3%)을 넘을 수 없다. 분류 정확도는 분포 차이의 **보수적 하한**이다.

4.1 실험 설계 한눈에 보기

① 재료
세 교사가 모두 답한 질문 1,199개 × 3 = 답변 3,597개. 정답(레이블) = 생성 모델

② 질문 단위 분할
질문을 train 839 / val 179 / test 181개로 나누고, 같은 질문의 세 답은 같은 쪽에

③ 글 → 숫자
로지스틱: 글자 조각 TF-IDF 벡터. RoBERTa: 토큰 열

④ 학습
train 답변 2,517개로 분류기를 학습

⑤ 설정 고르기
val 답변 537개로 규제 강도 C(로지스틱)와 체크포인트(RoBERTa)를 고름

⑥ 시험 한 번
test 답변 543개를 단 한 번 분류해 정확도·F1 계산

같은 과정을 **원문**과 서식을 지운 **정규화 텍스트**(4.6)에 각각 한 번씩, 두 분류기로 반복했다(2 × 2 = 4개 실험). 코드: `classify/common.py`(분할·정규화), `logistic.py`, `roberta.py`.

4.2 재료: 같은 질문에 대한 세 모델의 답

분류기가 보는 것은 아래와 같은 답변 하나뿐이다. 질문도, 모델 이름도 보지 않는다. 답변 하나가 분류 문제 하나이고, 정답은 "이 답을 쓴 모델"(GPT, Claude, Gemini 중 하나)이다. 예시는 test에 들어간 질문 **"'오지랖이 넓다'란 무슨 뜻인가요?"**에 대한 세 교사의 실제 답이다. 표시한 부분은 정규화(4.6)에서 지워지는 서식이다(↵ = 줄바꿈).

모델	원문 (raw)	정규화 후 (norm)
GPT 165자	'오지랖이 넓다'는 남의 일에 필요 이상으로 관심을 가지거나, 부탁받지 않았는데도 참견하는 성향을 뜻합니다. 대체로 부정적인 뉘앙스가 있습니다.↵↵ 예: "그 사람은 남의 사생활까지 물어봐서 오지랖이 넓어."↵ 다만 상황에 따라 남을 잘 챙기고 적극적으로 돕는다는 뜻으로 가볍게 쓰이기도 합니다.	오지랖이 넓다는 남의 일에 필요 이상으로 관심을 가지거나, 부탁받지 않았는데도 참견하는 성향을 뜻합니다. 대체로 부정적인 뉘앙스가 있습니다. 예: 그 사람은 남의 사생활까지 물어봐서 오지랖이 넓어. 다만 상황에 따라 남을 잘 챙기고 적극적으로 돕는다는 뜻으로 가볍게 쓰이기도 합니다.
Claude 437자	'오지랖이 넓다'는 **자기와 상관없는 남의 일에 지나치게 간섭하거나 참견한다**는 뜻의 관용 표현입니다.↵↵ **어원**↵ '오지랖'은 원래 웃옷이나 윗도리에 입는 겉옷의 앞자락을 가리키는 말입니다. … 의미로 확장되었습니다.↵↵ **쓰임**↵ - "그 친구는 오지랖이 넓어서 남의 집안일까지 다 챙겨."↵ - "오지랖 좀 그만 부리고 네 일이나 신경 써."↵↵ **뉘앙스**↵ 주로 부정적으로 쓰여 '주제넘게 참견한다'는 비판의 느낌이 강합니다. …↵↵ **참고**↵ '오지랖이 넓다'는 … 표준어는 '오지랖'입니다.	오지랖이 넓다는 자기와 상관없는 남의 일에 지나치게 간섭하거나 참견한다는 뜻의 관용 표현입니다. 어원 오지랖은 원래 웃옷이나 윗도리에 입는 겉옷의 앞자락을 가리키는 말입니다. … 의미로 확장되었습니다. 쓰임 그 친구는 오지랖이 넓어서 남의 집안일까지 다 챙겨. 오지랖 좀 그만 부리고 네 일이나 신경 써. 뉘앙스 주로 부정적으로 쓰여 주제넘게 참견한다는 비판의 느낌이 강합니다. … 참고 오지랖이 넓다는 … 표준어는 오지랖입니다.
Gemini 288자	'오지랖이 넓다'는 **자신과 상관없는 일이나 다른 사람의 일에 지나치게 참견하고 간섭한다**는 뜻의 관용 표현입니다.↵↵ * **유래:** '오지랖'은 원래 한복 등 웃옷의 앞자락을 가리킵니다. 옷의 앞자락이 넓으면 … 비유한 말입니다.↵ * **뉘앙스:** 때로는 정이 많거나 주변을 잘 챙긴다는 의미로 쓰이기도 하지만, 대체로 … 부정적인 의미(참견이 심함, 눈치가 없음)로 많이 사용됩니다.	오지랖이 넓다는 자신과 상관없는 일이나 다른 사람의 일에 지나치게 참견하고 간섭한다는 뜻의 관용 표현입니다. 유래: 오지랖은 원래 한복 등 웃옷의 앞자락을 가리킵니다. 옷의 앞자락이 넓으면 … 비유한 말입니다. 뉘앙스: 때로는 정이 많거나 주변을 잘 챙긴다는 의미로 쓰이기도 하지만, 대체로 … 부정적인 의미(참견이 심함, 눈치가 없음)로 많이 사용됩니다.

표 4-1. 같은 질문에 대한 세 교사의 답(긴 문장은 …로 줄임, 글자 수는 원문 기준). 같은 시스템 프롬프트로 생성했다.

- **원문에서 눈에 띄는 차이:** GPT는 굽은 따옴표(‘ ’ “ ”)를 쓰고 소제목 없이 짧은 문단으로 쓴다. Claude는 ****어원**, **쓰임**** 같은 굵은 소제목과 "-" 목록, 곧은 따옴표(" ')를 쓰고 "참고"로 마무리한다. Gemini는 "*" 목록 안에 ****유래:****처럼 굵은 글씨와 쌍점을 붙인다.
- **정규화 후에도 남는 차이:** 서식을 지워도 GPT의 "대체로", "다만", "예:", Claude의 소제목 단어("어원 … 쓰임 … 참고"), Gemini의 "유래: … 뉘앙스:"와 괄호 보충 설명 "(참견이 심함, 눈치가 없음)"이 남는다. 정규화 실험은 이런 **어휘·어미·문장 구성**만으로도 구별되는지를 묻는다.

4.3 질문 단위 분할: 왜 질문으로 나누는가

머신러닝에서는 자료를 세 부분으로 나눈다. **train**(교과서: 분류기가 보고 배움), **val**(모의고사: 설정을 고를 때만 씀), **test**(수능: 마지막에 단 한 번만 풀어 실력을 잼). test를 설정 고르기에 쓰면 test에 맞춘 설정이 되어 실력이 부풀려지므로, test는 끝까지 보지 않는다.

```
질문 1,199개를 무작위로 섞음(seed 42) → 70% / 15% / 15%
  train  질문 839개 × 답 3 = 답변 2,517개   (GPT 839, Claude 839, Gemini 839)
  val    질문 179개 × 답 3 = 답변   537개   (각 179)
  test   질문 181개 × 답 3 = 답변   543개   (각 181)   ← 예: "오지랖" 질문의 세 답은 모두 test
```

- **답변 단위로 나누면 생기는 문제:** 같은 질문의 GPT 답은 train에, Claude 답은 test에 들어갈 수 있다. 그러면 분류기는 "오지랖"이라는 **질문 주제**를 train에서 이미 본 셈이어서, 스타일이 아니라 내용의 기억으로 맞힐 여지가 생긴다.
- **질문 단위로 나누면:** test의 181개 질문은 분류기가 한 번도 본 적 없는 주제다. 게다가 한 질문의 세 답은 같은 내용을 다루므로 **내용으로는 셋을 구별할 수 없다**. 분류기는 쓰는 방식(스타일)으로만 맞혀야 한다.
- **클래스 균형:** 모든 split에서 세 모델이 정확히 1/3씩이므로, 아무렇게나 찍으면 정확도는 33.3%가 된다. 이것이 "우연" 기준선이다.

4.4 분류기 ① 글자 n-gram TF-IDF + 다항 로지스틱 회귀

글을 숫자로 바꿔야 하는 이유. 집값을 "비싼 집 / 싼 집"으로 분류하는 로지스틱 회귀는 면적, 방 수, 역까지 거리처럼 **숫자로 된 열**을 입력으로 받는다. 글은 숫자가 아니므로 먼저 "답변 하나 = 숫자 여러 개가 든 한 행"으로 바꿔야 한다. TF-IDF는 이 변환 방법이고, 열 하나하나가 **글자 조각**이다.

	집값 분류	이 실험
한 행	집 한 채	답변 하나
열(특징)	면적, 방 수, 역까지 거리 …	글자 조각 115,353개 각각 (" 다만", "**", "하여", "니다." …)
칸의 값	84㎡, 3개, 500m	그 조각이 그 답변에서 얼마나 두드러지는가 (TF-IDF 값, 대부분 0)
정답	비싼 집 / 싼 집 (2개)	GPT / Claude / Gemini (3개 → **다항** 로지스틱)
학습 자료	집 수천 채	train 답변 2,517개

1단계, 글자 n-gram으로 자르기. 단어 대신 **연속한 글자 2~4개**를 하나의 조각(n-gram)으로 센다. 한국어는 "다만", "다만은", "다만도"처럼 어미·조사가 붙어 단어 모양이 계속 바뀌므로, 글자 조각으로 세면 형태소 분석기 없이도 어간·어미·기호를 함께 잡을 수 있다. 단어 경계(공백)도 조각에 포함해 단어의 시작과 끝을 구분한다. 예를 들어 "보통 다만"은 다음 12개 조각이 된다(␣ = 공백).

```
"보통"  → ␣보, 보통, 통␣, ␣보통, 보통␣, ␣보통␣
"다만"  → ␣다, 다만, 만␣, ␣다만, 다만␣, ␣다만␣
"**유래:**" → **, *유, 유래, 래:, :*, ** … (마크다운 기호도 조각이 된다)
```

train 답변 전체에서 나온 조각 중 **3개 이상의 답변**에 나온 것만 열로 남겼다(min_df = 3). 원문 115,353개, 정규화 111,506개다. 어휘 목록과 IDF는 **train에서만** 만들고, val·test는 그 목록으로 변환만 한다(test 정보가 학습에 새지 않게).

2단계, TF-IDF로 값 매기기. 각 칸의 값은 두 숫자의 곱이다.

```
TF  (term frequency)    = 1 + log(이 답변에서 그 조각이 나온 횟수)      많이 나올수록 크지만 log로 완만하게
IDF (inverse doc. freq.) = log((1 + 전체 답변 수) ÷ (1 + 그 조각이 나온 답변 수)) + 1
                                                                  흔한 조각일수록 작고, 드문 조각일수록 큼
값 = TF × IDF  →  답변마다 벡터 길이가 1이 되도록 나눔(긴 답이 무조건 큰 값을 갖지 않게)
```

GPT의 "오지랖" 답변 속 조각	이 답에서 횟수	IDF	최종 TF-IDF 값	뜻
"남의"	2	6.75	0.143	드문 조각 → 값이 큼 (하지만 주제 단어다)
" “" (굽은 따옴표)	1	3.21	0.040	중간 정도로 드문 조각
"다만"	1	2.18	0.027	꽤 흔한 조각
"니다."	3	1.00	0.026	거의 모든 답변에 나옴 → IDF 최소

표 4-2. 실제 계산값(train 답변 2,517개 기준). 이 답변은 115,353칸 중 264칸만 0이 아니다.

3단계, 다항 로지스틱 회귀로 점수 매기기. 모델마다 가중치 벡터(115,353개 숫자)가 하나씩 있다. 답변 벡터 x와 각 가중치를 곱해 더한 것이 그 모델의 점수이고, 점수를 softmax로 확률로 바꿔 가장 높은 모델을 답으로 고른다.

```
점수_GPT    = Σ (가중치_GPT,조각    × 그 조각의 TF-IDF 값) + 절편
점수_Claude = Σ (가중치_Claude,조각 × …) + 절편
점수_Gemini = Σ (가중치_Gemini,조각 × …) + 절편
P(GPT) = e^점수_GPT ÷ (e^점수_GPT + e^점수_Claude + e^점수_Gemini)

예) GPT의 "오지랖" 답변: 점수 GPT 3.24, Claude −1.88, Gemini −1.36
    → P = GPT 98.4%, Claude 0.6%, Gemini 1.0%  → "GPT"로 예측 (정답)
    가장 큰 근거: " “"(굽은 따옴표) 가중치 GPT +6.53 / Claude −3.84 / Gemini −2.69
    반면 "남의"의 가중치는 −0.01 / +0.06 / −0.05로 거의 0 → 주제 단어는 무시됨
```

4단계, 학습. 학습은 train 답변 2,517개에서 **정답 모델의 확률이 최대가 되도록**(로그우도 최대화) 가중치를 조정하는 것이다. 이때 TF-IDF 값이 컸던 "남의" 같은 주제 단어는 세 모델 모두에 고르게 나오므로 구별에 도움이 안 되어 가중치가 0 근처로 남고, 특정 모델에만 자주 나오는 조각의 가중치가 커진다. 가중치가 가장 큰 조각은 원문에서 GPT "“ ‘ 보통 다만", Claude "- ** " 고,", Gemini "' * :** 하여"였고, 정규화 후에는 GPT "보통 즉 다만", Claude "고, 참고 정리", Gemini "하여 및 적인"이었다.

5단계, 규제 강도 C를 val로 고르기. 조각이 11만 개가 넘어 train 답변을 통째로 외워 버리기 쉽다(과적합). 그래서 가중치가 너무 커지지 않게 벌점(L2 규제)을 준다. C는 그 벌점의 반대(클수록 규제가 약함)다. C ∈ {0.25, 1, 4, 16, 64, 256}으로 각각 학습하고 val 정확도가 가장 높은 값을 골랐다: 원문 C = 16(val 98.1%), 정규화 C = 64(val 94.2%). 고른 모델로 test를 한 번 평가했다.

4.5 분류기 ② KLUE-RoBERTa 미세조정

로지스틱과의 차이. TF-IDF는 글자 조각이 **몇 번 나왔는지**만 보고 순서와 문맥은 버린다. KLUE-RoBERTa는 한국어 텍스트로 미리 학습된 언어 모델(사전학습 인코더, 약 1.1억 파라미터)로, 문장을 **단어 순서와 앞뒤 문맥까지** 읽고 이해한 표현을 만든다. 정규화로 기호를 지워도 "어떤 순서로 무엇을 말하는가"를 볼 수 있다.

1. **토큰화:** 답변을 하위 단어(subword) 토큰으로 자른다. 최대 512토큰까지 넣고, 이를 넘는 답변 2개(원문)는 뒷부분을 잘랐다.
2. **분류 머리 붙이기:** 문장 맨 앞 [CLS] 위치의 출력(768개 숫자, 답변 전체의 요약)에 출력이 3개인 층을 붙여 GPT·Claude·Gemini 점수를 내고 softmax로 확률을 만든다.
3. **미세조정:** 정답 모델의 확률이 커지도록(교차 엔트로피 최소화) 사전학습된 가중치 전체와 분류 머리를 함께 조금씩 바꾼다. 4 epoch, 학습률 2e-5(warmup 10% 후 선형 감소), weight decay 0.01, 실효 배치 16(8 × 누적 2), 1 epoch = 158 step, 총 632 step, seed 42.
4. **체크포인트 고르기:** 25 step마다 val 정확도를 재고 가장 높은 시점의 모델을 고른다: 원문 step 275(val 98.5%), 정규화 step 525(val 98.3%). 로지스틱의 C 선택과 같은 역할이다.
5. **시험:** 고른 모델로 test 543개를 한 번 분류한다.

	다항 로지스틱 회귀	KLUE-RoBERTa
답변을 표현하는 방법	글자 조각이 몇 번 나왔는지 (순서 무시)	토큰 순서와 앞뒤 문맥을 반영한 768차원 벡터
볼 수 있는 것	특정 단어·어미·기호의 빈도	문장 구성, 논리 전개, 어조 같은 뉘앙스
사전 지식	없음 (이 데이터만 봄)	한국어 대량 사전학습
학습하는 숫자 수	약 35만 개 (조각 11.5만 종 × 3 모델)	약 1.1억 개
설정 고르기	규제 강도 C (val로 선택)	학습 체크포인트 (val 정확도로 선택)
해석	쉬움 (어떤 조각이 근거인지 보임, 4.4)	어려움
연구에서의 역할	“단순한 빈도 통계로도 구별된다”	“문맥을 보는 신경망으로도 구별된다”

표 4-6. 두 분류기 비교.

	BERT	RoBERTa (구조는 같고 사전학습 방법만 개선)
사전학습 과제	빈칸 맞히기 + 다음 문장 예측	빈칸 맞히기만 (다음 문장 예측은 효과가 없어 제거)
빈칸 위치	데이터를 만들 때 한 번 고정	학습할 때마다 새로 가림
데이터·학습량	16GB, 작은 배치	훨씬 많은 데이터, 큰 배치, 더 긴 학습

표 4-7. RoBERTa는 BERT와 무엇이 다른가. klue/roberta-base는 KLUE 팀이 한국어로 사전학습한 모델이다(12층, 768차원, 어휘 32,000개).

```
답변이 RoBERTa에 들어가는 모양 (## = 앞 조각에 붙는 조각)
"FBI는 연방수사국입니다. 다만, 보통 주 경찰과 다릅니다."
→ [CLS] FBI ##는 연방 ##수 ##사 ##국 ##입니다 . 다만 , 보통 주 경찰 ##과 다릅니다 . [SEP]
→ 12층의 Transformer가 모든 토큰이 서로를 참고하게 하며 벡터를 고친다
→ 맨 앞 [CLS] 자리의 벡터(768개 숫자) → 분류층 → GPT / Claude / Gemini 점수 → softmax 확률
```

[CLS]는 원래 의미 없는 자리 표시 토큰이다. 손실을 이 자리에서만 계산하므로, 미세조정 중에 "세 모델을 가를 정보를 이 자리에 모으도록" 학습된다.

4.6 통제 실험: 정규화로 "겉모양" 지우기

원문으로만 구별되면 "굵게·목록 같은 서식 습관만 다르다"는 해석이 가능하다. 그래서 서식을 모두 지운 텍스트로 같은 실험을 다시 했다. 지운 것은 다음 네 가지다(`common.normalize`).

지운 것	예 (원문 → 정규화)
마크다운 강조 기호 ** __ `	**어원** → 어원
줄 맨 앞의 소제목·목록 기호 # - * • 1. 1)	* **유래:** … → 유래: …
모든 따옴표 “ ” ‘ ’ " '	‘오지랖이 넓다’는 → 오지랖이 넓다는
줄바꿈과 연속 공백 → 공백 하나	문단·목록 구조가 한 줄로 이어짐

단어, 어미, 쉼표·쌍점·괄호, 문장 순서는 그대로 남는다. 표 4-1의 "오지랖" 예에서 정규화 후 로지스틱은 Gemini 답을 **GPT로 틀렸다**(GPT 64%, Gemini 18%). "* **유래:**" 같은 Gemini 서식 단서가 사라졌기 때문이다. 같은 답을 RoBERTa는 정규화 후에도 Gemini 99.8%로 맞혔다. 문맥을 읽는 분류기는 서식이 없어도 문장 구성으로 구별한다는 뜻이다.

4.7 평가 지표: 정확도와 F1 점수

test 답변 543개(모델마다 181개)의 예측을 실제 모델과 맞대어 센 **혼동행렬**에서 두 지표를 계산한다. 아래는 로지스틱 회귀 · 원문의 실제 결과다.

실제 \ 예측	GPT로 예측	Claude로 예측	Gemini로 예측	합계
실제 GPT	**171**	6	4	181
실제 Claude	0	**179**	2	181
실제 Gemini	1	2	**178**	181
합계	172	187	184	543

표 4-3. 혼동행렬(로지스틱 회귀 · 원문 · test). 대각선(굵게) = 맞힌 개수.

```
정확도 (accuracy) = 맞힌 답변 수 ÷ 전체 = (171 + 179 + 178) ÷ 543 = 97.2%

GPT의 정밀도 (precision) = GPT라고 예측한 것 중 진짜 GPT  = 171 ÷ 172 = 0.994   (열 방향)
GPT의 재현율 (recall)    = 진짜 GPT 중 GPT로 찾아낸 것     = 171 ÷ 181 = 0.945   (행 방향)
GPT의 F1 = 2 × 정밀도 × 재현율 ÷ (정밀도 + 재현율)
         = 2 × 0.994 × 0.945 ÷ (0.994 + 0.945) = 0.969

Claude: 정밀도 179 ÷ 187 = 0.957, 재현율 179 ÷ 181 = 0.989 → F1 0.973
Gemini: 정밀도 178 ÷ 184 = 0.967, 재현율 178 ÷ 181 = 0.983 → F1 0.975
```

- **왜 정확도인가:** 세 모델이 test에 정확히 181개씩 있어(클래스 균형) 정확도가 치우침 없이 전체 실력을 나타내고, "우연 = 33.3%"라는 분명한 기준선과 바로 비교할 수 있다. 질문 단위 부트스트랩(질문 181개를 복원추출해 1,000번 재계산)으로 95% 신뢰구간도 구했다.
- **왜 F1을 함께 보나:** 정확도는 세 모델을 합친 평균이라, 특정 모델 하나를 계속 헷갈려도 가려질 수 있다. 극단적으로 모든 답을 "GPT"라고 하는 분류기는 정확도 33.3%이고 GPT 재현율은 100%지만, GPT 정밀도는 33%, Claude·Gemini의 F1은 0이다. 모델별 F1은 "그 모델이라고 말했을 때 믿을 만한가(정밀도)"와 "그 모델의 답을 빠짐없이 찾는가(재현율)"를 함께 본다. 조화평균이라 둘 중 하나만 낮아도 F1이 크게 떨어진다.
- **이 실험에서 읽을 점:** 모든 실험에서 세 모델의 F1이 0.91 이상으로 고르다(그림 4-2). 한 모델만 잘 구별되는 것이 아니라 **세 모델이 서로 모두 구별**된다는 뜻이다. 표 4-3에서 가장 많은 실수는 GPT 답을 Claude로 본 6개다.

4.8 결과

분류기	텍스트	test 정확도	95% CI	GPT F1	Claude F1	Gemini F1
다항 로지스틱 회귀	원문	**97.2%**	95.6-98.5%	0.969	0.973	0.975
다항 로지스틱 회귀	정규화	**92.1%**	89.5-94.3%	0.910	0.914	0.938
KLUE-RoBERTa	원문	**97.1%**	95.6-98.3%	0.978	0.967	0.967
KLUE-RoBERTa	정규화	**96.5%**	94.8-97.8%	0.959	0.978	0.959

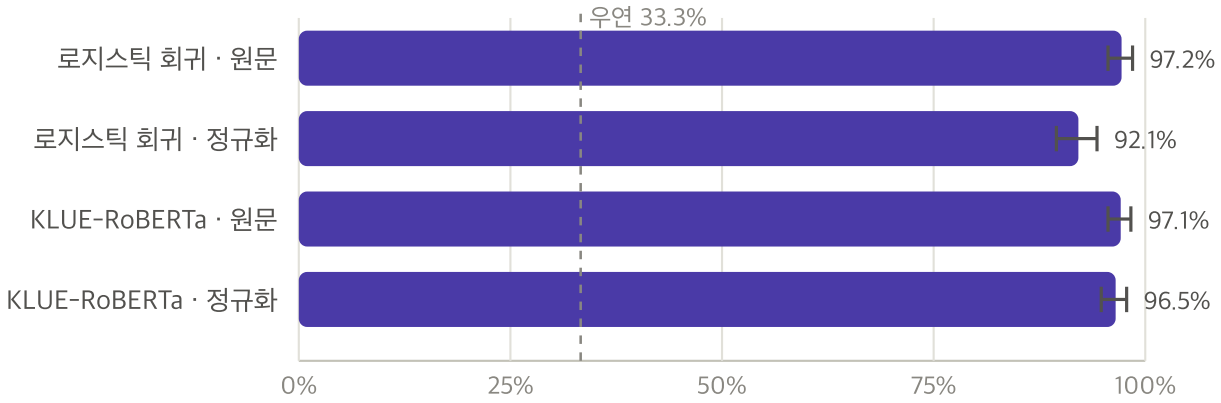


그림 4-1. 답변만 보고 생성 모델을 맞힌 test 정확도와 95% 신뢰구간(test 질문 181개 × 3 = 답변 543개, 질문 단위 bootstrap). 정규화 = 굵게·목록·따옴표·줄바꿈을 모두 지운 텍스트.

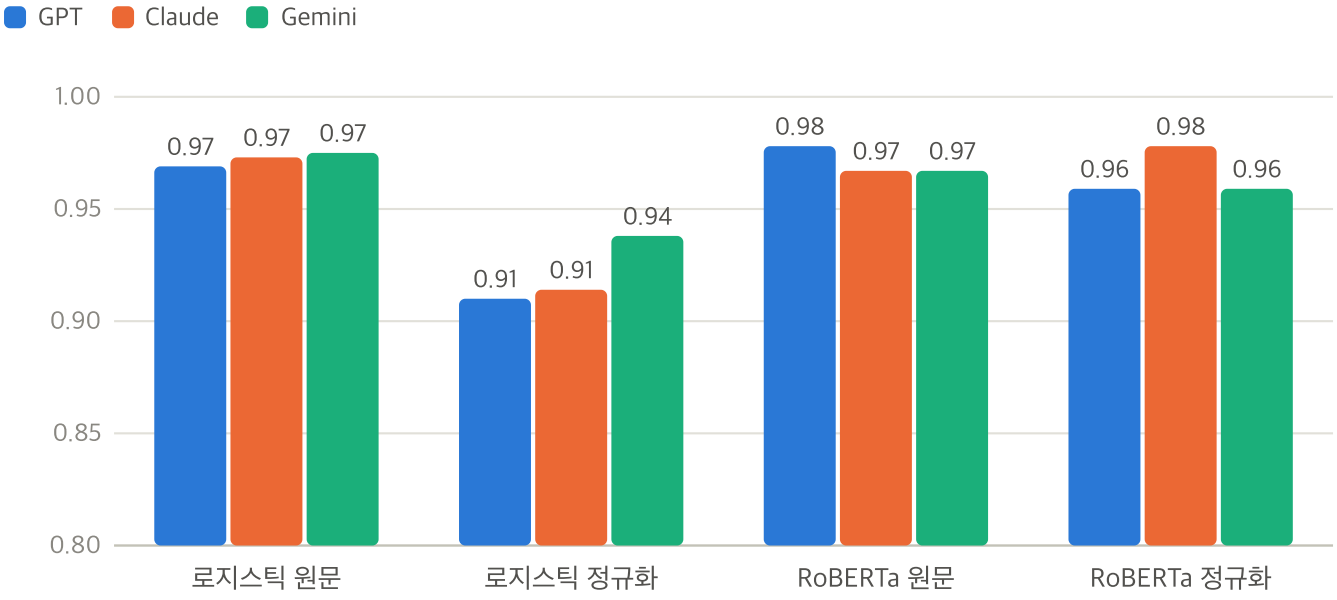


그림 4-2. 생성 모델별 F1 점수. 어느 모델도 특별히 헷갈리지 않고 세 모델 모두 0.91 이상으로 구별된다.

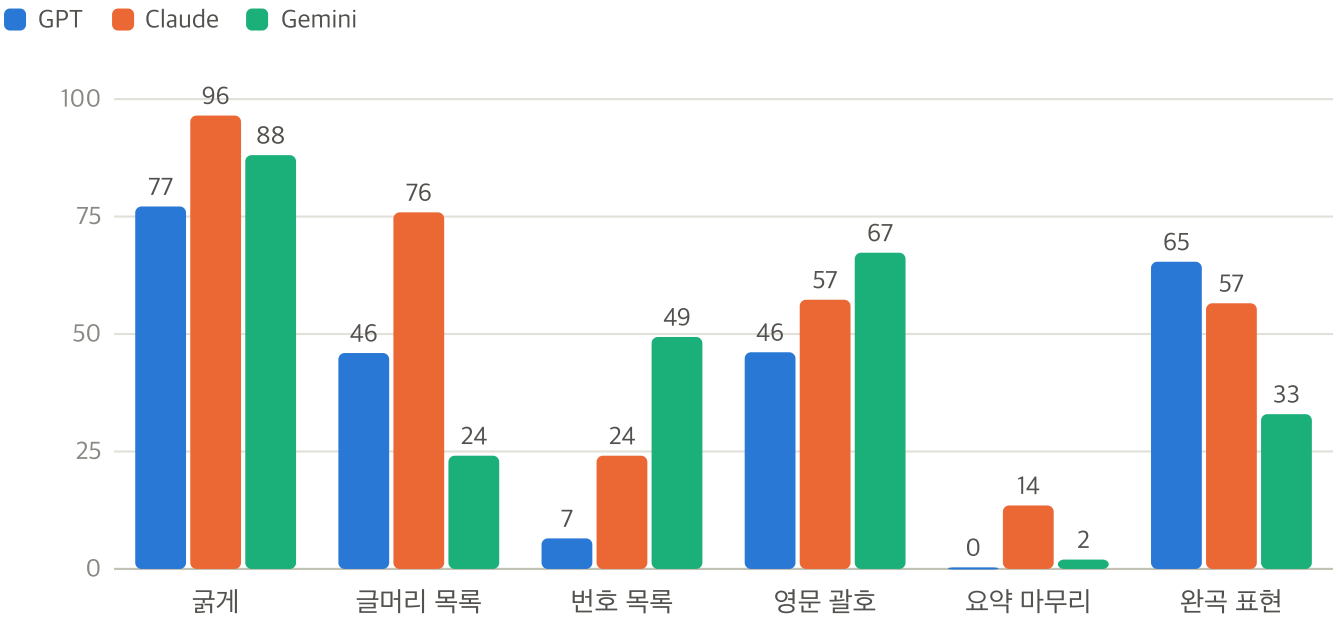


그림 4-3. 교사 답변 3,597개에서 각 형식·문체 특징이 나타난 답변 비율(%). 같은 질문, 같은 시스템 프롬프트로 생성했다.

결과 해석

- **답변만으로 생성 모델이 거의 완벽하게 구별된다:** 원문 97.2%(로지스틱), 97.1%(RoBERTa). 우연 33.3%의 약 3배.
- **서식을 지워도 구별된다:** 정규화 텍스트에서도 92.1%, 96.5%. 정규화에서 RoBERTa가 로지스틱보다 높아, 단어 빈도를 넘어선 **문장 수준의 뉘앙스 차이**도 있다.
- **세 모델의 프로필:** GPT는 짧고 완곡한 문단형(중앙값 380자, 완곡 표현 65%), Claude는 길고 구조화된 목록형(587자, 글머리 목록 76%, "정리하면" 마무리), Gemini는 번호로 나눈 설명형(482자, 번호 목록 49%, 영문 괄호 병기 67%).

4.9 세 교사의 스타일 프로필 자세히

그림 4-3은 차이가 큰 특징 6개만 보였다. 아래 표는 교사 답변 3,597개에서 잰 전체 지표다. 행마다 가장 큰 값을 굵게 표시했다.

구분	지표	GPT	Claude	Gemini
길이	글자 수 중앙값 (범위)	380 (59-814)	**587** (269-1,056)	482 (181-915)
	문장 수 중앙값	7	**12**	9
	문장당 글자 수	**56**	48	55
	문단 수 중앙값	3	**4**	**4**
형식	굵게(**) 사용	77%	**96%**	88%
	글머리 목록(-, *)	46%	**76%**	24%
	번호 목록(1.)	7%	24%	**49%**
문체	영문 괄호 병기	46%	57%	**67%**
	한자 병기	10%	**15%**	13%
	합쇼체(~니다) 비중	98%	97%	**99%**
	요약형 마무리("정리하면" 등)	0%	**14%**	2%
	완곡 표현("~수 있습니다", "보통" 등)	**65%**	57%	33%
어휘	대표 표현 (그 모델 사용률 / 다른 두 모델)	보통 32% / 9% 특히 19% / 6% 다만 41% / 25%	정리하면 13% / 0% 그래서 17% / 4% 알려져 있습니다 15% / 4%	위해 21% / 7% 통해 13% / 3% 따라서 16% / 7%

표 4-4. 비율 = 그 특징이 한 번이라도 나타난 답변의 비율. 대표 표현 = 그 모델 답변에서 쓰인 비율 ÷ 다른 두 모델에서 쓰인 비율이 가장 큰 어절 (그 모델 답변의 10% 이상에서 쓰인 것만). 코드 `results/style_analysis.py`.

지표	어떻게 쟀나 (규칙 기반)
글자 수 / 문장 수 / 문단 수	공백·줄바꿈 포함 문자열 길이 / ". ! ?" 뒤 공백으로 문장 나눔 / 빈 줄로 구분된 덩어리
굵게, 글머리·번호 목록	**가 한 번이라도 있으면 1 / 줄이 "- * •" 또는 "1. 1)"로 시작하면 1
영문 괄호·한자 병기	괄호 안에 영문자가 있으면 1 / 한자가 하나라도 있으면 1
합쇼체 비중	"니다." 종결 수 ÷ ("니다." + "요.") 종결 수
요약형 마무리	마지막 문단에 "요약하면, 정리하면, 결론적으로, 요컨대, 한마디로, 종합하면"이 있으면 1
완곡 표현	"일반적으로, 보통, 대체로, 경우에 따라, 수 있습니다, 수 있어요" 중 하나라도 있으면 1
대표 표현	어절 1~2개 묶음별로 (그 모델 사용률 ÷ 다른 두 모델 사용률)의 로그가 큰 순. 그 모델 답변의 10% 이상에서 쓰인 것만

표 4-8. 표 4-4의 지표를 잰 방법. 형식 지표는 정규식 규칙이라 일부 예외가 있을 수 있다(예: 문장 속 "1." 같은 숫자).

"Claude는 600자 규칙을 어겼나?" 시스템 프롬프트는 "600자 이내"를 요구했다. 넘은 비율은 **글자를 어떻게 세느냐**에 따라 크게 달라진다(그림 4-4). 원문 그대로 세면 Claude 답의 43%가 넘지만, 마크다운 기호와 줄바꿈을 빼면 26%, 공백까지 빼면 1.4%뿐이다. Claude가 "600자"를 공백을 뺀 글자 수로 해석했을 수 있으므로 "규칙 위반"이 아니라 **"가장 길게 쓰는 경향"**으로 해석한다. 어떤 기준으로 세도 Claude가 가장 길다(중앙값이 GPT의 약 1.5배).

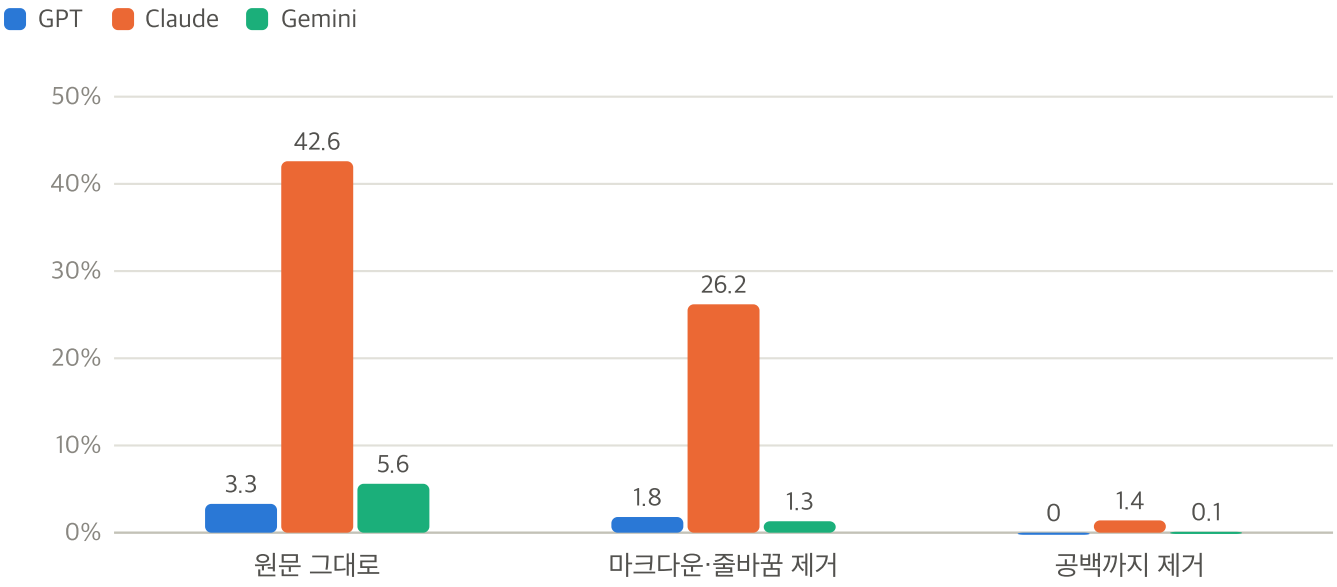


그림 4-4. 600자를 넘은 답변 비율(%)을 세 가지 글자 세기 기준으로 잰 것. 마크다운 기호를 가장 많이 쓰는 Claude에서 기준에 따른 차이가 가장 크다.

4.10 분류 결과 더 깊이 보기: 평가자가 물어볼 만한 것

> **정확도가 "분포가 다르다"는 증거가 되는 이유.** 두 분포에서 나온 표본을 구분하는 분류기가 낼 수 있는 **최대** 정확도는 두 분포의 거리(total variation distance, TV)로 정해진다. 사전확률이 같은 두 집단이면 최대 정확도 = (1 + TV) ÷ 2다. 실제 분류기는 이 최댓값보다 낮을 수밖에 없으므로, **test 정확도는 분포 차이의 하한**이다. 더 좋은 분류기를 쓰면 정확도는 올라갈 수만 있다. 그래서 "97%로 구별된다"는 "세 모델의 답 분포가 최소한 이만큼은 다르다"는 뜻이다.

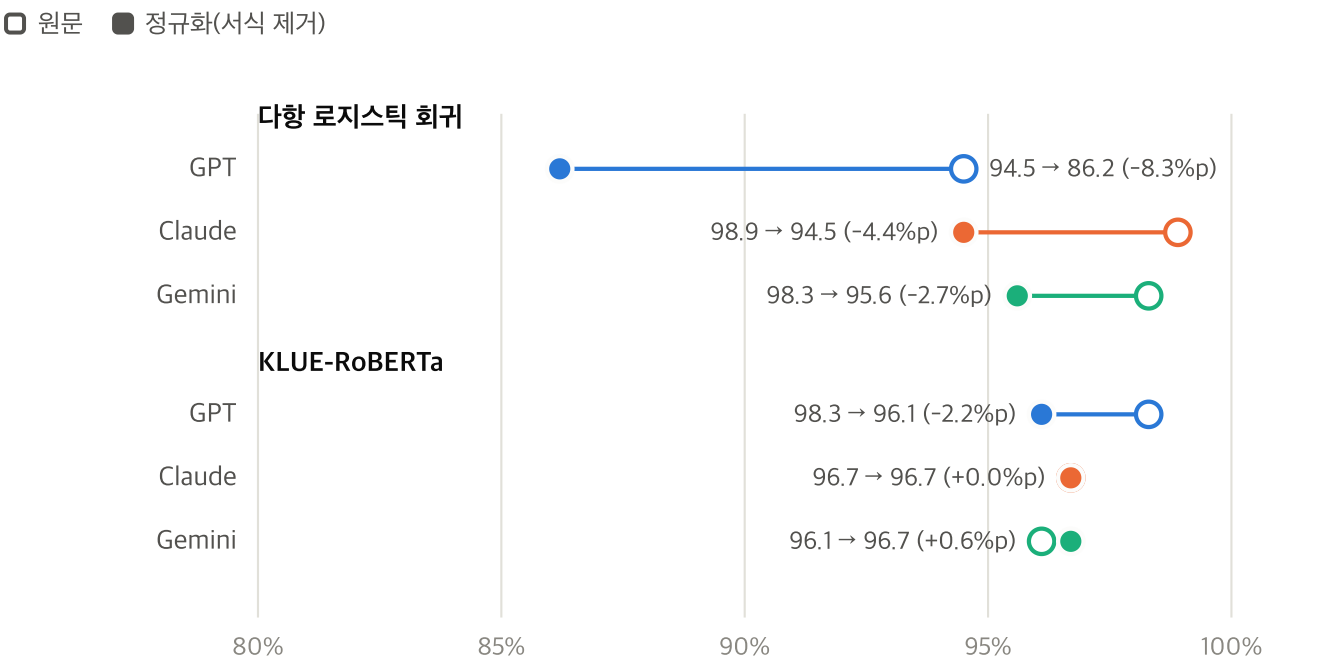


그림 4-5. 서식을 지웠을 때(속 빈 점 → 채운 점) 모델별 재현율(그 모델의 답을 그 모델로 맞힌 비율)의 변화. 로지스틱 회귀에서는 GPT가 가장 크게 떨어지고(−8.3%p), RoBERTa는 세 모델 모두 96% 이상을 유지한다.

그림 4-5 읽기. 원문에서 GPT를 알아보는 가장 강한 단서는 **굽은 따옴표(“ ”)**였다(4.4의 가중치). 정규화로 따옴표가 사라지자 빈도만 보는 로지스틱 회귀는 GPT를 덜 알아봤지만, 문맥을 읽는 RoBERTa는 거의 그대로였다. GPT의 개성이 기호보다 **문장 수준의 말투**("보통 ~라고 합니다", "다만")에 있다는 뜻이다.

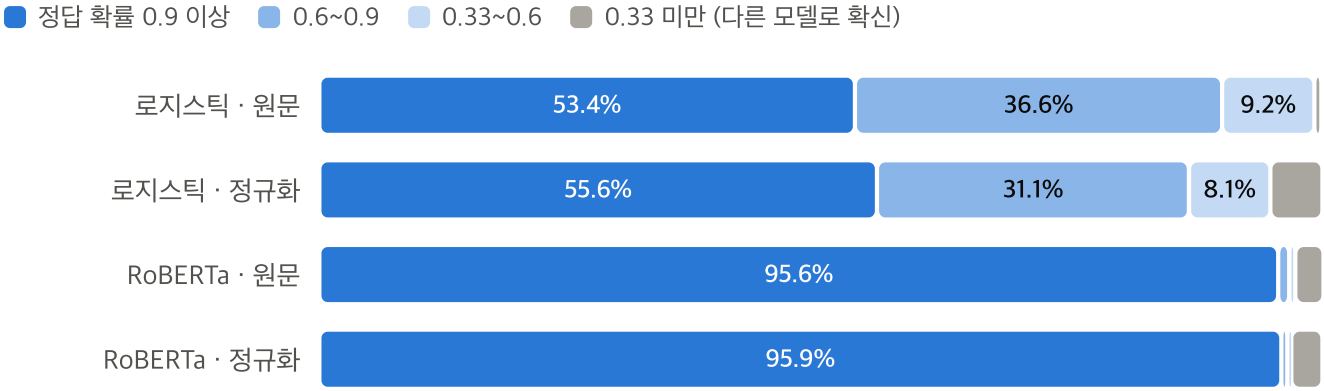


그림 4-6. test 답변 543개에서 분류기가 정답 모델에 준 확률의 분포(%). 진한 칸일수록 확신하고 맞힌 답이다.

그림 4-6 읽기. 정확도는 "몇 개 맞혔나"만 알려 주고, 확신도는 "얼마나 쉽게 맞혔나"를 알려 준다. RoBERTa는 약 96%의 답에 정답 확률 0.9 이상을 주어, 세 모델의 답이 경계에서 거의 겹치지 않는다. 로지스틱은 규제 때문에 확률이 덜 극단적이다. 신경망은 실제보다 과하게 확신하는 경향이 있으므로 "확률 0.99 = 99% 확실"로 읽지는 않는다.

조건	둘 다 틀림	로지스틱만 틀림	RoBERTa만 틀림	합계 (로지스틱 / RoBERTa)
원문	**3**	12	13	15 / 16
정규화	**8**	35	11	43 / 19

표 4-5. test 답변 543개에서 두 분류기가 틀린 답의 겹침.

표 4-5 읽기. 두 분류기는 **서로 다른 답에서 틀린다**. 원문에서 둘 다 틀린 답은 3개뿐이다. 글자 빈도와 문맥이라는 전혀 다른 단서로 같은 결론(세 모델이 구별된다)에 도달했으므로 결과가 강건하다.

> **해석의 범위.** 분류기 정확도는 통계 모델의 정확도이지 LLM 평가자의 능력이 아니다. "평가자도 자기 계열 문체를 알아볼 **단서가 존재한다**"는 간접 근거로만 쓰고, 실제로 평가자가 자기 계열을 우대했는지는 6절의 판정 자료로 따로 확인한다.

> **결론.** 세 LLM의 한국어 답변은 형식뿐 아니라 어휘와 뉘앙스에서도 통계적으로 구별되는 서로 다른 분포를 가진다. 학생이 이 차이를 물려받는다면, 평가자가 자기 계열 답을 알아볼 단서가 존재한다 → **선호 누출의 전제 조건이 충족**된다.

5 학생 모델 학습 (SFT)

↑ 목차

5.1 학습 과정

- **시작 모델:** Qwen3-0.6B-Base. 대화 스타일이 없는 Base 모델이라 학생의 스타일은 교사에게서 왔다고 말할 수 있다.
- **학생 15명 = 교사 3 × seed 5 (42~46).** 같은 교사 안에서는 학습 무작위성(데이터 순서, dropout)만 바꿔 다섯 번 학습했다. 교사 간에는 답변 외의 모든 조건이 같다.
- **형식:** ChatML(시스템 프롬프트 + 질문 + 교사 답 + 종료 토큰). 시스템 프롬프트와 질문은 손실에서 가리고(-100) **교사 답만 학습**한다.
- **설정(15명 동일):** full fine-tuning, AdamW lr 1e-5, cosine(warmup 5%), 실효 배치 16, 3 epoch = 189 step(1 epoch = 63 step), bf16, Colab A100. 15개 run_info의 하이퍼파라미터·데이터 해시가 한 종류임을 확인했다.

- **응답 생성:** 학습이 끝난 학생이 평가 질문 400개에 greedy 디코딩(반복 억제 1.1, 최대 1,024토큰)으로 답한다. 이 답을 6절에서 평가한다.

5.1.1 학습 설정과 그 이유

설정	값 (15명 동일)	왜 이렇게 정했나
시작 모델	Qwen3-0.6B-Base	대화 스타일이 없는 Base 모델이라 학생의 스타일이 교사에게서 왔다고 말할 수 있다
학습 방식	Full fine-tuning	0.6B는 전체 학습이 가능하고, 누출을 보려면 교사 스타일이 충분히 흡수돼야 한다
옵티마이저 · 학습률	AdamW · 1e-5	작은 모델 전체 미세조정의 흔한 범위(1e-5~2e-5). 너무 크면 사전학습 능력이 망가진다
스케줄	cosine, warmup 5%	처음 약 10 step 동안 0 → 1e-5로 올린 뒤 cosine으로 0까지 줄인다
배치	8 × 누적 2 = 실효 16	8개씩 두 번 계산한 기울기를 모아 한 번 업데이트
epoch / step	3 epoch / 189 step	1,000 ÷ 16 ≈ 63 step/epoch
gradient clipping	1.0	기울기가 갑자기 커지는 업데이트를 막는다
weight decay	0	데이터가 1,000개로 적고 epoch가 짧다
최대 길이	1,024토큰	넘는 예제는 자르지 않고 질문째 빼도록 함(실제 0개). 잘린 답을 배우면 문장 중간에 끝나는 답을 배운다
손실 계산	교사 답 + 끝 토큰만	시스템 프롬프트·질문은 -100으로 가림. 끝 토큰까지 배워야 "여기서 답을 끝낸다"를 배운다
최종 모델	마지막 step(189)	val 최저점(step 120)이 아니라 계획한 3 epoch를 썼다. 오른 폭이 1~2%로 작고, 목적이 최고 성능이 아니라 스타일 전이이며, 학생마다 다른 시점을 고르면 조건이 달라진다
seed	42, 43, 44, 45, 46	데이터 순서와 dropout 등 학습 무작위성만 바꿔 반복한다

표 5-A. 15명 모두 같은 설정. 실제 쓴 값은 학생마다 `sft/runs/{teacher}_seed{n}/run_info.json`에 기록되어 있다.

선택	고른 것	대안	고른 이유
시작 모델	**Base**	Instruct(대화용으로 조정된 모델)	Instruct는 이미 특정 회사의 대화 스타일로 조정돼 있어, 학생의 문체가 교사에게서 왔는지 구분할 수 없다
학습 방식	**Full fine-tuning**	LoRA(작은 행렬만 학습, 보통 가중치의 1% 미만)	LoRA는 메모리를 아끼지만 스타일 흡수가 약할 수 있다. 0.6B는 전체 학습이 가능하다(약 10GB)

표 5-B. 모델과 학습 방식을 고른 이유.

같게 맞춘 것	확인 결과
학습 질문 1,000개 · 검증 질문 199개	15명 모두 질문 id 해시 1종류 ✅
교사별 학습 파일	같은 교사의 seed 5개가 파일 해시·답변 토큰 수까지 동일 ✅
하이퍼파라미터 · 프롬프트 형식	15명 모두 1종류 ✅
학습 환경	15명 모두 NVIDIA A100 40GB, 같은 라이브러리 버전 ✅
학습 기록	15명 모두 3 epoch / 189 step ✅
다른 것	**교사 답변(3종)과 seed(5종)뿐**
seed가 실제로 다른 학생을 만들었나	같은 교사의 seed 42와 43 학생은 평가 질문 400개 중 똑같은 답이 **0개**, 최종 val loss도 seed마다 0.001~0.003 다름

표 5-C. 15명이 정말 같은 조건에서 학습했는지 학습 기록으로 검증한 결과.

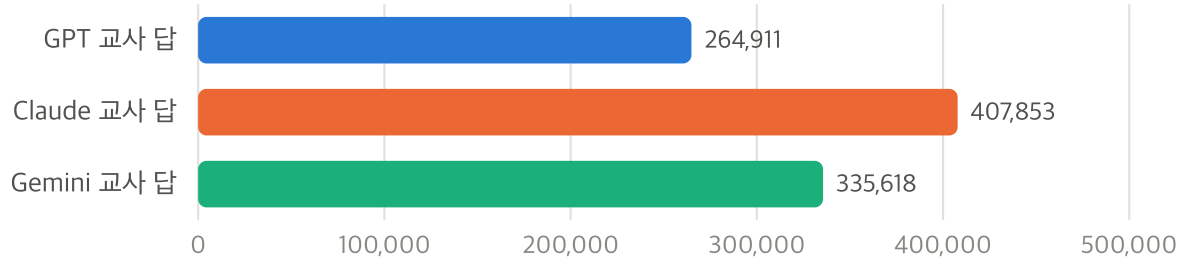


그림 5-0. 교사별 학습 데이터 1,000개의 답변 토큰 합. 같은 1,000문항이지만 Claude 학생은 GPT 학생보다 약 1.5배 많은 토큰을 보고 배운다.

"Claude 학생에게 유리하지 않나?" 답변 길이는 교사 스타일 자체의 일부라 일부러 맞추지 않았다(길이를 맞추면 교사의 스타일을 바꾸게 된다). 대신 평가 단계에서 답 길이를 통제한 모형으로 결과가 유지되는지 확인했다(6.4.1).

5.1.2 학습 데이터 한 건은 실제로 이렇게 생겼다

LLM은 결국 **긴 글 한 줄**을 읽고 "다음 토큰"을 맞히도록 학습한다. 그래서 (시스템 프롬프트, 질문, 교사 답) 한 쌍을 Qwen이 아는 대화 형식(ChatML) 하나로 이어 붙인다. `<|im_start|>`와 `<|im_end|>`는 발언의 시작과 끝을 알리는 특수 토큰이다.

학습 데이터 한 건이 실제로 모델에 들어가는 모양 (Qwen ChatML 형식)

<|im_start|>system
당신은 한국어 사용자의 질문에 답하는 어시스턴트입니다. … (규칙 1~6, 그림 3-1과 같음)<|im_end|>
<|im_start|>user
흥선대원군 때 경복궁을 다시 짓던 중 부족한 재정을 충당하기 위해 발행한 돈은 무엇이었나요?<|im_end|>
<|im_start|>assistant
당백전(當百錢)입니다. 흥선대원군은 경복궁 중건 비용을 마련하기 위해 1866년에 기존 화폐보다 액면가를 100배로 정한 당백전을 발행했습니다. 그러나 실제 가치는 낮아 물가 상승과 경제 혼란을 초래했습니다.<|im_end|>

회색 = 손실에서 가림(-100). 모든 예제에 똑같이 들어가는 지시문과 질문 파란 바탕 = 학습하는 부분(교사 답)

주황 = 끝 토큰(이것까지 배워야 "여기서 답을 끝낸다"를 배운다)

그림 5-A. GPT 교사 데이터 1,000개 중 한 건(질문 id 13816). 같은 질문의 Claude·Gemini 교사 답으로는 각각 Claude·Gemini 학생을 학습했다. 회색 부분을 가리지 않으면 매번 똑같은 시스템 프롬프트가 손실을 지배해, 교사마다 다른 **답의 스타일**을 배우는 신호가 약해진다.

5.2 loss와 perplexity란 무엇인가

5절의 지표는 모두 **"학생이 이미 쓰여 있는 교사의 답을 얼마나 '자기가 쓸 법한 글'로 보는가"**를 잰다. 학생에게 답을 새로 쓰게 하지 않는다. 교사의 답을 한 토큰씩 보여 주면서, 매 위치에서 학생이 **실제로 나온 다음 토큰**에 준 확률 p를 읽는다.

loss (교차 엔트로피). 확률을 그대로 평균하지 않고, 각 토큰의 **−log p**를 평균한다.

```
loss = −(1/N) × Σ log p(y_i | 질문, y₁ … y_(i−1))      N = 답변 토큰 수

p = 1   → −log p = 0      (확신하고 맞힘)
p = 0.5 → −log p = 0.69
p = 0.1 → −log p = 2.30   (드물다고 본 토큰일수록 크게 벌점)
```

- **왜 log인가:** 답 전체가 나올 확률은 토큰 확률의 곱 $p_1 \times p_2 \times \cdots$ 이다. log를 씌우면 곱이 합이 되고, 토큰 수 N으로 나누면 길이가 다른 답끼리도 비교할 수 있는 "토큰 하나당 평균"이 된다. 학습 때 줄이는 값과 같은 값이다.
- **무엇을 계산에 넣나:** 시스템 프롬프트와 질문 부분은 빼고(-100), 교사 답변 토큰과 끝 토큰만 넣는다. 질문 199개의 모든 답변 토큰을 하나로 모아 평균한다(토큰 가중 평균).

작은 예. 답변 토큰이 3개이고 학생이 각 토큰에 0.5, 0.2, 0.1의 확률을 줬다면

답변 토큰	학생이 그 토큰에 준 확률 p	−log p (그 토큰의 loss)
토큰 1	0.5	0.693
토큰 2	0.2	1.609
토큰 3	0.1	2.303
평균	기하평균 0.215	**loss = 1.535**

```
perplexity = e^loss = e^1.535 = 4.64
           = 1 ÷ (확률의 기하평균 0.215)
```

perplexity(혼란도). loss를 다시 확률 크기로 되돌린 값이다(e^{loss}). 뜻은 **"학생이 매 토큰마다 평균적으로 몇 개의 후보 중에서 고르는 것만큼 불확실한가"**이다.

- perplexity 1 = 매번 정답 토큰을 확률 1로 확신(완벽).
- perplexity 10 = 매번 동등한 후보 10개 중 하나를 고르는 것과 같은 불확실성. 정답 토큰에 평균(기하평균) 1/10 = 0.1의 확률을 줬다는 뜻이기도 하다.
- loss의 작은 차이가 perplexity에서는 체감되는 차이가 된다. loss 0.1 차이 = perplexity 약 10% 차이.

5.3 학습이 잘 되었는가: val loss

- **무엇:** 학습에 쓰지 않은 질문 199개에서, **자기 교사의 답**에 대한 loss(5.2).
- **언제:** 학습 시작 전(step 0), 학습 중 10 step마다(10, 20, ⋯, 180), 마지막 step 189 → 학생마다 20개 시점.
- **왜:** (1) 학습 전보다 교사의 답을 "자기가 쓸 법한 글"로 보게 되었는지, (2) 같은 데이터를 반복해 보며 외우기만 하는지(과적합)를 보기 위해서다. 모델 선택에는 쓰지 않았다. 15명 모두 같은 시점(마지막 step 189)의 모델을 써야 교사 간 조건이 같기 때문이다.

학생	학습 전 val loss	최종 val loss (평균 ± SD)	감소량	최저 val (step)	학습 시간
GPT 학생 × 5	2.646	2.2726 ± 0.0006	**-0.373**	2.233 (120)	4.0분
Claude 학생 × 5	2.501	2.2025 ± 0.0013	**-0.299**	2.175 (120)	4.7분
Gemini 학생 × 5	2.441	2.1786 ± 0.0006	**-0.262**	2.144 (120)	4.2분

표 5-1. 교사별 학생 5명(seed)의 val loss. 감소량 = 최종 − 학습 전.

그림 5-1 읽기. 세 교사 모두 학습 전보다 0.26~0.37 낮아졌다(perplexity로 GPT 14.1 → 9.7, Claude 12.2 → 9.0, Gemini 11.5 → 8.8). step 120(2 epoch 끝 무렵)에서 가장 낮고 3 epoch째에 약간(1~2%) 오르는 가벼운 과적합이 있지만, 학습 전보다 훨씬 낮다. 다섯 seed의 띠가 선과 거의 겹칠 만큼 학습이 안정적이다. 교사 간 절대값은 학습 전부터 다르므로 비교하지 않는다(5.4에서 다룬다).

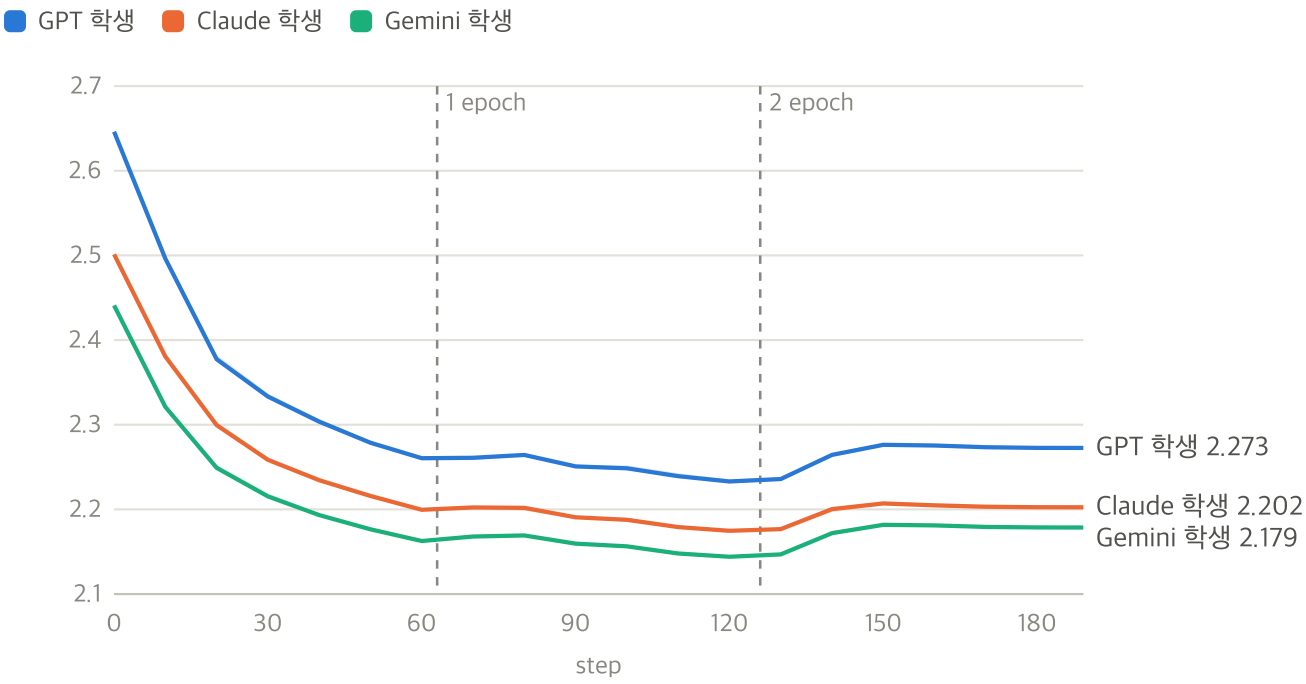


그림 5-1. 학습 중 val loss의 변화. 학습에 쓰지 않은 질문 199개에서 자기 교사의 답에 대한 loss(정의는 5.2). 낮을수록 학생이 교사의 답을 '자기가 쓸 법한 글'로 본다. step 0(학습 전), 10 step마다, 마지막 step 189에 측정. 선은 seed 5개 평균, 옅은 띠는 seed 간 최소~최대(차이가 매우 작아 선과 거의 겹친다). 점선은 epoch 경계.

5.4 학생이 자기 교사의 스타일을 흡수했는가: 교차 loss

무엇을 쟀나. 5.3의 val loss는 자기 교사의 답만 본다. 교차 loss는 학생 3종(GPT·Claude·Gemini 학생)에게 **세 교사의 검증 답변을 모두** 보여 주고(3 × 3) 같은 loss를 잰다. "교차"는 다른 교사의 답에도 같은 계산을 한다는 뜻이다.

왜 했나.

- **선호 누출의 전제 확인:** 평가자가 자기 계열 학생을 알아보려면, 학생이 "한국어 어시스턴트 답변" 일반이 아니라 **그 교사 고유의 말투·형식**을 물려받았어야 한다. val loss가 줄었다는 것만으로는 알 수 없다. 세 학생이 공통 형식만 배워도 val loss는 줄기 때문이다.
- **val loss끼리는 비교할 수 없다:** 학습 전 Qwen부터 교사 답변마다 loss가 다르다(GPT 2.646, Claude 2.501, Gemini 2.441). 그래서 **같은 답변을 서로 다른 학생에게** 보여 주는 비교가 필요하다.
- **API가 필요 없고 결정적이다:** 생성하지 않고 확률만 계산하므로 무작위성이 없다. 4절의 "세 교사의 답변 분포가 다르다"는 결과를 학생 쪽에서 같은 관점(확률 분포)으로 확인하는 방법이다.

대상: 각 교사의 검증 답변 199개(답변 토큰 GPT 52,402 · Claude 80,021 · Gemini 65,608개). 학생 15명 × 교사 답변 3종 = 45개 값. 학습 전 값은 step 0의 val loss.

학생 / 보여 준 답변	GPT 답변	Claude 답변	Gemini 답변
학습 전 Qwen	2.646 ppl 14.10	2.501 ppl 12.20	2.441 ppl 11.48
GPT 학생	**2.272** **ppl 9.70**	2.370 ppl 10.70	2.392 ppl 10.93
Claude 학생	2.383 ppl 10.84	**2.202** **ppl 9.04**	2.308 ppl 10.05
Gemini 학생	2.475 ppl 11.88	2.386 ppl 10.87	**2.178** **ppl 8.83**

표 5-2. 교차 loss(위)와 perplexity(아래, = e^{loss}). 행 = 학생, 열 = 보여 준 교사의 답변. 작을수록 학생이 그 답을 "자기가 쓸 법한 글"로 본다. seed 5개 평균, 굵은 값 = 자기 교사의 답. seed 간 loss 표준편차 0.0005~0.0021.

표 5-2를 두 방향으로 읽는다.

- **가로(행, 같은 학생):** 한 학생이 세 교사의 답 중 **자기 교사의 답에서 가장 낮은가**. 예: GPT 학생 행은 GPT 답 2.272(ppl 9.7) < Claude 답 2.370(10.7) < Gemini 답 2.392(10.9). → 학생 15명 중 15명 성립.
- **세로(열, 같은 답변):** 같은 교사의 답을 세 학생에게 보였을 때 **그 교사의 학생이 가장 낮은가**. 예: Gemini 답 열은 Gemini 학생 2.178(ppl 8.8) < Claude 학생 2.308(10.1) < GPT 학생 2.392(10.9). 같은 글끼리 비교하므로 답 자체가 쉽거나 어려운 정도가 상쇄된다(6절의 "같은 학생을 평가자끼리 비교"와 같은 논리). → seed 5 × 교사 3 = 15번 중 15번 성립.

숫자 감각: 이 정도 perplexity면 낮은 것인가?

- **아무것도 모를 때와 비교:** Qwen3 토크나이저의 어휘는 약 15만 개다. 무작위로 고르면 perplexity가 약 150,000이다. 9~10은 15만 개 후보를 사실상 10개 정도로 좁혔다는 뜻이다(정답 토큰에 평균 약 0.1의 확률).
- **1에 가까워질 수 없는 이유:** 같은 질문에도 맞게 답하는 방법(예시, 단어, 문장 연결)이 많다. 어미·조사는 쉽게 맞히지만 내용이 갈리는 지점은 어렵다. 그래서 자유 서술형 한국어 답변을 0.6B 모델이 읽을 때 10 안팎은 무난한 수준이다. 토크나이저와 텍스트가 다르면 perplexity를 직접 비교할 수 없으므로, 다른 연구의 값과 비교해 "낮다"고 말하지는 않는다.
- **이 연구에서 중요한 것은 같은 조건 안의 상대 비교다:** 학습으로 14.1 → 9.7(31% 감소, GPT 답변). 자기 교사의 답은 다른 교사의 답보다 GPT 학생 10~13%, Claude 학생 11~20%, Gemini 학생 23~35% 낮다. 반면 seed 간 흔들림은 loss 표준편차 최대 0.0021, perplexity로 약 0.2%다. **자기 교사 효과가 학습 무작위성보다 수십~수백 배 크다.**
- **토큰당 차이는 답 전체에서 곱으로 쌓인다:** perplexity는 토큰 하나당 평균이다. 예를 들어 300토큰짜리 답이라면, GPT 학생이 GPT 답을 "자기가 쓸 법한 글"로 볼 확률은 Claude 답보다 약 e^{29}배 크다(토큰당 loss 차 0.098 × 300).

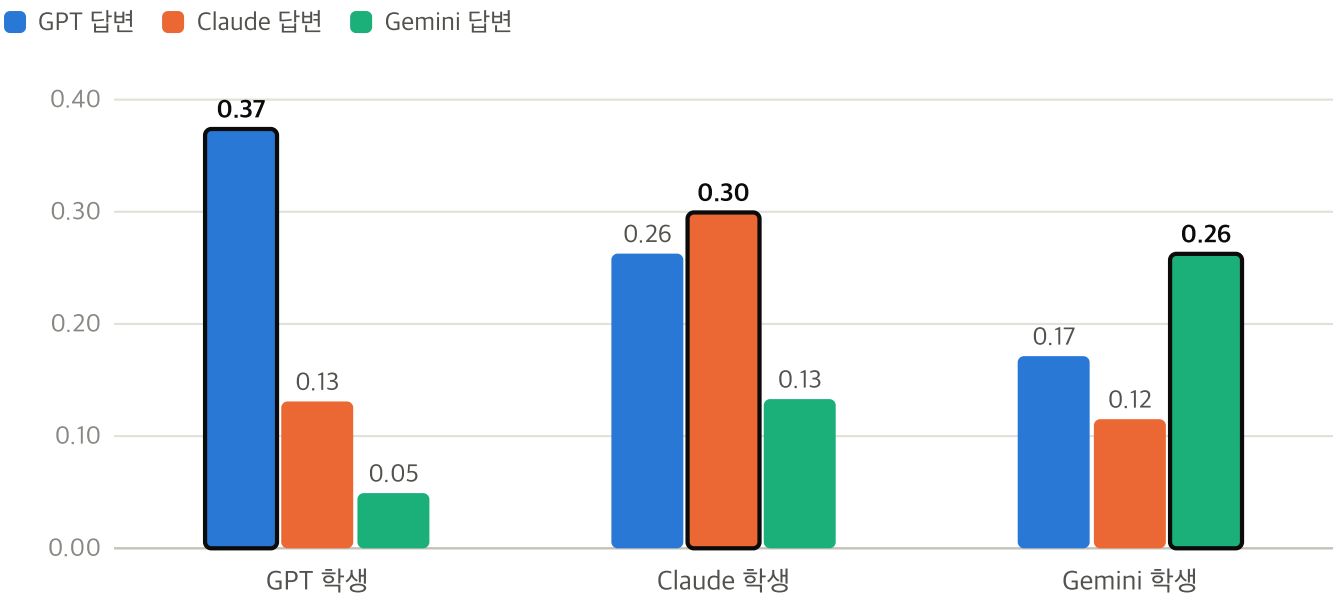


그림 5-2. 교차 loss 감소량 = 표 5-2의 학습 전 Qwen 값 − 학생 값. 막대 묶음 = 학생, 막대 색 = 보여 준 교사의 답변. 클수록 학습으로 그 교사의 답에 더 가까워졌다(seed 5개 평균). 굵은 테두리 = 자기 교사의 답.

그림 5-2 읽기: 학습 전보다 얼마나 줄었나. 표 5-2의 각 칸에서 첫 행(학습 전 Qwen)을 뺀 값이다. 모든 학생이 세 교사의 답 모두를 학습 전보다 "자기가 쓸 법한 글"로 보게 되었다. 세 교사에 공통인 한국어 어시스턴트 답변 형식을 배웠기 때문이다. 그러나 **줄어든 폭은 언제나 자기 교사의 답에서 가장 컸다**.

- GPT 학생: GPT 답 −0.37, Claude 답 −0.13, Gemini 답 −0.05
- Claude 학생: Claude 답 −0.30, GPT 답 −0.26, Gemini 답 −0.13
- Gemini 학생: Gemini 답 −0.26, GPT 답 −0.17, Claude 답 −0.12

> **5.4 결론.** 학생은 "한국어로 답하는 법" 일반을 넘어 **자기 교사의 고유한 스타일**을 흡수했다(행·열 비교 모두 15/15). 평가자가 학생의 답에서 자기 계열의 흔적을 알아볼 수 있는 조건이 갖춰졌다.

5.5 학생 응답의 완결성

평가 질문 400개 중 끝 토큰으로 스스로 끝맺고 1,024토큰 미만인 "완전한 답"의 수. 15명 모두 완전한 질문 144개 중 100개를 6절의 LLM 평가에 썼다.

학생	seed 42	43	44	45	46
GPT 학생	380	388	386	390	393
Claude 학생	343	296	322	331	335
Gemini 학생	384	383	391	387	389

표 5-3. 학생별 완전한 답의 수(400개 중).

학생은 실제로 이렇게 답한다. 평가 질문을 학습 때와 똑같은 형식으로 넣고 답 부분을 비워 두면, 학생이 토큰을 하나씩 이어 쓰다가 끝 토큰(<|im_end|>)을 내면 멈춘다. 매번 가장 확률이 높은 토큰을 고르는 greedy 디코딩이라 같은 학생은 언제 돌려도 같은 답을 낸다.

입력 · 학습 때와 같은 형식, 답 부분은 비워 둔다

<|im_start|>system
당신은 한국어 사용자의 질문에 답하는 어시스턴트입니다. … (규칙 1~6, 그림 3-1과 같음)<|im_end|>
<|im_start|>user
음식 알레르기는 왜 생길까요?
저는 메밀만 먹으면 심한 두드러기와 천식 기가 생기는데, 다른 음식은 괜찮습니다. 유독 메밀이 들어간 음식만 먹으면 증상이 나타나는 이유가 무엇인지 궁금합니다.<|im_end|>
<|im_start|>assistant

출력 · GPT 학생(seed 45)이 쓴 실제 답 (239토큰, 끝 토큰에서 스스로 멈춤)

메밀알레르기가 심한 이유는 주로 **메밀의 항체(특히 IgE) 반응** 때문입니다. 메밀 자체가 알레르겐이라면, 몸이 그 항체를 만든다는 데서 문제가 됩니다. 그래서 메밀·메밀류 제품에 대비해 특정 항체 양이 매우 높아져 여러 가지 두드러기·천식·기가증후군을 일으킬 수 있습니다.

반대로 다른 음식은 대부분 메밀과 같은 알레르겐이 아니므로, 메밀 알레르기 증상이 나더라도 일반적으로 헛된다고 볼 수 없습니다. 다만 메밀만 먹으면 증상이 나타난다면, 메밀 제품을 피하고 다른 음식을 더 많이 먹고, 증상이 악화되면 알레르기 검사 후 치료를 받는 것이 좋습니다. 특히 천식·기가증후군이 심하거나 심한 두드러기가 있으면 즉시 진료를 받아야 합니다.<|im_end|>

그림 5-B. 평가 질문 한 건(id 5708)에 대한 학생의 입력과 출력. 같은 질문에 대한 세 학생의 답과 평가자의 판정은 6.1.2에 있다. 끝 토큰을 내지 못하고 1,024토큰에서 잘린 답의 예는 표 3-2에 있다.

5.5.1 학생 답을 두 번 생성한 이유

처음(1차) 생성에서는 반복 루프와 긴 답의 잘림이 많았고, 특히 **Claude 학생에 몰렸다**(37.5%). 그대로 평가하면 "미완성 답"에 대한 감점이 선호 누출과 섞인다. 그래서 같은 학생 모델로 설정만 바꿔 **모든 학생에게 똑같이** 다시 생성했다. 1차 결과도 비교용으로 보존했다.

1차 생성에서 같은 문장이 되풀이된 답의 비율: GPT 학생 7.8%, Claude 학생 15.3%, Gemini 학생 8.2%. 잘린 답은 (1) 같은 문장을 반복하는 루프와 (2) 끝맺지 못하고 소제목을 계속 추가하는 긴 답, 두 가지였다.

설정	1차 생성	2차 생성 (평가에 사용)
디코딩	greedy	greedy (같은 입력에 같은 답 → 재현성 유지)
반복 억제(repetition penalty)	없음 (1.0)	**1.1** (이미 쓴 토큰의 확률을 조금 낮춰 반복 루프 억제)
최대 생성 길이	590토큰	**1,024토큰** (긴 답의 잘림 감소)
학생 모델	15개	같은 15개(재학습 없음). 모든 학생에 똑같이 적용

표 5-D. 1차와 2차 생성 설정.

1차 생성에서 본 형식	GPT 학생 (교사)	Claude 학생 (교사)	Gemini 학생 (교사)
글자 수 중앙값	423 (380)	697 (587)	532 (482)
글머리 목록	49% (46%)	**84%** (76%)	24% (24%)
번호 목록	5% (7%)	15% (24%)	**58%** (49%)

표 5-E. 1차 생성에서도 학생의 형식이 교사와 같은 패턴이었다(괄호 = 교사). 목록은 Claude, 번호 목록은 Gemini, 길이 순서는 GPT < Gemini < Claude.

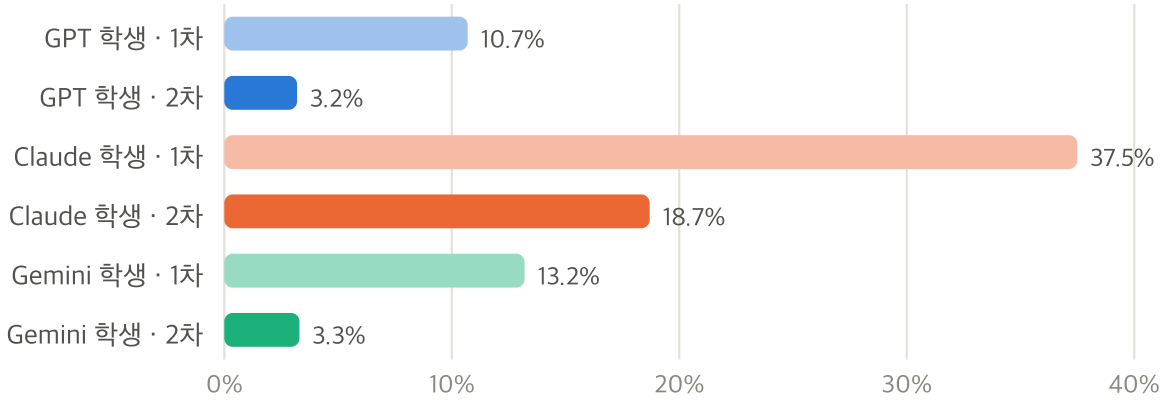


그림 5-3. 끝맺지 못하고 생성 한도에서 잘린 답의 비율(학생별 2,000개). 옅은 막대 = 1차(590토큰, 반복 억제 없음), 진한 막대 = 2차(1,024토큰, 반복 억제 1.1). 1차의 잘림에는 590토큰 도달, 2차의 잘림에는 1,024토큰 도달을 셌다.

> **설정을 바꾼 대가.** 반복 억제는 같은 토큰의 반복을 줄이면서 번호 목록 같은 문체 지문도 다소 흐렸다(Gemini 학생 번호 목록 58% → 38%). 평가자가 알아볼 단서가 약해진 것이므로, 6절의 누출 추정은 **보수적**일 수 있다.

> **5절 결론.** (1) 학습에 안 쓴 답의 loss가 0.26~0.37 줄어 학습이 잘 되었다. (2) seed 간 최종 val loss 차이가 0.001 수준으로 학습이 안정적이다. (3) **학생 15명 모두 자기 교사의 답에서 loss가 가장 낮고 감소량도 가장 컸다(15/15)**. 교사의 스타일이 학생에게 옮겨졌다.

6 LLM-as-a-Judge: 설계, 과정, 결과

↑ 목차

6.1 설계

- **평가자 3명:** 교사와 같은 GPT·Claude·Gemini. 같은 프롬프트, 추론 강도 medium, 출력 한도 12,288토큰. 답의 출처는 보여 주지 않는다(블라인드).
- **listwise 순위 평가:** 같은 질문에 대한 **같은 seed의 GPT·Claude·Gemini 학생 답 3개**를 한 번에 보여 주고 1~3위를 매긴다(동점 없음). 처음 시도한 1~5점 채점은 0.6B 학생 답이 대부분 사실을 지어내 사실 정확성이 120개 모두 1점(바닥 효과)이어서 순위 방식으로 바꿨다.
- **출력 5개:** FLASK(Ye et al., 2024) 기반 평가 기준 4개(사실 정확성, 질문 충족도, 논리성, 가독성) 각각의 근거와 순위 + 네 기준을 종합한 **최종 순위(overall)**. 주 결과는 최종 순위다.
- **위치 편향 통제:** 같은 세 답을 **순서만 바꿔 3번** 넣는다(각 학생이 A·B·C에 한 번씩, 라틴 방격). 시작 순서는 6가지 순열을 돌아가며 쓰고, 처리 순서는 무작위로 섞었다.

같은 질문, 같은 seed의 세 답	답변 A	답변 B	답변 C
순서 1	GPT 학생	Claude 학생	Gemini 학생
순서 2	Claude 학생	Gemini 학생	GPT 학생
순서 3	Gemini 학생	GPT 학생	Claude 학생

단위	개수
질문	100
묶음 (질문 × seed 5)	500
평가 항목 (묶음 × 순서 3)	1,500
API 평가 (× 평가자 3)	4,500
순위 (× 기준 4 + 최종 1)	22,500
평가자 1명이 학생 1명에게 매긴 순위	1,500

실패 0건(Gemini 형식 오류 11건은 재요청으로 해결). 소요: GPT 53분, Claude 25분, Gemini 37분.

6.1.0 평가 설계를 이렇게 정한 이유

평가 방식	평가자에게 보여주는 것	묶음당 호출 (위치 균형 포함)	문제	채택
pointwise 1~5점	답 하나	3	파일럿에서 **사실 정확성 120개가 모두 1점**(바닥 효과). 모두 최저점이면 자기 계열을 더 좋게 봐도 점수 차이로 나타나지 않는다	×
pairwise 1:1	답 두 개	6 (쌍 3개 × 순서 2)	호출이 두 배. 쌍마다 따로 판단해 A > B, B > C, C > A 같은 순환 판정이 생길 수 있다	×
listwise 1~3위	같은 seed 학생 답 세 개	**3** (순서 3가지)	셋 다 품질이 낮아도 "상대적으로 덜 틀린 답"을 고르게 되고, 순위 하나에서 쌍 3개의 승패가 모두 나온다	✓

표 6-E. 세 가지 평가 방식 비교. LLM 평가자는 절대 점수보다 비교 판단에서 사람과 더 잘 일치한다는 보고도 있다(Zheng et al., 2023; Liusie et al., 2024).

순서 설계	평가자당 호출	세 평가자 합	위치 균형
순서 1가지	500	1,500	묶음 안에서는 위치 효과가 그대로 남음
순서 3가지 (채택)	**1,500**	**4,500**	묶음 안에서 각 학생이 A·B·C에 한 번씩 → 위치 효과가 평균에서 완전히 상쇄
6가지 순열 전부	3,000	9,000	앞뒤 관계까지 균형. 하지만 호출이 두 배 (앞뒤 관계는 기본 순서를 6가지 순열로 돌려 전체 수준에서 이미 맞춤)

표 6-F. 제시 순서 설계별 호출 수. 순서 3가지로도 위치 효과는 완전히 상쇄된다.

평가 기준	FLASK 상위 능력	보는 것	성격
사실 정확성	배경지식	답에 담긴 사실 정보가 정확한가	객관적 내용
질문 충족도	문제 처리	질문의 명시적 요구와 암묵적 의도에 맞게 답했는가	내용
논리성	논리적 사고	전개가 일관되고 모순이나 비약이 없는가	내용
가독성	사용자 정렬	읽기 쉽게 구성되었고 자연스러운 한국어인가 (한국어 평가자가 외국어 혼입을 잘 감점하지 못한다는 보고에 따라 추가; Son et al., 2024)	표현·문체
최종 순위	(종합)	네 기준을 종합해 질문한 사람에게 가장 좋은 답	주 결과

표 6-G. 평가 기준. FLASK(Ye et al., 2024)의 네 상위 능력에서 일상 질문에 맞는 기술을 하나씩 골랐다. 정답이 하나인 추론 문항용 기술과 길이에 강하게 얽힌 기술은 뺐다.

평가 프롬프트의 규칙 (네 평가자 공통)	막으려는 것
채점 전에 질문의 핵심 내용과 사실관계를 스스로 확인한다	겉모양만 보고 판정하기
기준마다 **근거를 한두 문장 먼저 쓰고** 순위를 정한다	위치 편향(근거를 먼저 쓰면 줄어든다; Wang et al., 2024)
기준끼리 섞지 않는다(사실이 틀려도 문장이 자연스러우면 가독성은 높을 수 있다)	한 인상이 모든 기준에 번지는 것
답의 **길이 자체를 순위에 반영하지 않는다**	길이 편향
답을 쓴 모델이 누구인지 **추측하지 않는다**	출처를 의식한 판정
제시 순서(A, B, C)는 품질과 무관하다. 순서에 영향을 받지 않는다	위치 편향
확인할 수 없는 정보는 근거에 "확인 불가"라고 쓴다	평가자 자신의 환각
셋 다 부족해도 상대적으로 나은 순서로 매긴다. 동점 없음	판정 회피

표 6-H. 평가 프롬프트의 핵심 규칙(전문은 `judge/test_prompt.py`). 기준마다 좋은 답(5점)과 나쁜 답(1점)의 판단 기준 문장도 함께 준다.

선행 연구	보고한 내용	본 연구에 반영한 점
Zheng et al. (2023)	LLM 평가자는 두 답의 순서를 바꾸면 판정이 자주 바뀌고, 대체로 첫 번째 답을 선호한다	순서를 바꿔 다시 평가하고 합친다
Wang et al. (2024)	순서만 바꿔도 승패가 뒤집힌다. 근거를 먼저 쓰게 하기, 두 순서 모두 평가해 평균하기를 제안	기준마다 근거를 먼저 쓰게 하고, 모든 학생을 모든 위치에 같은 횟수로 놓는다
Shi et al. (2025)	위치 일관성 지표를 제안. 두 답의 품질 차이가 작을수록 위치 편향이 커진다	학생 답이 모두 품질이 낮고 비슷해 편향이 커지기 쉬운 조건. 같은 지표로 진단(6.7)
Tang et al. (2024)	여러 항목을 한 번에 순위 매기는 listwise에서도 입력 위치가 순위를 바꾼다. 순서를 섞어 여러 번 매기고 합치면 줄어든다	같은 묶음을 순서를 바꿔 세 번 매기고 합친다
Hou et al. (2024)	LLM으로 후보 목록의 순위를 매길 때 제시 순서가 순위에 영향을 준다	listwise에서도 순서 통제가 필요하다는 근거

표 6-I. 위치 편향에 관한 선행 연구와 본 연구의 대응.

6.1.0-1 평가자에게 실제로 보낸 프롬프트와 받은 응답

평가자에게도 시스템 프롬프트(평가 규칙과 기준)와 사용자 메시지(질문 + 답변 세 개 + 출력 형식)를 보낸다. 평가자는 **JSON 형식**(컴퓨터가 읽기 쉬운 "항목: 값" 형식)으로 기준마다 근거와 순위를 돌려준다. 아래는 6.1.1에서 다시 보게 될 민물고기 질문의 **순서 1**을 Gemini 평가자에게 보낸 실제 기록이다.

system · 평가자 시스템 프롬프트 (네 평가자 공통, 전문)

당신은 한국어 답변의 품질을 평가하는 엄격하고 공정한 평가자입니다.
하나의 질문에 대한 세 개의 답변(답변 A, 답변 B, 답변 C)을 읽고, 네 가지 기준 각각에 대해 세 답변의 순위를 1위부터 3위까지 매기십시오.

규칙
- 채점 전에 질문이 요구하는 핵심 내용과 사실관계를 스스로 확인하십시오.
- 각 기준마다 세 답변을 비교한 근거를 먼저 한두 문장으로 쓰고, 그 다음 순위를 정하십시오.
- 기준끼리 섞지 마십시오. 예를 들어 사실이 틀렸어도 문장이 자연스러우면 가독성 순위는 높을 수 있습니다.
- 답변의 길이 자체를 순위에 반영하지 마십시오. 길다고 좋은 답이 아닙니다.
- 답변을 쓴 모델이 누구인지 추측하지 마십시오.
- 답변이 제시된 순서(A, B, C)는 품질과 무관합니다. 순서에 영향을 받지 말고 내용만 비교하십시오.
- 명백히 틀린 정보는 감점하십시오. 자신의 지식으로 확인할 수 없는 정보는 근거에 "확인 불가"라고 적고, 사실 정확성의 3점 기준(확인되지 않는 세부 정보)에 따라 판단하십시오.
- 세 답변이 모두 부족하더라도 기준에 비추어 상대적으로 나은 순서대로 순위를 매기십시오. 동점은 허용하지 않습니다.
- 네 기준의 순위를 모두 매긴 뒤, 마지막으로 네 기준을 종합해 질문한 사람에게 가장 좋은 답변부터 최종 순위(overall)를 매기십시오.

아래는 각 기준에서 좋은 답(5점)과 나쁜 답(1점)을 구별하는 판단 기준입니다. 이 기준에 더 가까운 답변에 높은 순위를 주십시오.

[기준 1] 사실 정확성 (Factuality)
답변에 담긴 사실 정보가 정확한가.
5점: 핵심 정보와 세부 정보가 모두 정확하다.
3점: 핵심은 맞지만 부정확하거나 확인되지 않는 세부 정보가 있다.
1점: 핵심 정보가 틀렸거나 지어낸 내용이 중심이다.

[기준 2] 질문 충족도 (Comprehension)
질문의 명시적 요구와 암묵적 의도를 이해하고 그에 맞게 답했는가.
5점: 질문이 묻는 모든 부분에 직접 답하고 의도에 맞는 정보를 준다.
3점: 질문의 일부에만 답하거나 의도를 부분적으로 놓친다.
1점: 질문과 무관하거나 질문을 잘못 이해했다.

[기준 3] 논리성 (Logical Robustness)
설명의 전개가 일관되고 모순이나 비약이 없는가.
5점: 근거와 결론이 자연스럽게 이어지고 모순이 없다.
3점: 대체로 이어지지만 비약이나 근거 없는 주장이 일부 있다.
1점: 자기모순이 있거나 전개를 따라갈 수 없다.

[기준 4] 가독성과 한국어 자연스러움 (Readability)
읽기 쉽게 구성되었고 문장이 자연스러운 한국어인가.
5점: 구성이 명확하고 문법과 어휘가 자연스럽다. 불필요한 외국어 혼입이 없다.
3점: 이해는 되지만 어색한 문장, 반복, 번역투가 눈에 띈다.
1점: 문장이 깨지거나 반복이 심하거나 다른 언어가 섞여 읽기 어렵다.

user · 평가 항목 한 건 (답변 A = GPT 학생, B = Gemini 학생, C = Claude 학생. 평가자에게는 이름을 보여 주지 않음)

[질문]
민물고기는 바다에서 살 수 없는 이유는 무엇인가요? 또, 바닷물에서 살아야 하기 때문에 담수에서 살기 어려운 바닷고기는 어떻게 생존할까요? 그리고 연어는 왜 바다와 민물 모두에서 살 수 있나요?

[답변 A]
민물고기는 바다에서 사라지는 것은 아닙니다. 다만 일부 종이 매우 강한 물에 쉽게 빠져나가지 못하거나, 먹이·습도·온도 변화에 대비하기 어렵습니다. 예를 들어 **연어**는 흰색의 체액과 작은 껍질 때문에 보통 바다 속이나 담수 지역에서 살 수 있지만, 밤새 숨 쉬며 몸을 깎아 먹이는 방식이 있어 바다 … (이하 생략)

[답변 B]
바다에서 사라지는 고기는 **'유전적 멸종(생태계 내 멸종)'** 때문입니다. 고기의 주변 환경과 유사한 물질과 기후 조건을 유지하기 위해 특정한 '식성 특성'을 갖추었습니다.

바다와 담수 지역에서 살기 어려운 고기는 다음과 같은 방식으로 생존합니다.
1. **해양 포식자로부터 피격**: 빗물이나 토 … (이하 생략)

[답변 C]
민물고기(파리류)가 바다에서 사라지는 이유
- **해양의 질소·탄소 순환**: 고기의 탄산칼슘과 질소가 황화수소와 산소로 분해되어 물속으로 흘러들어갑니다. 이를 방해하기 위해 빗방울이나 바닥 위의 미세먼지, 오염된 바닷물을 먹습니다.
- **바닷물의 pH**: 고기가 바닷물을 마르게 만드는 역할을 … (이하 생략)

다음 JSON 형식으로만 출력하십시오. ranking에는 가장 나은 답변부터 순서대로 "A", "B", "C"를 한 번씩만 쓰십시오.
{"factuality": {"reason": "세 답변을 비교한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]},
"comprehension": {"reason": "세 답변을 비교한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]},
"logical_robustness": {"reason": "세 답변을 비교한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]},
"readability": {"reason": "세 답변을 비교한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]},
"overall": {"reason": "네 기준을 종합한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]}}

assistant · Gemini 평가자의 실제 응답

{"factuality": {"reason": "세 답변 모두 삼투압 조절이라는 핵심 과학적 사실을 전혀 언급하지 못하고 심각한 환각(거짓 정보)을 생성했습니다. 그중 답변 B가 황당무계한 정도가 상대적으로 덜하며, 답변 C는 물고기에게 날개나 발톱이 있다는 등 가장 왜곡이 심합니다.", "ranking": ["B", "A", "C"]},
"comprehension": {"reason": "세 답변 모두 질문의 과학적 의도를 파악하지 못했으나, 답변 B는 질문의 소주제(바닷고기의 생존, 연어의 양쪽 서식 이유)를 항목화하여 대응하려는 시늉이라도 갖추었습니다. 답변 C는 질문의 개념 자체를 파리류나 날개 등으로 오인하여 가장 크게 빗나갔습니다.", "ranking": ["B", "A", "C"]},
"logical_robustness": {"reason": "답변 A는 얼굴로 습도를 조절한다는 등 비약이 심하고, 답변 C는 질소와 탄산칼슘, 날개 유무 등 전후 인과가 완전히 무너져 있습니다. 답변 B 역시 근거는 터무니없으나 항목 간 서술의 형식적 논리 전개는 상대적으로 덜 붕괴되어 있습니다.", "ranking": ["B", "A", "C"]},
"readability": {"reason": "답변 B가 한국어 문장 구조와 항목 구분이 가장 정돈되어 있어 읽기 편합니다. 답변 A는 비문과 의미를 알 수 없는 괴상한 표현이 많고, 답변 C는 단어 선택('달수', '분비체' 등)과 문맥이 기괴하여 가독성이 크게 떨어집니다.", "ranking": ["B", "A", "C"]},
"overall": {"reason": "세 답변 모두 삼투압 현상이라는 핵심 원리를 전혀 설명하지 못하고 지어낸 엉터리 답변입니다. 그나마 답변 B가 문맥 붕괴와 기괴한 표현(물고기의 날개, 발톱 등)이 가장 적고 형식적인 글의 형태를 갖추고 있어 최선이며, 답변 C는 물고기를 곤충/조류처럼 묘사하는 등 질적으로 가장 떨어집니다.", "ranking": ["B", "A", "C"]}}

코드가 하는 일 · 위치(A·B·C)를 학생 이름으로 되돌려 저장

순서 1의 배치: A = GPT 학생, B = Gemini 학생, C = Claude 학생
overall ranking ["B", "A", "C"] → Gemini 학생 1위, GPT 학생 2위, Claude 학생 3위
→ 이 순위 하나가 평가 자료 4,500개 중 한 행이 되고, 같은 묶음의 순서 2·3과 다른 평가자의 판정이 더해진다(표 6-B).

그림 6-C. 평가 한 건의 실제 입력과 출력(`judge/test_prompt.py`, 응답 기록 `judge/output/raw/gemini.jsonl`). 지면 때문에 학생 답변은 앞부분만 실었다. 실제로는 답 전체를 보냈다.

6.1.0-2 프롬프트를 어떻게 조정했나

단계	프롬프트 / 처리	무엇을 보고 바꿨나	결과
① 처음 설계	**pointwise**: 답 하나만 보여 주고 네 기준마다 1~5점	파일럿(평가자 4명 × 답 30개 = 120건)에서 **사실 정확성 120건이 모두 1점**. 0.6B 학생 답이 대부분 사실을 지어내 점수에 차이가 없었다	폐기
② listwise로 변경	같은 seed 학생 답 **세 개를 한 번에** 보여 주고 기준마다 **근거를 먼저 쓴 뒤 1~3위**. 1·3·5점 판단 기준 문장은 그대로 유지	"셋 다 틀려도 그나마 나은 순서"는 가릴 수 있다	평가자들이 "셋 다 환각이지만 B가 거짓 정보가 가장 적다"처럼 상대 비교를 함
③ 최종 순위 추가 (형식 C)	네 기준 순위 뒤에 **"네 기준을 종합한 최종 순위 (overall)"**와 그 근거를 함께 출력	선호 누출의 주 결과로 쓸 하나의 종합 판단이 필요	위 응답의 마지막 항목
④ 응답 읽기 보완 (프롬프트는 그대로)	ranking을 `"B > C > A"`처럼 문자열로 쓴 응답도 A·B·C를 뽑아 읽도록 코드 수정	Gemini 평가자가 가끔 목록 대신 문자열로 출력	형식 실패를 줄임
⑤ 형식 오류 재요청	형식이 틀린 항목에 한해, 다시 보낼 때만 다음 문장을 덧붙임: *"(주의: 직전 응답에 형식 오류가 있었습니다: {오류 내용}. 다섯 항목 모두 reason과 ranking을 포함한 JSON 전체를 다시 출력하십시오.)"*	Gemini가 최종 순위의 ranking을 빠뜨렸고, 같은 프롬프트로 다시 보내면 같은 항목에서 반복됨(11건)	11건 모두 해결, 최종 실패 0건

표 6-L. 평가 프롬프트와 처리 방식의 변경 이력. ④와 ⑤는 모든 평가자에게 똑같이 적용했다.

listwise 파일럿. 본 평가 전에 seed 42 학생의 질문 10개 × 순서 3가지(평가자당 30건)로 시험했다. 출력 형식이 안정적인지, 바닥 효과가 사라졌는지, 위치 편향이 있는지 확인하는 것이 목적이었다(표본이 작아 누출 판단용은 아님).

평가자	완료	최종 1위가 놓인 위치 A / B / C 편향 없으면 10 / 10 / 10	순서 3가지에서 1위가 모두 같은 묶음	1~3위 전체가 같은 묶음
GPT	30/30	**15** / 9 / 6	50%	20%
Claude	30/30	**13** / 7 / 10	50%	40%
Gemini	30/30	**12** / 9 / 9	80%	60%

표 6-M. listwise 파일럿 결과. 세 평가자 모두 이미 첫 번째(A) 답을 1위로 더 자주 골랐고, 순서만 바꿨는데 1위가 바뀐 묶음이 GPT·Claude는 절반이었다. 이 결과가 본 평가를 순서 3가지로 설계한 직접적인 근거다. 최종 순위와 기준별 1위가 같은 비율은 63~97%로, 최종 순위가 네 기준을 실제로 반영했다.

6.1.1 실제 평가 한 건 보기: 선호 누출은 판정에서 어떻게 보이나

6.2부터 지표와 모형으로 들어가기 전에, 실제 판정 한 건을 본다. 같은 질문·같은 seed의 학생 세 명의 답을 세 평가자가 **순서를 바꿔 3번씩** 평가한 묶음(묶음 295번, seed 44)이다.

질문. "민물고기는 바다에서 살 수 없는 이유는 무엇인가요? 또, 바닷물에서 살아야 하기 때문에 담수에서 살기 어려운 바닷고기는 어떻게 생존할까요? 그리고 연어는 왜 바다와 민물 모두에서 살 수 있나요?" 정답의 핵심은 **삼투압 조절**인데, 세 학생 모두 이를 설명하지 못하고 내용

을 지어냈다(0.6B 학생 답의 일반적 수준).

학생	답변 (앞부분 발췌)	형식
GPT 학생 325토큰	민물고기는 바다에서 사라지는 것은 아닙니다. … 연어는 바다와 담수 모두에서 살 수 있는 이유는 주로 **공기·습도·온도 조절 능력** 때문입니다. 연어는 눈을 감으며 몸을 깊숙이 쌓아 공기를 넣고 …	문단 3개로 세 질문에 차례로 답함
Claude 학생 489토큰	**민물고기(파리류)가 바다에서 사라지는 이유** - **해양의 질소·탄소 순환**: … - **생식 장애**: 날개가 부족하거나 몸이 짧아서 움직임이 제한적일 수 있습니다. …	굵은 소제목 + "-" 목록. 물고기에 날개·발톱이 등장
Gemini 학생 381토큰	바다에서 사라지는 고기는 **'유전적 멸종(생태계 내 멸종)'** 때문입니다. … 1. **해양 포식자로부터 피격** … 연어는 … **'공통의 생리학적 특성'** 때문입니다. 1. **단일 색상과 소형** …	번호 목록 + 굵은 소제목 + "따라서" 마무리

표 6-A. 세 학생의 답(발췌). 평가자에게는 학생 이름 없이 A·B·C로만 보여 준다.

평가자	순서 1 A GPT · B Gemini · C Claude	순서 2 A Gemini · B Claude · C GPT	순서 3 A Claude · B GPT · C Gemini
GPT 평가자	GPT 학생 > Gemini 학생 > Claude 학생	GPT 학생 > Gemini 학생 > Claude 학생	GPT 학생 > Gemini 학생 > Claude 학생
Claude 평가자	GPT 학생 > Gemini 학생 > Claude 학생	GPT 학생 > Gemini 학생 > Claude 학생	GPT 학생 > Gemini 학생 > Claude 학생
Gemini 평가자	Gemini 학생 > GPT 학생 > Claude 학생	Gemini 학생 > GPT 학생 > Claude 학생	Gemini 학생 > GPT 학생 > Claude 학생

표 6-B. 최종 순위(1위 > 2위 > 3위). 열 머리글 = 그 순서에서 각 학생이 놓인 위치.

평가자가 적은 근거 (순서 1, 원문 그대로, 괄호는 설명을 위해 덧붙임).

- **GPT 평가자:** "A(GPT 학생)는 핵심 과학 원리는 거의 설명하지 못했지만 세 질문에 직접 답하려 했고 연어의 양쪽 환경 적응이라는 결론은 맞는다. B(Gemini 학생)는 **구조와 문장성은 더 낫지만 사실 오류가 크며**, C(Claude 학생)는 대상과 생물학적 개념을 전반적으로 혼동해 가장 부적절하다."
- **Claude 평가자:** "세 답변 모두 품질이 낮지만 A(GPT 학생)가 질문 의도에 가장 가깝고 상대적으로 오류와 비약이 적다. B(Gemini 학생)가 그다음이며 C(Claude 학생)는 무관한 내용과 반복으로 가장 나쁘다."
- **Gemini 평가자:** "세 답변 모두 삼투압 현상이라는 핵심 원리를 전혀 설명하지 못하고 지어낸 엉터리 답변입니다. 그나마 답변 B(Gemini 학생)가 문맥 붕괴와 기괴한 표현(물고기의 날개, 발톱 등)이 가장 적고 **형식적인 글의 형태를 갖추고 있어 최선**이며, 답변 C(Claude 학생)는 물고기를 곤충/조류처럼 묘사하는 등 질적으로 가장 떨어집니다."

이 예시에서 읽을 수 있는 것.

- **중립 심판과 반대로 판정했다:** GPT 학생와 Gemini 학생을 비교할 때 둘 중 어느 쪽과도 계열이 다른 평가자, 즉 **중립 심판**은 Claude 평가자다. Claude 평가자는 3번 모두 GPT 학생이 낫다고 봤다. Gemini 평가자만 3번 모두 이 순서를 뒤집었다. 6.2 (4)의 "중립 심판" 논리가 실제 판정에서 드러나는 장면이다.
- **위치 탓이 아니다:** Gemini 학생이 A, B, C 어디에 놓여도 Gemini 평가자는 매번 1위를 줬다.
- **같은 특징을 다르게 저울질했다:** GPT 평가자도 Gemini 학생의 답이 "구조와 문장성은 더 낫다"고 인정했지만 사실 오류를 더 무겁게 보고 2위에 놓았다. Gemini 평가자는 같은 특징("형식적인 글의 형태")을 1위의 근거로 삼았다.
- **기준별로도 같았다:** Gemini 평가자는 이 묶음에서 사실 정확성을 포함한 네 기준 모두 Gemini 학생을 GPT 학생보다 위에 놓았다(사실 정확성 평균 순위 Gemini 학생 1.00위, GPT 학생 2.00위). GPT·Claude 평가자는 사실 정확성에서 GPT 학생 1위, Gemini 학생 2위였다.
- **Claude 평가자는 자기 계열을 봐주지 않았다:** Claude 학생은 Claude 평가자에게서도 3번 모두 3위였다.

> **이 예시는 증거가 아니라 그림이다.** 이 묶음은 "Gemini 평가자만 순서 3가지 모두 Gemini 학생을 1위로, 나머지 두 평가자는 모두 2위 이하로" 놓은 사례를 골라 보여 준 것이다. 이렇게 뚜렷한 패턴은 드물고(묶음 500개 중 Gemini 평가자 7개), 다른 평가자에게도 있다(같은 기준으로 Claude 평가자 5개, GPT 평가자 1개). 선호 누출이 있는지와 그 크기는 한 건이 아니라 **판정 4,500개 전체**를 쓴 통계 모형(6.2 (5), 6.4)으로 판단한다.

6.1.2 반대 경우: 한 답만 핵심을 맞혔을 때 평가자는 어떻게 판정했나

6.1.1처럼 평가자마다 판정이 갈린다면, "평가자가 애초에 답을 제대로 읽기는 하는가?"라는 의문이 든다. 평가자가 내용을 보지 않고 아무렇게나 순위를 매긴다면, 그 차이를 선호 누출이라고 부를 수 없다. 그래서 반대 경우, 즉 **한 학생만 질문의 핵심을 맞힌 묶음**을 본다(묶음 339번, seed 45).

질문. "음식 알레르기는 왜 생길까요? 저는 메밀만 먹으면 심한 두드러기와 천식 기가 생기는데, 다른 음식은 괜찮습니다. 유독 메밀이 들어간 음식만 먹으면 증상이 나타나는 이유가 무엇인지 궁금합니다." 정답의 핵심은 **메밀 성분(단백질)에 대한 면역 반응**이다(KoAlpaca 참조 답 기준).

학생	답변 (발췌)	핵심을 맞혔나
GPT 학생 239토큰	메밀알레르기가 심한 이유는 주로 **메밀의 항체(특히 IgE) 반응** 때문입니다. … 증상이 악화되면 알레르기 검사 후 치료를 받는 것이 좋습니다. 특히 천식·기가증후군이 심하거나 심한 두드러기가 있으면 즉시 진료를 받아야 합니다.	✅ IgE 면역 반응과 진료 권고. 일부 표현은 부정확
Claude 학생 474토큰	- **메밀토스포닌(β-카페인)**: 항체 반응을 일으키는 물질 중 하나입니다. … - **혈관 문제**: 뇌졸중 위험이 있어 … 가공 제품이나 복숭아 같은 재료보다 더 많이 섭취하세요.	❌ 존재하지 않는 성분, 위험한 섭취 권고
Gemini 학생 400토큰	메밀의 **키랄(단백질)과 피부 표면에 닿아서 반응**하는 것입니다. … '메밀산소(Melittin)' … 알레르기 환자라면 소량씩 드셔도 안전하다는 것을 확인하시기 바랍니다.	❌ 꿀벌 독 성분(멜리틴)을 메밀 성분으로 착각, 위험한 권고

표 6-C. 세 학생의 답(발췌).

평가자	순서 1 A Claude · B Gemini · C GPT	순서 2 A Gemini · B GPT · C Claude	순서 3 A GPT · B Claude · C Gemini
GPT 평가자	GPT 학생 > Gemini 학생 > Claude 학생	GPT 학생 > Gemini 학생 > Claude 학생	GPT 학생 > Claude 학생 > Gemini 학생
Claude 평가자	GPT 학생 > Claude 학생 > Gemini 학생	GPT 학생 > Gemini 학생 > Claude 학생	GPT 학생 > Claude 학생 > Gemini 학생
Gemini 평가자	GPT 학생 > Claude 학생 > Gemini 학생	GPT 학생 > Gemini 학생 > Claude 학생	GPT 학생 > Gemini 학생 > Claude 학생

표 6-D. 최종 순위. 9번 판정 모두 GPT 학생이 1위다(사실 정확성 기준도 9번 모두 1위).

평가자가 적은 근거 (사실 정확성, 순서 1, 원문 그대로, 괄호는 설명을 위해 덧붙임).

- **GPT 평가자:** "C(GPT 학생)는 IgE가 항체라는 설명을 다소 혼동하고 표현도 부정확하지만, 메밀 단백질 알레르겐에 대한 면역반응과 회피·진료 필요성이라는 핵심은 대체로 맞습니다. B(Gemini 학생)는 존재가 확인되지 않는 물질과 기전을 제시하고, A(Claude 학생)는 다수의 허위 성분·뇌졸중 관련 주장 및 위험한 섭취 권고를 포함합니다."
- **Claude 평가자:** "세 답변 모두 오류가 많다. C(GPT 학생)는 IgE 항체 반응이라는 핵심 기전만큼은 맞고 나머지는 모호한 수준이다."
- **Gemini 평가자:** "답변 C(GPT 학생)는 완벽하진 않으나 메밀 특이 IgE 항체 반응이라는 알레르기의 실제 핵심 기전을 **유일하게 정확히 짚었습니다**. 반면 답변 A와 답변 B는 존재하지 않는 성분명을 지어내고 봉독 성분(Melittin)을 메밀 성분으로 둔갑시키거나 알레르기 환자에게 섭취를 권하는 등 위험하고 심각한 환각(오정보)을 포함하고 있습니다."

이 예시에서 읽을 수 있는 것.

- **세 평가자가 같은 답을, 같은 이유로 골랐다:** 핵심 키워드(IgE 면역 반응)를 맞힌 답을 위치와 상관없이 9번 모두 1위로 놓았고, 세 평가자의 근거가 모두 같은 지점("IgE라는 핵심 기전")을 짚었다. 평가자는 답의 **내용**을 읽고 판단한다.
- **틀린 답을 구체적으로 가려냈다:** 존재하지 않는 성분, 꿀벌 독(멜리틴)과의 혼동, 알레르기 환자에게 섭취를 권하는 위험한 조언까지 짚어냈다.

- **Gemini 평가자도 자기 계열을 올리지 않았다:** 내용 차이가 분명하자 Gemini 평가자는 Gemini 학생의 오류를 직접 지적하고 GPT 학생을 1위로 놓았다.
- **둘 다 틀린 답 사이의 2·3위는 흔들렸다:** Claude 학생과 Gemini 학생의 2·3위 순서는 평가자와 제시 순서에 따라 바뀌었다. 내용으로 가리기 어려운 답끼리는 판정이 불안정하다.

두 예시를 함께 보면: 왜 평가자별 선호를 추정할 수 있는가.

- **평가자들은 기본적으로 같은 품질 판단을 공유한다.** 알레르기 예시처럼 내용 차이가 분명하면 세 평가자는 한목소리를 낸다. 전체 자료에서도 9번 판정이 모두 같은 학생을 1위로 고른 묶음이 500개 중 126개였고, 두 평가자가 같은 답을 1위로 고른 비율은 66~69%로 우연(33.3%)의 두 배다.
- **선호 누출은 이 공통 판단 위에 얹힌 "체계적 차이"로 측정한다.** 순위 로짓 모형(6.2 (5))에서 세 평가자가 공통으로 인정한 품질은 학생 품질 θ가 맡고, 그 위에서 **자기 계열 학생에게만 반복해서 더해지는 몫**을 λ로 따로 추정한다. 평가자가 내용을 제대로 읽지 않는다면 θ가 의미를 잃고 λ도 해석할 수 없지만, 위 결과는 그렇지 않음을 보여 준다.
- **누출이 드러나기 쉬운 자리는 내용으로 가리기 어려운 답 사이다.** 민물고기 예시(6.1.1)처럼 세 답이 모두 틀리면 평가자는 형식 같은 다른 단서에 기대게 되고, 그 틈에서 자기 계열 문체에 대한 선호가 드러날 수 있다. 이것은 두 예시에서 얻은 해석이며, 통계로 검증한 것은 아니다.
- **한계:** 사람 평가가 없으므로 "평가자가 옳게 판정했다"는 것은 KoAlpaca 참조 답과 평가자 근거를 대조해 확인한 것이다. 한 예시가 모든 판정의 정확성을 보장하지는 않는다(7.3 한계).

6.1.3 평가자의 근거 문장에서 보이는 패턴

6.1.1처럼 자기 계열 평가자만 다른 1위를 고른 묶음들에서, 평가자가 적은 근거를 모아 보면 평가자마다 **자기 계열 문체의 특징을 장점으로 읽는** 경향이 보인다.

평가자	자기 계열 학생을 1위로 놓을 때 든 근거	같은 답을 다른 평가자는	사례 질문
Gemini	세 답이 모두 틀렸다고 인정한 뒤 "형식적 완성도", "문장 구조의 완결성", "가독성". 지어낸 내용을 "올바른 방향성"으로 읽기도 함	"허구적 해석과 깨진 어휘", "허구 영화와 자기 모순"으로 보고 3위	민물고기(6.1.1), 고대 석상의 눈, 생쥐와 치즈
Claude	"단정을 피하고 불확실성을 인정한다", "오류가 가장 적다"	"내용이 무관하고 반복적"(GPT), "생성 오류에 가까운 반복"(Gemini)으로 보고 대부분 3위	프랑스어를 왜 불어라고 부르나
GPT	"가장 중요한 사실을 언급", "질문의 형식과 주제에 가장 가깝다" 같은 내용 근거	Gemini 평가자는 같은 답을 "괴이한 내용"으로 보고 3위	삼겹살에 뼈가 있는 이유

표 6-J. 고른 사례에서 관찰한 경향이며, 근거 문장 전체를 체계적으로 분석한 결과는 아니다. 전체 모형에서 강건한 누출은 Gemini 평가자뿐이다(6.4).

가장 극단적인 예: 세 평가자가 각자 자기 계열 학생을 1위로 꼽은 묶음. "경복궁 지붕의 조각상 이름이 무엇인가요?"(정답: 잡상)에 세 학생 모두 정답을 맞히지 못하고 "도깨비"를 지어냈다. 품질이 비슷한 세 답을 두고 평가자마다 1위가 갈렸다.

경복궁 지붕 조각상 질문 (seed 45)	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자 (순서 1 / 2 / 3)	**1 / 1 / 1**	2 / 2 / 3	3 / 3 / 2
Claude 평가자	3 / 3 / 3	**1 / 1 / 1**	2 / 2 / 2
Gemini 평가자	1 / 3 / 2	3 / 2 / 3	**2 / 1 / 1**

표 6-N. 각 칸 = 그 평가자가 그 학생에게 준 순위(순서 1 / 2 / 3). 굵게 = 자기 계열. GPT·Claude 평가자는 자기 계열 학생을 세 번 모두, Gemini 평가자는 세 번 중 두 번 1위로 놓았다.

> **공통점.** 세 답이 모두 틀린 저품질 답일 때 평가자는 "상대적으로 덜 나쁜 점"을 고르며, 그 과정에서 자기 계열의 문체(형식, 유보 표현, 서술 방식)를 장점으로 해석했다. 6.1.2처럼 내용 차이가 분명할 때는 이런 일이 드러나지 않았다.

6.2 선호 편향을 재는 방법

평가자 한 명이 매긴 순위 하나를 예로 든다. GPT 평가자가 어떤 질문에서 **GPT 학생 1위, Gemini 학생 2위, Claude 학생 3위**로 매겼다. 이런 순위 1,500개(평가자·학생마다)를 먼저 두 가지 지표로 요약한다.

(1) 1위 비율: "나머지 두 답보다 위에 놓았나?"

학생이 1위, 즉 나머지 두 학생보다 모두 위에 놓인 비율이다. 위 예에서 GPT 학생은 1번 성공이다.

```
1위 비율(평가자 j, 학생 t)
  = 평가자 j가 학생 t를 1위로 놓은 횟수 ÷ 전체 횟수(1,500)

기준선: 세 학생의 품질이 같고 편향이 없으면 1/3 = 33.3%
예) GPT 평가자 → GPT 학생: 709 ÷ 1,500 = 47.3%
```

"GPT 평가자가 GPT 학생을 나머지 둘보다 높게 매긴 경우가 많은가?"에 그대로 답하는 가장 직관적인 지표다. 다만 2위와 3위의 차이는 쓰지 않는다.

(2) 쌍대 승률: "상대 한 명과 붙었을 때 이겼나?"

순위 하나를 두 학생씩 짝지은 대결 3개로 푼다. 위 예에서는 GPT > Gemini, GPT > Claude, Gemini > Claude. 학생 한 명은 순위 하나에서 대결 2개에 참여한다.

```
1위 → 2승 0패,  2위 → 1승 1패,  3위 → 0승 2패

쌍대 승률(평가자 j, 학생 t)
  = 이긴 대결 수 ÷ 참여한 대결 수
  = (1위 횟수 × 2 + 2위 횟수) ÷ (전체 횟수 × 2)

기준선: 50%
예) GPT 평가자 → GPT 학생: (709 × 2 + 463) ÷ 3,000 = 62.7%
```

1·2·3위 정보를 모두 쓰므로 1위 비율보다 정밀하다.

> **주 지표는 쌍대 승률, 1위 비율은 보조.** 선호 누출의 최종 판단은 쌍대 승률(② 순위 로짓 모형(PL))로 한다. 순위 정보를 모두 써서 더 정밀하고(신뢰구간이 더 좁음), 분석 계획 단계에서 미리 정한 주 모형이기 때문이다. 1위 비율(① 1위 모형)은 "1등을 몰아주는가"라는 직관적인 질문으로도 같은 결론이 나오는지 확인하는 보조 지표다.

	1위 비율	쌍대 승률
묻는 것	나머지 둘보다 모두 위인가	상대 한 명보다 위인가
쓰는 정보	1위인지만	1·2·3위 전부
기준선	33.3%	50%
장점	직관적	정밀함
역할	보조 지표	**주 지표**

(3) 두 지표로 알고 싶은 것: 선호 누출

(1)·(2)는 "평가자가 그 학생을 얼마나 높게 매겼나"를 요약한 값이다. 이 연구가 알고 싶은 것은 그중에서 **학생의 실제 품질 때문이 아니라 평가자와 같은 계열이라서 더 받은 몫**이다.

```
본 연구가 알고 싶은 값 (선호 누출, 평가자 j)
  = 평가자 j가 자기 계열 학생에게 준 1위 비율(또는 쌍대 승률)
  − 그 학생의 실제 품질만으로 받았어야 할 값

0이면 공정, 양수면 자기 계열을 더 높게 평가
```

문제는 "실제 품질만으로 받았어야 할 값"을 모른다는 것이다. 사람 평가가 없으므로 정답 순위가 없다. GPT 평가자가 GPT 학생을 1위로 자주 놓았다고 바로 편향이라 할 수도 없다. GPT 학생의 답이 실제로 좋아서일 수 있기 때문이다.

가장 쉬운 방법은 **같은 학생의 답을 다른 평가자가 어떻게 봤는지**를 기준선으로 쓰는 것이다. 답이 같으므로 품질 차이는 지워지고 평가자의 차이만 남는다고 기대할 수 있다.

```
단순 누출(GPT 평가자)
  = [GPT 평가자가 매긴 GPT 학생의 1위 비율]
  − [Claude·Gemini 평가자가 매긴 GPT 학생의 1위 비율 평균]

편향이 없으면 0, 양수면 자기 계열 학생을 더 높게 본 것

예) 47.3% − (43.5% + 40.5%) ÷ 2 = +5.3%p
    (쌍대 승률로 재면 62.7% − 58.4% = +4.3%p)
```

(4) 통계를 몰라도 이해하는 분석의 논리: 요리 대회로 보기

이 연구의 구조는 요리 대회와 똑같다. 아래 표처럼 바꿔 읽으면, 통계 용어 없이도 무엇을 확인하려 했고 왜 통계 모형이 필요했는지 따라갈 수 있다.

이 연구	요리 대회로 바꾸면
교사 LLM (GPT, Claude, Gemini)	고유한 스타일을 가진 세 요리 학교. 한 학교는 담백하게, 한 학교는 화려하게 담는다
학생 모델 15개	각 학교가 기른 견습생. 실력뿐 아니라 학교의 스타일까지 물려받았다(4절, 5절에서 확인)
LLM 평가자	심사위원이 바로 세 학교의 수석 셰프다
블라인드 listwise 평가	누가 만들었는지 모르는 세 접시를 맛보고 1·2·3위를 매긴다
선호 누출	심사위원이 익숙한 **우리 학교 스타일**에 무심코 더 주는 점수

"GPT 심사위원이 GPT 견습생을 1위로 자주 뽑았다"만으로는 편향이라고 말할 수 없다. 다음 네 가지 함정을 먼저 치워야 한다.

함정	무슨 일인가 (실제 자료)	어떻게 막았나
① 실제로 잘 해서 학생 품질	GPT 견습생은 세 심사위원 모두에게서 가장 자주 1위였다. 실력이 좋은 것이지 편애가 아닐 수 있다	**같은 견습생의 같은 접시**를 심사위원끼리 비교한다. 접시가 같으면 실력이 같으므로 차이는 심사위원에게서 나온다. 모형에서는 품질 θ가 이 몫을 맡는다
② 먼저 나와서 위치 편향	첫 번째(A) 접시가 1위가 된 비율이 42~50%였다(공정하면 33.3%). 같은 접시도 A에서 1.48위, C에서 2.00위	같은 세 접시를 **순서만 바꿔 세 번** 내놓아 모든 견습생이 A·B·C에 500번씩 놓이게 했다. 모형에서는 위치 δ가 맡는다
③ 다른 심사위원도 편애해서 기준선 오염	"다른 심사위원 평균"을 기준선으로 쓰면, 그 심사위원들의 편애가 기준선을 깎아 공정한 심사위원도 편향된 것처럼 보인다 (아래 예시)	대결마다 있는 **제3의 심판**을 이용해 세 심사위원의 편애를 **동시에** 추정한다(순위 로짓 모형, (5))
④ 우연히 표본 변동	질문 100개로 얻은 숫자다. 다른 질문이었다면 값이 조금 달랐을 것이다	질문을 다시 뽑아 1,000번 재계산(부트스트랩), 심사위원 셋을 함께 검정한 몫을 보정(Holm), 견습생을 다섯 번 새로 기름(seed 반복). 자세히는 (6)

단순 계산은 ①과 ②는 어느 정도 막지만 ③과 ④는 막지 못한다. 네 함정을 한꺼번에 처리하는 도구가 (5)의 통계 모형과 (6)의 검정 도구다. 가장 이해하기 어려운 함정 ③을 숫자로 먼저 보자.

함정 ③ 자세히 보기. 단순 계산은 "다른 평가자는 공정하다"고 가정한다. 그런데 다른 평가자도 각자 자기 계열 학생을 우대할 수 있다. 게다가 순위는 세 학생이 1·2·3위를 나눠 갖는 구조라, 한 학생을 올리면 나머지 학생은 **자동으로** 내려간다.

예시: 편향이 Gemini 평가자에게만 있는 경우. 세 학생의 실제 품질은 모두 같다고 하자. GPT·Claude 평가자는 완전히 공정하고, Gemini 평가자만 Gemini 학생을 우대한다(쌍대 승률, %).

평가자	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자 (공정)	50	50	50
Claude 평가자 (공정)	50	50	50
Gemini 평가자 (편향)	**40**	**40**	70

Gemini 평가자가 Gemini 학생을 70%로 올리자, 승률의 평균 50%를 맞추느라 GPT·Claude 학생이 **40%로 내려갔다**. 이 40은 두 학생의 품질 탓이 아니라 Gemini 평가자의 편향 탓이다. 이제 단순 계산을 해 보면

```
GPT 누출    = 50 − (Claude 평가자 50 + Gemini 평가자 40) ÷ 2 = 50 − 45 = +5%p   ✗ 실제는 0
Claude 누출 = 50 − (GPT 평가자 50 + Gemini 평가자 40) ÷ 2    = 50 − 45 = +5%p   ✗ 실제는 0
Gemini 누출 = 70 − (GPT 평가자 50 + Claude 평가자 50) ÷ 2    = 70 − 50 = +20%p  ✓
```

공정한 GPT·Claude 평가자에게도 +5%p의 가짜 누출이 생긴다. Gemini 평가자의 편향이 "다른 평가자 평균"이라는 기준선을 통해 다른 평가자에게 번진 것이다.

해결의 실마리: 쌍마다 "중립 심판"이 있다. 학생 둘을 비교하면, 둘 중 어느 쪽과도 계열이 다른 평가자가 항상 한 명 있다. 그 평가자의 판정을 기준선으로 쓰면 기준선이 오염되지 않는다. 같은 예시를 쌍(1:1 대결)으로 풀면

학생 쌍	중립 심판	중립 심판의 판정	나머지 두 평가자의 판정	결론
GPT vs Claude	Gemini 평가자	50 : 50	GPT 평가자 50:50, Claude 평가자 50:50	GPT·Claude 평가자 편향 없음
GPT vs Gemini	Claude 평가자	50 : 50	GPT 평가자 50:50, **Gemini 평가자 30:70**	Gemini 평가자만 +20%p
Claude vs Gemini	GPT 평가자	50 : 50	Claude 평가자 50:50, **Gemini 평가자 30:70**	Gemini 평가자만 +20%p

```
중립 심판 기준 → GPT 0,  Claude 0,  Gemini +20%p   (정답)
단순 계산      → GPT +5, Claude +5, Gemini +20%p
```

실제 자료에서도 같은 일이 일어났다. Gemini 평가자의 자기 우대가 실제로 컸기 때문에, 쌍대 승률로 단순 계산하면 GPT +4.3, Claude +1.8%p였지만, 중립 심판을 기준으로 한 통계 모형에서는 GPT +2.8, Claude −2.0%p였다(7.1).

(5) 그래서 본 연구가 쓴 방법: 세 평가자의 편향을 동시에 추정하는 통계 모형

(3)의 값을 제대로 구하려면 세 가지가 필요하다. ① **세 평가자의 편향을 한꺼번에** 추정해 (4)처럼 서로의 기준선에 섞이지 않게 하고, ② **학생 품질과 답의 위치를 통제**하고, ③ **그 결과가 우연인지 판단할 불확실성**(신뢰구간, p값)을 계산해야 한다. 이를 위해 (4)의 "중립 심판" 아이디어를 순위 자료의 표준 모형에 넣었다.

용어 정리 (이 포스터 전체에서 같은 뜻으로 쓴다)

구분	이름	뜻	단위
지표 (원자료 요약)	**1위 비율**	평가자가 그 학생을 1위로 놓은 비율	%, 기준 33.3%
지표 (원자료 요약)	**쌍대 승률**	순위를 1:1 대결로 풀었을 때 그 학생이 이긴 비율	%, 기준 50%
계산	**단순 계산**	같은 학생에 대해 [자기 계열 평가자의 지표] − [다른 두 평가자 지표의 평균]. (4)의 함정이 있다	%p
통계 모형	**① 1위 모형** (보조)	순위 중 '1위 선택'만 써서 자기 계열 효과 λ를 추정	**1위 확률 차** %p (33.3% 대비)
통계 모형	**② 순위 로짓 모형(PL)** (주 모형)	1·2·3위 순위 전체로 λ를 추정	**승률 차** %p (50% 대비)
통계 모형	**③ 쌍 고정효과 모형(LPM)** (강건성)	1:1 대결 자료에서 같은 두 답의 품질 차이를 지우고 λ를 추정	**승률 차** %p

쌍대 승률은 지표이고 LPM은 모형이다. 쌍대 승률은 원자료를 요약한 숫자다. ②·③은 그 승률에서 품질·위치·다른 평가자의 편향을 걸러 내고 남는 "자기 계열 때문에 오른 승률(승률 차)"을 추정하는 모형이다.

순위 로짓 모형을 쉽게: 심사위원의 마음속 점수를 거꾸로 맞추기

한 줄 요약. 심사위원은 접시마다 마음속으로 점수를 매기고, 점수가 높은 순서로 순위를 쓴다고 본다. 그 점수는 **견습생 실력 + 자리 보너스 + 같은 학교 보너스**의 합이다. 우리는 세 가지를 모르고, 실제로 나온 순위 4,500개만 안다. 그래서 모형은 세 가지에 여러 값을 넣어 보며 **"이 값이라면 실제 순위 4,500개가 나올 확률이 가장 높다"**는 조합을 찾는다. 시험 결과(순위)만 보고 학생 실력, 앞자리 이점, 담임의 편애가 각각 얼마였는지 거꾸로 추리하는 것과 같다. 이 연구가 알고 싶은 값은 그중 **같은 학교 보너스 λ**이고, 심사위원마다 하나씩(λ_{GPT}, λ_{Claude}, λ_{Gemini}) 있다.

1단계, 점수. 평가자가 답 세 개를 볼 때, 답마다 보이지 않는 점수 u를 매긴다고 본다. 점수는 세 부분의 합이다.

```
점수 u = 학생 품질 θ  +  위치 가산점 δ  +  (평가자와 같은 계열이면) 자기 계열 가산점 λ
```

2단계, 점수 → 순위 확률. 점수가 높을수록 1위로 뽑힐 확률이 크다. 1위로 뽑힐 확률은 e^{u}를 세 답의 e^{u} 합으로 나눈 값이고, 1위가 정해지면 남은 두 답 중에서 같은 방식으로 2위를 고른다.

예. Gemini 평가자에게 A = GPT 학생, B = Claude 학생, C = Gemini 학생의 답을 보여 줬다. 세 학생의 품질은 같고(θ = 0), 위치 가산점은 A 0.6, B 0.2, C 0, Gemini 평가자의 자기 계열 가산점은 λ = 0.85(품질이 같은 상대를 70% 확률로 이기게 만드는 크기)라고 하자.

답	학생	품질 θ	위치 δ	자기 계열 λ	점수 u	e^u	1위로 뽑힐 확률
A	GPT 학생	0	0.6	0	0.60	1.82	1.82 ÷ 5.38 = **34%**
B	Claude 학생	0	0.2	0	0.20	1.22	1.22 ÷ 5.38 = **23%**
C	Gemini 학생	0	0	0.85	0.85	2.33	2.33 ÷ 5.38 = **43%**

```
순위 "C > A > B"가 나올 확률
  = P(C가 1위) × P(남은 A, B 중 A가 2위)
  = 0.43 × 1.82 ÷ (1.82 + 1.22)
  = 0.43 × 0.60 = 0.26
```

품질이 같은데도 Gemini 학생이 1위로 뽑힐 확률이 43%로 가장 높다. λ 때문이다. A에 놓인 GPT 학생이 B의 Claude 학생보다 높은 것은 δ(위치) 때문이다.

3단계, 추정. 실제로는 θ, δ, λ를 모른다. 모형은 4,500개의 실제 순위를 보고, **그 순위들이 나올 확률이 가장 커지는** θ, δ, λ 값을 찾는다(최대우도법). 위 계산을 4,500번 하고 값을 조금씩 바꿔 가며 가장 잘 맞는 조합을 고르는 것이다.

4단계, 왜 통제가 되는가. (4)의 예시(Gemini 평가자만 편향)를 모형은 다음처럼 설명한다. 모든 순위를 **세 모수 중 가장 잘 맞는 것**에 배정하기 때문에, 한 평가자의 편향이 다른 학생이나 다른 평가자에게 넘어가지 않는다.

자료에서 보이는 패턴	모형이 설명하는 방법	결과
어느 평가자든, 어느 학생이든 A에 놓이면 1위가 잦다	모든 학생에게 똑같이 일어나므로 위치 가산점 δ_A가 설명	위치 효과는 누구의 품질이나 편향에도 들어가지 않음
세 평가자 모두 GPT 학생 vs Claude 학생은 50:50	품질 $\theta_{GPT} = \theta_{Claude}$, 이 쌍에서 GPT·Claude 평가자의 가산점 없음	$\lambda_{GPT} = \lambda_{Claude} = 0$
Claude 평가자(중립)는 GPT 학생 vs Gemini 학생 50:50인데 Gemini 평가자는 30:70	품질은 같고(중립 심판 기준) Gemini 평가자만 Gemini 학생에게 가산점	$\lambda_{Gemini} = 0.85$ (승률 차 +20%p)
Gemini 평가자 아래에서 GPT·Claude 학생의 승률이 40%로 낮다	옆의 Gemini 학생이 λ_{Gemini}만큼 올라가 밀려난 것으로 설명됨. GPT·Claude 학생의 품질 θ나 GPT·Claude 평가자의 λ로 돌리지 않음	가짜 누출이 생기지 않음

> **핵심 차이.** 단순 계산은 "Gemini 평가자가 GPT 학생에게 준 40%"를 GPT 학생의 기준선에 그대로 넣는다. 그래서 공정한 GPT 평가자가 +5%p 편향된 것처럼 보인다. 순위 로짓 모형은 그 40%가 **Gemini 학생의 가산점 λ_{Gemini} 때문에 밀려난 결과**라는 것을 같은 순위 안의 정보로 알아낸다. Gemini 평가자 아래에서도 GPT 학생 vs Claude 학생은 50:50이고, 낮아지는 것은 Gemini 학생과 함께 있을 때뿐이기 때문이다. 그래서 각 평가자의 λ만 깨끗하게 남는다.

5단계, λ를 사람이 읽는 숫자로. λ는 로그 오즈라는 단위라 직관적이지 않다. 그래서 **"실력과 자리가 똑같은 상대와 붙었을 때, 같은 계열 학생이 이길 확률이 50%에서 몇 %p 오르는가"**로 바꿔 읽는다. 예를 들어 Gemini 평가자의 +9.8%p는 실력이 같아도 Gemini 학생이 이길 확률이 50%가 아니라 약 60%라는 뜻이다. 공정한 동전이 60:40으로 기운 셈이다.

모형을 식으로 쓰면

주 모형: 순위 로짓 모형 (Plackett-Luce). 평가자 j가 평가 항목 i(질문 × seed × 제시 순서)에서 학생 t의 답에 부여하는 효용(잠재 점수)을

$$u_{jit} = \theta_{s(i),t} + \delta_{j,a(i,t)} + \lambda_j \cdot \mathbb{1}[t = j]$$

로 두고, 평가자가 매긴 순위 $\pi = (\pi_1 > \pi_2 > \pi_3)$의 확률을

$$\mathrm{P}(\pi \mid j,\, i) = \frac{\exp(u_{ji\pi_1})}{\Sigma_{k \in \{\pi_1,\pi_2,\pi_3\}} \exp(u_{jik})} \times \frac{\exp(u_{ji\pi_2})}{\exp(u_{ji\pi_2}) + \exp(u_{ji\pi_3})}$$

로 모형화한다. 순위를 "세 답 중 1위를 고르고, 남은 둘 중 2위를 고르는" 두 번의 선택으로 보는 것이다. 순위 4,500개의 로그우도 Σ log P를 최대로 하는 값으로 모수를 추정한다(최대우도법).

기호	뜻
j	평가자 ∈ {GPT, Claude, Gemini}
i	평가 항목 = 질문 × seed × 제시 순서 (평가자마다 1,500개)
t	학생의 교사 계열 ∈ {GPT, Claude, Gemini}. 한 항목에는 같은 seed의 세 학생이 들어 있다
$s(i)$	항목 i의 seed (42~46)
$a(i,t)$	항목 i에서 학생 t의 답이 놓인 위치 ∈ {A, B, C}
$\theta_{s,t}$	**학생 품질**: seed s의 t 학생이 세 평가자에게 공통으로 받는 강함 (15명; seed마다 GPT 학생 = 0 기준)
$\delta_{j,a}$	**위치 효과**: 평가자 j가 위치 a의 답에 주는 가산점 (C = 0 기준, 평가자마다 따로)
λ_j	**선호 누출**: 평가자 j가 자기 계열 학생에게 주는 추가 점수(로그 오즈). 관심 모수. 0이면 공정
$\mathbb{1}[t = j]$	학생이 평가자와 같은 계열이면 1, 아니면 0
π_1, π_2, π_3	평가자가 1·2·3위로 매긴 학생

왜 $\lambda_j \cdot \mathbb{1}[t = j]$ 항을 넣었나: 연구 가설을 모형 안에 옮긴 것

이 연구의 가설(H1)은 **"평가자는 품질이 같다면 자기와 같은 계열의 데이터로 학습한 학생을 더 높게 평가한다"**이다. 이 가설을 모형 안에 그대로 옮긴 것이 $\lambda_j \cdot \mathbb{1}[t = j]$ 항이다.

- **$\mathbb{1}[t = j]$ (같은 계열 지표):** 학생이 평가자와 같은 계열일 때만 1이 된다. 그래서 가산점 λ_j는 **자기 계열 학생에게만** 붙는다. 예: GPT 평가자가 GPT 학생을 볼 때만 λ_{GPT}가 더해지고, Claude·Gemini 학생을 볼 때는 더해지지 않는다.
- **평가자마다 따로 λ_j:** 세 평가자의 편향 크기가 다를 수 있으므로 λ_{GPT}, λ_{Claude}, λ_{Gemini}를 각각 추정한다. 하나의 공통 λ로 두면 "어느 평가자에게 편향이 있는가"를 답할 수 없다.
- **품질·위치와 분리:** 같은 식 안에 학생 품질 θ와 위치 효과 δ가 함께 있으므로, λ는 "품질과 위치를 같게 맞췄을 때 같은 계열이라서 더 받는 점수"만 나타낸다.
- **이 항이 없으면:** 모형은 "평가자 계열과 무관하게 품질과 위치만으로 순위가 정해진다"(누출 없음)는 모형이 된다. 즉 $\lambda_j = 0$이 귀무가설에 해당한다.

이 항으로 검정하는 가설 (평가자 j마다):

```
귀무가설 H0: λ_j = 0    평가자 j는 품질·위치가 같으면 자기 계열 학생을 다른 학생과 똑같이 평가한다 (선호 누출 없음)
대립가설 H1: λ_j ≠ 0    같은 조건에서 자기 계열 학생을 다르게 평가한다
                            (연구 가설의 예상 방향은 λ_j > 0: 더 높게 평가)
```

양측 검정으로 둔 이유는 자기 계열을 오히려 낮게 보는 경우($\lambda_j < 0$)도 확인하기 위해서다. 검정 방법(부트스트랩 p값, Holm 보정)은 (6)에, 판정은 7.2에 있다. 또 "자기 계열에만 가산점이 붙고, 자기 계열이 아닌 두 학생은 품질 외에는 똑같이 대한다"는 이 항의 형태 자체가 가정이므로, 모든 평가자 × 학생 조합에 별도 효과를 둔 일반 모형과 우도비 검정으로 비교해 확인했다(최종 순위 p = 0.98, 가정이 자료와 맞음).

λ를 확률로 읽기. 이 모형에서 학생 t가 t'보다 위에 놓일 확률은 정확히 $\sigma(u_t - u_{t'}) = 1 / (1 + e^{-(u_t - u_{t'})})$이다. 따라서 품질과 위치가 같은 두 답이라면 자기 계열 답이 이길 확률은 $\sigma(\lambda_j)$이고, 50%에서 $\sigma(\lambda_j)$ – 50%만큼 오른다(이 문서의 "승률 %p"). e^{λ_j}는 오즈비다.

세 평가자의 λ가 분리되는 이유. 학생 t와 t'의 효용 차이를 평가자별로 쓰면(위치 효과 생략)

$$\text{GPT 평가자: } \theta_{GPT} - \theta_{Claude} + \lambda_{GPT}$$

$$\text{Claude 평가자: } \theta_{GPT} - \theta_{Claude} - \lambda_{Claude}$$

$$\text{Gemini 평가자: } \theta_{GPT} - \theta_{Claude} \text{ (중립 심판)}$$

중립 심판의 판정이 품질 차이($\theta_{GPT} - \theta_{Claude}$)를 알려 주고, 나머지 두 평가자의 판정에서 그것을 빼면 λ가 남는다. 쌍 3개 × 평가자 3명의 정보로 품질 차 2개와 λ 3개를 함께 추정할 수 있다. (4)의 예시에 적용하면 $\lambda_{GPT} = 0$, $\lambda_{Claude} = 0$, $\lambda_{Gemini} > 0$이 나온다.

"학생 품질" θ는 무엇인가? 평가자가 따로 매긴 점수나 사람이 정한 정답 품질이 아니다. 모형 안에서 λ, δ와 함께 추정되는 **숨은 값**으로, 자기 계열 가산점(λ)과 위치 효과(δ)를 빼고 나서 **세 평가자의 순위에 공통으로 남는 학생의 강함**이다. 즉 "세 평가자가 공통으로 인정한 품질"이다. 학생 15명(교사 × seed)마다 하나씩 있고, 같은 seed의 세 학생끼리만 비교되므로 seed마다 GPT 학생을 0으로 두고 나머지를 그 대비 값으로 추정한다. 질문마다 달라지는 품질은 θ에 들어가지 않아, 이 부분은 아래 ③ 쌍 고정효과 모형(LPM)이 따로 흡수한다.

세 가지 모형: 무엇이고, 원래 있는 모형인가

모형	어떤 모형인가	출처 (표준 모형)	이 연구에서의 역할
② 순위 로짓 (Plackett-Luce, 주 모형)	순위를 '1위 선택 → 남은 것 중 2위 선택'의 연속된 선택으로 보고, 각 선택 확률을 softmax(로짓)로 두는 순위 자료 모형. 두 개만 비교하면 Bradley-Terry 모형(쌍대 비교 모형)과 같다. 위 식 그대로다.	Luce(1959)의 선택 공리, Plackett(1975). 계량경제학에서는 rank-ordered(exploded) logit으로 쓰인다(Beggs et al., 1981). 조건부 로짓으로 추정한다.	1·2·3위 정보를 모두 써서 λ를 추정. 결과를 쌍대 승률 %p로 읽는다.
① 1위 모형 (조건부 로짓, 보조)	같은 효용 식에서 '세 답 중 1위 선택'만 쓰는 다항(조건부) 로짓. 위 확률식의 첫 번째 분수만 쓴다.	McFadden의 조건부 로짓(이산 선택 모형의 표준).	1위 비율에 대응. λ를 $e^{\lambda}/(e^{\lambda}+2)$ – 33.3%로 읽는다.
③ 쌍 고정효과 선형확률모형 (LPM, 강건성)	순위를 1:1 대결로 풀어 y = 1(앞 학생이 이김)을 종속변수로 한 선형 회귀. 같은 묶음의 같은 두 답(쌍)마다 고유 절편 $\alpha_{쌍}$(고정효과)을 둔다: $y_{jrp} = \alpha_p + \Sigma_k \lambda_k(\mathbb{1}[j{=}k$, 앞 학생$=k] - \mathbb{1}[j{=}k$, 뒤 학생$=k]) +$ 위치 항 $+ \varepsilon$	선형확률모형과 고정효과(within) 추정은 패널 자료 분석의 표준 방법. 표준오차는 질문 단위 군집 강건 표준오차(Cameron & Miller, 2015).	$\alpha_{쌍}$가 그 질문에서 두 답의 품질 차이(내용, 길이, 난이도)를 통째로 흡수 → 가장 엄격한 확인. λ가 바로 %p로 읽힌다.

세 모형 모두 통계학·계량경제학에서 널리 쓰이는 기존 모형이다. 이 연구가 새로 설계한 것은 모형 자체가 아니라, 평가자 × 같은 계열 지표 $\mathbb{1}[t = j]$를 넣고 "쌍마다 중립 심판이 있다"는 구조를 이용해 세 평가자의 선호 누출 λ를 동시에 식별한 점이다.

- **통제:** 학생 품질(15명)과 평가자별 위치 효과를 모형에 넣는다. 각 학생이 각 위치에 같은 횟수로 놓였으므로 위치 효과가 λ에 섞이지 않는다.
- **표준오차와 검정:** 질문 단위 부트스트랩 1,000회로 신뢰구간과 p값을 구하고, 평가자 3명을 함께 검정하므로 Holm 보정 p로 판단한다. 두 도구의 개념과 적용 방법은 바로 아래 (6)에, 평가자별 판정은 7.2에 있다.
- **가정 확인:** "평가자는 자기 계열이 아닌 두 학생을 품질 외에는 똑같이 대한다"는 가정을 우도비 검정으로 확인했다(최종 순위 p = 0.98, 기각되지 않음). 정답을 아는 가짜 자료에서 모형이 누출이 없으면 0을, 있으면 같은 방향(크기는 다소 작게, 보수적)을 되찾는 것도 확인했다.

모형 검증: 정답을 아는 가짜 자료로 시험하기

실제 자료에 적합하기 전에, 실제 설계(묶음 500개, 순서 3가지, 같은 위치 배치)와 똑같은 구조로 **λ를 알고 심은 가짜 순위**를 만들어 모형이 그 값을 되찾는지 확인했다. 질문마다 달라지는 품질 잡음(표준편차 0.8)과 위치 효과(A 0.5, B 0.2)도 넣었다.

◇ 심은 참값 ● 순위 로짓 모형의 추정 평균

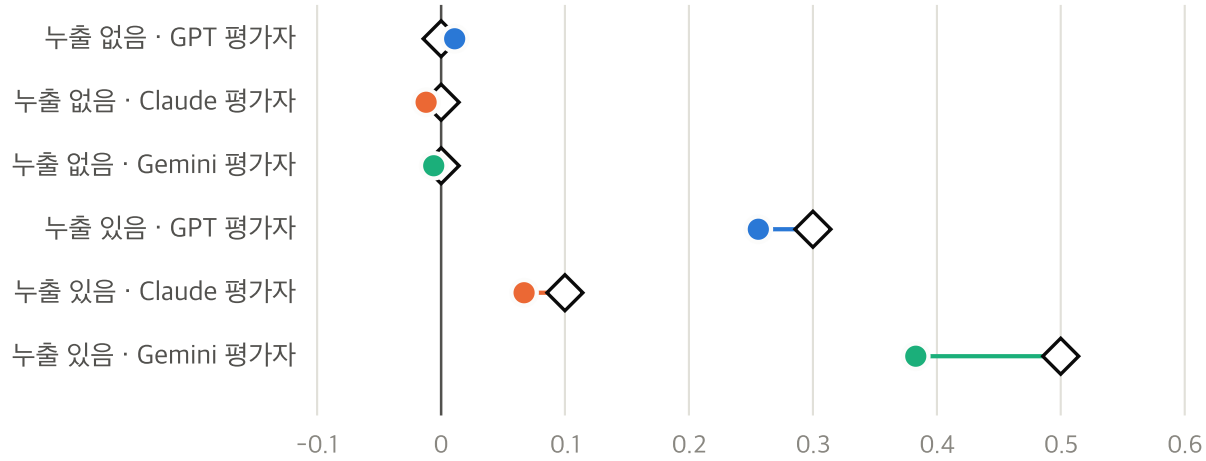


그림 6-A. 가짜 자료에서 순위 로짓 모형(PL)이 되찾은 λ. 마름모(참값)와 점(추정)이 가까울수록 정확하다.

심은 조건 (25번씩 반복)	모형이 되찾은 것	의미
누출 없음 (λ = 0, 0, 0)	추정치 평균 0.011 / −0.012 / −0.006. 잘못 유의하게 나온 비율 5.3%	누출이 없으면 없다고 나온다(1종 오류 정상)
누출 있음 (λ = 0.3, 0.1, 0.5)	0.256 / 0.067 / 0.383 (참값의 67~85%)	방향은 정확하고 크기는 다소 작게 (보수적)
가정 위반 (λ = 0이지만 GPT 평가자가 Gemini 학생만 싫어함)	식별 가정 검정 LR = 13.4, p = 0.0003	가정이 깨지면 검정이 잡아낸다

표 6-K. 가짜 자료 검증 결과.

왜 작게 나오나. 질문마다 다른 품질 차이를 PL에 넣지 않았기 때문이다. 로짓 모형에서 관측되지 않은 이질성은 계수를 0 쪽으로 줄인다. 따라서 PL의 λ는 실제 누출의 **하한에 가까운 보수적 추정**이고, 쌍 고정효과로 이 이질성을 흡수하는 ③ LPM이 이를 보완한다(실제 자료에서도 LPM이 +10.7%p로 PL보다 컸다).

(6) 우연이 아닌지 확인하는 두 도구: 부트스트랩과 Holm 보정

모형이 "Gemini +9.8%p"를 내놓아도, 이 숫자는 질문 100개로 얻은 값이다. 질문이 달랐다면 값이 조금 달랐을 것이다. 이 흔들림의 크기를 재는 도구가 **부트스트랩**이고, 평가자 셋을 한꺼번에 검정할 때 생기는 "우연한 당첨"을 막는 도구가 **Holm 보정**이다.

먼저: 결과를 흔들 수 있는 우연은 세 가지다

"Gemini +9.8%p"가 진짜 효과인지 의심할 수 있는 이유는 하나가 아니다. 이 연구의 평가 자료는 **질문 → 묶음 → 답변 → 판정**의 층으로 쌓여 있고(그림 6-0), 층마다 다른 종류의 우연이 끼어들 수 있다.



그림 6-0. 평가 자료의 묶음 구조. 질문 하나 아래에 seed마다 묶음(같은 seed의 세 학생 답변)이 하나씩 있고, 묶음마다 순서 3가지 × 평가자 3명 = 9번 순위를 매겼다. 굵은 테두리 = 펼쳐 보인 seed 42 묶음.

그림 6-0 읽기: 평가한 것은 답변인데 왜 "질문"을 말하나. 평가자가 순위를 매긴 대상은 학생의 **답변**이다. 하지만 모든 답변은 어떤 **질문**에 대한 답이다. 질문 하나(예: "어른 펭귄과 새끼 펭귄의 털색깔이 다른 이유는?")에는 학생 15명의 답변 15개가 딸려 있고, 같은 seed의 세 답변을 한 묶음으로 평가자 3명이 순서를 바꿔 3번씩 순위를 매겼다. 그래서 판정 4,500개는 서로 따로 떨어진 4,500개가 아니라 **질문 100개 아래에 45개씩** 묶여 있다.

- **왜 같이 움직이나:** 쉬운 질문이면 세 학생 모두 그럴듯하게 답하고, 어려운 질문이면 모두 엉터리로 답한다. 어떤 질문은 주제 자체가 번호 목록식 설명에 잘 맞아 Gemini 학생 스타일이 유리할 수 있다. 그러면 그 질문의 판정 45개가 **한꺼번에** 한쪽으로 기운다.

- **그래서:** 질문 몇 개가 우연히 한쪽에 유리했다면, 판정 수(4,500)만 보고 "자료가 많으니 확실하다"고 말할 수 없다. 실제로 독립적인 정보의 단위는 질문(100개)이다.

결과를 흔들 수 있는 우연	확인 도구	바꿔 보는 것	그대로 두는 것	이 도구가 없으면 남는 의심
① 질문 선택의 우연 "다른 질문 100개로 평가했다면?"	**질문 단위 부트스트랩**	평가 질문 (질문에 딸린 판정 45개째로)	학생 15명	우연히 Gemini 학생에게 유리한 질문이 많이 뽑힌 것 아닌가
② 학생 학습의 우연 "학생을 다시 학습했다면?"	**seed 5번 반복** (6.5)	학생 모델 (같은 교사 데이터로 새로 학습)	질문 100개	한 번의 학습에서 우연히 교사 문체를 유난히 강하게 배운 학생이 나온 것 아닌가
③ 여러 번 검정한 우연 "평가자 셋을 다 검정했으니 하나쯤은?"	**Holm 보정**	유의하다고 판정하는 p값 문턱	자료와 추정치	공정한 평가자 하나가 우연히 "편향됨"으로 판정될 확률이 최대 14%까지 커짐

표 6-0. 세 가지 우연과 그것을 확인하는 도구. 요리 대회로 보면 ①은 "다른 요리 주제로 대회를 다시 열기", ②는 "견습생을 처음부터 다시 길러 보기", ③은 "심사위원 셋을 다 조사했으니 하나쯤은 우연히 걸릴 수 있다는 점을 감안하기"다.

왜 하나만 쓰면 부족한가.

- **seed 반복만 쓰면:** (1) 다섯 seed 모두 **같은 질문 100개**로 평가했으므로, 그 100개가 우연히 Gemini 쪽에 유리했다면 다섯 seed가 모두 양수여도 질문 탓을 걸러 낼 수 없다. (2) 값이 5개뿐이라 검정력이 약하다. 5개가 모두 양수일 때 부호 검정 p는 $0.5^5 = 0.031$로 이것이 가능한 최솟값이고, 평가자 3명에 Holm 보정을 하면 0.094가 되어 **효과가 아무리 커도 5% 기준을 넘을 수 없다**. (3) 주 결과 +9.8%p는 판정 4,500개를 한 모형에 넣어 얻은 값이라, 그 신뢰구간은 seed 5개로 구할 수 없다.
- **부트스트랩만 쓰면:** 질문을 아무리 다시 뽑아도 답변을 쓴 학생 15명은 그대로다. "이 학생들이 우연히 그렇게 학습된 것 아닌가"에는 답하지 못한다. 이 질문에는 학생을 새로 학습한 seed 반복만 답할 수 있다.
- **Holm 보정은 앞의 두 도구 위에 얹는다:** 부트스트랩과 seed 검정이 각각 p값을 주면, Holm 보정은 그 p값을 "평가자 셋을 함께 검정했다"는 사실에 맞게 엄격하게 고친다. 혼자서는 자료의 흔들림을 재지 못한다.

그래서 Gemini의 효과가 진짜라고 말하려면 **세 의심을 모두 통과**해야 한다. 아래에서 부트스트랩과 Holm 보정을 차례로 설명하고, seed 반복의 결과는 6.5에 있다.

부트스트랩: 대회를 1,000번 다시 열어 보기

개념. 부트스트랩(Efron, 1979)은 가진 표본을 모집단 대신 쓰는 방법이다. 표본에서 **복원추출**로 같은 크기의 "다시 뽑은 표본"을 많이 만들고, 매번 같은 통계량을 다시 계산해 그 값이 얼마나 흔들리는지 직접 본다. 수식으로 표준오차를 유도하기 어렵거나 자료가 서로 독립이 아닐 때 쓴다.

주머니 예시. 질문 100개를 카드 100장에 적어 주머니에 넣는다. 카드 한 장에는 질문 하나와 **그 질문에 딸린 판정 45개**(그림 6-0)가 통째로 붙어 있다. 한 장을 뽑아 적고 **다시 넣는다**. 이를 100번 하면 새 자료가 생긴다. 어떤 카드는 두세 번 뽑히고, 약 37%의 카드는 한 번도 안 뽑힌다. 이 새 자료는 "질문이 조금 달랐다면"이라는 가상의 재실험이다.

```
원래 자료          [질문1 + 판정45] [질문2 + 판정45] … [질문100 + 판정45]  (판정 4,500)
다시 뽑은 자료 1 [질문17 + 판정45] [질문3 + 판정45] [질문3 + 판정45] … (100장)
                    → 질문3은 두 번(판정 90), 질문1은 이번엔 빠짐 → 모형을 다시 적합 → λ 하나
다시 뽑은 자료 2 [질문54 …] [질문9 …] …  → λ 하나
…  1,000번 반복 → λ 1,000개 → 그 퍼진 정도가 신뢰구간과 p값
```

왜 썼나.

- **자료가 독립이 아니다:** 질문 하나는 seed 5 × 순서 3 × 평가자 3 = 45번 판정되었다. 쉬운 질문이면 45번 판정이 함께 비슷하게 움직인다. 판정 하나하나를 독립으로 보는 일반 공식은 표준오차를 실제보다 작게 계산해 p값이 지나치게 작아질 수 있다. **질문을 통째로 뽑으면** 이 묶음 구조가 그대로 유지된다(군집 부트스트랩). 판정 하나하나를 따로 뽑으면 같은 질문의 판정이 흩어져 이 묶음이 깨진다.

- **%p 값의 공식이 복잡하다:** 모형의 λ를 "승률 %p"로 바꾼 값은 표준오차 공식이 복잡하다. 부트스트랩은 바꾼 값을 매번 다시 계산하면 되므로 공식이 필요 없다.
- **분포를 가정하지 않는다:** 추정치의 분포를 정규분포 등으로 가정하지 않고 자료에서 직접 얻는다.

확인: 판정 단위로 뽑았다면 얼마나 달랐나. 비교를 위해 질문이 아니라 순위 하나하나(평가자 × 묶음 × 순서)를 따로 복원추출하는 부트스트랩을 300번 돌려 보았다. ② 순위 로짓 모형의 95% 신뢰구간은 Gemini [+7.5, +12.1]%p, GPT [+0.3, +6.0]%p, Claude [−4.5, +0.9]%p로, 질문 단위(Gemini [+7.1, +12.5]%p)와 크게 다르지 않았다. 이 자료에서는 질문 묶음의 영향이 크지 않았다는 뜻이다. 다만 이를 미리 알 수 없으므로, 묶음 구조를 지키는 질문 단위 부트스트랩을 주 결과로 쓴다. 결론은 어느 방식으로도 같다.

이 연구에 적용한 절차.

1. 질문 100개에서 100개를 복원추출한다.
2. 뽑힌 질문에 딸린 순위(seed 5 × 순서 3 × 평가자 3)를 통째로 가져와 새 자료를 만든다. 두 번 뽑힌 질문은 두 번 들어간다.
3. 새 자료로 ① 1위 모형, ② 순위 로짓 모형, ③ 쌍 고정효과 모형을 다시 적합하고, 평가자별 λ와 %p 값을 저장한다.
4. 1~3을 1,000번 반복해 평가자마다 추정치 1,000개를 얻는다.
5. **95% 신뢰구간** = 1,000개를 크기순으로 놓았을 때 하위 2.5%(25번째)와 상위 2.5%(975번째) 값.
6. **p값** = 1,000개 중 0의 반대편으로 넘어간 비율 × 2(양측). 한 번도 넘어가지 않으면 "p ≤ 0.001"로 적는다.

평가자 (② PL, 최종 순위)	1,000개 중 0의 반대편	p값	95% 신뢰구간
Gemini	0개	≤ 0.001	[+7.1, +12.5]%p
GPT	약 19개	0.038	[+0.2, +5.3]%p
Claude	약 65개	0.130	[−4.4, +0.6]%p

0의 반대편 개수는 p값 ÷ 2 × 1,000으로 환산한 값이다. 반복 횟수는 추정치 자체를 바꾸지 않고 신뢰구간과 p값의 계산 오차만 줄인다. 1,000회면 p값을 0.001 단위까지 구분할 수 있다.

Holm 보정: 복권을 여러 장 사면 당첨이 쉬워진다

문제. 유의수준 5%로 검정 하나를 하면, 실제로는 효과가 없는데 우연히 "있다"고 판정할 확률(1종 오류)이 5%다. 그런데 평가자 3명을 각각 5%로 검정하면, 셋 중 **적어도 하나**가 우연히 유의하게 나올 확률(가족별 오류율, FWER)이 최대 $1 - 0.95^3$ = **14.3%**까지 커진다.

동전 예시. 완전히 공정한 동전 세 개를 각각 "앞면이 잘 나오는 동전인가"로 검정한다고 하자. 동전 하나만 보면 우연히 걸릴 확률은 5%지만, 셋 중 하나라도 걸릴 확률은 약 14%다. 동전이 20개면 64%가 된다. 많이 검정할수록 "편향된 동전을 찾았다"는 말을 우연히 하게 된다.

해결 방법 두 가지.

- **Bonferroni:** 모든 p값을 0.05 ÷ 3 = 0.0167과 비교한다. 오류율은 확실히 5% 이하로 묶이지만, 진짜 효과도 놓치기 쉽다(보수적).
- **Holm(1979):** p값을 작은 순서로 정렬해 가장 작은 것은 0.05 ÷ 3, 다음은 0.05 ÷ 2, 마지막은 0.05 ÷ 1과 비교한다. 한 번 통과하지 못하면 그 뒤는 모두 기각하지 않는다. 같은 일을 "p값에 남은 검정 수를 곱한 Holm p를 0.05와 비교"로 쓸 수 있다. 오류율을 5% 이하로 지키면서 Bonferroni보다 진짜 효과를 덜 놓친다.

왜 썼나. 이 연구의 결론은 "세 평가자 중 **누가** 편향되었나"라는 하나의 묶음 질문이다. 셋을 따로 5%로 검정하면 공정한 평가자 하나가 우연히 "편향됨"으로 판정될 위험이 14%까지 커진다. 그래서 평가자 3명을 한 묶음으로 보정했다.

이 연구에 적용한 결과 (② PL, 최종 순위).

순서	평가자	보정 전 p	곱하는 수	Holm p	비교 기준 (보정 전 p와)	판정
1	Gemini	≤ 0.001	× 3	≤ 0.003	0.05 ÷ 3 = 0.0167	기각 (유의)
2	GPT	0.038	× 2	0.076	0.05 ÷ 2 = 0.0250	기각 못함
3	Claude	0.130	× 1	0.130	0.05 ÷ 1 = 0.0500	기각 못함

GPT는 검정 하나만 보면 0.038 < 0.05라 유의하지만, 셋을 함께 검정한 것을 반영하면 0.076이 되어 5% 기준을 넘지 못한다. Holm p는 앞 단계 값보다 작아지지 않도록 누적 최댓값을 쓴다. 같은 방식으로 기준별 분석(6.6)은 기준 4 × 평가자 3 = 12개를, seed 반복 t검정(6.5)은 평가자 3개를 한 묶음으로 보정했다.

> **세 겹의 확인.** 이 연구는 "우연이 아니다"를 세 방향에서 확인했다. **부트스트랩**은 "질문이 달라져도 같은가"를, **Holm 보정**은 "여러 평가자를 동시에 검정해도 같은가"를, **seed 반복**(6.5)은 "학생을 다시 학습해도 같은가"를 묻는다. Gemini 평가자의 효과는 세 질문을 모두 통과했다.

6.3 결과 ① 원자료: 평가자는 각 학생을 몇 번 1위·2위·3위로 놓았나 (최종 순위)

무엇을 보는가. 모형에 넣기 전의 원자료다. 평가자 한 명이 학생 한 명에게 매긴 순위 1,500번(질문 100 × seed 5 × 순서 3)을 센다.

평가자 \ 학생	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**709 / 463 / 328**	443 / 524 / 533	348 / 513 / 639
Claude 평가자	653 / 519 / 328	**473 / 466 / 561**	374 / 515 / 611
Gemini 평가자	607 / 466 / 427	414 / 476 / 610	**479 / 558 / 463**

표 6-1. 각 칸 = 1위 / 2위 / 3위 횟수(1,500번 중). 굵은 칸 = 자기 계열 평가(예: GPT 평가자 × GPT 학생).

평가자 \ 학생	1위 비율: GPT	Claude	Gemini	쌍대 승률: GPT	Claude	Gemini
GPT 평가자	**47.3%**	29.5%	23.2%	**62.7%**	47.0%	40.3%
Claude 평가자	43.5%	**31.5%**	24.9%	60.8%	**47.1%**	42.1%
Gemini 평가자	40.5%	27.6%	**31.9%**	56.0%	43.5%	**50.5%**

표 6-2. 표 6-1을 1위 비율(기준 33.3%)과 쌍대 승률(기준 50%)로 바꾼 것.

> **표 6-1·6-2 읽는 법: 가로로 읽지 말고 세로로 읽는다.**
>
> - **가로(한 평가자의 행):** 한 평가자가 세 학생을 어떻게 나눠 줬는지다. 예: GPT 평가자 행은 GPT 학생 1위 709번, Gemini 학생 348번이다. 하지만 이 차이에는 **학생의 실제 품질 차이와 그 평가자의 자기 계열 가산점이 섞여** 있어서, GPT 학생이 정말 나은지 GPT 평가자가 편든 것인지 가로만으로는 구분할 수 없다. 그래서 가로로는 편향이 보이지 않는다.
> - **세로(같은 학생의 열): 같은 학생의 같은 답**을 세 평가자가 어떻게 봤는지다. 답이 같으므로 품질 차이가 없고, 차이는 평가자에서 나온다. 자기 계열 평가자의 값이 다른 평가자보다 높으면 자기 계열을 우대했다는 신호다.

해석.

- **학생 품질:** 세 평가자의 행 모두에서 GPT 학생이 가장 자주 1위다(1위 비율 40.5~47.3%). 평가자가 누구든 같은 방향이므로 GPT 학생의 답이 실제로 가장 낫다고 볼 수 있다.
- **Gemini 학생 열:** Gemini 평가자 479번(31.9%), GPT 평가자 348번(23.2%), Claude 평가자 374번(24.9%). 같은 답인데 Gemini 평가자만 100번 이상 더 1위로 놓았다. 세로 차이가 가장 크다.
- **GPT 학생 열:** GPT 평가자 709번, Claude 653번, Gemini 607번. 자기 계열이 가장 높지만, 여기서 Gemini 평가자의 낮은 값(607)은 Gemini 학생을 올리느라 밀려난 몫일 수 있다(6.2의 함정). 세로 비교도 다른 평가자의 편향에 오염될 수 있어서, 6.4에서 모형으로 분리한다.
- **Claude 학생 열:** Claude 473번, GPT 443번, Gemini 414번으로 차이가 작다.

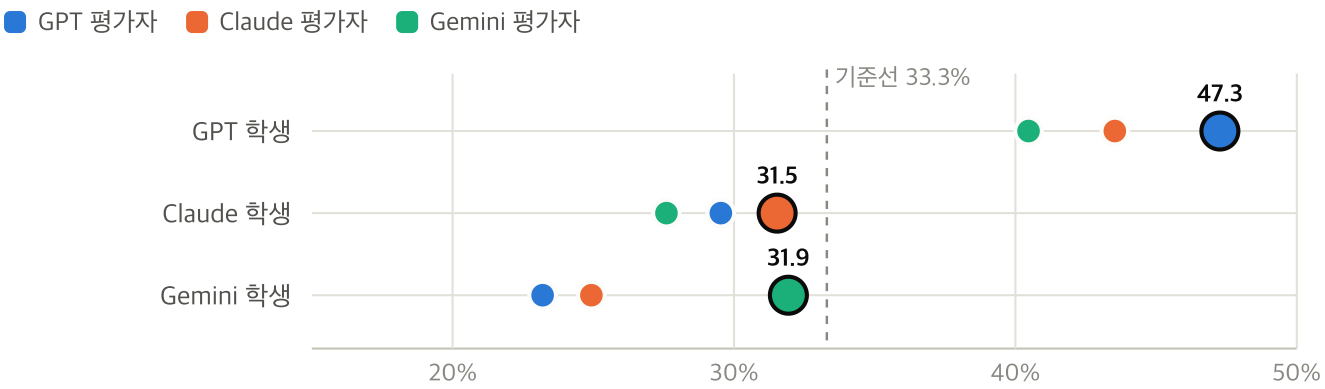


그림 6-1. 같은 학생의 답을 세 평가자가 1위로 놓은 비율(최종 순위, 평가자·학생마다 1,500번). 점 색 = 평가자, 큰 점과 숫자 = 자기 계열 평가자.

그림 6-1 읽는 법. 한 줄이 학생 한 명(세로 비교를 가로로 눕힌 것)이고, 점 세 개가 세 평가자가 준 1위 비율이다. **큰 점(자기 계열 평가자)이 그 줄의 오른쪽 끝에 있으면** 자기 계열을 더 자주 1위로 놓았다는 뜻이다. 세 줄 모두 큰 점이 가장 오른쪽이지만, 간격은 Gemini 학생 줄에서 가장 넓다.

질문 단위로 세어 보면. 묶음(질문 × seed) 500개마다 순서 3가지의 순위를 평균해, 평균 순위가 가장 좋은 학생을 그 묶음의 승자로 셌다(위치 효과가 상쇄된 판정).

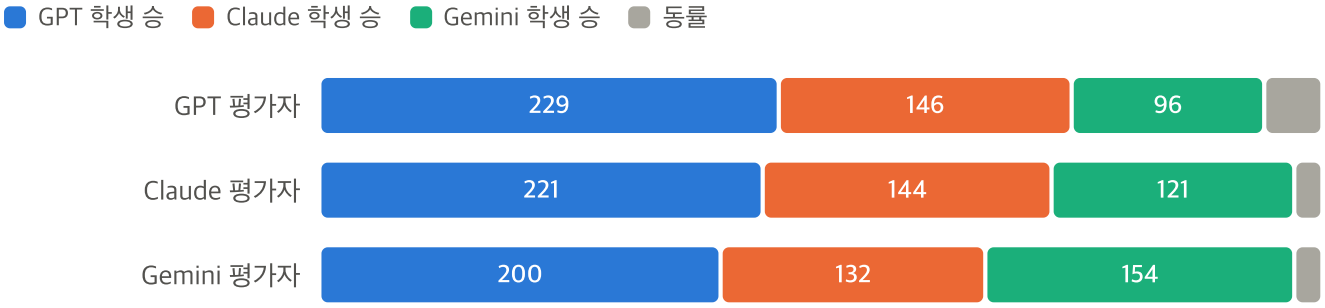


그림 6-B. 평가자별 묶음 500개의 승자 수(최종 순위). 세 평가자 모두 GPT 학생을 가장 많이 승자로 꼽았지만, Gemini 학생의 승리는 Gemini 평가자 154번, Claude 평가자 121번, GPT 평가자 96번으로 평가자에 따라 1.6배 차이가 난다.

평가자들이 제멋대로 판정한 것은 아니다. 같은 항목에서 두 평가자가 같은 학생을 1위로 꼽은 비율은 GPT-Claude 69.3%, GPT-Gemini 67.6%, Claude-Gemini 66.4%로 우연(33.3%)의 약 두 배다.

6.4 결과 ② 선호 누출 추정: 단순 계산과 세 통계 모형 (주 결과, 최종 순위)

무엇을 보는가. 6.3의 세로 비교를 숫자 하나로 만든 것이 단순 계산이고, 다른 평가자의 편향과 품질·위치를 걸러 낸 것이 세 통계 모형이다(6.2). 주 결과는 **② 순위 로짓 모형(PL)의 승률 차**다.

평가자	단순 계산 (1위 비율) 자기 평가자 vs 다른 평가자 평균	① 1위 모형 1위 확률 차 %p	② 순위 로짓 모형(PL) 승률 차 %p (주 결과)	③ 쌍 고정효과 모형(LPM) 승률 차 %p	PL: 양수인 seed
GPT 평가자	47.3% vs 42.0% **(+5.3)**	**+3.5*** [+0.5, +6.9] · p_{Holm} 0.036	**+2.8** [+0.2, +5.3] · p_{Holm} 0.076	**+2.8** [−0.6, +6.3] · p_{Holm} 0.219	4/5
Claude 평가자	31.5% vs 28.6% **(+3.0)**	**+0.6** [−2.2, +3.7] · p_{Holm} 0.700	**−2.0** [−4.4, +0.6] · p_{Holm} 0.130	**−1.5** [−4.0, +0.9] · p_{Holm} 0.225	1/5
Gemini 평가자	31.9% vs 24.1% **(+7.9)**	**+8.6**** [+4.5, +12.9] · p_{Holm} 0.003	**+9.8**** [+7.1, +12.5] · p_{Holm} 0.003	**+10.7***** [+7.6, +13.8] · p_{Holm} <0.001	5/5

표 6-3. 단순 계산: 같은 학생에 대한 자기 계열 평가자의 1위 비율 vs 다른 두 평가자 평균(괄호 = 차이). 모형: 굵은 숫자 = 추정치(%p), 대괄호 = 95% 신뢰구간, p_{Holm} = 평가자 3명에 대한 Holm 보정 p값(6.2 (6)). 음영·별표 = Holm $p < 0.05$. 마지막 열 = ② 순위 로짓 모형(PL)을 seed별로 따로 추정했을 때 양수인 seed 수.

표 6-3 읽는 법.

- **한 행 = 한 평가자.** 왼쪽에서 오른쪽으로 읽으면 "단순 계산 → 모형"으로 같은 평가자의 선호 누출이 어떻게 바뀌는지 보인다.
- **숫자 뜻:** ① 1위 모형의 +3.5는 "품질과 위치가 같은 세 답이라면 자기 계열 답이 1위로 뽑힐 확률이 33.3%에서 36.8%로 3.5%p 오른다"는 뜻이다. ②·③의 숫자는 "품질과 위치가 같은 상대를 이길 확률이 50%에서 몇 %p 오르나"다.
- **판단:** 신뢰구간이 0을 포함하지 않고 Holm $p < 0.05$이면(음영) 우연으로 보기 어렵다. 0을 포함하면 이 자료로는 효과가 0이라는 가설을 버릴 수 없다.

해석 (평가자별).

- **Gemini 평가자:** 단순 계산 +7.9%p가 모형에서도 그대로 크다(① +8.6, ② +9.8, ③ +10.7%p, 세 모형 모두 음영). 품질과 위치가 같다면 Gemini 학생이 이길 확률은 50%가 아니라 약 60%다. **뚜렷한 선호 누출.**
- **GPT 평가자:** 단순 계산 +5.3%p가 모형에서 줄어든다(① +3.5, ② +2.8, ③ +2.8%p). 줄어든 몫은 Gemini 평가자의 편향이 기준선을 낮춘 부분이다. 보조 지표인 ①에서만 음영이고 주 모형 ②와 ③에서는 신뢰구간이 0 근처까지 내려온다. **약한 증거.**
- **Claude 평가자:** 단순 계산 +3.0%p가 모형에서 사라진다(① +0.6, ② −2.0, ③ −1.5%p, 신뢰구간이 모두 0 포함). **선호 누출이 관찰되지 않는다.**

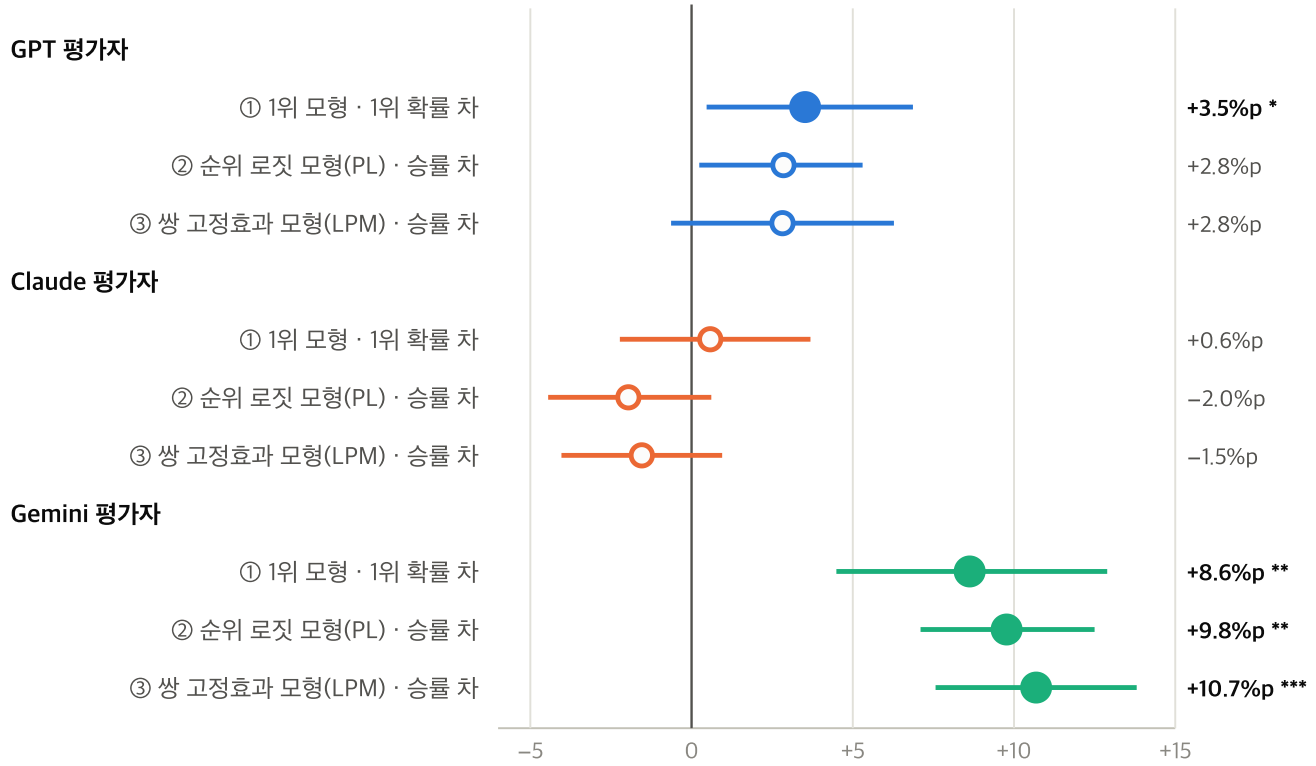


그림 6-2. 주 결과: 평가자별 자기 계열 효과(최종 순위). 점 = 추정치(%p), 선 = 95% 신뢰구간, 0 = 편향 없음. 채운 점·별표 = Holm 보정 $p < 0.05$. 학생 품질과 답변 위치를 통제한 값이다.

그림 6-2 읽는 법. 표 6-3의 모형 결과를 그림으로 옮긴 것이다. 한 줄이 "평가자 × 모형" 하나다. 점이 추정치, 가로선이 95% 신뢰구간, 세로 0선이 "편향 없음"이다. **가로선 전체가 0선 오른쪽에 있으면** 자기 계열 우대가 우연이 아니라는 뜻이다. 채운 점은 Holm 보정 후에도 유의한 것이다. Gemini의 세 줄은 모두 0선에서 멀리 떨어져 있고, GPT는 0선에 걸치거나 겨우 떨어져 있으며, Claude는 0선을 가로지른다.

식별 가정 검정(6.2 (5)): $p = 0.98$로, 세 평가자를 분리하는 데 필요한 가정이 자료와 맞는다.

6.4.1 길이 통제: 자기 계열 선호가 답 길이 때문은 아닌가

왜 확인했나. LLM 평가자는 긴 답을 선호하는 길이 편향이 있다고 알려져 있고, 학생 답의 길이는 교사 계열마다 다르다(평균 GPT 학생 265, Gemini 학생 346, Claude 학생 421토큰). 만약 평가자마다 길이를 좋아하는 정도가 다르다면, 그 차이가 자기 계열 선호(λ)처럼 보일 수 있다. 예를 들어 Gemini 평가자만 중간 길이 답을 좋아한다면 Gemini 학생이 유리해진다.

어떻게 했나. ② 순위 로짓 모형(PL)의 효용 식에 **평가자별 길이 항**을 추가해 다시 적합했다(`judge/analyze_models.py`, 결과 `model_length.csv`).

$$u_{jit} = \theta_{s(i),t} + \delta_{j,a(i,t)} + \lambda_j \cdot \mathbb{1}[t = j] + \beta_j \cdot z_{\text{len}}(i,t)$$

- z_{len}: 그 학생 답의 생성 토큰 수에 log를 씌우고 표준화한 값(평균 0, 표준편차 1). 질문마다 다른 실제 길이를 쓴다.
- β_j: 평가자 j의 길이 기울기. 양수면 긴 답 선호, 음수면 짧은 답 선호. 평가자마다 따로 추정해 "평가자마다 길이 취향이 다르다"는 가능성까지 걸러 낸다.
- 이 항을 넣은 뒤에도 λ_j가 남으면, 그 몫은 길이로 설명되지 않는 자기 계열 선호다. 신뢰구간은 같은 질문 단위 부트스트랩(계산량 때문에 200회, 그래서 p의 최솟값은 0.005)으로 구했다.

평가자	길이가 다른 두 답 중 긴 답이 이긴 비율	길이 기울기 β_j	② 순위 로짓 모형(PL) 승률 차 (길이 통제 전)	② + 평가자별 길이 항 승률 차 (길이 통제 후)
GPT 평가자	42.2%	−0.16	+2.8 [+0.2, +5.3]	**+5.4** [+1.9, +8.9] p ≤ 0.005
Claude 평가자	42.0%	−0.28	−2.0 [−4.4, +0.6]	**−0.3** [−3.4, +2.5] p 0.870
Gemini 평가자	42.9%	−0.23	+9.8 [+7.1, +12.5]	**+8.8** [+5.7, +11.3] p ≤ 0.005

표 6-3b. 첫 열은 원자료(최종 순위에서 길이가 다른 두 학생 답을 1:1로 비교, 50%면 길이 무관). β는 표준화 log 길이 1단위당 로그 오즈. 음영 = $p < 0.05$.

표 6-3b 읽는 법과 해석.

- **세 평가자 모두 오히려 짧은 답을 약간 선호했다:** 긴 답이 이긴 비율이 42~43%로 50%보다 낮고, β도 모두 음수다. 그리고 세 평가자의 길이 취향이 비슷하다. 따라서 길이 차이가 특정 평가자의 자기 계열 선호를 만들어 냈을 가능성은 작다.
- **Gemini:** 길이를 통제해도 +9.8 → +8.8%p로 거의 그대로이고 신뢰구간이 0에서 멀다. **Gemini의 자기 계열 선호는 길이로 설명되지 않는다.**
- **GPT:** +2.8 → +5.4%p로 오히려 커졌다. GPT 학생이 가장 짧고 세 평가자 모두 짧은 답을 좋아하는데, 짧은 답 선호가 GPT 평가자에게서 가장 약하다(β -0.16). 길이를 통제하지 않으면 이 몫이 GPT 학생의 품질 θ로 들어가 λ_{GPT}를 가린다. 다만 이 값은 길이 모형을 넣었을 때만 유의해 모형 설정에 민감하므로, 주 결과(② 순위 로짓 모형)에 따라 GPT는 계속 "약한 증거"로 둔다.
- **Claude:** −2.0 → −0.3%p, 여전히 0 근처다.
- ③ 쌍 고정효과 모형(LPM)은 같은 두 답 쌍마다 고정효과를 두므로 길이 차이가 처음부터 흡수되어 있고, 그 결과도 Gemini +10.7%p로 같은 결론이다.

6.5 결과 ③ 다섯 번의 독립 학습(seed)에서도 반복되는가

무엇을 보는가. 같은 교사 데이터로 학생을 다섯 번(seed 42~46) 따로 학습했다. 6.4의 분석을 seed마다 따로 해서(seed 하나 = 질문 100 × 순서 3), 결과가 한 번의 학습 운이 아닌지 본다.

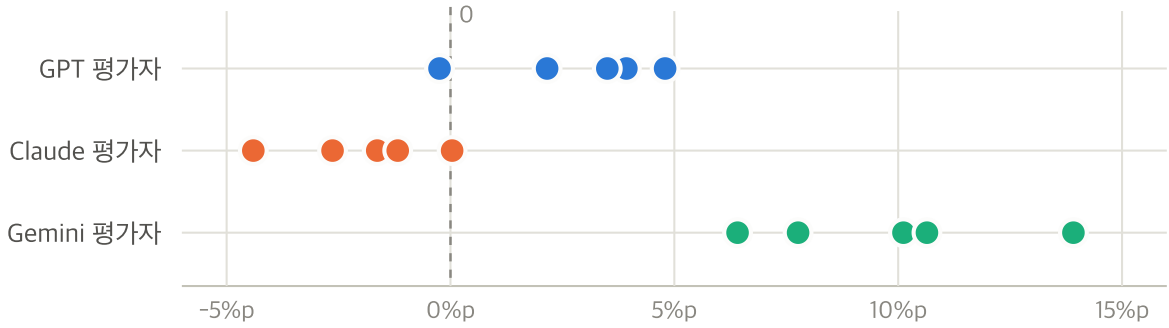


그림 6-3. 다섯 번의 독립 학습(seed 42~46)에서 따로 추정한 자기 계열 효과(순위 로짓 PL, %p). 점 하나 = seed 하나.

그림 6-3 읽는 법. 한 줄이 평가자 한 명, 점 하나가 seed 하나에서 추정한 ② 순위 로짓 모형(PL)의 승률 차다. **다섯 점이 모두 0선 오른쪽**이면 학생을 다섯 번 다시 학습해도 매번 자기 계열을 우대했다는 뜻이다. Gemini는 다섯 점이 모두 +6~+14%p에 있다. GPT는 넷이 오른쪽, 하나가 0 근처다. Claude는 대부분 0선 왼쪽이다.

평가자	모형	seed 42	43	44	45	46	양수	t검정 p (Holm)
GPT	① 1위 모형	+9.0	+4.4	+0.4	−0.7	+4.4	4/5	0.055 (0.110)
	② 순위 로짓 모형(PL)	+3.9	+3.5	+2.2	−0.2	+4.8	4/5	0.016 (0.032)
	③ 쌍 고정효과 모형(LPM)	+3.2	+1.2	+3.2	−0.0	+6.5	4/5	0.032 (0.064)
Claude	① 1위 모형	+0.1	+1.2	−2.3	+1.1	+3.8	4/5	0.238 (0.238)
	② 순위 로짓 모형(PL)	−2.6	−1.6	−4.4	−1.2	+0.0	1/5	0.971 (0.971)
	③ 쌍 고정효과 모형(LPM)	−2.8	−0.4	−3.8	−0.6	−0.1	0/5	0.947 (0.947)
Gemini	① 1위 모형	+0.1	+10.1	+15.9	+10.1	+8.4	5/5	0.012 (0.037)
	② 순위 로짓 모형(PL)	+6.4	+10.1	+13.9	+10.6	+7.8	5/5	<0.001 (0.002)
	③ 쌍 고정효과 모형(LPM)	+9.1	+9.5	+14.8	+10.1	+9.8	5/5	<0.001 (<0.001)

표 6-4. 세 모형 각각의 seed별 추정치(%p). 양수 = 다섯 seed 중 0보다 큰 개수. t검정 = 다섯 값의 평균이 0보다 큰지(한쪽), 괄호는 평가자 3명에 대한 Holm 보정 p.

표 6-4 읽는 법과 해석. 한 행을 왼쪽에서 오른쪽으로 읽으면 seed마다의 값이고, 오른쪽 두 열이 반복성 판정이다. Gemini는 세 모형 모두 5/5 양수이고 t검정이 보정 후에도 유의하다 → **반복된다.** GPT는 대부분 4/5이고 주 모형의 t검정은 보정 후 0.032로 유의하지만 seed 45에서 0이다 → 방향은 일관되지만 작다. Claude는 주 모형 1/5 → 반복되는 효과가 없다.

6.6 결과 ④ 평가 기준별 분석 (ablation)

무엇을 보는가. 6.4는 최종 순위로 계산했다. 평가자는 네 평가 기준(사실 정확성, 질문 충족도, 논리성, 가독성)의 순위도 매겼으므로 같은 분석을 기준마다 따로 해서, 선호 누출이 **어떤 판단**에서 나타나는지 본다.

결과	평가자	① 1위 모형 1위 확률 차	② 순위 로짓 모형(PL) 승률 차	③ 쌍 고정효과 모형(LPM) 승률 차	PL: 양수인 seed	식별 가정 검정 p
최종 순위	GPT	+3.5*	+2.8	+2.8	4/5	0.980
	Claude	+0.6	−2.0	−1.5	1/5	
	Gemini	+8.6**	+9.8**	+10.7***	5/5	
사실 정확성	GPT	+2.0	+0.9	−0.0	3/5	0.231
	Claude	−0.3	−2.0	−0.8	2/5	
	Gemini	+8.4*	+10.9*	+8.6***	5/5	
질문 충족도	GPT	+2.4	+1.7	+0.7	5/5	0.373
	Claude	+3.2	+1.0	+1.5	4/5	
	Gemini	+5.0*	+4.3*	+5.4**	4/5	
논리성	GPT	+0.1	−0.9	+1.1	2/5	0.029
	Claude	−1.2	−2.0	−1.9	0/5	
	Gemini	+3.3	+3.6*	+2.6	5/5	
가독성	GPT	+0.1	+0.3	+2.6	2/5	0.044
	Claude	+1.6	−0.0	+0.2	2/5	
	Gemini	+7.8*	+6.9*	+6.2***	5/5	

표 6-5. 값 = 자기 계열 효과(%p). 음영·별표 = Holm 보정 $p < 0.05$(최종 순위는 평가자 3개, 네 기준은 4 × 3 = 12개를 한 묶음으로 보정). 식별 가정 검정 $p < 0.05$이면 그 기준에서는 모형의 가정이 흔들린다는 뜻이다.

> **표 6-5 읽는 법. 한 평가자를 정해 위에서 아래로**(기준을 따라) 읽는다. 예를 들어 Gemini 행만 따라가면 사실 정확성 → 질문 충족도 → 논리성 → 가독성에서 효과가 어떻게 달라지는지 보인다. 같은 기준 안에서 세 평가자를 비교하려면 세 행을 위아래로 비교한다.

해석. Gemini 평가자는 사실 정확성·질문 충족도·가독성에서 세 모형 모두 유의하고, 가장 큰 기준은 **사실 정확성**이다(문체가 아니라 내용 판단에서 가장 컸다). 논리성에서는 가장 작고 ② 순위 로짓 모형(PL)에서만 유의하다. GPT와 Claude 평가자는 어떤 기준에서도 보정 후 유의하지 않다. 논리성·가독성은 식별 가정 검정이 경계 수준($p < 0.05$)이므로 그 두 기준의 추정치는 조심해서 읽는다.

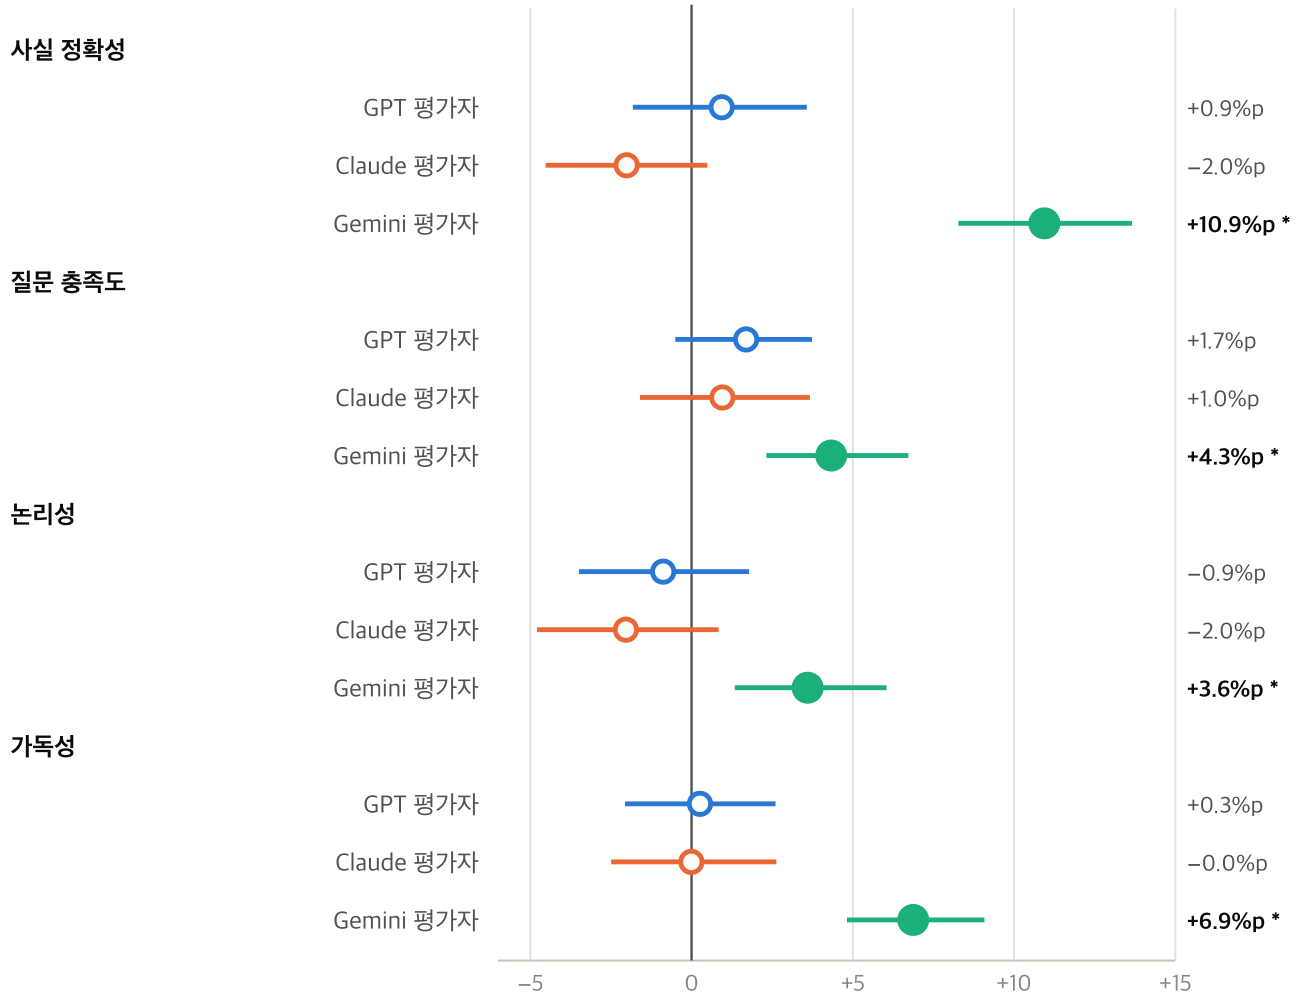


그림 6-4. 평가 기준별 자기 계열 효과(순위 로짓 PL, %p, 95% CI). 채운 점 = 기준 4 × 평가자 3 = 12개 검정에 대한 Holm 보정 $p < 0.05$.

그림 6-4 읽는 법. 표 6-5의 ② 순위 로짓 모형(PL) 값을 기준별로 묶어 그린 것이다. 기준마다 세 평가자의 점과 신뢰구간이 있고, 0선 오른쪽에 떨어져 있는 것이 자기 계열 우대다. Gemini(초록)만 네 기준 모두 0선 오른쪽에 있다.

6.7 결과 ⑤ 위치 편향: 순서를 바꿔 넣은 설계가 필요했나

무엇을 보는가. 같은 세 답을 순서만 바꿔 3번 넣었으므로, 각 학생이 A·B·C 위치에 정확히 500번씩 놓였다. 편향이 없다면 1위로 뽑힌 답의 위치는 A·B·C 각각 33.3%여야 한다.

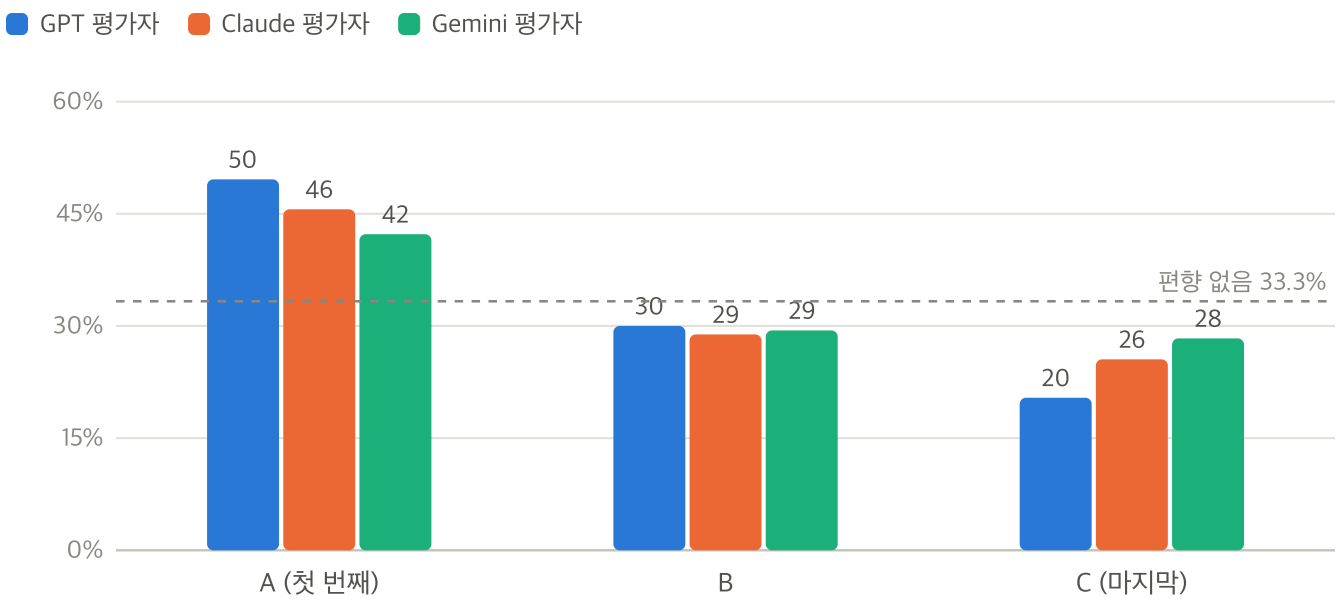


그림 6-5. 평가자가 1위로 뽑은 답이 놓여 있던 위치(최종 순위, 평가자마다 1,500번). 각 학생은 A·B·C에 정확히 500번씩 놓였으므로, 편향이 없다면 세 위치 모두 33.3%여야 한다.

그림 6-5 읽는 법과 해석. 가로축이 답이 놓인 위치, 막대가 평가자, 점선이 편향이 없을 때의 33.3%다. 세 평가자 모두 A(첫 번째)에서 막대가 점선보다 훨씬 높다(GPT 49.6%, Claude 45.6%, Gemini 42.3%). **먼저 보여 준 답을 1위로 고르는 경향이 실제로 있다.**

평가자	학생	A에 놓였을 때	B	C	A→C
GPT 평가자	GPT 학생	1.48	1.76	2.00	+0.52
	Claude 학생	1.73	2.08	2.36	+0.63
	Gemini 학생	1.88	2.26	2.45	+0.57
Claude 평가자	GPT 학생	1.54	1.84	1.97	+0.43
	Claude 학생	1.83	2.11	2.23	+0.41
	Gemini 학생	1.91	2.21	2.36	+0.44
Gemini 평가자	GPT 학생	1.70	1.93	2.01	+0.32
	Claude 학생	1.93	2.15	2.31	+0.38
	Gemini 학생	1.78	2.03	2.16	+0.39

표 6-6. 같은 학생의 같은 답이 A·B·C에 놓였을 때 받은 평균 순위(1~3, 작을수록 좋음, 위치마다 500번). A→C = C에 놓였을 때 − A에 놓였을 때.

표 6-6 읽는 법과 해석. 한 행을 왼쪽에서 오른쪽으로 읽으면 **답은 그대로 두고 위치만 바꿨을 때**의 순위 변화다. 모든 행에서 A → C로 갈수록 순위가 나빠진다. 예: GPT 평가자가 본 GPT 학생은 A에서 1.48위, C에서 2.00위로, 같은 답이 위치만으로 약 0.5등 차이가 난다. 이 위치 효과는 학생 간 품질 차이와 비슷하거나 크다. 각 학생이 세 위치에 똑같이 놓였기 때문에 6.4의 결과에는 이 효과가 섞이지 않는다.

결과	GPT 평가자	Claude 평가자	Gemini 평가자
최종 순위	49.6% · 2.24배 · 49%	45.6% · 1.83배 · 58%	42.3% · 1.69배 · 67%
사실 정확성	46.9% · 2.14배 · 51%	42.3% · 1.58배 · 60%	41.3% · 1.69배 · 71%
질문 충족도	51.2% · 2.15배 · 44%	46.2% · 1.80배 · 56%	42.9% · 1.72배 · 66%
논리성	32.3% · 1.31배 · 49%	41.0% · 1.43배 · 56%	41.7% · 1.76배 · 66%
가독성	35.5% · 1.17배 · 53%	47.3% · 1.89배 · 51%	43.1% · 1.62배 · 63%

표 6-7. 결과(최종 순위·네 기준)별, 평가자별: 1위가 A에 놓여 있던 비율 · 모형의 A 위치 오즈비(C 대비) · 순서 3가지에서 1위가 모두 같았던 묶음 비율.

순서 3가지에서 1위뿐 아니라 **1~3위 전체**가 같았던 묶음은 더 적다: GPT 평가자 24%, Claude 34%, Gemini 38%(최종 순위). 위치가 바뀌면 순위 전체가 흔들리는 일이 흔했다.

표 6-7 읽는 법과 해석. 한 칸에 세 숫자가 있다. 첫째(33.3%보다 클수록 첫 번째 답 선호), 둘째(1보다 클수록 A 위치 가산점이 큼), 셋째(100%에 가까울수록 순서를 바꿔도 판정이 안정적). 거의 모든 기준에서 A 선호가 나타났고, 순서 3가지에서 1위가 같았던 묶음은 약 절반~3분의 2뿐이다. 학생 답이 모두 품질이 낮고 비슷해 위치가 판정을 쉽게 바꾸는 조건이다. **순서를 하나로만 정해 평가했다면 위치 효과가 선호 누출보다 결과를 더 크게 좌우했을 것이다.**

예외. GPT 평가자는 논리성·가독성에서 A 선호가 약하고(1위가 A인 비율 32.3%, 35.5%) B에 놓인 답을 1위로 가장 자주 골랐다. 위치 편향의 방향과 크기는 평가자와 판단 종류에 따라 다르며, 각 학생을 모든 위치에 같은 횟수로 놓는 설계는 이런 경우에도 결과를 보호한다.

7 결과 해석

↑ 목차

연구 질문: "한국어 합성데이터에서도 LLM 평가자는 자기 모델이 만든 데이터로 학습한 모델의 답을 더 선호하는가?"

답: 그렇다. 다만 모든 평가자가 아니라 평가자 모델에 따라 다르다. Gemini 평가자는 학생 품질과 위치를 통제한 뒤에도 자기 계열 학생을 분명히 더 높게 평가했고, GPT 평가자는 같은 방향의 약한 효과, Claude 평가자는 효과가 없었다.

7.1 단순 계산에서 통계 모형으로: 무엇이 달라졌고 왜 달라졌나

1단계: 단순 계산
같은 학생에 대해 [자기 계열 평가자의 값] – [다른 두 평가자 평균]. 원자료를 그대로 보여 준다.

2단계: 한계
다른 평가자도 자기 계열을 우대해 기준선이 오염된다. 품질·위치 통제가 없고, 우연인지 판단할 불확실성(p값, 신뢰구간)이 없다.

3단계: 통계 모형
쌍마다 중립 심판을 이용해 세 평가자의 효과를 동시에 추정. 학생 품질·위치 통제, 부트스트랩 신뢰구간, Holm 보정.

4단계: 결과
Gemini는 그대로 크고 유의. GPT는 줄어 약한 증거. Claude는 사라짐.

평가자	단순 계산 (쌍대 승률) 자기 평가자 – 다른 평가자 평균	② 순위 로짓 모형(PL) 승률 차 [95% CI]	모형 – 단순	왜 달라졌나
GPT 평가자	62.7% – 58.4% = **+4.3**	**+2.8** [+0.2, +5.3]	−1.4	단순 계산의 기준선(Claude·Gemini 평가자 평균)이 Gemini 평가자의 자기 우대 때문에 낮아져 있었다. 이를 빼면 효과가 작아진다
Claude 평가자	47.1% – 45.2% = **+1.8**	**−2.0** [−4.4, +0.6]	−3.8	Gemini 평가자가 Gemini 학생을 올리며 Claude 학생을 끌어내린 몫이 단순 계산에 섞여 있었다. 이를 빼면 남는 효과가 없다
Gemini 평가자	50.5% – 41.2% = **+9.3**	**+9.8**** [+7.1, +12.5]	+0.4	자기 우대가 커서 다른 평가자 기준선의 왜곡보다 훨씬 크다. 두 방법 모두 같은 결론

주 지표(쌍대 승률) 기준, %p. 별표·음영 = Holm $p < 0.05$. 1위 비율로 보아도 같은 방향이다(단순 GPT +5.3 → 모형 +3.5, Claude +3.0 → +0.6, Gemini +7.9 → +8.6).

읽는 법. 단순 계산은 "다른 평가자 평균"을 기준선으로 쓰는데, Gemini 평가자는 자기 계열 학생을 크게 올려 주므로 Gemini 평가자 아래에서 GPT·Claude 학생은 낮게 평가된다. 그 낮아진 값이 GPT·Claude 학생의 기준선에 들어가 GPT·Claude 평가자의 누출이 부풀려진다. 모형은 이 몫을 Gemini의 λ로 따로 떼어 내므로, 남는 GPT·Claude의 효과가 작아진다.

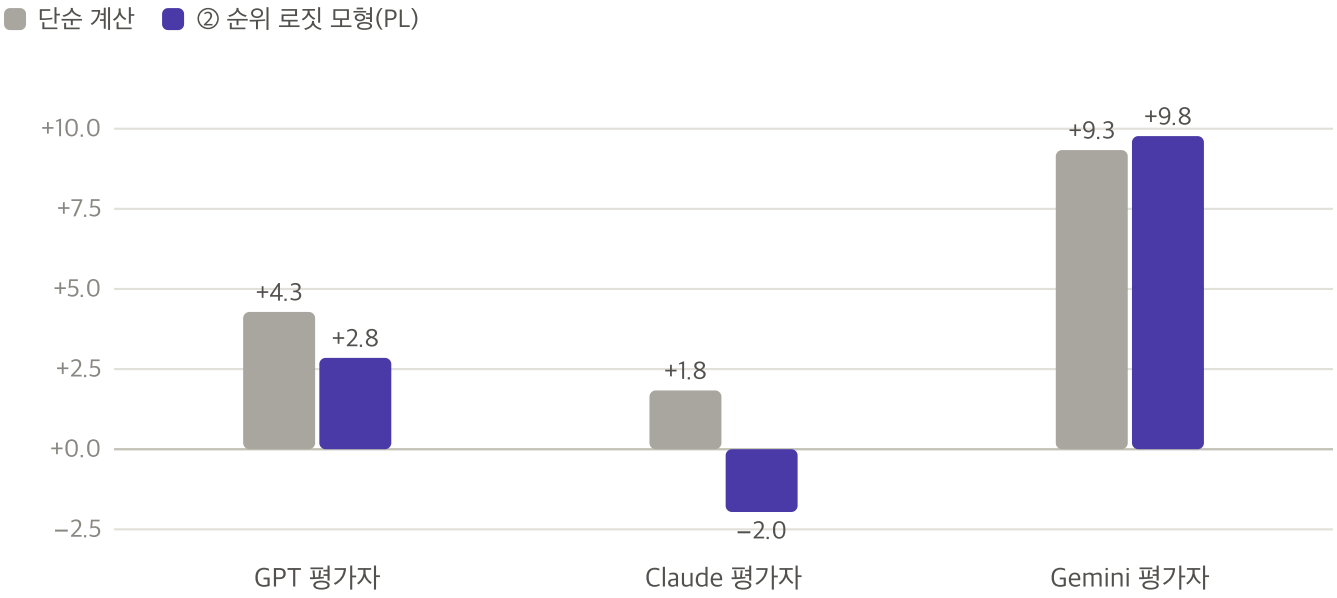


그림 7-1. 같은 주 지표(쌍대 승률)로 잰 자기 계열 효과(%p): 단순 계산 vs 통계 모형. 단순 계산에서는 Gemini 평가자의 강한 자기 우대가 다른 평가자의 기준선을 낮춰 GPT·Claude의 값이 부풀려진다. 모형으로 세 평가자를 동시에 추정하면 GPT는 줄고 Claude는 0 아래로 내려간다.

7.2 가설 검정: 무엇을 검정했고 왜 "유의하다/유의하지 않다"고 판단했나

(1) 가설. 평가자 j(GPT, Claude, Gemini) 각각에 대해 주 모형(② 순위 로짓 PL)의 자기 계열 효과 λ_j를 검정한다.

```
귀무가설 H0: λ_j = 0
  "평가자 j는 품질과 위치가 같다면 자기 계열 학생과 다른 학생을
   같은 확률(50%)로 이긴다고 판정한다" → 선호 누출 없음

대립가설 H1: λ_j ≠ 0  (양측 검정)
  "같은 조건에서 자기 계열 학생을 이긴다고 판정할 확률이 50%와 다르다"

유의수준 α = 0.05
```

양측 검정을 쓴 이유: 평가자가 자기 계열을 오히려 **낮게** 볼 가능성(음수)도 열어 두기 위해서다. Claude의 추정치가 실제로 음수였다.

(2) 판정 규칙. 신뢰구간과 p값은 질문 단위 부트스트랩 1,000회로 구했고, 평가자 3명을 함께 검정했으므로 Holm 보정 p로 판단한다. 두 도구의 개념, 사용 이유, 적용 절차와 Holm 계산 표는 6.2 (6)에 있다.

```
판정 기준
  95% 신뢰구간이 0을 포함하지 않고 Holm p < 0.05  →  H0 기각 (선호 누출 있음)
  신뢰구간이 0을 포함하거나 Holm p ≥ 0.05          →  H0 기각 못함
```

p값은 "선호 누출이 없는데도(H0) 이만큼 큰 효과가 우연히 나올 확률"에 해당한다. 신뢰구간은 "같은 방식으로 실험을 반복할 때 효과의 참값이 있을 범위"로 읽는다.

(3) 평가자별 판정과 그 이유

평가자	판정 (유의수준 5%, Holm 보정)	이유
GPT 평가자	**기각 못함** (보정 전에는 기각, 약한 증거)	추정치 +2.8%p, 95% 신뢰구간 [+0.2, +5.3]%p. 이 검정 하나만 보면 p 0.038 < 0.05라 기각되지만, 평가자 3명을 함께 검정했으므로 Holm 보정을 하면 p 0.076 > 0.05가 되어 기각하지 못한다. 신뢰구간 하한(+0.2%p)도 0에 매우 가깝다. 같은 자료를 다른 방식으로 본 쌍 고정효과 모형에서도 +2.8%p, p 0.110로 유의하지 않다. 다만 보조 지표인 1위 모형에서는 +3.5%p, Holm p 0.036로 유의하다. seed별 추정치 5개의 t검정은 Holm p 0.032로 유의해 방향은 반복되지만, 다섯 개 중 하나(seed 45)는 0 근처다. 평가자별 길이 항을 넣으면 +5.4%p로 유의해지지만(6.4.1), 그 모형에서만 유의해 설정에 민감하다. 방향은 일관되게 양수지만 크기가 작아, 주 모형의 전체 자료 검정에서 5% 기준을 안정적으로 넘지 못한다 → **약한 증거**로 해석한다.
Claude 평가자	**기각 못함**	추정치 −2.0%p, 95% 신뢰구간 [−4.4, +0.6]%p이 0을 포함한다(보정 전 p 0.130, Holm p 0.130). 즉 자료가 "자기 계열 효과 0"과 모순되지 않는다. 이것이 효과가 0임을 증명하는 것은 아니다. 신뢰구간의 상한이 +0.6%p이므로, 효과가 있더라도 이보다 작은 수준이라는 뜻이다. 보조 지표(+0.6%p, Holm p 0.700)와 쌍 고정효과 모형(−1.5%p, p 0.225)도 같다.
Gemini 평가자	**귀무가설 기각**	추정치 +9.8%p, 95% 신뢰구간 [+7.1, +12.5]%p 전체가 0보다 크다. 부트스트랩 1,000번 재추정에서 0 이하로 내려간 경우가 한 번도 없었고(보정 전 p ≤ 0.001), 평가자 3명을 함께 검정한 것을 감안해도(Holm p ≤ 0.003) 우연으로 보기 어렵다. 보조 지표(1위 모형 +8.6%p, Holm p ≤ 0.003)와 쌍 고정효과 모형(+10.7%p, Holm p <0.001)에서도 같은 결론이다.

(4) seed 반복 검정. seed마다 따로 추정한 효과 5개로 두 가지를 검정했다(한쪽 검정, "누출이 양수인가"를 묻기 때문).

- **부호 검정:** H0 "각 seed의 효과가 양수일 확률 = 1/2". 5개 모두 양수면 $p = 0.5^5 = 0.031$. 다만 seed가 5개뿐이라 이 값이 가능한 최소 p이고, 평가자 3명에 Holm 보정을 하면 0.094가 되어 5%를 넘을 수 없다. 그래서 t검정을 함께 본다.
- **일표본 t검정:** H0 "5개 seed 효과의 평균 ≤ 0", H1 "평균 > 0". 크기의 일관성까지 반영한다. Gemini: Holm p = 0.002로 기각, GPT: 0.032, Claude: 0.971.

(5) "유의하지 않음"을 읽는 법. 유의하지 않다는 것은 "효과가 없다"가 아니라 "**이 자료로는 효과가 0이라는 가설을 버릴 만큼 증거가 충분하지 않다**"는 뜻이다. 그래서 신뢰구간을 함께 보고, 효과가 있다면 최대 어느 정도인지(신뢰구간 상한)를 함께 말한다. 반대로 "유의하다"는 효과가 크다는 뜻이 아니므로, 효과 크기(%p)를 함께 보고한다.

7.3 종합: 연구 질문에 대한 답과 근거

왜 이렇게 결론 내릴 수 있는가

1. **전제가 성립한다:** 세 교사의 답은 서식을 지워도 96.5%로 구별되고(4절), 학생 15명 모두 자기 교사의 스타일을 흡수했다(5절). 평가자가 자기 계열을 알아볼 단서가 있다.
2. **품질이 아니라 평가자 차이다:** 같은 학생의 같은 답을 평가자끼리 비교했고, 학생 품질(15명)과 평가자별 위치 효과를 모형에 넣어 통제했다. 각 쌍에 중립인 제3의 평가자를 기준으로 삼아 세 평가자의 효과를 분리했고, 이를 위한 가정은 자료와 맞았다(p = 0.98).
3. **Gemini의 효과는 크고 강건하다:** 1위 확률 +8.6%p(33.3% → 41.9%), 승률 +9.8%p(50% → 59.8%), 같은 두 답을 직접 비교한 가장 엄격한 모형에서 +10.7%p. 세 모형 모두 Holm p ≤ 0.003.
4. **우연이 아니다:** Gemini의 효과는 학생을 다섯 번 따로 학습한 모든 경우에서 양수였다(5/5, t검정 Holm p = 0.002).
5. **최종 순위만의 현상이 아니다:** Gemini는 사실 정확성·질문 충족도·가독성에서 세 모형 모두 유의했고, 누출이 가장 큰 기준은 **사실 정확성**이었다. 문체 취향을 넘어 자기 계열의 서술로 쓰인 내용을 더 정확하다고 판단했다.
6. **길이로 설명되지 않는다:** 순위 로짓 모형에 평가자별 길이 항을 추가해 다시 적합해도 Gemini의 승률 차는 +8.8%p로 유지되었다(6.4.1). 세 평가자 모두 오히려 짧은 답을 약간 선호했다.

가설별 판정

가설	판정	근거
H1 자기 계열 선호	**부분 지지**	Gemini 강함, GPT 약함, Claude 없음
H2 기준별 차이	**Gemini에서만 지지 (예상과 다른 방향)**	Gemini: 사실 정확성 최대, 논리성 최소. GPT·Claude는 어느 기준에서도 유의하지 않아 기준 간 비교 불가
H3 seed 반복	**Gemini에서 지지**	5/5 seed 양수, t검정 유의

모델 성능과 누출: 성능이 높은 평가자일수록 편향이 적은가

"Claude가 가장 성능이 높아서 편향이 없는 것 아닌가?"라는 질문에 답하기 위해, 실험에 쓴 세 모델의 공개 성능 지표를 확인했다. 기준은 **Artificial Analysis Intelligence Index**다. 새 LLM이 나올 때마다 같은 조건으로 10개 평가(지식, 추론, 과학, 코딩, 업무 과제 등)를 돌려 하나의 점수로 공개하는 독립 지표이며, 같은 모델도 추론 강도 설정마다 따로 점수를 매긴다. 본 연구는 교사 생성과 평가 모두 추론 강도 **medium**을 썼으므로 medium 설정 점수로 비교한다.

평가자	실험에 쓴 모델 (API 이름)	실험 설정	AA 지수 medium 설정	AA 지수 최고 설정	자기 계열 효과 ② PL 승률 차 [95% CI]	판정 (7.2)
GPT	gpt-5.6-terra (2026년 7월 출시)	reasoning effort medium	30	42 (max)	+2.8 [+0.2, +5.3]	약한 증거
Claude	claude-sonnet-5-5 (2026년 9월)	adaptive thinking, effort medium	**41**	**56** (max)	−2.0 [−4.4, +0.6]	없음
Gemini	gemini-3.8-flash (2026년 9월)	thinking level medium	40	41 (high)	**+9.8** [+7.1, +12.5]	**뚜렷함**

표 7-2. 실험에 쓴 세 모델의 성능 지표(Artificial Analysis Intelligence Index v4.3.2, artificialanalysis.ai, 2026년 10월 15일 확인)와 본 연구의 자기 계열 효과. 최고 설정은 각 모델에서 점수가 가장 높은 추론 설정이다.

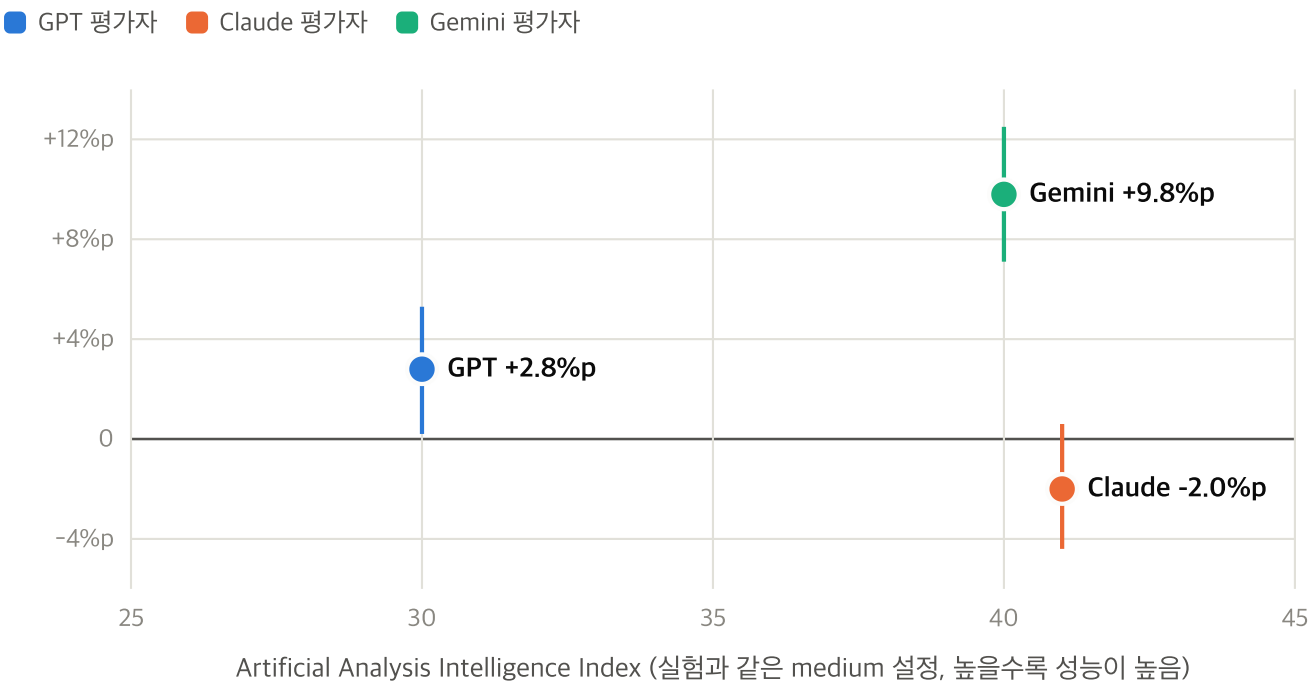


그림 7-2. 평가자 성능(가로)과 자기 계열 효과(세로). 세로선 = 95% 신뢰구간. 성능이 거의 같은 Claude(41)와 Gemini(40)의 누출이 가장 크게 다르다.

점검 결과.

- **Claude는 실제로 성능이 가장 높다.** 최고 설정 기준 56으로 세 모델 중 가장 높고, 실험 설정(medium)에서도 41로 가장 높다. 그리고 누출이 없었다. 이것만 보면 "성능이 높으면 편향이 적다"는 해석이 가능해 보인다.
- **그러나 Gemini가 반례다.** 실험 설정에서 Gemini(40)는 Claude(41)와 성능이 거의 같은데 누출은 가장 컸다(+9.8%p vs −2.0%p). 반대로 GPT는 성능이 가장 낮은데(30) 누출은 Gemini보다 훨씬 작았다. 성능 순서(Claude ≈ Gemini > GPT)와 누출 순서(Gemini > GPT > Claude)가 맞지 않는다.
- **따라서 "성능에 따라 편향이 정해진다"는 결론은 낼 수 없다.** 이 자료가 지지하는 것은 "누출은 평가자 **계열**에 따라 다르며, 범용 성능만으로는 설명되지 않는다"는 데까지다.

> **이 비교의 한계.** (1) 평가자가 3개뿐이라 성능과 누출의 상관을 통계적으로 검정할 수 없다. 회사가 다르면 학습 데이터·정렬 방식도 달라 성능과 계열이 섞여 있다. (2) 이 지표는 영어 중심의 지식·추론·코딩·업무 과제 점수로, **한국어 능력이나 평가자로서의 능력**을 직접 재지 않는다. 한국어별 순위가 있는 공개 리더보드(LMArena)는 이번에 접근할 수 없어 확인하지 못했다. (3) 공개 지표는 계속 갱신되므로 확인한 날짜와 판을 함께 적었다. 성능의 영향을 제대로 보려면 **계열을 고정하고 크기만 바꾸는** 비교가 필요하며, 이것이 8.4의 평가자 크기 실험이다.

방법론적 함의

- **단순 계산은 편향을 퍼뜨린다:** 다른 평가자를 기준선으로 쓰는 단순 계산으로는 세 평가자 모두 누출이 있어 보였다(승률 기준 GPT +4.3, Claude +1.8%p). 효과를 동시에 추정하면 Claude는 사라지고 GPT는 작아진다(7.1, 그림 7-1).
- **위치 편향이 누출보다 크다:** 첫 번째 답이 1위로 뽑힐 오즈가 마지막보다 1.7~2.2배(Gemini 누출 오즈비 1.49배). 순서 균형 설계 없이는 누출을 잴 수 없다.

한계

- 사람 평가가 없어 어느 평가자의 순위가 "옳은지"는 말할 수 없다. 누출은 평가자 간 체계적 차이로 정의했다.
- 0.6B 학생의 답은 대부분 품질이 낮다. 높은 품질의 답 사이에서도 같은 크기인지는 알 수 없다.
- 특정 모델 버전, 한국어 일반 질문 100개의 결과다. 중립 평가자(HyperCLOVA X)는 실행하지 않았다. 이를 보완할 실험은 8절에 정리했다.

한계	구체적으로	결과에 주는 영향
사람 평가 없음	평가자 순위가 사람의 판단과 맞는지 확인하지 않았다	누출(평가자 간 체계적 차이)은 정답 없이도 정의되지만, 어느 평가자가 "옳은지"는 말할 수 없다
PL 추정의 보수성	가짜 자료에서 PL은 참값의 67~85%를 되찾았다	실제 누출은 보고값보다 **클 수 있다**
반복 억제의 영향	반복 억제 1.1이 문체 지문을 흐렸다(Gemini 학생 번호 목록 58% → 38%)	누출 추정이 **보수적**일 수 있다
질문 선정의 치우침	15명 모두 끝까지 쓴 질문만 써서 짧게 답할 수 있는 질문 쪽으로 치우쳤다	긴 답이 필요한 질문에서도 같은지는 알 수 없다
식별 가정	중립 평가자 없이 세 효과를 분리하려면 가정이 필요하다. 자료에서 기각되지 않았지만($p = 0.98$) 검정은 자유도 1	HyperCLOVA 같은 외부 평가자로 가정 없이 확인할 수 있다(8.2)
기준별 식별 가정	논리성($p = 0.029$)·가독성($p = 0.044$)에서 경계 수준으로 기각	두 기준의 추정치는 조심해서 읽는다
seed의 범위	seed는 학습 무작위성만 바꾼다. 부호 검정의 최소 p는 0.031(Holm 후 0.094)	"다른 데이터에서도 같은가"가 아니라 "다시 학습해도 같은가"만 보여 준다
평가자 설정	추론 강도·출력 한도는 맞췄지만 제공사마다 추론 구현이 다르다	완전히 같은 조건의 평가자 비교는 아니다

표 7-1. 한계를 자세히 정리한 것과 각 한계가 결과에 주는 영향.

결론. 한국어 합성데이터로 학습한 모델의 평가에서도 LLM 평가자의 선호 누출은 존재할 수 있으며, 평가자에 따라 승부를 50:50에서 약 60:40으로 기울일 만큼 크다. LLM-as-a-Judge로 학생 모델을 비교할 때는 생성 모델과 다른 계열의 평가자를 쓰거나, 여러 계열의 평가자와 순서 균형 설계를 함께 쓰고 평가자 효과를 모형으로 분리해 보고해야 한다.

8 향후 연구 계획: 선호 누출을 어떻게 억제할 것인가

↑ 목차

본 연구는 Gemini 평가자의 선호 누출을 **측정**했다. 다음 단계는 누출을 **줄이는 방법**을 실험으로 검증하는 것이다. 아래 실험은 모두 지금 갖춘 코드(학습·생성·평가·분석)와 자료를 그대로 이어서 할 수 있는 것만 골랐다. 측정 도구는 지금과 같다: 같은 listwise 설계(순서 3가지)와 순위 로짓 모형으로 개입 전후의 λ를 비교한다.

지금까지
Gemini 평가자가 자기 계열 학생을 +9.8%p 우대함을 확인 (분석)

8.1 데이터 쪽
학습 데이터의 비율과 문체를 바꾸면 누출이 줄어드는가

8.2 평가자 검증
다른 계열·외부 평가자는 정말 공정한가

8.3 평가 쪽
평가 입력·프롬프트·평가자 구성을 바꾸면 줄어드는가

8.4 크기
평가자나 학생이 커지면 저절로 사라지는가

8.1 데이터 쪽 억제: 학습 데이터의 비율과 문체를 바꾸면 누출이 줄어드는가

(1) 데이터 비율 조절. 학생 학습 데이터 1,000개에서 Gemini 답의 비율 p를 바꿔 학생을 새로 학습한다. 질문 1,000개는 지금과 같고, 질문마다 세 교사의 답 중 **하나만** 골라 쓰도록 배정한다(같은 질문이 두 번 들어가지 않게). 나머지는 GPT와 Claude 답으로 반씩 채운다.

학생 (seed 42·43·44)	GPT 답	Claude 답	Gemini 답	Gemini 비율 p
Gemini 0%	500	500	0	0
Gemini 25%	375	375	250	0.25
균등 혼합	333	333	334	1/3
Gemini 50%	250	250	500	0.5
Gemini 75%	125	125	750	0.75
Gemini 100% (현재 연구의 Gemini 학생 재사용)	0	0	1,000	1

표 8-1. 비율별 학생 구성(학습 예제 수). 새 비율 4개(0·25·50·75%) × seed 3개(42·43·44) = 학생 12명. 균등 혼합(1/3)은 여유가 있으면 추가한다. 학습은 표 5-A와 같은 설정, 학생당 약 4분(A100).

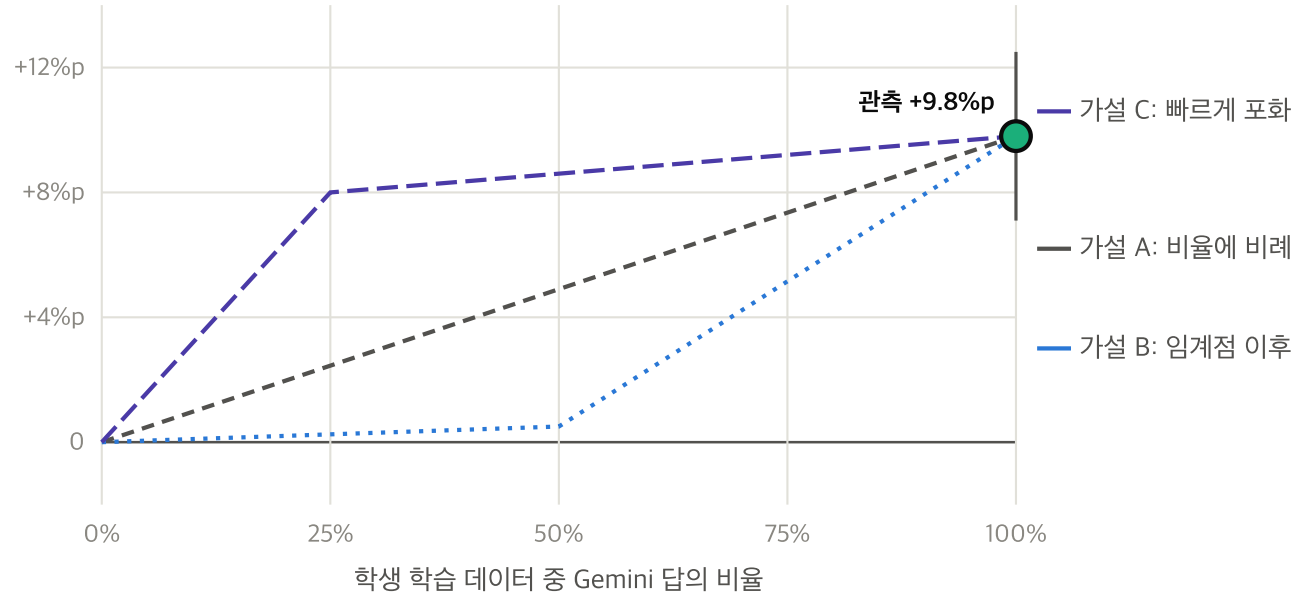


그림 8-1. **실험 전 가설 그림**. 점(Gemini 100%)만 현재 연구의 실제 관측값이고, 점선은 결과가 나올 수 있는 세 가지 모양이다.

- **평가 묶음:** 같은 seed의 (GPT 순수 학생, Claude 순수 학생, **Gemini p% 학생**) 세 명을 지금처럼 순서 3가지로 평가한다. GPT·Claude 순수 학생과 Gemini 100% 학생은 현재 연구의 학생을 재사용한다. 비율 하나당 질문 100 × seed 3 × 순서 3 = 900항목 × 평가자 3 = 2,700호출, 새 비율 4개면 약 10,800호출.
- **모형:** 지금의 "같은 계열이면 1" 지표를 "학생이 배운 데이터 중 평가자 계열 데이터의 비율 $x_{t,j}$"로 바꾼다: $u = \theta + \delta + \lambda_j \cdot x_{t,j}$. 순수 학생은 x가 0 또는 1이라 지금 모형과 같고, 혼합 학생으로 비율에 따른 변화를 본다. 비율마다 따로 λ를 둔 모형과 우도비 검정으로 비교해 그림 8-1의 어느 모양인지 판정한다.
- **조작 점검:** 혼합 학생의 답에 4절의 분류기(KLUE-RoBERTa)를 적용해 "Gemini답다"는 확률이 p에 따라 오르는지, 교차 loss(5.4)가 p에 따라 변하는지 먼저 확인한다. 문체가 실제로 비율만큼 옮겨졌는지 보는 단계다.
- **의미:** 가설 A면 "여러 모델 데이터를 섞으면 그 비율만큼 누출이 준다", 가설 C면 "조금만 섞여도 누출이 생기므로 섞기만으로는 막을 수 없다"는 실무 결론이 나온다. 영어 환경에서는 합성데이터 비율과 누출 사이의 양의 관계가 보고되었다(Li et al., 2026).

(2) 학습 데이터 문체 중화. Gemini 답의 **내용은 두고 문체만 지운 데이터**로 학생을 학습해, 누출이 어떤 단서에서 오는지 가른다.

학습 데이터	만드는 방법	남는 것 / 지워지는 것	결과 해석
① Gemini 원문 (현재)	그대로	내용 + 서식 + 어휘·문체 모두 남음	기준선 λ = +9.8%p
② 서식 제거	4.6의 정규화 규칙으로 굵게·목록·따옴표·줄바꿈 제거	**서식**만 지워짐	λ가 크게 줄면 → 누출의 주된 단서는 **서식**
③ 문체 재작성	제3의 모델(평가에 쓰지 않는 모델)로 "내용은 그대로, 문장은 새로" 다시 쓰게 함	**서식 + 어휘·문체**가 지워지고 내용만 남음	②에서는 남고 ③에서 줄면 → 단서는 **어휘·문체**. ③에서도 남으면 → Gemini가 고른 **내용·지식** 자체를 Gemini 평가자가 맞다고 봄

표 8-2. 학습 데이터 문체 중화 실험(Gemini 학생만 새로 학습, 조건당 seed 3). 재작성은 의미가 바뀌지 않았는지 무작위 50개를 사람이 확인한다. 이 실험은 "왜 Gemini 평가자가 Gemini 학생을 고르는가"의 메커니즘에 답한다.

8.2 다른 계열 평가자는 정말 공정한가: 외부 평가자로 검증

"생성 모델과 다른 계열의 평가자를 쓰라"는 권고가 성립하려면, 다른 계열 평가자가 **실제로 어느 학생도 우대하지 않는지** 확인해야 한다. 세 교사와 무관한 평가자로 같은 1,500개 항목을 평가한다.

외부 평가자 후보	선정 이유	주의할 점
HyperCLOVA X (네이버)	한국어 특화, 세 교사와 무관. 코드·설정 준비 완료 (run_judge.py --judge hyperclova)	호출 한도로 1,500건에 8~10시간
공개 모델 1~2개 (예: LG EXAONE, Meta Llama 계열)	세 교사 회사와 무관하고, 직접 실행할 수 있어 버전을 고정하기 쉽다	**Qwen 계열은 제외**: 학생의 시작 모델(Qwen3-0.6B-Base)과 같은 계열이라 다른 종류의 누출이 생길 수 있다

표 8-3. 외부 평가자 후보. 같은 평가 프롬프트(표 6-H), 같은 추론 강도·출력 한도를 쓴다.

분석	방법	확인하는 것
① 외부 평가자의 계열 선호 검정	순위 로짓 모형에 외부 평가자 k × 학생 계열 t의 효과 $\gamma_{k,t}$를 넣고, $\gamma_{k,GPT} = \gamma_{k,Claude} = \gamma_{k,Gemini}$(어느 학생도 특별히 우대하지 않음)을 우도비 검정	"다른 계열 평가자는 정말 공정한가". 외부 평가자도 특정 형식(예: 목록형)을 좋아할 수 있으므로, 그런 경향이 있으면 누출과 구별해 **스타일 선호**로 따로 보고
② 주 결과 재확인	외부 평가자를 품질 기준선으로 써서 Gemini 평가자의 λ를 다시 추정	현재 결과(+9.8%p)가 "쌍마다 중립 심판" 가정 없이도 재현되는가
③ 학생 순위 비교	평가자 구성별로 학생 15명의 순위를 계산: 자기 계열 평가자 단독 / 다른 계열 평가자만 / 외부 평가자 / 전체 앙상블	평가자를 바꾸면 어느 학생이 이기는지가 뒤집히는가(Kendall τ, 1위 일치율)

표 8-4. 외부 평가자 자료로 할 분석. ①에서 외부 평가자도 특정 학생을 우대하면 "다른 계열 평가자만 쓰면 된다"는 권고를 고쳐야 한다.

8.3 평가 쪽 억제: 평가 입력과 프롬프트를 바꾸면 누출이 줄어드는가

학생은 그대로 두고 **평가 방식만** 바꿔, 지금과 같은 1,500개 항목을 세 평가자에게 다시 평가받는다. 학습이 필요 없어 가장 빠르게 할 수 있다. 조건마다 Gemini 평가자의 λ를 기준선(+9.8%p)과 비교한다.

개입	평가 단계에서 바꾸는 것	가설	새 호출 수
a. 답 서식 제거	평가 전에 세 학생 답에 4.6의 정규화를 적용(굵게·목록·따옴표·줄바꿈 제거)	누출 단서가 서식이면 λ가 줄어든다. 분류 실험에서 서식을 지워도 92~97%로 구별되었으므로 완전히 사라지지는 않을 것	4,500
b. 답 문체 재작성	제3의 모델로 세 답을 "내용은 그대로, 같은 형식으로" 다시 쓴 뒤 평가	문체 단서까지 지우면 λ가 더 줄어든다. 영어 연구에서는 효과가 작았다는 보고가 있어(Li et al., 2026) 한국어에서 확인할 가치가 있다	4,500 (+ 재작성 1,500)
c. 참조 답 제공	평가 프롬프트에 KoAlpaca 참조 답을 함께 주고 "참조 답과 비교해 사실관계를 판단하라"고 지시	판단의 기준이 문체 대신 정답과의 일치로 옮겨가 λ가 줄어든다. 특히 누출이 가장 컸던 **사실 정확성**에서 효과가 클 것	4,500
d. 판정 절차 지시	"먼저 각 답의 사실 주장을 나열하고 하나씩 맞는지 확인한 뒤 순위를 정하라"는 단계적 확인 지시 추가	형식적 완성도에 기대는 판정(6.1.3의 Gemini 근거 패턴)이 줄어든다	4,500
e. 평가자 구성 바꾸기	자기 계열 판정 빼기(leave-own-out), 다른 계열·외부 평가자만 쓰기, 여러 계열 앙상블	자기 계열 판정을 빼면 Gemini 학생의 순위 상승이 사라진다	0 (기존 자료 + 8.2)
f. 모형 보정	현재 설계로 평가한 뒤 추정한 λ를 빼고 보정 순위를 보고	보정 순위가 외부 평가자 순위(8.2)와 일치한다	0

표 8-5. 평가 단계 개입. a~d는 세 평가자 모두에게 똑같이 적용해야 "쌍마다 중립 심판" 구조가 유지된다.

판정 기준	내용
누출이 줄었나	Gemini 평가자의 λ가 기준선(+9.8%p) 대비 절반 이하로 줄거나 95% 신뢰구간이 0을 포함
품질 판단은 유지되나	6.1.2 같은 "한 답만 핵심을 맞힌" 묶음에서 만장일치가 유지되고, 평가자 간 1위 일치율(66~69%)과 외부 평가자와의 순위 일치가 떨어지지 않음
위치 편향은 어떻게 되나	A 위치 오즈비가 함께 줄어드는지도 보고(개입이 위치 편향을 키우면 실무에 쓰기 어렵다)

표 8-6. 개입이 성공했는지 판정하는 기준. 누출만 줄고 품질 판단이 무너지면 실무에 쓸 수 없으므로 세 가지를 함께 본다.

8.4 평가자나 학생이 커지면 누출이 저절로 사라지는가

가장 자주 나올 반론은 "**더 큰 모델을 평가자로 쓰면 편향이 없지 않나?**"이다. 방향은 미리 알 수 없어서(아래 두 가설이 반대를 예측) 실험으로 확인한다.

축	설계	새로 필요한 것	확인하는 것
A. 평가자 크기	같은 회사의 크기가 다른 평가자 2~3개(예: Gemini의 경량·표준·최상위 모델, GPT·Claude도 같은 방식)로 **같은 1,500개 항목**을 평가	추가 평가자당 1,500 호출. 학생과 항목은 그대로	평가자 크기에 따라 λ가 줄어드는가, 그대로인가, 커지는가
B. 학생 크기	같은 교사 데이터로 Qwen3-1.7B(가능하면 4B) 학생을 seed 3개씩 학습해, 답 품질이 높아졌을 때 같은 평가를 반복	학생 9명(교사 3 × seed 3), 응답 생성, 4,500 호출 내외. 4B는 A100 40GB에서 같은 설정으로 학습 가능한지 먼저 확인	답 품질이 오르면 누출이 줄어드는가 (6.1.1·6.1.2에서 본 "내용 차이가 분명하면 누출이 드러나지 않는다"는 관찰의 검증)

표 8-7. 크기 실험. A는 학생을 새로 만들 필요가 없어 바로 할 수 있다.

경쟁하는 가설	예측	근거
H-큰 평가자는 내용을 더 잘 본다	평가자가 클수록 λ ↓	더 정확한 사실 판단이 문체 단서를 덮는다
H-큰 평가자는 자기 문체를 더 잘 알아본다	평가자가 클수록 λ ↑ 또는 유지	LLM이 자기 출력을 알아보는 능력이 클수록 자기 선호도 크다는 상관이 보고되었다 (Panickssery et al., 2024)

표 8-8. 평가자 크기에 대한 경쟁 가설. 어느 쪽이 나와도 결과는 의미가 있다. λ가 줄면 "큰 평가자가 해법"이라는 실무 권고가, 유지되거나 커지면 "크기로는 해결되지 않는다"는 더 강한 결론이 나온다.

8.5 실행 순서와 규모

순서	실험	새로 필요한 것	답하는 질문
1	8.3 a·c·d 평가 단계 개입	기존 학생 답 그대로, 조건당 4,500 호출	평가 프롬프트·입력만 바꿔서 누출을 줄일 수 있는가 (가장 싸고 빠름)
2	8.2 외부 평가자	외부 평가자당 1,500 호출	다른 계열 평가자는 정말 공정한가, 주 결과가 가정 없이 재현되는가
3	8.4 A 평가자 크기	추가 평가자당 1,500 호출	더 큰 평가자를 쓰면 해결되는가
4	8.1 데이터 비율 조절	학생 12명 학습, 약 10,800 호출	데이터를 섞으면 누출이 비율만큼 줄어드는가
5	8.1 학습 데이터 문체 중화, 8.3 b, 8.4 B	재작성 데이터, 학생 추가 학습	누출의 단서는 서식인가, 문체인가, 내용인가 / 학생 품질이 높아지면 사라지는가

표 8-9. 비용이 적고 기존 자료를 그대로 쓰는 실험부터 진행한다. 호출 수는 평가자 3명 기준이다.

실무 권고 (현재 결과 기준). LLM-as-a-Judge로 학생 모델을 비교할 때는 ① 데이터 생성 모델과 다른 계열의 평가자를 쓰고, ② 여러 계열의 평가자와 순서 균형 설계를 함께 쓰며, ③ 평가자별 효과를 분리해 보고한다. 8.2~8.4의 실험은 이 권고가 실제로 순위를 바로잡는지, 그리고 더 간단한 방법(데이터 섞기, 참조 답 제공, 더 큰 평가자)으로 대신할 수 있는지 검증하는 단계다.

9 초록

↑ 목차

LLM이 생성한 합성데이터로 학습한 모델을 다시 LLM이 채점하는 LLM-as-a-Judge 평가에서는 채점 LLM이 자기 데이터로 학습한 모델을 우대하는 선호 누출(preference leakage)이 보고되었으나, 관련 연구는 주로 영어로 이루어져 한국어 데이터에서의 양상은 충분히 다뤄지지 않았다. 본 연구는 GPT, Claude, Gemini의 한국어 답변으로 각각 학습한 학생 모델 15개를 같은 세 모델이 평가하도록 하였다. 평가자는 한 질문에 대한 세 학생의 답변을 FLASK 기반 네 기준(사실 정확성, 질문 충족도, 논리성, 가독성)과 이를 종합한 최종 순위에서 각각 1~3위로 매겼다(listwise 평가 4,500회). 이를 세 평가자가 공통으로 인정한 학생별 답변 품질과 답변이 프롬프트에 놓인 순서를 통제하며 평가자별 자기 계열 우대를 동시에 추정하는 순위 로짓 모형으로 분석하였다. 그 결과 최종 순위에서 Gemini 평가자는 품질이 같은 상대에 대해 자기 계열 학생의 승률을 9.8%p(95% 신뢰구간 7.1~12.5) 높게 판정하였고, 이는 5회 반복 학습과 답변의 생성 토큰 수를 통제한 뒤에도 유지되었다. 예를 들어 세 학생이 모두 핵심인 삼투압 조절을 설명하지 못한 '민물고기는 왜 바다에서 살 수 없는가' 질문에서 GPT와 Claude 평가자는 제시 순서를 바꾼 세 번 모두 GPT 학생을 1위로 판정하였으나, Gemini 평가자만 세 번 모두 Gemini 학생을 1위로 판정하였다. 반면 GPT 학생만 핵심 기전(IgE 면역 반응)을 맞힌 메밀 알레르기 질문에서는 세 평가자가 아홉 번 모두 GPT 학생을 1위로 판정하여, 평가자들이 내용의 우열은 공통으로 가려내며 자기 계열 우대는 우열이 분명하지 않은 답변 사이에서 나타날 수 있음을 시사하였다. 자기 계열 평가자의 승률에서 다른 두 평가자의 평균을 뺀 단순 비교에서는 GPT(4.3%p)와 Claude(1.8%p)도 선호를 보였으나, 이는 Gemini 평가자가 자기 학생을 올리며 다른 학생의 승률을 함께 낮춘 몫이 기준선에 섞인 결과로, 이를 분리한 모형에서는 유의하지 않았다. 이는 한국어 데이터로 학습한 모델의 평가에서 평가자 선택만으로 학생 모델 간 성능 순위가 바뀔 수 있음을 보여 주며, 생성 모델과 다른 계열의 평가자를 쓰고 답변 순서를 바꿔 가며 반복 평가하는 설계가 필요함을 시사한다.

주요용어: 선호 누출(preference leakage), LLM-as-a-Judge, 합성데이터, 순위 로짓 모형.

부록. 예상 질문과 답

↑ 목차

포스터 발표에서 나올 만한 질문을 모았다. 오른쪽 열은 자세한 근거가 있는 위치다.

예상 질문	짧은 답	근거
사람이 봐도 LLM이 매긴 순위가 맞나?	사람 평가는 하지 않았다. 다만 누출은 "정답 대비 오차"가 아니라 "같은 답에 대한 평가자 간 체계적 차이"라 정답 없이도 정의된다. 판정이 무작위가 아니라는 근거: 평가자 간 1위 일치 66~69%(우연 33%), 9번 모두 같은 1위인 묶음 126개, 근거 문장이 실제 사실관계를 짚음. 보완안: 묶음 50개를 사람 2명이 같은 조건으로 매겨 일치도(Kendall τ)와 사람 기준 누출을 계산	6.1.2, 그림 6-B
선호 누출을 통계적으로 "증명"했나?	"증명"이 아니라 "통계적 증거를 제시"했다. 이 조건(질문 100개, 해당 모델 버전, 0.6B 학생)에서 Gemini의 자기 계열 선호는 우연으로 보기 어렵고(Holm $p \le 0.003$) 세 모형·다섯 seed에서 재현되었다. Claude의 "효과 없음"도 증명이 아니다(신뢰구간 −4.4~+0.6%p)	6.4, 7.2
단순 비교에서는 세 평가자 모두 누출이 있었는데 왜 모형에서는 달라졌나?	단순 비교의 기준선(다른 평가자 평균)에 Gemini 평가자의 강한 자기 우대가 섞여 GPT·Claude의 값이 부풀었다. 모형은 세 효과를 동시에 추정해 분리했다	6.2 (4), 7.1
중립 평가자(HyperCLOVA) 없이 누출을 말할 수 있나?	있다. 학생 쌍마다 두 학생 어느 쪽과도 계열이 다른 평가자가 중립 심판 역할을 한다. 필요한 가정은 자료에서 기각되지 않았다. 중립 평가자를 추가하면 가정 없이 확인하고 정밀도도 높아진다	6.2 (5), 8.2
중립 평가자(HyperCLOVA X)는 왜 아직 돌리지 않았나?	호출 한도 때문에 한 번에 1개씩만 보낼 수 있어(동시 8개에서 429 오류) 1,500건에 8~10시간이 걸린다. 먼저 세 계열 평가자만으로 누출이 있는지 확인했다. 코드와 설정은 준비되어 있고(출력 한도 12,288토큰도 HyperCLOVA 기준에 맞춤), 파일럿에서 호출을 확인했다. 지도교수 피드백 후 실행할 계획이다	8.2
Gemini가 편향돼도 더 큰 모델을 평가자로 쓰면 편향이 없지 않나?	그렇게 단정할 근거가 없다. (1) 큰 평가자가 내용을 더 잘 보면 누출이 줄 수도 있지만, LLM이 자기 출력을 알아보는 능력이 클수록 자기 선호도 크다는 상관이 보고되어(Panickssery et al., 2024) 큰 평가자가 자기 문체를 더 잘 알아보고 누출이 유지되거나 커질 수도 있다. 방향을 미리 알 수 없다. (2) 실무에서는 비용 때문에 경량·표준급 평가자를 대량 평가에 쓰는 경우가 많아, 본 연구 조건(Gemini 평가자 gemini-3.8-flash) 자체가 현실적인 사용 조건이다. (3) 그래서 같은 1,500개 항목을 같은 회사의 크기가 다른 평가자로 다시 평가해 λ가 크기에 따라 어떻게 변하는지 직접 확인할 계획이다. 학생을 키워 답 품질이 높아질 때도 같은 실험을 한다. 참고로 공개 성능 지표에서 Gemini와 Claude는 실험 설정에서 성능이 거의 같았지만 누출은 정반대였다	7.3(표 7-2), 8.4
누출을 실제로 줄이려면 어떻게 해야 하나?	세 방향의 실험을 계획했다. 데이터 쪽(교사 데이터 비율 조절, 학습 데이터 문체 중화), 평가자 쪽(외부 평가자 검증, 자기 계열 판정 빼기), 평가 입력 쪽(답 서식 제거·재작성, 참조 답 제공, 단계적 사실 확인 지시). 학습이 필요 없는 평가 쪽 개입부터 진행한다	8.1~8.3, 표 8-9
순서를 바꿔 3번 평가한 것이 정말 필요했나?	필요했다. 첫 번째 답이 1위로 뽑힐 오즈가 마지막보다 1.7~2.2배로, 가장 큰 누출(오즈비 1.49)보다 크다	6.7
0.6B 학생의 답이 대부분 틀렸는데 의미가 있나?	의미는 있지만 범위가 제한된다. 품질 차이가 작은 비교에서 평가자의 선호가 판정에 더 크게 작용하며, 비슷한 수준의 후보 모델을 비교하는 실무에서도 같은 상황이 생긴다. 품질이 높은 답 사이에서도 같은지는 알 수 없다	6.1.1, 6.1.2, 표 7-1
학생이 정말 교사 스타일을 배웠나?	교차 loss에서 15명 모두 자기 교사의 답을 가장 "자기가 쓸 법한 글"로 봤고(15/15), 생성한 답에서도 목록·번호 목록·길이 순서가 교사와 같은 패턴이었다	5.4, 표 5-E
왜 Base 모델이고, 왜 LoRA가 아닌가?	Instruct는 이미 특정 회사의 대화 스타일이 있어 교사 스타일의 전이를 구분할 수 없다. LoRA는 스타일 흡수가 약할 수 있고, 0.6B는 전체 학습이 가능하다	표 5-B
학생 답을 왜 두 번 생성했나? 결과를 고른 것 아닌가?	1차 생성에서 잘림이 Claude 학생에 몰려(37.5%) 미완성 감점이 누출과 섞일 수 있었다. 같은 학생 모델에 모든 학생 똑같이 설정만 바꿔 재생성했고, 1차 결과도 보존했다	5.5.1
Claude 학생이 더 길게 쓰는데 길이 때문 아닌가?	길이를 통제한 모형에서도 Gemini의 누출은 +8.8%p로 유지되었고, 세 평가자 모두 오히려 짧은 답을 약간 선호했다	6.4.1
val loss가 2 epoch에서 가장 낮았는데 왜 3	오른 폭이 1~2%로 작고, 목적이 최고 성능이 아니라 스타일 전이이며, 15명 모두 같은 시점을 써야 공정하다	5.3, 표 5-A

예상 질문	짧은 답	근거
epoch 모델인가?		

참고문헌

↑ 목차

1. Li, D. et al. (2026). Preference Leakage: A Contamination Problem in LLM-as-a-judge. ICLR 2026. arXiv:2502.01534.
2. Luce, R. D. (1959). Individual Choice Behavior. Wiley. · Plackett, R. L. (1975). The analysis of permutations. Applied Statistics, 24(2), 193-202.
3. Panickssery, A., Bowman, S. R., & Feng, S. (2024). LLM Evaluators Recognize and Favor Their Own Generations. NeurIPS 2024.
4. Shi, L. et al. (2025). Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge. arXiv:2406.07791.
5. Wang, P. et al. (2024). Large Language Models are not Fair Evaluators. ACL 2024.
6. Ye, S. et al. (2024). FLASK: Fine-grained Language Model Evaluation based on Alignment Skill Sets. ICLR 2024.
7. Zheng, L. et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. NeurIPS 2023.
8. Efron, B. (1979). Bootstrap methods: Another look at the jackknife. The Annals of Statistics, 7(1), 1-26.
9. Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65-70.
10. Bradley, R. A., & Terry, M. E. (1952). Rank analysis of incomplete block designs: I. The method of paired comparisons. Biometrika, 39(3/4), 324-345.
11. McFadden, D. (1974). Conditional logit analysis of qualitative choice behavior. In P. Zarembka (Ed.), Frontiers in Econometrics, 105-142. Academic Press.
12. Beggs, S., Cardell, S., & Hausman, J. (1981). Assessing the potential demand for electric cars. Journal of Econometrics, 17(1), 1-19.
13. Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2020). The Curious Case of Neural Text Degeneration. ICLR 2020. arXiv:1904.09751.
14. Welleck, S., Kulikov, I., Roller, S., Dinan, E., Cho, K., & Weston, J. (2020). Neural Text Generation with Unlikelihood Training. ICLR 2020. arXiv:1908.04319.
15. Xu, J., Liu, X., Yan, J., Cai, D., Li, H., & Li, J. (2022). Learning to Break the Loop: Analyzing and Mitigating Repetitions for Neural Text Generation. NeurIPS 2022. arXiv:2206.02369.
16. Li, H., Lan, T., Fu, Z., Cai, D., Liu, L., Collier, N., Watanabe, T., & Su, Y. (2023). Repetition In Repetition Out: Towards Understanding Neural Text Degeneration from the Data Perspective. NeurIPS 2023. arXiv:2310.10226.
17. Keskar, N. S., McCann, B., Varshney, L. R., Xiong, C., & Socher, R. (2019). CTRL: A Conditional Transformer Language Model for Controllable Generation. arXiv:1909.05858.
18. Tang, R. et al. (2024). Found in the Middle: Permutation Self-Consistency Improves Listwise Ranking in Large Language Models. NAACL 2024.
19. Hou, Y. et al. (2024). Large Language Models are Zero-Shot Rankers for Recommender Systems. ECIR 2024.
20. Liusie, A., Manakul, P., & Gales, M. (2024). LLM Comparative Assessment: Zero-shot NLG Evaluation through Pairwise Comparisons using Large Language Models. EACL 2024.
21. Son, G. et al. (2024). LLM-as-a-Judge & Reward Model: What They Can and Cannot Do. arXiv:2409.11239.
22. Artificial Analysis (2026). Artificial Analysis Intelligence Index v4.3.2. https://artificialanalysis.ai (2026년 10월 15일 확인).

23. Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. Journal of Human Resources, 50(2), 317-372.

그림과 표의 수치는 분석 결과 파일(classify/output, sft/runs, judge/output/analysis, results/output)에서 가져왔다.