LLM-as-a-Judge 선호 누출: 설계, 결과, 해석

GPT·Claude·Gemini가 만든 답으로 각각 학습한 작은 학생 모델들의 답을, 같은 세 모델이 평가자가 되어 순위를 매겼다. 평가자가 **자기 모델의 데이터로 학습한 학생**을 더 높게 평가하는지(선호 누출, preference leakage)를 측정했다.

코드 `judge/` (`select_items.py` → `run_judge.py` → `merge_results.py` → `descriptive.py`, `analyze_models.py`) · 작성 2026-10-01 · 평가자: GPT·Claude·Gemini (중립 평가자 HyperCLOVA X는 미실행)

한눈에 보는 결론

1. **Gemini 평가자는 자기 계열 학생을 분명히 더 높게 평가했다.** 품질과 위치를 통제한 뒤에도 자기 계열 학생이 1위로 뽑힐 확률이 +8.6%p(33.3% → 41.9%), 다른 학생을 이길 확률이 +9.8%p 높았다. 세 가지 통계 모형에서 모두 유의했고, 다섯 번의 독립 학습(seed)에서 모두 같은 방향(양수)이었으며, 네 평가 기준 중 세 개에서 세 모형 모두 유의했다.
2. **GPT 평가자는 약한 증거**를 보였다. 1위 비율 기준으로는 +3.5%p로 유의했지만(Holm p = 0.036), 전체 순위·쌍 고정효과 모형에서는 같은 방향이되 유의하지 않았다.
3. **Claude 평가자에서는 자기 계열 선호가 관찰되지 않았다.**
4. **위치 편향은 실제로 컸다.** 같은 답이라도 첫 번째(A)에 놓이면 1위로 뽑힐 확률이 42~50%로, 기대값 33.3%보다 훨씬 높았다. 같은 질문을 순서만 바꿔 3번 평가한 설계 덕분에 이 효과를 상쇄할 수 있었다.

1. 연구 질문
2. 실험 설계 쉽게 이해하기
3. 선호 편향을 재는 방법: 1위 비율과 승률
4. 결과 Ⅰ. 최종 순위(overall)로 본 선호 편향 — 주 결과
5. 결과 Ⅱ. 위치 편향은 실제로 있었나
6. 결과 Ⅲ. 평가 기준별 분석 (ablation)
7. 사례
8. 종합 결론과 해석
9. 예상 질문과 답변
10. 한계
11. 부록 A-H · 참고문헌

1. 연구 질문

"LLM 평가자는 자기 모델이 만든 합성데이터로 학습한 모델의 답을 더 좋게 평가하는가?"

요즘 작은 모델은 큰 모델(GPT, Claude, Gemini)이 만든 답으로 학습시키고(합성데이터 증류), 그 성능도 큰 모델에게 채점을 맡긴다(LLM-as-a-Judge). 이때 데이터를 만든 모델과 채점하는 모델이 같으면, 채점 모델이 자기 문체를 물려받은 답을 좋게 보는 **선호 누출**이 생길 수 있다(Li et al., 2025). 이 연구는 한국어 질문에서 이 현상이 실제로 나타나는지, 얼마나 큰지 측정했다.

- **가설 H1:** 평가자는 품질이 같다면 자기 계열 학생을 더 높은 순위에 놓는다. → 4절(최종 순위)
- **가설 H2:** 이 선호는 평가 기준에 따라 크기가 다르다. → 6절(기준별 ablation)
- **가설 H3:** 이 선호는 학습 무작위성(seed)에 따른 우연이 아니라 다섯 번의 반복 학습에서 모두 나타난다. → 4.4, 6절

전제 확인(앞선 단계): 세 교사의 답은 답만 보고도 97% 정확도로 구별되고(다항 로지스틱 97.2%, KLUE-RoBERTa 97.1%; 서식을 지운 텍스트에서도 92.1%, 96.5%), 학생 15명 모두 자기 교사의 문체를 물려받았다(교차 loss 15/15). 즉 평가자가 자기 계열 문체를 알아볼 수 있는 조건이다.

2. 실험 설계 쉽게 이해하기

2.1 등장인물

역할	누구	하는 일
교사 3명	GPT, Claude, Gemini	같은 한국어 질문 1,000개에 답을 써서 학습 데이터를 만든다.
학생 15명	Qwen3-0.6B-Base를 교사 답으로 학습 (교사 3 × seed 5)	예: "GPT 학생 seed 42" = GPT의 답으로 학습한 학생. 같은 교사로 학습 무작위성(seed)만 바꿔 5번 따로 학습했다.
평가자 3명	GPT, Claude, Gemini (교사와 같은 모델)	학생 답에 순위를 매긴다. 답을 누가 썼는지는 모른다.

궁금한 것: GPT 평가자는 GPT 학생의 답을, Claude 평가자는 Claude 학생의 답을, Gemini 평가자는 Gemini 학생의 답을 다른 평가자보다 더 좋게 보는가?

2.2 평가 한 번은 이렇게 생겼다

평가자에게 **질문 하나와 학생 답 세 개**를 한꺼번에 보여 준다. 세 답은 **같은 질문**에 대한 **같은 seed의 GPT·Claude·Gemini 학생**의 답이다(교사만 다르고 학습 조건은 같음). 평가자는 답이 "답변 A, B, C"로만 보이고

누가 썼는지 모른다.

```
[평가자가 받는 것]                          [평가자가 내놓는 것]
질문: 삼겹살에 뼈가 있는 이유는?          사실 정확성    1위 B, 2위 A, 3위 C    + 근거 한두 문장
답변 A: (Gemini 학생의 답)          →       질문 충족도    1위 B, 2위 C, 3위 A    + 근거
답변 B: (GPT 학생의 답)                    논리성          …                      + 근거
답변 C: (Claude 학생의 답)                 가독성          …                      + 근거
                                                 최종 순위(overall) 1위 B, 2위 A, 3위 C   +
네 기준을 종합한 근거
```

위 순위는 출력 형식을 보여 주는 예시다. 실제 평가자의 순위와 근거는 7절 사례에 있다.

- **순위는 다섯 개:** 평가 기준 4개(사실 정확성, 질문 충족도, 논리성, 가독성) 각각의 순위와, 네 기준을 모두 고려한 **최종 순위(overall)**. 동점은 없다.
- **왜 점수가 아니라 순위인가:** 처음에 답 하나씩 1~5점을 매기게 했더니 0.6B 학생의 답이 대부분 사실을 지어내서 사실 정확성이 전부 1점이 나왔다. 모두 1점이면 차이를 볼 수 없으므로, 세 답을 나란히 놓고 "그나마 나은 순서"를 매기게 바꿨다(부록 D).

2.3 같은 질문을 순서만 바꿔 3번 넣는다 (위치 편향 통제)

LLM 평가자는 답의 내용과 상관없이 **먼저 나온 답을 좋게 보는 경향(위치 편향)**이 있다고 알려져 있다(Zheng et al., 2023; Wang et al., 2024). GPT 학생의 답이 늘 A에 놓이면 GPT 학생이 이득을 본다. 그래서 같은 세 답을 **순서만 바꿔 3번** 평가자에게 넣었다.

같은 질문, 같은 세 답	답변 A	답변 B	답변 C
순서 1	GPT 학생	Claude 학생	Gemini 학생
순서 2	Claude 학생	Gemini 학생	GPT 학생
순서 3	Gemini 학생	GPT 학생	Claude 학생

세 번 중 각 학생이 A·B·C에 **정확히 한 번씩** 놓이므로, 세 번의 결과를 합치면 위치의 이득·손해가 모든 학생에게 똑같이 들어가 상쇄된다. 시작 순서도 질문마다 6가지 중에서 돌아가며 바꿨다(부록 E).

2.4 전체 규모

단위	개수	설명
질문	100	학생 15명 모두 답을 끝까지 쓴 질문 144개 중 추첨(부록 F)
묶음 (질문 × seed)	500	같은 질문, 같은 seed의 학생 3명 답 = 한 묶음
평가 항목 (묶음 × 순서 3)	1,500	평가자에게 한 번 보내는 단위

단위	개수	설명
평가 (항목 × 평가자 3)	4,500	API 호출 수. 실패 0건(Gemini 형식 오류 11건은 재요청으로 해결)
순위 (평가 × 5)	22,500	평가마다 기준 4개 + 최종 순위 1개
평가자 한 명이 학생 한 명에게 매긴 순위	1,500	= 100 질문 × 5 seed × 3 순서 (seed 하나에서는 300)

3. 선호 편향을 재는 방법: 1위 비율과 승률

평가자 한 명이 매긴 순위 하나를 예로 들자. GPT 평가자가 어떤 질문에서 **GPT 학생 1위, Gemini 학생 2위, Claude 학생 3위**로 매겼다.

3.1 1위 비율: "나머지 두 답보다 위에 놓았나?"

학생이 **1위**(= 나머지 두 학생보다 모두 위)를 받은 비율이다. 위 예에서 GPT 학생은 1위이므로 1번 성공이다.

```
1위 비율(평가자 j, 학생 t) = 평가자 j가 학생 t를 1위로 놓은 횟수 ÷ 전체 횟수 (1,500)
기준선: 세 학생의 품질이 같고 편향이 없으면 1/3 = 33.3%
```

가장 직관적인 지표다. "GPT 평가자가 GPT 학생을 나머지 둘보다 높게 매긴 경우가 많은가?"라는 질문에 그대로 답한다. 다만 2위와 3위의 차이는 쓰지 않는다.

3.2 쌍대 승률: "상대 한 명과 붙었을 때 이겼나?"

순위 하나를 **두 학생씩 짝지은 대결 3개**로 푼다. 위 예에서는 GPT > Gemini, GPT > Claude, Gemini > Claude. 학생 한 명은 순위 하나에서 대결 2개에 참여한다.

```
1위 → 2승 0패,   2위 → 1승 1패,   3위 → 0승 2패
쌍대 승률(평가자 j, 학생 t) = 이긴 대결 수 ÷ 참여한 대결 수 = (1위 횟수 × 2 + 2위 횟수) ÷ (전체 횟수 × 2)
기준선: 50%
```

2위와 3위의 차이까지 쓰므로 정보가 더 많아 추정이 안정적이다. 대신 "1위를 했나"보다 덜 직관적이다.

3.3 두 지표 비교

	1위 비율	쌍대 승률
질문	나머지 둘보다 모두 위에 놓였나	상대 한 명보다 위에 놓였나

	1위 비율	쌍대 승률
쓰는 정보	1위인지만	1·2·3위 전부
기준선	33.3%	50%
장점	직관적, "1등을 몰아준다"는 그림과 같음	정보가 많아 더 정밀
역할	보조 지표	**주 지표**
이 문서에서	**주 지표는 쌍대 승률(모형 ② 순위 로짓 PL), 1위 비율(모형 ①)은 보조 지표다.** 쌍대 승률은 순위 정보를 모두 써서 더 정밀하고, 분석 계획 단계에서 미리 정한 주 모형이다. 1위 비율로도 같은 결론이 나오는지 함께 보고한다.	

3.4 선호 편향(누출)은 "같은 학생을 평가자끼리 비교"해서 잰다

GPT 평가자가 GPT 학생을 1위로 자주 놓았다고 해서 바로 편향은 아니다. **GPT 학생의 답이 실제로 좋아서**일 수 있다. 그래서 같은 GPT 학생의 답을 **다른 평가자(Claude, Gemini)가 어떻게 봤는지**와 비교한다. 답이 같으므로 품질 차이는 지워지고 평가자의 차이만 남는다.

```
단순 누출(GPT 평가자) = [GPT 평가자가 매긴 GPT 학생의 1위 비율] − [Claude·Gemini 평가자가 매긴 GPT 학생의 1위 비율 평균]
편향이 없으면 0,  양수면 자기 계열 학생을 더 높게 본 것
```

3.5 단순 비교의 함정과 통계 모형

단순 비교에는 함정이 있다. **비교 대상인 "다른 평가자"도 각자 자기 계열 학생을 우대할 수 있다.** 예를 들어 Gemini 평가자가 Gemini 학생을 올려 주면, 같은 순위 안의 GPT 학생은 자동으로 한 칸 내려간다. 그러면 GPT 학생의 기준선(다른 평가자 평균)이 낮아져 GPT 평가자의 누출이 실제보다 크게 보인다. 세 평가자의 편향이 서로의 기준선에 섞이는 것이다.

이를 풀기 위해 세 평가자의 편향을 **동시에** 추정하는 통계 모형을 썼다. 핵심 아이디어는 **학생 두 명을 비교할 때, 둘 중 어느 쪽과도 계열이 다른 평가자가 항상 한 명 있다**는 점이다. 예를 들어 GPT 학생과 Claude 학생의 비교에서는 Gemini 평가자가 "중립 심판"이다. 이 중립 심판의 판정을 기준으로 각 평가자의 자기 계열 우대를 떼어 낸다.

모형	쉽게 말하면	결과 단위
① 1위만 쓴 모형	"세 답 중 누구를 1위로 뽑았나"만 보고, 학생 품질·위치를 빼고도 자기 계열이 더 자주 뽑히는지 추정. 3.1의 1위 비율에 대응.	품질이 같은 세 답 중 자기 계열이 1위로 뽑힐 확률이 33.3%에서 몇 %p 오르나
② 전체 순위 모형 (Plackett-Luce)	"1위 고르기 → 남은 둘 중 2위 고르기"를 모두 써서 같은 것을 추정. 3.2의 승률에 대응. **주 모형.**	품질이 같은 상대를 이길 확률이 50%에서 몇 %p 오르나
③ 쌍 고정효과 모형 (LPM)	같은 두 답을 9번(평가자 3 × 순서 3) 비교한 자료에서, 그 두 답의 품질 차이를 통째로 지우고 평가자의 차이만 봄. 가장 엄격한 확인.	중립 심판보다 자기 계열이 이긴다고 판정할 확률이 몇 %p 높나

모형의 식, 표준오차 계산(질문 단위 부트스트랩 1,000회), 정답을 아는 가짜 자료로 한 검증은 부록 G에 있다. 가짜 자료 검증에서 모형은 누출이 없으면 0을, 있으면 같은 방향을(크기는 다소 작게) 되찾았다.

3.6 반복(seed)과 p값

- **seed별 계산:** 같은 분석을 seed마다 따로 해서 평가자마다 값 5개를 얻는다. 5개 모두 양수면 "학생을 다섯 번 다시 학습해도 매번 나타났다"는 뜻이다(부호 검정 $p = 0.5^5 = 0.031$).
- **p값:** "편향이 전혀 없다면 이 정도 차이가 우연히 나올 확률". 0.05보다 작으면 우연으로 보기 어렵다고 판단한다.
- **Holm 보정:** 평가자 3명을 한꺼번에 검정하면 우연히 하나쯤 유의하게 나올 확률이 커지므로, p값을 그만큼 엄격하게 보정한다(Holm, 1979). 이 문서의 결론은 **보정된 p값(Holm p)**을 기준으로 한다.

---

4. 결과 Ⅰ. 최종 순위(overall)로 본 선호 편향 — 주 결과

이 절의 모든 수치는 **최종 순위(overall)**만으로 계산했다. 평가 기준 4개 각각의 결과는 6절(ablation)에 같은 형식으로 정리했다.

4.1 원자료: 각 평가자가 각 학생에게 준 1위·2위·3위 횟수

각 칸 = 1위 / 2위 / 3위 횟수 (1,500번 중). 굵은 칸은 자기 계열 평가(예: GPT 평가자 × GPT 학생).

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**709 / 463 / 328**	443 / 524 / 533	348 / 513 / 639
Claude 평가자	653 / 519 / 328	**473 / 466 / 561**	374 / 515 / 611
Gemini 평가자	607 / 466 / 427	414 / 476 / 610	**479 / 558 / 463**

▼ seed별 횟수 (seed마다 300번 중)

seed 42

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**132 / 91 / 77**	90 / 120 / 90	78 / 89 / 133
Claude 평가자	101 / 123 / 76	**96 / 100 / 104**	103 / 77 / 120
Gemini 평가자	114 / 96 / 90	89 / 102 / 109	**97 / 102 / 101**

seed 43

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**146 / 89 / 65**	79 / 96 / 125	75 / 115 / 110
Claude 평가자	130 / 109 / 61	**86 / 86 / 128**	84 / 105 / 111
Gemini 평가자	120 / 95 / 85	70 / 95 / 135	**110 / 110 / 80**

seed 44

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**147 / 94 / 59**	91 / 111 / 98	62 / 95 / 143
Claude 평가자	155 / 80 / 65	**88 / 104 / 108**	57 / 116 / 127
Gemini 평가자	124 / 92 / 84	83 / 93 / 124	**93 / 115 / 92**

seed 45

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**137 / 91 / 72**	99 / 103 / 98	64 / 106 / 130
Claude 평가자	139 / 95 / 66	**101 / 97 / 102**	60 / 108 / 132
Gemini 평가자	127 / 83 / 90	89 / 96 / 115	**84 / 121 / 95**

seed 46

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**147 / 98 / 55**	84 / 94 / 122	69 / 108 / 123
Claude 평가자	128 / 112 / 60	**102 / 79 / 119**	70 / 109 / 121
Gemini 평가자	122 / 100 / 78	83 / 90 / 127	**95 / 110 / 95**

읽는 법. GPT 평가자는 GPT 학생을 1,500번 중 709번 1위로 놓았고, Gemini 학생은 348번만 1위로 놓았다. Gemini 평가자는 Gemini 학생을 479번 1위로 놓아, GPT·Claude 평가자(348번, 374번)보다 100번 이상 많았다.

4.2 1위 비율과 쌍대 승률

1위 비율 기준선 33.3%, 쌍대 승률 기준선 50%. 굵은 칸은 자기 계열 평가. **같은 학생(열)을 세로로** 비교하면 평가자에 따른 차이가 보인다.

평가자	1위 비율: GPT 학생	Claude 학생	Gemini 학생	쌍대 승률: GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**47.3%**	29.5%	23.2%	**62.7%**	47.0%	40.3%
Claude 평가자	43.5%	**31.5%**	24.9%	60.8%	**47.1%**	42.1%

평가자	1위 비율: GPT 학생	Claude 학생	Gemini 학생	쌍대 승률: GPT 학생	Claude 학생	Gemini 학생
Gemini 평가자	40.5%	27.6%	**31.9%**	56.0%	43.5%	**50.5%**

- **학생 품질:** 세 평가자 모두 GPT 학생을 가장 높게 봤다(1위 비율 40.5~47.3%). 평가자와 무관한 공통 경향이므로 학생 자체의 품질 차이다.
- **자기 계열 쪽으로의 기울기:** 각 학생 열에서 자기 계열 평가자의 값이 가장 높다. 특히 Gemini 학생은 Gemini 평가자에게서 1위 비율 31.9%, 다른 두 평가자에게서 23.2%와 24.9%를 받았다.

▼ seed별 1위 비율과 쌍대 승률

1위 비율 (seed마다 300번 중)

seed	평가자	GPT 학생	Claude 학생	Gemini 학생
42	GPT 평가자	**44.0%**	30.0%	26.0%
	Claude 평가자	33.7%	**32.0%**	34.3%
	Gemini 평가자	38.0%	29.7%	**32.3%**
43	GPT 평가자	**48.7%**	26.3%	25.0%
	Claude 평가자	43.3%	**28.7%**	28.0%
	Gemini 평가자	40.0%	23.3%	**36.7%**
44	GPT 평가자	**49.0%**	30.3%	20.7%
	Claude 평가자	51.7%	**29.3%**	19.0%
	Gemini 평가자	41.3%	27.7%	**31.0%**
45	GPT 평가자	**45.7%**	33.0%	21.3%
	Claude 평가자	46.3%	**33.7%**	20.0%
	Gemini 평가자	42.3%	29.7%	**28.0%**
46	GPT 평가자	**49.0%**	28.0%	23.0%
	Claude 평가자	42.7%	**34.0%**	23.3%
	Gemini 평가자	40.7%	27.7%	**31.7%**

쌍대 승률

seed	평가자	GPT 학생	Claude 학생	Gemini 학생
42	GPT 평가자	**59.2%**	50.0%	40.8%
	Claude 평가자	54.2%	**48.7%**	47.2%
	Gemini 평가자	54.0%	46.7%	**49.3%**

seed	평가자	GPT 학생	Claude 학생	Gemini 학생
43	GPT 평가자	**63.5%**	42.3%	44.2%
	Claude 평가자	61.5%	**43.0%**	45.5%
	Gemini 평가자	55.8%	39.2%	**55.0%**
44	GPT 평가자	**64.7%**	48.8%	36.5%
	Claude 평가자	65.0%	**46.7%**	38.3%
	Gemini 평가자	56.7%	43.2%	**50.2%**
45	GPT 평가자	**60.8%**	50.2%	39.0%
	Claude 평가자	62.2%	**49.8%**	38.0%
	Gemini 평가자	56.2%	45.7%	**48.2%**
46	GPT 평가자	**65.3%**	43.7%	41.0%
	Claude 평가자	61.3%	**47.2%**	41.5%
	Gemini 평가자	57.3%	42.7%	**50.0%**

4.3 선호 편향 추정: 단순 비교와 세 가지 모형

평가자	단순 비교: 1위 비율 (자기 vs 다른 평가자)	단순 비교: 쌍대 승률	모형 ① 1위만 (1위 확률 %p)	모형 ② 전체 순위 PL (승률 %p)	모형 ③ 쌍 고정효과 LPM (승률 %p)
GPT 평가자	47.3% vs 42.0% **+5.3**	62.7% vs 58.4% **+4.3**	+3.5* [+0.5, +6.9] Holm p 0.036	+2.8 [+0.2, +5.3] Holm p 0.076	+2.8 [−0.6, +6.3] Holm p 0.219
Claude 평가자	31.5% vs 28.6% **+3.0**	47.1% vs 45.2% **+1.8**	+0.6 [−2.2, +3.7] Holm p 0.700	−2.0 [−4.4, +0.6] Holm p 0.130	−1.5 [−4.0, +0.9] Holm p 0.225
Gemini 평가자	31.9% vs 24.1% **+7.9**	50.5% vs 41.2% **+9.3**	+8.6** [+4.5, +12.9] Holm p 0.003	+9.8** [+7.1, +12.5] Holm p 0.003	+10.7*** [+7.6, +13.8] Holm p <0.001

단순 비교: 같은 학생에 대해 자기 계열 평가자의 값 vs 다른 두 평가자의 평균, 아래 굵은 수가 차이(%p). 모형: 추정치(%p), [95% 신뢰구간], 평가자 3명에 대한 Holm 보정 p. 별표는 Holm p < 0.05(*), 0.01(**), 0.001(***).

읽는 법과 해석.

- **단순 비교에서는 세 평가자 모두 양수다**(1위 비율 기준 GPT +5.3, Claude +3.0, Gemini +7.9%p). 하지만 3.5의 함정 때문에 이 값에는 다른 평가자의 편향이 섞여 있다.
- **세 평가자의 편향을 분리한 모형에서는 그림이 달라진다.**

- **Gemini:** 세 모형 모두에서 크고 유의하다. 품질이 같은 세 답이라면 Gemini 학생의 답이 1위로 뽑힐 확률이 33.3%에서 약 41.9%로(+8.6%p), 다른 학생을 이길 확률이 50%에서 59.8%로(+9.8%p) 오른다. 같은 두 답을 직접 비교한 가장 엄격한 모형에서도 +10.7%p다.
- **GPT:** 1위만 본 모형에서 +3.5%p로 보정 후에도 유의하지만(Holm p = 0.036), 전체 순위 모형(+2.8%p, Holm p = 0.076)과 쌍 고정효과 모형(+2.8%p, p = 0.22)에서는 같은 방향이되 유의하지 않다. **방향은 일관되지만 증거가 약하다.**
- **Claude:** 단순 비교의 +3.0%p는 모형에서 거의 사라진다(+0.6, −2.0, −1.5%p, 모두 유의하지 않음). 단순 비교의 양수 값은 주로 Gemini 평가자가 Claude 학생을 낮게 본 영향이 기준선에 섞인 것이다.
- **식별 가정 확인:** 모형이 세 평가자를 분리하려면 "평가자는 자기 계열이 아닌 두 학생을 품질 외에는 똑같이 대한다"는 가정이 필요하다. 이 가정을 검정한 결과 p = 0.98로, 자료와 잘 맞았다(부록 G).

4.4 다섯 번의 독립 학습(seed)에서도 반복되는가

평가자	지표	seed 42	43	44	45	46	양수	한쪽 p (부호 / t)
GPT	단순: 1위 비율	+8.2	+7.0	+2.5	+1.3	+7.3	5/5	—
	모형 ① 1위만	+9.0	+4.4	+0.4	−0.7	+4.4	4/5	부호 0.188 / t 0.055 Holm: 부호 0.375 / t 0.110
	모형 ② PL	+3.9	+3.5	+2.2	−0.2	+4.8	4/5	부호 0.188 / t 0.016 Holm: 부호 0.375 / t 0.032
	모형 ③ LPM	+3.2	+1.2	+3.2	−0.0	+6.5	4/5	부호 0.188 / t 0.032 Holm: 부호 0.375 / t 0.064
Claude	단순: 1위 비율	+2.2	+3.8	+0.3	+2.3	+6.2	5/5	—
	모형 ① 1위만	+0.1	+1.2	−2.3	+1.1	+3.8	4/5	부호 0.188 / t 0.238 Holm: 부호 0.375 / t 0.238
	모형 ② PL	−2.6	−1.6	−4.4	−1.2	+0.0	1/5	부호 0.969 / t 0.971 Holm: 부호 0.969 / t 0.971
	모형 ③ LPM	−2.8	−0.4	−3.8	−0.6	−0.1	0/5	부호 1.000 / t 0.947 Holm: 부호 1.000 / t 0.947
Gemini	단순: 1위 비율	+2.2	+10.2	+11.2	+7.3	+8.5	5/5	—
	모형 ① 1위만	+0.1	+10.1	+15.9	+10.1	+8.4	5/5	부호 0.031 / t 0.012 Holm: 부호 0.094 / t 0.037
	모형 ② PL	+6.4	+10.1	+13.9	+10.6	+7.8	5/5	부호 0.031 / t <0.001 Holm: 부호 0.094 / t 0.002
	모형 ③ LPM	+9.1	+9.5	+14.8	+10.1	+9.8	5/5	부호 0.031 / t <0.001 Holm: 부호 0.094 / t <0.001

각 칸은 그 seed의 묶음 100개 × 순서 3가지만으로 계산한 누출(%p). 부호 검정: 5개 중 양수 개수에 대한 한쪽 이항검정. t검정: 5개 평균이 0보다 큰지 한쪽 검정. Holm: 평가자 3명에 대한 보정.

- **Gemini:** 모든 지표에서 다섯 seed 모두 양수였다. 전체 순위 모형과 쌍 고정효과 모형에서는 +6~15%p로 고르게 컸고, 1위 지표는 seed 42에서만 작았다(+0.1~2.2%p, 나머지 seed +7~16%p). 학생을 다섯 번 다시 학습해도 매번 같은 방향이었다. t검정은 보정 후에도 유의하다(전체 순위 모형 Holm p = 0.002).
- **GPT:** 모형 기준 다섯 중 넷이 양수이고 seed 45에서는 0에 가깝다.
- **Claude:** 단순 비교로는 다섯 모두 양수였지만, 모형에서는 0 근처다. 전체 순위 모형과 쌍 고정효과 모형은 다섯 중 0~1개만 양수였고, 1위 모형은 넷이 양수지만 평균 +0.8%p로 작고 유의하지 않다(t검정 p = 0.24).
- **부호 검정의 한계:** seed가 5개라 부호 검정의 최솟값이 0.031이고, 평가자 3명에 Holm 보정을 하면 5/5여도 0.094가 된다. 그래서 반복성은 "5/5"와 t검정을 함께 본다.

4.5 질문별 승자와 평가자 간 일치

질문(묶음)마다 순서 3가지의 순위를 평균해, 평균 순위가 가장 좋은 학생을 그 질문의 승자로 셌다(위치 효과가 상쇄된 판정). seed마다 100개, 합계 500개.

평가자	seed	GPT 학생 승	Claude 학생 승	Gemini 학생 승	동률
GPT 평가자	42	**41**	33	23	3
	43	**50**	24	22	4
	44	**46**	30	13	11
	45	**45**	30	18	7
	46	**47**	29	20	4
	합계	**229**	146	96	29
Claude 평가자	42	31	**32**	35	2
	43	44	**25**	25	6
	44	51	**26**	20	3
	45	51	**30**	18	1
	46	44	**31**	23	2
	합계	221	**144**	121	14

평가자	seed	GPT 학생 승	Claude 학생 승	Gemini 학생 승	동률
Gemini 평가자	42	39	29	**31**	1
	43	40	22	**34**	4
	44	38	28	**29**	5
	45	43	27	**28**	2
	46	40	26	**32**	2
	합계	200	132	**154**	14

- Gemini 학생의 승리 수는 평가자에 따라 크게 달랐다: Gemini 평가자 154번, Claude 평가자 121번, GPT 평가자 96번. 같은 500개 질문인데 평가자에 따라 1.6배 차이가 난다.
- 그래도 평가자들이 제멋대로 판정한 것은 아니다. 같은 항목에서 두 평가자가 같은 학생을 1위로 꼽은 비율은 GPT-Claude 69.3%, GPT-Gemini 67.6%, Claude-Gemini 66.4%로, 우연(33.3%)의 약 두 배다. 세 평가자 모두 GPT 학생을 가장 많이 승자로 꼽았다.

> **4절 결론 (최종 순위 기준).** Gemini 평가자는 학생 품질과 위치를 통제한 뒤에도 자기 계열 학생을 뚜렷하게 더 높게 평가했다(1위 확률 +8.6%p, 승률 +9.8%p, 모든 모형·모든 seed에서 양수). GPT 평가자는 같은 방향의 약한 증거(+2.8~3.5%p, 1위 모형에서만 보정 후 유의), Claude 평가자는 증거가 없다. 단순 비교만 했다면 세 평가자 모두 편향이 있다고 잘못 결론 내렸을 것이다.

5. 결과 Ⅱ. 위치 편향은 실제로 있었나

같은 질문을 순서만 바꿔 3번 넣었기 때문에, **같은 답이 A·B·C 중 어디에 놓였느냐에 따라 순위가 달라졌는지**를 직접 볼 수 있다. 네 가지 방법으로 계산했다(최종 순위 기준).

방법	계산	편향이 없다면
① 1위의 위치	평가자가 1위로 뽑은 답이 A·B·C 중 어디에 놓여 있었는지 비율(1,500번). 33.3%씩과 다른지 카이제곱 검정.	A·B·C 각 33.3%
② 위치별 평균 순위	같은 학생의 같은 답이 A에 놓였을 때, B일 때, C일 때 받은 평균 순위(각 500번).	세 위치에서 같음
③ 순서 간 일치 (위치 일관성)	같은 묶음을 순서 3가지로 평가했을 때 1위(또는 1~3위 전체)가 세 번 모두 같았던 묶음 비율(Shi et al., 2025).	100%에 가까움
④ 모형의 위치 효과	전체 순위 모형(②)에 함께 넣은 평가자별 위치 효과. A·B에 놓인 답이 C에 놓인 답보다 1위로 뽑힐 오즈가 몇 배인지.	1배

평가자	① 1위가 A	B	C	카이제곱 p	③ 순서 3가지 1위 동일	1~3위 전체 동일	④ 모형 오즈비 A / B (C 대비)
GPT 평가자	**49.6%**	30.0%	20.4%	<0.001	243/500 (49%)	121/500 (24%)	2.24배 / 1.39배
Claude 평가자	**45.6%**	28.9%	25.5%	<0.001	290/500 (58%)	170/500 (34%)	1.83배 / 1.22배
Gemini 평가자	**42.3%**	29.4%	28.3%	<0.001	337/500 (67%)	192/500 (38%)	1.69배 / 1.23배

②의 결과(위치별 평균 순위)는 아래 표.

평가자	학생	A에 놓였을 때	B	C	A→C 차이	세 위치 평균
GPT 평가자	GPT 학생	1.48	1.76	2.00	+0.52	**1.75**
	Claude 학생	1.73	2.08	2.36	+0.63	2.06
	Gemini 학생	1.88	2.26	2.45	+0.57	2.19
Claude 평가자	GPT 학생	1.54	1.84	1.97	+0.43	1.78
	Claude 학생	1.83	2.11	2.23	+0.41	**2.06**
	Gemini 학생	1.91	2.21	2.36	+0.44	2.16
Gemini 평가자	GPT 학생	1.70	1.93	2.01	+0.32	1.88
	Claude 학생	1.93	2.15	2.31	+0.38	2.13
	Gemini 학생	1.78	2.03	2.16	+0.39	**1.99**

▼ seed별 위치 편향 (①, ③)

평가자	seed	1위가 A	B	C	1위 동일	1~3위 동일
GPT 평가자	42	51.7%	29.0%	19.3%	45/100	22/100
	43	48.7%	31.0%	20.3%	51/100	23/100
	44	50.7%	30.7%	18.7%	45/100	25/100
	45	49.0%	30.3%	20.7%	50/100	26/100
	46	48.0%	29.0%	23.0%	52/100	25/100
Claude 평가자	42	44.3%	28.0%	27.7%	54/100	33/100
	43	46.0%	26.7%	27.3%	55/100	30/100
	44	48.0%	29.0%	23.0%	54/100	36/100
	45	45.3%	29.7%	25.0%	60/100	37/100
	46	44.3%	31.0%	24.7%	67/100	34/100

평가자	seed	1위가 A	B	C	1위 동일	1~3위 동일
Gemini 평가자	42	39.3%	31.7%	29.0%	75/100	36/100
	43	42.7%	29.3%	28.0%	62/100	37/100
	44	44.3%	28.0%	27.7%	60/100	42/100
	45	43.3%	29.0%	27.7%	70/100	34/100
	46	41.7%	29.0%	29.3%	70/100	43/100

- ① **첫 번째 답 선호:** 세 평가자 모두 A에 놓인 답을 1위로 훨씬 자주 골랐다(GPT 49.6%, Claude 45.6%, Gemini 42.3%; 기대 33.3%). 카이제곱 $p < 0.001$이고, 다섯 seed 모두에서 같은 크기로 나타났다.
- ② **같은 답, 다른 순위:** 예를 들어 GPT 평가자가 본 GPT 학생은 A에 놓이면 평균 1.48위, C에 놓이면 2.00위다. 답은 같은데 위치만으로 0.5등 차이가 난다. 이 위치 효과(A→C 0.31~0.63)는 학생 간 품질 차이와 비슷하거나 더 크다.
- ③ **순서를 바꾸면 1위가 자주 바뀐다:** 순서 3가지에서 1위가 모두 같았던 묶음은 GPT 49%, Claude 58%, Gemini 67%뿐이다. 학생 답이 모두 품질이 낮고 비슷해서 위치가 판정을 쉽게 바꾸는 조건이다(Shi et al., 2025: 품질 차이가 작을수록 위치 편향이 커진다).
- ④ **위치 효과가 선호 누출보다 크다:** A에 놓인 답이 1위로 뽑힐 오즈는 C보다 1.7~2.2배다. 가장 큰 선호 누출(Gemini, 오즈비 1.49배)보다 크다.

> **5절 결론.** 위치 편향은 실제로 존재했고 선호 누출보다 컸다. 순서를 하나로만 정해 평가했다면, 어느 학생이 첫 번째에 놓였는지가 결과를 좌우했을 것이다. 각 학생을 A·B·C에 똑같이 500번씩 놓은 설계 덕분에 4절의 선호 누출 추정에는 위치 효과가 들어가지 않는다(모형에서도 위치를 한 번 더 통제했다).

---

6. 결과 Ⅲ. 평가 기준별 분석 (ablation)

4절은 최종 순위(overall)로 결론을 냈다. 평가자는 같은 평가에서 네 기준 각각의 순위도 매겼으므로, **4절과 똑같은 계산(1위 비율, 쌍대 승률, 세 모형, seed 반복)**을 기준마다 따로 했다. 선호 누출이 어떤 판단(사실, 질문 이해, 논리, 문체)에서 나타나는지 보기 위해서다.

6.1 요약: 기준 × 평가자

결과	평가자	단순: 1위 비율 차 (%p)	모형 ① 1위만 (%p)	모형 ② PL (%p)	모형 ③ LPM (%p)	PL 양수 seed	식별 가정 검정 p
최종 순위 (overall)	GPT	+5.3	**+3.5***	+2.8	+2.8	4/5	0.980
	Claude	+3.0	+0.6	−2.0	−1.5	1/5	
	Gemini	+7.9	**+8.6****	**+9.8****	**+10.7*****	5/5	
사실 정확성	GPT	+3.4	+2.0	+0.9	−0.0	3/5	0.231
	Claude	+1.6	−0.3	−2.0	−0.8	2/5	
	Gemini	+6.7	**+8.4***	**+10.9***	**+8.6*****	5/5	
질문 충족도	GPT	+4.2	+2.4	+1.7	+0.7	5/5	0.373
	Claude	+4.7	+3.2	+1.0	+1.5	4/5	
	Gemini	+5.4	**+5.0***	**+4.3***	**+5.4****	4/5	
논리성	GPT	+0.9	+0.1	−0.9	+1.1	2/5	0.029
	Claude	−0.4	−1.2	−2.0	−1.9	0/5	
	Gemini	+2.9	+3.3	**+3.6***	+2.6	5/5	
가독성	GPT	+2.8	+0.1	+0.3	+2.6	2/5	0.044
	Claude	+3.2	+1.6	−0.0	+0.2	2/5	
	Gemini	+7.8	**+7.8***	**+6.9***	**+6.2*****	5/5	

값은 선호 누출(%p). 별표와 굵은 칸은 Holm 보정 $p < 0.05$(최종 순위는 평가자 3개, 기준은 4 × 3 = 12개를 한 묶음으로 보정). 식별 가정 검정: $p < 0.05$면 "평가자가 자기 계열이 아닌 두 학생을 같게 대한다"는 가정이 그 기준에서 흔들린다는 뜻.

- **Gemini 평가자:** 사실 정확성, 질문 충족도, 가독성에서 세 모형 모두 유의하다. 누출이 가장 큰 기준은 **사실 정확성**(+8.4~10.9%p)이고, 가장 작은 기준은 논리성(+2.6~3.6%p; 전체 순위 모형에서만 유의)이다.
- **GPT·Claude 평가자:** 어떤 기준에서도 보정 후 유의하지 않다. 단순 비교에서는 질문 충족도(GPT +4.2, Claude +4.7%p)나 가독성에서 양수가 보였지만 모형에서는 작아진다.
- **예상과 다른 점:** "문체가 개입하는 가독성에서 크고, 객관적인 사실 정확성에서 작을 것"이라는 예상(H2)과 달리, Gemini의 누출은 사실 정확성에서 가장 컸다. 자기 계열의 서술 방식으로 쓰인 내용을 더 정확하다고 판단했다는 뜻이다(7.1 사례 5, 7.3 예시 2).
- **주의:** 논리성($p = 0.029$)과 가독성($p = 0.044$)에서는 식별 가정 검정이 경계 수준으로 기각되었다. 이 두 기준에서는 평가자가 특정 계열 학생을 품질과 별개로 다르게 대하는 효과가 있을 수 있어, 모형 추정치를 조심해서 읽어야 한다. 최종 순위와 사실 정확성·질문 충족도에서는 가정이 기각되지 않았다.

6.2 기준별 위치 편향

각 칸 = ① 1위가 A에 놓여 있던 비율 / ④ 모형의 A 위치 오즈비(C 대비) / ③ 순서 3가지에서 1위가 같았던 묶음 비율.

결과	GPT 평가자	Claude 평가자	Gemini 평가자
최종 순위 (overall)	49.6% / 2.24배 / 49%	45.6% / 1.83배 / 58%	42.3% / 1.69배 / 67%
사실 정확성	46.9% / 2.14배 / 51%	42.3% / 1.58배 / 60%	41.3% / 1.69배 / 71%
질문 충족도	51.2% / 2.15배 / 44%	46.2% / 1.80배 / 56%	42.9% / 1.72배 / 66%
논리성	32.3% / 1.31배 / 49%	41.0% / 1.43배 / 56%	41.7% / 1.76배 / 66%
가독성	35.5% / 1.17배 / 53%	47.3% / 1.89배 / 51%	43.1% / 1.62배 / 63%

위치 편향은 거의 모든 기준에서 나타났다. 예외적으로 **GPT 평가자의 논리성·가독성**에서는 A 선호가 약하고 (32.3%, 35.5%) B에 놓인 답이 1위로 가장 자주 뽑혔다. 위치 편향의 방향과 크기가 평가자와 판단 종류에 따라 달라진다는 뜻이며, 순서 균형 설계는 이런 경우에도 결과를 보호한다.

6.3 사실 정확성: 상세 결과

4절과 같은 표를 이 기준의 순위로 계산했다.

1위 비율과 쌍대 승률

평가자	1위 비율: GPT 학생	Claude 학생	Gemini 학생	쌍대 승률: GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**49.0%**	29.8%	21.2%	**64.8%**	48.2%	37.0%
Claude 평가자	47.8%	**30.7%**	21.5%	65.6%	**47.7%**	36.6%
Gemini 평가자	43.4%	28.5%	**28.1%**	59.1%	44.6%	**46.3%**

선호 편향 추정 (Holm 보정은 기준 4 × 평가자 3 = 12개 묶음)

평가자	단순 비교: 1위 비율 (자기 vs 다른 평가자)	단순 비교: 쌍대 승률	모형 ① 1위만 (1위 확률 %p)	모형 ② 전체 순위 PL (승률 %p)	모형 ③ 쌍 고정효과 LPM (승률 %p)
GPT 평가자	49.0% vs 45.6% **+3.4**	64.8% vs 62.3% **+2.5**	+2.0 [−1.2, +5.2] Holm p 1.000	+0.9 [−1.8, +3.6] Holm p 1.000	−0.0 [−3.7, +3.6] Holm p 1.000
Claude 평가자	30.7% vs 29.2% **+1.6**	47.7% vs 46.4% **+1.3**	−0.3 [−2.9, +2.7] Holm p 1.000	−2.0 [−4.5, +0.5] Holm p 0.912	−0.8 [−3.3, +1.7] Holm p 1.000
Gemini 평가자	28.1% vs 21.3% **+6.7**	46.3% vs 36.8% **+9.5**	+8.4* [+4.2, +13.0] Holm p 0.012	+10.9* [+8.3, +13.7] Holm p 0.012	+8.6*** [+5.2, +12.0] Holm p <0.001

▼ 1·2·3위 횟수, seed별 반복, 위치 편향

1위 / 2위 / 3위 횟수

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**735 / 474 / 291**	447 / 552 / 501	318 / 474 / 708
Claude 평가자	717 / 535 / 248	**461 / 510 / 529**	322 / 455 / 723
Gemini 평가자	651 / 470 / 379	428 / 483 / 589	**421 / 547 / 532**

seed별 누출 (%p)

평가자	지표	seed 42	43	44	45	46	양수	한쪽 p (부호 / t)
GPT	단순: 1위 비율	+4.2	+4.0	+1.0	+1.7	+6.2	5/5	—
	모형 ① 1위만	+5.0	+3.2	−1.2	−0.6	+3.1	3/5	부호 0.500 / t 0.095
	모형 ② PL	+3.0	+2.9	+0.3	−1.5	−0.2	3/5	부호 0.500 / t 0.184
	모형 ③ LPM	+1.5	+2.2	+0.7	−3.2	−1.4	3/5	부호 0.500 / t 0.509
Claude	단순: 1위 비율	−0.2	+0.0	−0.7	+3.5	+5.2	2/5	—
	모형 ① 1위만	−1.5	−2.1	−2.6	+2.5	+2.8	2/5	부호 0.812 / t 0.552
	모형 ② PL	−3.3	−4.3	−4.7	+1.1	+1.3	2/5	부호 0.812 / t 0.897
	모형 ③ LPM	−3.7	−3.5	−2.7	+2.6	+3.1	2/5	부호 0.812 / t 0.695
Gemini	단순: 1위 비율	+0.5	+5.5	+11.7	+6.8	+9.2	5/5	—
	모형 ① 1위만	−0.3	+6.3	+17.0	+9.9	+11.4	4/5	부호 0.188 / t 0.018
	모형 ② PL	+6.0	+12.2	+13.3	+9.8	+13.2	5/5	부호 0.031 / t <0.001
	모형 ③ LPM	+8.2	+10.0	+10.0	+6.5	+8.4	5/5	부호 0.031 / t <0.001

위치 편향

평가자	① 1위가 A	B	C	카이제곱 p	③ 순서 3가지 1위 동일	1~3위 전체 동일	④ 모형 오즈비 A / B (C 대비)
GPT 평가자	**46.9%**	30.5%	22.5%	<0.001	253/500 (51%)	138/500 (28%)	2.14배 / 1.40배
Claude 평가자	**42.3%**	29.5%	28.2%	<0.001	298/500 (60%)	185/500 (37%)	1.58배 / 1.16배
Gemini 평가자	**41.3%**	30.2%	28.5%	<0.001	357/500 (71%)	206/500 (41%)	1.69배 / 1.26배

6.4 질문 충족도: 상세 결과

4절과 같은 표를 이 기준의 순위로 계산했다.

1위 비율과 쌍대 승률

평가자	1위 비율: GPT 학생	Claude 학생	Gemini 학생	쌍대 승률: GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**40.9%**	33.0%	26.1%	**55.9%**	49.1%	45.0%
Claude 평가자	35.9%	**36.2%**	27.9%	53.0%	**50.8%**	46.2%
Gemini 평가자	37.6%	30.0%	**32.4%**	52.8%	46.5%	**50.7%**

선호 편향 추정 (Holm 보정은 기준 4 × 평가자 3 = 12개 묶음)

평가자	단순 비교: 1위 비율 (자기 vs 다른 평가자)	단순 비교: 쌍대 승률	모형 ① 1위만 (1위 확률 %p)	모형 ② 전체 순위 PL (승률 %p)	모형 ③ 쌍 고정효과 LPM (승률 %p)
GPT 평가자	40.9% vs 36.8% **+4.2**	55.9% vs 52.9% **+3.1**	+2.4 [−0.1, +5.1] Holm p 0.476	+1.7 [−0.5, +3.7] Holm p 0.912	+0.7 [−2.6, +4.0] Holm p 1.000
Claude 평가자	36.2% vs 31.5% **+4.7**	50.8% vs 47.8% **+3.0**	+3.2 [+0.2, +6.4] Holm p 0.342	+1.0 [−1.6, +3.7] Holm p 1.000	+1.5 [−1.1, +4.1] Holm p 1.000
Gemini 평가자	32.4% vs 27.0% **+5.4**	50.7% vs 45.6% **+5.1**	+5.0* [+1.4, +8.5] Holm p 0.012	+4.3* [+2.3, +6.7] Holm p 0.012	+5.4** [+2.6, +8.2] Holm p 0.001

▼ 1·2·3위 횟수, seed별 반복, 위치 편향

1위 / 2위 / 3위 횟수

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**614 / 450 / 436**	495 / 483 / 522	391 / 567 / 542
Claude 평가자	539 / 511 / 450	**543 / 439 / 518**	418 / 550 / 532
Gemini 평가자	564 / 456 / 480	450 / 495 / 555	**486 / 549 / 465**

seed별 누출 (%p)

평가자	지표	seed 42	43	44	45	46	양수	한쪽 p (부호 / t)
GPT	단순: 1위 비율	+4.0	+5.7	+2.5	+2.7	+6.0	5/5	—
	모형 ① 1위만	+3.8	+3.9	+0.3	−0.5	+4.7	4/5	부호 0.188 / t 0.041
	모형 ② PL	+0.8	+1.0	+0.7	+1.2	+4.6	5/5	부호 0.031 / t 0.043
	모형 ③ LPM	−0.0	−0.6	+0.8	−1.5	+4.8	2/5	부호 0.812 / t 0.273

평가자	지표	seed 42	43	44	45	46	양수	한쪽 p (부호 / t)
Claude	단순: 1위 비율	+1.7	+5.7	+4.3	+6.8	+5.0	5/5	—
	모형 ① 1위만	+0.3	+4.4	+2.9	+5.1	+3.5	5/5	부호 0.031 / t 0.009
	모형 ② PL	+0.9	+1.7	+0.5	+2.0	−0.4	4/5	부호 0.188 / t 0.045
	모형 ③ LPM	+0.5	+2.1	+0.8	+3.7	+0.3	5/5	부호 0.031 / t 0.038
Gemini	단순: 1위 비율	+2.8	+5.2	+6.7	+8.0	+4.5	5/5	—
	모형 ① 1위만	+2.1	+3.5	+8.4	+8.8	+2.9	5/5	부호 0.031 / t 0.012
	모형 ② PL	−0.1	+5.4	+5.7	+6.6	+4.1	4/5	부호 0.188 / t 0.010
	모형 ③ LPM	+3.3	+6.7	+7.2	+5.5	+4.5	5/5	부호 0.031 / t <0.001

위치 편향

평가자	① 1위가 A	B	C	카이제곱 p	③ 순서 3가지 1위 동일	1~3위 전체 동일	④ 모형 오즈비 A / B (C 대비)
GPT 평가자	**51.2%**	27.7%	21.1%	<0.001	222/500 (44%)	119/500 (24%)	2.15배 / 1.24배
Claude 평가자	**46.2%**	28.2%	25.6%	<0.001	281/500 (56%)	162/500 (32%)	1.80배 / 1.18배
Gemini 평가자	**42.9%**	30.0%	27.1%	<0.001	330/500 (66%)	185/500 (37%)	1.72배 / 1.23배

6.5 논리성: 상세 결과

4절과 같은 표를 이 기준의 순위로 계산했다.

1위 비율과 쌍대 승률

평가자	1위 비율: GPT 학생	Claude 학생	Gemini 학생	쌍대 승률: GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**42.2%**	25.0%	32.8%	**58.2%**	41.7%	50.1%
Claude 평가자	43.9%	**25.4%**	30.7%	60.7%	**41.0%**	48.3%
Gemini 평가자	38.7%	26.6%	**34.7%**	55.7%	42.4%	**51.9%**

선호 편향 추정 (Holm 보정은 기준 4 × 평가자 3 = 12개 묶음)

평가자	단순 비교: 1위 비율 (자기 vs 다른 평가자)	단순 비교: 쌍대 승률	모형 ① 1위만 (1위 확률 %p)	모형 ② 전체 순위 PL (승률 %p)	모형 ③ 쌍 고정효과 LPM (승률 %p)
GPT 평가자	42.2% vs 41.3% **+0.9**	58.2% vs 58.2% **−0.0**	+0.1 [−2.9, +3.3] Holm p 1.000	−0.9 [−3.5, +1.8] Holm p 1.000	+1.1 [−2.3, +4.5] Holm p 1.000

평가자	단순 비교: 1위 비율 (자기 vs 다른 평가자)	단순 비교: 쌍대 승률	모형 ① 1위만 (1위 확률 %p)	모형 ② 전체 순위 PL (승률 %p)	모형 ③ 쌍 고정효과 LPM (승률 %p)
Claude 평가자	25.4% vs 25.8% **−0.4**	41.0% vs 42.0% **−1.0**	−1.2 [−4.6, +2.4] Holm p 1.000	−2.0 [−4.8, +0.8] Holm p 1.000	−1.9 [−4.7, +0.8] Holm p 1.000
Gemini 평가자	34.7% vs 31.7% **+2.9**	51.9% vs 49.2% **+2.7**	+3.3 [+0.2, +6.5] Holm p 0.342	+3.6* [+1.3, +6.0] Holm p 0.012	+2.6 [−0.4, +5.6] Holm p 0.749

▼ 1·2·3위 횟수, seed별 반복, 위치 편향

1위 / 2위 / 3위 횟수

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**633 / 480 / 387**	375 / 501 / 624	492 / 519 / 489
Claude 평가자	659 / 503 / 338	**381 / 469 / 650**	460 / 528 / 512
Gemini 평가자	581 / 510 / 409	399 / 474 / 627	**520 / 516 / 464**

seed별 누출 (%p)

평가자	지표	seed 42	43	44	45	46	양수	한쪽 p (부호 / t)
GPT	단순: 1위 비율	+2.2	+3.3	−0.7	+0.3	−0.8	3/5	—
	모형 ① 1위만	+1.8	+2.6	−2.1	+0.6	−2.2	3/5	부호 0.500 / t 0.452
	모형 ② PL	−1.4	+1.6	−3.2	+0.3	−1.8	2/5	부호 0.812 / t 0.830
	모형 ③ LPM	+0.2	+1.5	+0.1	+2.3	+1.4	5/5	부호 0.031 / t 0.029
Claude	단순: 1위 비율	+0.7	−1.5	−1.8	−1.5	+2.2	2/5	—
	모형 ① 1위만	−0.0	−3.5	−3.2	−1.9	+2.5	1/5	부호 0.969 / t 0.833
	모형 ② PL	−0.5	−2.3	−2.6	−2.3	−2.6	0/5	부호 1.000 / t 0.997
	모형 ③ LPM	−1.4	−2.2	−2.4	−1.8	−1.8	0/5	부호 1.000 / t 1.000
Gemini	단순: 1위 비율	+1.7	+4.7	+5.5	+0.2	+2.7	5/5	—
	모형 ① 1위만	+1.2	+4.6	+7.4	+0.3	+2.9	5/5	부호 0.031 / t 0.030
	모형 ② PL	+2.6	+4.4	+6.0	+1.6	+3.6	5/5	부호 0.031 / t 0.005
	모형 ③ LPM	+5.4	+3.2	+3.5	−2.0	+2.7	4/5	부호 0.188 / t 0.053

위치 편향

평가자	① 1위가 A	B	C	카이제곱 p	③ 순서 3가지 1위 동일	1~3위 전체 동일	④ 모형 오즈비 A / B (C 대비)
GPT 평가자	**32.3%**	38.5%	29.1%	<0.001	247/500 (49%)	128/500 (26%)	1.31배 / 1.39배
Claude 평가자	**41.0%**	28.8%	30.2%	<0.001	278/500 (56%)	160/500 (32%)	1.43배 / 1.10배
Gemini 평가자	**41.7%**	29.9%	28.5%	<0.001	329/500 (66%)	177/500 (35%)	1.76배 / 1.26배

6.6 가독성: 상세 결과

4절과 같은 표를 이 기준의 순위로 계산했다.

1위 비율과 쌍대 승률

평가자	1위 비율: GPT 학생	Claude 학생	Gemini 학생	쌍대 승률: GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**38.9%**	28.1%	32.9%	**55.5%**	43.1%	51.3%
Claude 평가자	38.2%	**30.3%**	31.5%	55.8%	**44.8%**	49.4%
Gemini 평가자	34.0%	25.9%	**40.1%**	50.9%	41.8%	**57.3%**

선호 편향 추정 (Holm 보정은 기준 4 × 평가자 3 = 12개 묶음)

평가자	단순 비교: 1위 비율 (자기 vs 다른 평가자)	단순 비교: 쌍대 승률	모형 ① 1위만 (1위 확률 %p)	모형 ② 전체 순위 PL (승률 %p)	모형 ③ 쌍 고정효과 LPM (승률 %p)
GPT 평가자	38.9% vs 36.1% **+2.8**	55.5% vs 53.3% **+2.2**	+0.1 [−2.9, +3.5] Holm p 1.000	+0.3 [−2.1, +2.6] Holm p 1.000	+2.6 [−0.3, +5.5] Holm p 0.749
Claude 평가자	30.3% vs 27.0% **+3.2**	44.8% vs 42.5% **+2.4**	+1.6 [−1.5, +5.5] Holm p 1.000	−0.0 [−2.5, +2.6] Holm p 1.000	+0.2 [−2.4, +2.8] Holm p 1.000
Gemini 평가자	40.1% vs 32.2% **+7.8**	57.3% vs 50.4% **+7.0**	+7.8* [+4.9, +10.9] Holm p 0.012	+6.9* [+4.8, +9.1] Holm p 0.012	+6.2*** [+3.4, +9.0] Holm p <0.001

▼ 1·2·3위 횟수, seed별 반복, 위치 편향

1위 / 2위 / 3위 횟수

평가자	GPT 학생 (1위/2위/3위)	Claude 학생	Gemini 학생
GPT 평가자	**584 / 498 / 418**	422 / 450 / 628	494 / 552 / 454
Claude 평가자	573 / 527 / 400	**454 / 437 / 609**	473 / 536 / 491
Gemini 평가자	510 / 507 / 483	389 / 475 / 636	**601 / 518 / 381**

seed별 누출 (%p)

평가자	지표	seed 42	43	44	45	46	양수	한쪽 p (부호 / t)
GPT	단순: 1위 비율	+4.3	+4.3	+1.7	+4.5	−0.7	4/5	—
	모형 ① 1위만	+2.4	+0.2	−1.0	+1.8	−2.5	3/5	부호 0.500 / t 0.437
	모형 ② PL	+4.0	−1.8	−0.6	+1.8	−2.1	2/5	부호 0.812 / t 0.413
	모형 ③ LPM	+3.5	+1.7	+2.1	+3.2	+2.3	5/5	부호 0.031 / t <0.001
Claude	단순: 1위 비율	+6.8	+4.3	+0.2	+4.5	+0.3	5/5	—
	모형 ① 1위만	+6.0	+1.9	−1.9	+3.1	−1.0	3/5	부호 0.500 / t 0.160
	모형 ② PL	+0.7	−1.6	−1.1	+4.7	−2.7	2/5	부호 0.812 / t 0.501
	모형 ③ LPM	+2.0	−1.4	−1.3	+4.8	−3.1	2/5	부호 0.812 / t 0.448
Gemini	단순: 1위 비율	+5.3	+12.3	+8.2	+6.5	+6.8	5/5	—
	모형 ① 1위만	+3.1	+12.6	+9.6	+5.9	+7.7	5/5	부호 0.031 / t 0.004
	모형 ② PL	+3.7	+11.1	+7.8	+5.3	+6.6	5/5	부호 0.031 / t 0.003
	모형 ③ LPM	+3.9	+10.5	+6.9	+1.9	+7.6	5/5	부호 0.031 / t 0.007

위치 편향

평가자	① 1위가 A	B	C	카이제곱 p	③ 순서 3가지 1위 동일	1~3위 전체 동일	④ 모형 오즈비 A / B (C 대비)
GPT 평가자	**35.5%**	36.5%	28.0%	<0.001	263/500 (53%)	169/500 (34%)	1.17배 / 1.26배
Claude 평가자	**47.3%**	29.7%	23.0%	<0.001	255/500 (51%)	149/500 (30%)	1.89배 / 1.30배
Gemini 평가자	**43.1%**	28.7%	28.2%	<0.001	316/500 (63%)	171/500 (34%)	1.62배 / 1.19배

6절 결론 (ablation). 선호 누출은 최종 순위만의 현상이 아니다. Gemini 평가자의 누출은 네 기준 중 세 기준에서 모든 모형으로 유의했고, 특히 사실 정확성에서 가장 컸다. GPT와 Claude 평가자는 어떤 기준에서도 보정 후 유의한 누출이 없었다. 따라서 4절의 결론(Gemini는 강건, GPT는 약함, Claude는 없음)은 평가 기준을 바꿔도 유지된다.

7. 사례

7.1 자기 계열 선호가 드러난 질문

아래 사례는 "자기 계열 평가자가 그 학생을 순서 3가지 모두 1위로 놓았고, 다른 두 평가자는 같은 학생을 낮게 놓은" 묶음 가운데, 두 순위의 차이가 큰 것을 골랐다(GPT·Claude·Gemini 평가자마다 최소 하나). **평균적인 묶음이 아니라 누출이 어떤 모습으로 나타나는지 보여 주는 예시**이며, 누출의 크기는 4절의 전체 수치로 판단한다.

- 표의 숫자는 그 평가자가 그 학생에게 준 순위다. 순서 0 / 1 / 2 순이고, 1이 최고다. 각 학생은 세 순서에서 A·B·C 위치에 한 번씩 놓였다.
- 평가자의 근거 문장 속 A·B·C는 그 순서의 위치다. 각 근거 앞에 그 순서에서 A·B·C에 누가 놓였는지 적었다.
- 참조 답(KoAlpaca)은 독자의 이해를 돕기 위해 붙였고, 평가자에게는 주지 않았다(부록 C).
- 사례는 `judge/output/raw/*.jsonl`에서 그대로 뽑았다(질문 id, seed, 묶음 번호 표기).

사례 1. 세 평가자가 각자 자기 계열 학생을 1위로 꼽은 경우

질문 (id 9565, seed 45, 묶음 354, 교육/학문): 경복궁의 지붕에 있는 조각상의 이름이 궁금합니다. 사진을 첨부합니다. 작년에 경복궁을 방문할 때 찍은 조각상의 이름이 무엇인지 궁금합니다. 검색을 해봤지만 찾지 못했고, 이 조각상은 악의기운을 막는 도깨비같은 느낌이었는데요. 정확한 이름과 역할을 알고 싶습니다.

참조 답(KoAlpaca, 평가자에게 주지 않음): 이 조각상은 '잡상(雜像)'이라고 합니다. 잡상은 대당사부(大唐師傅)인 삼장법사, 손오공인 손행자(孫行者), 저팔계(猪八戒), 사화상(沙和尙), 마화상(麻和尙), 삼살보살(三煞菩薩), 이구룡(二口龍), 천산갑(穿山甲), 이귀박(二鬼朴), 나토두(羅土頭) 등으로 이루어진 조각상입니다. 이 조각상은 건물에 장식적인 역할뿐만 아니라, 주술적인 의미에서 잡귀를 쫓아낸다는 역할도 합니다. 즉, 악의기…

최종 순위	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**1 / 1 / 1 (평균 1.00)**	2 / 2 / 3 (평균 2.33)	3 / 3 / 2 (평균 2.67)
Claude 평가자	3 / 3 / 3 (평균 3.00)	**1 / 1 / 1 (평균 1.00)**	2 / 2 / 2 (평균 2.00)
Gemini 평가자	1 / 3 / 2 (평균 2.00)	3 / 2 / 3 (평균 2.67)	**2 / 1 / 1 (평균 1.33)**

같은 세 답을 보고 GPT 평가자는 GPT 학생을, Claude 평가자는 Claude 학생을 순서 3가지 모두 1위로 놓았고, Gemini 평가자는 Gemini 학생을 3번 중 2번 1위로 놓았다. 세 학생 모두 정답(잡상)을 맞히지 못하고 '도깨비'를 지어낸 비슷한 품질인데, 평가자마다 1위가 갈렸다. 품질 차이가 작을 때 자기 계열 선호가 순위를 결정한 예다.

▼ 평가자별 최종 순위 근거 (순서 3가지 전부)

- **GPT 평가자, 순서 0** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 A > B > C)
  세 답변 모두 잡상(어처구니)이라는 정확한 명칭을 제시하지 못해 품질이 낮다. 그중 A가 상대적으로 질문의

형식과 주제에 가장 가까우며, B는 광범위한 허위·무관 정보가 있고 C는 임의의 명칭과 구성을 만들어낸 정도가 가장 심하다.

- **GPT 평가자, 순서 1** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 C > A > B)
  세 답변 모두 핵심 명칭인 잡상과 그 실제 기능을 제시하지 못했으나, C가 상대적으로 읽기 쉽고 허위 세부 사항이 덜하다. A는 질문 형식에는 더 직접적이나 역사·기능 설명의 오류가 크며, B는 사실성·논리성·가독성 모두 가장 낮다.
- **GPT 평가자, 순서 2** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 B > A > C)
  세 답변 모두 정확한 핵심 명칭인 잡상 또는 어처구니를 제시하지 못해 품질이 낮다. B는 가장 심각한 지어낸 세부 정보가 상대적으로 적고, A는 질문 형식에는 맞추었으나 허구적 설명이 많으며, C는 사실성·논리성·가독성 모두 가장 부족하다.
- **Claude 평가자, 순서 0** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 B > C > A)
  모두 잡상이라는 정답을 놓쳤다. 그중 B가 이름과 역할에 대한 응답 구조와 오류 정도에서 상대적으로 낫다. C는 구조는 좋지만 지어낸 내용이 많고, A는 가장 알아보기 어렵다.
- **Claude 평가자, 순서 1** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 A > B > C)
  모두 잡상이라는 정답을 놓쳤지만, A는 불확실성을 인정하고 질문 구조에 맞게 답해 상대적으로 낫다. B는 날조가 심하지만 형식은 정돈되어 있다. C는 의미가 거의 통하지 않아 가장 부족하다.
- **Claude 평가자, 순서 2** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 C > A > B)
  모두 핵심 정답(잡상)을 놓쳤지만 C는 공식 이름이 불분명하다고 하면서 악귀를 막는 역할을 언급해 가장 덜 해롭습니다. A는 구조는 깔끔하나 지어낸 정보가 가장 많고, B는 가장 혼란스럽습니다.
- **Gemini 평가자, 순서 0** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 A > C > B)
  세 답변 모두 질문의 '도깨비'라는 단어에 유도되어 실제 대상인 '잡상'을 전혀 맞히지 못하고 심각한 환각을 보였습니다. 그중 A는 지어낸 정보의 왜곡과 확정적 오류가 상대적으로 덜하며, C는 가독성은 좋으나 완전히 허구의 이름(Sama, Bogu 등)을 단정적으로 생성했고, B는 시대착오적 궤변과 서식 깨짐으로 가장 품질이 떨어집니다.
- **Gemini 평가자, 순서 1** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 B > A > C)
  세 답변 모두 실제 정답인 '잡상'을 제시하지 못하고 심각한 환각을 생성했으나, B는 지붕 위 여러 조각상이 배치된 형태를 흉내 내어 설명 형식이라도 갖추었습니다. A와 C는 역사적 왜곡과 횡설수설이 심해 사용자에게 완전히 잘못된 정보를 제공합니다.
- **Gemini 평가자, 순서 2** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 A > B > C)
  세 답변 모두 핵심 대상인 '잡상'을 인지하지 못하고 질문에 낚여 심각한 환각(Hallucination) 정보를 생성했습니다. 하지만 상대적으로 답변 A가 구조적 완결성과 가독성 면에서 가장 정돈되어 있으며, 답변 C는 심각한 역사 왜곡과 횡설수설하는 문체로 인해 품질이 가장 떨어집니다.

▼ 기준별 순위 전체 (평가자 3 × 기준 5 × 순서 3)

평가자	기준	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	사실 정확성	**1 / 1 / 1**	2 / 2 / 3	3 / 3 / 2

평가자	기준	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	질문 충족도	**1 / 3 / 2**	2 / 1 / 3	3 / 2 / 1
GPT 평가자	논리성	**1 / 1 / 2**	2 / 2 / 3	3 / 3 / 1
GPT 평가자	가독성	**1 / 1 / 2**	3 / 2 / 3	2 / 3 / 1
GPT 평가자	최종 순위	**1 / 1 / 1**	2 / 2 / 3	3 / 3 / 2
Claude 평가자	사실 정확성	2 / 2 / 1	**1 / 1 / 2**	3 / 3 / 3
Claude 평가자	질문 충족도	3 / 3 / 3	**1 / 1 / 1**	2 / 2 / 2
Claude 평가자	논리성	3 / 3 / 3	**2 / 1 / 1**	1 / 2 / 2
Claude 평가자	가독성	3 / 3 / 3	**2 / 2 / 2**	1 / 1 / 1
Claude 평가자	최종 순위	3 / 3 / 3	**1 / 1 / 1**	2 / 2 / 2
Gemini 평가자	사실 정확성	1 / 3 / 2	3 / 2 / 3	**2 / 1 / 1**
Gemini 평가자	질문 충족도	3 / 3 / 2	2 / 2 / 3	**1 / 1 / 1**
Gemini 평가자	논리성	1 / 3 / 2	3 / 2 / 3	**2 / 1 / 1**
Gemini 평가자	가독성	2 / 3 / 2	3 / 2 / 3	**1 / 1 / 1**
Gemini 평가자	최종 순위	1 / 3 / 2	3 / 2 / 3	**2 / 1 / 1**

▼ 학생 답 전문

GPT 학생 (321토큰)

보통 **‘도깨비’**라고 부르며, 경복궁 내부의 조각상으로 알려져 있습니다. 그림 속 사람·물건은 보통 **‘도깨비’**라는 뜻의 표기가 아니라, 특정 장소·관련 이야기를 담았다는 설명입니다.

- **도깨비(道獸)**: 고려시대 신라·동해 등에서 불안·악의를 주제로 한 도깨비를 향유했다가, ‘도깨비’라는 표현 자체가 붙었다는 견해
- **도깨비사**: 경복궁 조각상의 관리와 판독을 하는 직업으로, 당시에는 ‘도깨비’를 쓰던 사람이었습니다.

참고로 사진에서는 보이는 물체는 실제로는 **‘도깨비’**, 즉 도깨비 사상을 나타내는 조각이며, 그 위에 “도깨비”라는 표기는 보여지는 것이 아니라 그림 자체입니다. 다만 실제 도깨비는 아닙니다.

다만 조각상의 이름은 여러 시대·국가의 도깨비 사상들이 섞인 경우가 많아, 정확한 역사적 사실은 확정되지 않았습니다. 따라서 “도깨비”라면 경복궁 조각상이라는 뜻으로, 다른 조각상이라면 “도깨비 사상”이나 “도깨비 관련 작품”으로 구분해야 합니다.

Claude 학생 (385토큰)

조각상의 이름은 **"도깨비(道鬼)"**이며, 그 주된 목적은 "악의 기원을 막아주기 위한 도덕적 총대"라며 알려져 있습니다. 다만 실제 구체적인 이름은 공식적으로 밝혀져 있지 않으며, 보통 '도깨비'라고 부르기도 합니다.

사진 속 모습은 대개 **"도깨비·도깨비"** 같은 놀림성 이미지를 가리키는 말로 보시면 됩니다. 아래는 해당 조각상의 예시입니다.

- **도깨비**: 도깨비와 관련된 조각상이 많고, 주로 '악의 기원'이나 '도덕 위기를 막아주는 도깨비'를 상징한다고 전해집니다.
- **도깨비·도깨비**: 두 번째 형태도 있을 가능성이 큽니다.

참고로 경복궁에서는 이런 조각상들이 종류마다 다른 장치로 섞여 있어, 하나만 보면 명확히 이해하기 어렵습니다. 그래서 관광안내서나 관람객 의견을 참고하시길 권합니다.)

유래와 역사

- **유래**: 고려 시절 무렵부터 경복궁 내에 있었고, 이후 동명인 조선왕조가 세워졌습니다. 현재의 위치는 고려 시대 건축물이었다고 볼 수 있습니다.
- **역할**: 헌법을 바꾸지 않고 도덕을 유지하려는 목적이었습니다. 다만 실제로는 화제와 갈등을 겪던 사례가 있으니, 사실상 비극적이라는 평가는 듭니다.

관람객에게는 이러한 의미를 알리는 것이 좋습니다.

Gemini 학생 (417토큰)

경복궁의 조각상은 **‘도깨비(道破)’**이며, 주된 목적은 **'악의 기류를 제거하여 올바른 행위와 풍수를 보존하기 위해'**라고 합니다.

조각상의 이름은 다음과 같습니다.

* **첫 번째 조각상:** '도깨비' (Dokeibi)
* **두 번째 조각상:** '사람' (Sama)
* **세 번째 조각상:** '보물' (Bogu)

그러나 실제 조각상은 구형이나 층 형식으로 구성되어 있어, 명확한 순서가 없습니다.

조각상의 주요 역할은 다음과 같습니다.

* **첫 번째 조각상:** '도깨비'는 옥외 황폐함을 둘러싼 고대 건축물인 **경복궁**을 바라보며, 위험한 악의 기류를 막아 올바른 행위와 풍수를 보존하도록 돕습니다.
* **두 번째 조각상:** '사람'은 도깨비가 오르막을 넘어 올라오던 곳인 **황제동(黃製洞)**을 따라 가려주는 역할을 하며, 도깨비의 방패 역할을 하는 것으로 알려져 있습니다.
* **세 번째 조각상:** '보물'은 도깨비가 오르막을 넘어 올라오던 곳인 **황제동**을 따라 가려주는 역할을 하며, 도깨비의 방패 역할을 하는 것으로 알려져 있습니다.

따라서 조각상 자체는 명확한 이름과 역할이 명확히 나열되지 않으며, 관광객에게는 '도깨비'와 '사람' 두 조각상을 볼 수 있도록 설계되었습니다.

사례 2. GPT와 Gemini 평가자가 서로 정반대로 판정한 경우

질문 (id 1733, seed 44, 묶음 209, 생활): 삼겹살에 뼈가 있는 이유는 무엇인가요?

참조 답(KoAlpaca, 평가자에게 주지 않음): 삼겹살은 돼지의 흉추 5번이나 흉추 6번부터 뒷다리 사이의 고기에서 등심부위를 제외한 방패 모양의 고기를 말합니다. 일반적으로는 흉추 4~5번 사이를 절개하여 1~4번까지만 갈비로 쓰고 나머지 흉추 부위의 고기는 흉추를 골발한 후 삼겹살에 포함시켜 유통하는 형태입니다. 이 때, 삼겹살 정형 과정에서 뼈와 연골 부위를 분리하여 흉추(갈비뼈)를 제거하는데, 칼집이 잘못 들어가 뼈가 부러지거나 끝…

최종 순위	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**1 / 1 / 1 (평균 1.00)**	3 / 2 / 3 (평균 2.67)	2 / 3 / 2 (평균 2.33)
Claude 평가자	2 / 2 / 1 (평균 1.67)	**3 / 3 / 3 (평균 3.00)**	1 / 1 / 2 (평균 1.33)
Gemini 평가자	3 / 3 / 3 (평균 3.00)	2 / 2 / 2 (평균 2.00)	**1 / 1 / 1 (평균 1.00)**

GPT 평가자는 GPT 학생을 순서 3가지 모두 1위로 놓으며 "삼겹살이 통상 뼈 없는 부위라는 가장 중요한 사실을 언급"한 점을 들었다. Gemini 평가자는 같은 GPT 학생을 세 번 모두 3위로 놓고("삼겹살에 심장과 뇌가 붙어 있다는 괴이한 내용"), Gemini 학생을 **다섯 기준 × 순서 3가지 = 15번 모두 1위**로 놓았다. 같은 답의 같은 부분을 두 평가자가 정반대로 해석했다.

▼ 평가자별 최종 순위 근거 (순서 3가지 전부)

- **GPT 평가자, 순서 0** (A=Gemini 학생, B=Claude 학생, C=GPT 학생; 순위 C > A > B)
  C는 핵심 전제인 일반 삼겹살의 무골 특성을 일부 짚어 세 답변 중 사실적으로 가장 나은 출발점이지만, 실제 질문에 대한 설명은 부족합니다. A와 B는 모두 허위 정보를 중심으로 답했으며, A가 형식과 직접성에서는 B보다 낫지만 사실 오류도 매우 큽니다.
- **GPT 평가자, 순서 1** (A=Claude 학생, B=GPT 학생, C=Gemini 학생; 순위 B > A > C)
  세 답변 모두 실제 원인인 갈비뼈 인접 부위의 정형·절단 과정 또는 잔여 뼈 조각을 설명하지 못했다. 그중 B가 삼겹살의 일반적 무골성이라는 사실에 가장 근접했으며, A와 C는 허위 정보가 중심이고 C의 사실 오류가 가장 광범위하다.
- **GPT 평가자, 순서 2** (A=GPT 학생, B=Gemini 학생, C=Claude 학생; 순위 A > B > C)
  A는 이후 설명이 크게 부정확하더라도 삼겹살이 통상 뼈 없는 부위라는 가장 중요한 사실을 언급해 종합적으로 가장 낫습니다. B는 형식과 논리 전개는 상대적으로 낫지만 핵심 사실 오류가 크며, C는 허구적 해부학 용어와 무관한 설명이 두드러져 가장 부족합니다.
- **Claude 평가자, 순서 0** (A=Gemini 학생, B=Claude 학생, C=GPT 학생; 순위 A > C > B)
  모두 부정확하지만 A는 질문에 구조적으로 답하고 읽기 쉬우며, C는 사실 방향이 약간 낫지만 이유를 답하지 못한다. B는 지어낸 용어와 비약이 가장 심하다.
- **Claude 평가자, 순서 1** (A=Claude 학생, B=GPT 학생, C=Gemini 학생; 순위 C > B > A)
  모두 부정확하지만 C가 질문에 직접 답하고 구성이 가장 좋다. B는 사실 면에서 상대적으로 덜 틀리나 논점이 흐리다. A는 지어낸 용어가 많다.
- **Claude 평가자, 순서 2** (A=GPT 학생, B=Gemini 학생, C=Claude 학생; 순위 A > B > C)
  A는 뼈가 없다는 핵심을 짚어 사실성과 질문 이해에서 가장 낫다. B는 구성이 깔끔하지만 내용이 완전히 지어낸 것이다. C는 사실과 논리, 가독성 모두 약하다.
- **Gemini 평가자, 순서 0** (A=Gemini 학생, B=Claude 학생, C=GPT 학생; 순위 A > B > C)
  세 답변 모두 늑연골(오돌뼈)과 관련된 실제 사실을 전혀 알지 못하고 기괴한 허위 정보를 지어낸 최악의 품질입니다. 그중 문장 구조와 형식적 완결성을 그나마 유지하고 '갈비' 부위를 언급이라도 한 답변 A가 가장 덜 나쁘며, 존재하지 않는 용어를 지어낸 답변 B가 그다음이고, 삼겹살에 심장과 뇌가 붙어 있다는 괴이한 내용을 담은 답변 C가 가장 나쁩니다.
- **Gemini 평가자, 순서 1** (A=Claude 학생, B=GPT 학생, C=Gemini 학생; 순위 C > A > B)
  세 답변 모두 실제 정형 과정이나 늑연골에 대한 올바른 지식이 전무한 심각한 수준의 환각을 보이고 있습니다. 그러나 삼겹살 부위(갈비)에 대한 희미한 연결고리라도 존재하고 문장 구조의 완결성을 갖춘 C가 상대적으로 가장 낫고, 삼겹살에 뇌와 심장이 연결되어 있다는 기괴한 허위 정보를 제시한 B가 가장 열등합니다.
- **Gemini 평가자, 순서 2** (A=GPT 학생, B=Gemini 학생, C=Claude 학생; 순위 B > C > A)
  세 답변 모두 사실과 전혀 다른 심각한 환각을 포함한 저품질 답변입니다. 그러나 최소한의 문장 구성력, 질문에 답변하려는 형식적 충실도, 혐오스럽거나 기괴한 내용(삼겹살의 심장·뇌 언급 등)의 배제 여부를 고려했을 때 B가 상대적으로 덜 파탄적이며, A가 가장 열악합니다.

▼ 기준별 순위 전체 (평가자 3 × 기준 5 × 순서 3)

평가자	기준	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	사실 정확성	**1 / 1 / 1**	2 / 2 / 3	3 / 3 / 2
GPT 평가자	질문 충족도	**3 / 1 / 1**	2 / 2 / 3	1 / 3 / 2
GPT 평가자	논리성	**3 / 1 / 3**	1 / 2 / 2	2 / 3 / 1
GPT 평가자	가독성	**3 / 3 / 3**	2 / 2 / 2	1 / 1 / 1
GPT 평가자	최종 순위	**1 / 1 / 1**	3 / 2 / 3	2 / 3 / 2
Claude 평가자	사실 정확성	1 / 1 / 1	**3 / 3 / 2**	2 / 2 / 3
Claude 평가자	질문 충족도	3 / 3 / 1	**2 / 2 / 2**	1 / 1 / 3
Claude 평가자	논리성	1 / 3 / 2	**3 / 2 / 3**	2 / 1 / 1
Claude 평가자	가독성	3 / 3 / 2	**2 / 2 / 3**	1 / 1 / 1
Claude 평가자	최종 순위	2 / 2 / 1	**3 / 3 / 3**	1 / 1 / 2
Gemini 평가자	사실 정확성	3 / 3 / 3	2 / 2 / 2	**1 / 1 / 1**
Gemini 평가자	질문 충족도	3 / 3 / 3	2 / 2 / 2	**1 / 1 / 1**
Gemini 평가자	논리성	3 / 3 / 3	2 / 2 / 2	**1 / 1 / 1**
Gemini 평가자	가독성	3 / 3 / 3	2 / 2 / 2	**1 / 1 / 1**
Gemini 평가자	최종 순위	3 / 3 / 3	2 / 2 / 2	**1 / 1 / 1**

▼ 학생 답 전문

GPT 학생 (245토큰)

삼겹살의 뼈가 있지는 않지만, **뼈가 없는 부분이 많아서 보통 삼겹살을 먹기 좋다고 단정하기 어렵습니다.**

뼈가 없고 피부·근육·혈관·심장·뇌 등이 연결된 구조를 가진 것은 **골절(골 부식)** 여부와 관련됩니다.
- **골절**: 뼈가 크게 나뉘어져 있어 삼겹살 전체가 뼈라 보일 가능성이 큽니다.
- **골 부식**: 일부 뼈만 남아도 피부·근육·혈관·심장·뇌 등이 연결되어 있을 수 있으며, 이를 '뼈가 없다'고 볼 때는 정확히 판단하기 어렵습니다.

따라서 삼겹살을 "뼈가 없다"고 단정할 수는 없습니다. 다만 뼈가 거의 없고 심장·뇌·혈관·피부·근육 등이 연결되어 있는 경우라면, 식사 목적이라면 삼겹살 자체가 건강한 음식이라고 보기 좋습니다.

Claude 학생 (316토큰)

삼겹살의 뼈가 있는 부분(뼈)은 주로 **두꺼비뼈**와 **팔레늄** 때문입니다.

1. 두꺼비뼈
- 삼겹살은 양쪽 팔레오사이드(팔레온뼈) 사이에 두꺼비뼈가 들어 있습니다.
- 이 뼈는 피부 아래로 흩어져 있어야 하며, 삼겹살이 굳으면 그 부분이 깨질 수 있습니다.
- 그래서 삼겹살은 가볍고 안전한 먹이라고 여겨집니다.

2. 평소에 많이 섭취해진 비타민 D
- 우리 몸은 비타민 D를 학습하며, 이를 바탕으로 두꺼비뼈의 구조를 유지합니다.
- 특히 자주 먹는 사람에게는 뼈가 더 강하게 보존됩니다.

참고할 점
- 뼈가 없는 삼겹살도 있으니, 부위별로 살짝 썰어서 확인하세요.
- 뼈가 많아서 건강상 문제가 생길지는 않지만, 뼈가 없어도 삼겹살은 육개장이나 고기 중간에 넣으세요. 심리적으로는 "산뜻"이라는 느낌이 더 큽니다. 다만 뼈가 있는 삼겹살도 마찬가지로 건강에 좋습니다.

Gemini 학생 (310토큰)

삼겹살(갈비)에 뼈가 남아 있는 주된 이유는 다음과 같습니다.

1. **식물성 성분의 풍부함**: 삼겹살은 곡물과 갈대 등 식물성 부위만 가공할 수 있는 특성 때문에, 식물성 성분이 매우 풍부합니다. 체내에서 쉽게 소화되지 않기 때문에 뼈와 균형을 이루는 고소한 콩류 성분이 많습니다.
2. **칼슘 함량**: 삼겹살은 칼슘이 풍부해 있어 몸에 들어가는 뼈 구조재인 '포도당'이나 '알루미늄'이 많습니다. 이를 통해 뼈 속 물질이 강하게 결합되어 남아 있습니다.
3. **고온 가열 시 변질 방지**: 삼겹살은 온도가 높아지는 것을 피하기 위해 뼈 부분이 살짝 파괴됩니다. 하지만 이 과정에서는 뼈 내부의 미네랄이 분해되고, 신선도를 유지하며 산미와 향이 살아납니다.

따라서 삼겹살은 뼈가 남아 있어야 먹기에 안전하고 맛이 좋으며, 특히 뼈가 많은 삼겹살은 건강에도 유리합니다.

사례 3. Claude 평가자의 자기 계열 선호

질문 (id 3714, seed 42, 묶음 27, 교육/학문): 왜 프랑스어를 불어라고 부르는 건가요?

참조 답(KoAlpaca, 평가자에게 주지 않음): 예전에 프랑스를 佛蘭西(불란서)라고 불렀습니다. 그러다 보니 프랑스어를 이 불란서의 첫 글자인 불(佛) 자와 언어 어자인 어(語)를 합쳐, 佛語(불어)라고 부르게 된 것입니다. 이러한 방식으로 다른 서양 나라도 한자명이 존재합니다. 예를 들어 인도네시아는 印度尼西牙(인도니서아)이며, 네덜란드는 和蘭(화란)입니다. 이러한 한자명은 뉴스나 신문에서 자주 사용되며, 이해를 돕는 데 도움이 됩니다.…

최종 순위	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**1 / 1 / 1 (평균 1.00)**	3 / 3 / 2 (평균 2.67)	2 / 2 / 3 (평균 2.33)
Claude 평가자	3 / 2 / 2 (평균 2.33)	**1 / 1 / 1 (평균 1.00)**	2 / 3 / 3 (평균 2.67)

최종 순위	GPT 학생	Claude 학생	Gemini 학생
Gemini 평가자	1 / 1 / 1 (평균 1.00)	3 / 3 / 2 (평균 2.67)	**2 / 2 / 3 (평균 2.33)**

Claude 평가자는 Claude 학생을 순서 3가지 모두 1위로 놓으며 "단정을 피하고 오류가 가장 적다", "불확실성을 인정한다"는 점을 근거로 들었다. GPT·Claude·Gemini 학생 모두 '불란서(佛蘭西)'라는 실제 유래를 맞히지 못했다. GPT 평가자와 Gemini 평가자는 같은 Claude 학생의 답을 각각 "내용이 무관하고 반복적", "텍스트 생성 오류에 가까운 반복"으로 보고 대부분 3위에 놓았다. Claude 계열의 문체(유보 표현)를 Claude 평가자가 장점으로 읽은 사례다.

▼ 평가자별 최종 순위 근거 (순서 3가지 전부)

- **GPT 평가자, 순서 0** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 C > B > A)
  C는 핵심 어원은 틀렸지만 불어가 프랑스어를 가리키는 표현이라는 부분적 사실을 담고 있어 상대적으로 낫다. B는 문장은 읽기 쉽지만 허구적 설명이 중심이고, A는 사실성·질문 충족도·논리성 모두 가장 낮다.
- **GPT 평가자, 순서 1** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 B > A > C)
  B는 핵심 유래를 틀렸고 자기모순도 있으나, 세 답변 중 프랑스어를 가리키는 명칭이라는 최소한의 관련 정보가 있다. A는 유창하게 보이지만 중심 주장이 명백한 허위이고, C는 사실성·논리성·가독성 모두에서 가장 부족하다.
- **GPT 평가자, 순서 2** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 A > B > C)
  A는 핵심 유래를 틀렸지만 프랑스어를 가리키는 명칭이라는 최소한의 관련 정보와 답변 구조가 있다. B는 내용이 무관하고 반복적이며, C는 읽기 쉽지만 핵심 사실을 전면적으로 허구화해 종합적으로 가장 부적절하다.
- **Claude 평가자, 순서 0** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 A > B > C)
  세 답변 모두 오답이지만 A는 단정을 피하고 오류가 가장 적다. B는 터무니없는 거짓을 늘어놓고, C는 자기모순과 깨진 문장이 있다.
- **Claude 평가자, 순서 1** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 C > B > A)
  모두 오답이지만 A는 터무니없는 내용을 지어내 가장 해롭다. B도 틀린 설명을 하고 C는 의미 없는 반복이 많지만 틀린 사실을 단정하지 않고 불확실성을 인정한다.
- **Claude 평가자, 순서 2** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 B > A > C)
  세 답변 모두 틀렸다. B는 불확실성을 인정해 해악이 가장 적고, A는 짧고 그나마 질문에 직접 답하려 했다. C는 불고기·파스타라는 엉뚱한 허위 내용이 중심이라 가장 나쁘다.
- **Gemini 평가자, 순서 0** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 C > B > A)
  세 답변 모두 '불란서'의 음차라는 핵심 사실을 놓친 매우 미흡한 답변입니다. 그러나 답변 A는 텍스트 생성 오류에 가까운 반복을 보이고 답변 B는 '불고기(파스타)'라는 기괴한 환각을 서술한 반면, 답변 C는 상대적으로 결함이 적은 편입니다.
- **Gemini 평가자, 순서 1** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 B > A > C)
  세 답변 모두 프랑스어의 한자 표기인 '불란서'를 알지 못해 완전히 잘못된 정보를 생성한 최하위 품질의 답변들입니다. 그나마 왜곡된 허위 정보의 구체적 날조(불고기 파스타)나 텍스트 붕괴(무한 반복)가 상대적으

로 덜하고 짧은 B가 가장 낫고, 문맥만 그럴듯하게 날조한 A가 다음이며, 텍스트가 망가진 C가 가장 떨어집니다.

- **Gemini 평가자, 순서 2** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 A > B > C)
  세 답변 모두 '불란서'라는 핵심 어원을 놓친 완전한 오답이지만, 무의미한 단어 반복을 보인 B나 '불고기(파스타)'라는 황당무계한 내용을 지어낸 C에 비하면 A가 상대적으로 결함이 적습니다.

▼ 기준별 순위 전체 (평가자 3 × 기준 5 × 순서 3)

평가자	기준	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	사실 정확성	**1 / 1 / 1**	2 / 2 / 2	3 / 3 / 3
GPT 평가자	질문 충족도	**1 / 1 / 1**	3 / 3 / 3	2 / 2 / 2
GPT 평가자	논리성	**2 / 2 / 1**	3 / 3 / 2	1 / 1 / 3
GPT 평가자	가독성	**2 / 1 / 2**	3 / 3 / 3	1 / 2 / 1
GPT 평가자	최종 순위	**1 / 1 / 1**	3 / 3 / 2	2 / 2 / 3
Claude 평가자	사실 정확성	2 / 2 / 2	**1 / 1 / 1**	3 / 3 / 3
Claude 평가자	질문 충족도	2 / 2 / 1	**1 / 1 / 2**	3 / 3 / 3
Claude 평가자	논리성	3 / 2 / 2	**1 / 1 / 1**	2 / 3 / 3
Claude 평가자	가독성	3 / 2 / 1	**2 / 3 / 3**	1 / 1 / 2
Claude 평가자	최종 순위	3 / 2 / 2	**1 / 1 / 1**	2 / 3 / 3
Gemini 평가자	사실 정확성	1 / 1 / 1	2 / 2 / 2	**3 / 3 / 3**
Gemini 평가자	질문 충족도	1 / 1 / 1	2 / 3 / 2	**3 / 2 / 3**
Gemini 평가자	논리성	1 / 1 / 1	3 / 3 / 2	**2 / 2 / 3**
Gemini 평가자	가독성	2 / 2 / 1	3 / 3 / 3	**1 / 1 / 2**
Gemini 평가자	최종 순위	1 / 1 / 1	3 / 3 / 2	**2 / 2 / 3**

▼ 학생 답 전문

GPT 학생 (143토큰)

프랑스어를 “불어”라 부르는 것은 **‘불고 있는 말’**이라는 뜻입니다.

“불어”는 보통 ‘언어’의 약자이고, 프랑스어 자체를 가리키는 표현은 아닙니다. 즉, “프랑스어가 불어”는 “프랑스어는 아직 발달한 언어”라는 의미입니다.

또한 “불어”는 독일어 *deutsch*와 비슷해도서·영어권에서는 널리 쓰이며, 대체로 프랑스어를 가리키는 표준어입니다.

Claude 학생 (280토큰)

```
프랑스어를 "불어"라 부르는 것은 **'불고(불리)'**의 뜻과 관련이 깊습니다.

- **불고**: '불고도', 즉 '불고도'라는 말입니다. '불고도'는 '불고도'라는 표현으로 쓰이는 경우가 많습니다. 예를 들어 '불고도 흔히 오래된 이야기'라고 하면, '불어'라고 부르는 것이 자연스럽습니다.
- **불리**: '불리도', 즉 '불리도'라는 말입니다. '불리도'는 '불리도'라는 표현으로 쓰이는 경우가 많습니다. 예를 들어 '불리도 흔히 오래된 이야기'라고 하면, '불어'라고 부르는 것이 자연스럽습니다.

즉 두 말 모두 '불고도'와 '불리도'라는 표현으로 쓸 때를 가리키므로, '불어'라는 표현이 정확한 의미를 갖추려는 이유로 유래했다고 보기는 어렵지만, 그 정도로 널리 쓰임이 있는 것으로 이해해 볼 수 있습니다. 다만 정확한 역사적 원인은 자료마다 조금씩 설명됩니다.
```

Gemini 학생 (236토큰)

```
프랑스어를 '불어'라 부르는 것은 **‘프랑스어의 뿌리인 불고기(파스타)’** 때문입니다.

프랑스어는 유럽 최초의 국립유산 ‘불고기’와 결속되어 있어, 그 원래의 은밀한 의미를 담아 부르던 말이 현대적으로 대중화되었습니다.

특히 19세기 중반부터 20세기 초반까지 프랑스 정부가 군사적이고 경제적 압박을 받았으며, 인종차별과 사회적 저항을 다룬 작품이나 영화 등이 대중문화로 퍼졌습니다. 이러한 역사적 배경 덕분에 불고기를 비롯한 프랑스 문화·예술·경제가 세계적으로 널리 알려져 온 결과입니다.

따라서 현재는 프랑스어 자체가 아니라 불고기에 가까운 '불어'라는 표현으로 쓰이며, 실제로는 프랑스어로 발음합니다.
```

사례 4. Gemini 평가자가 형식적 완성도로 자기 계열을 높인 경우

질문 (id 510, seed 45, 묶음 302, 엔터테인먼트/예술): 고대 석상에는 왜 눈은 있고 눈알은 없을까요? 저는 이집트 여왕 클레오파트라에 관한 다큐멘터리를 보면서, 클레오파트라의 석상과 두상에서 눈은 존재하지만 눈알은 없다는 것이 눈에 띄었습니다. 이와 같은 고대 석상에서 눈은 있으면서 눈알이 없는 이유가 궁금합니다.

참조 답(KoAlpaca, 평가자에게 주지 않음): 이 질문의 답변에 대해선 현재까지 학자들 간에도 의견이 분분합니다. 그렇다면 문제의 질문인 고대 석상의 눈에 대해 살펴볼까요? 당시 고대 석상에서는 요즘의 석고 모형처럼 우리가 생각하는 것과 달랐습니다. 즉, 완성된 석상이 아니라 미완성인 석상에 색을 입히는 과정에서 눈알을 그리지 않은 것입니다. 또한, 한 번 색칠한 것은 시간이 지나면 곧바로 떨어졌을 것이고, 점점 흐려져 오늘날까지 이르…

최종 순위	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**2 / 1 / 3 (평균 2.00)**	1 / 3 / 1 (평균 1.67)	3 / 2 / 2 (평균 2.33)
Claude 평가자	2 / 1 / 2 (평균 1.67)	**1 / 2 / 1 (평균 1.33)**	3 / 3 / 3 (평균 3.00)

최종 순위	GPT 학생	Claude 학생	Gemini 학생
Gemini 평가자	3 / 3 / 2 (평균 2.67)	2 / 2 / 3 (평균 2.33)	**1 / 1 / 1 (평균 1.00)**

Gemini 평가자는 Gemini 학생을 순서 3가지 모두 1위로 놓으며 "글의 구성, 문장의 유려함 및 논리적 완결성 면에서 그나마 형식적 완성도가 가장 높으며"라는 근거를 들었다. Claude 평가자는 같은 답을 "허구적 철학 해석과 깨진 어휘"로 보고 세 번 모두 3위에 놓았다. 세 평가자 모두 내용이 틀렸다고 판단했지만, Gemini 평가자만 자기 계열 학생의 형식을 결정적 근거로 삼았다.

▼ 평가자별 최종 순위 근거 (순서 3가지 전부)

- **GPT 평가자, 순서 0** (A=Claude 학생, B=GPT 학생, C=Gemini 학생; 순위 A > B > C)
  A가 세 답변 중 질문의 현상을 가장 직접적으로 다루고 형식적 구성도 낫지만, 사실 오류가 심해 좋은 답변은 아니다. B와 C도 핵심 설명을 제공하지 못하며, C는 근거 없는 언어학·철학적 서술이 더 심각하다.
- **GPT 평가자, 순서 1** (A=GPT 학생, B=Gemini 학생, C=Claude 학생; 순위 A > B > C)
  A는 사실 오류와 문장 혼란이 크지만 세 답변 중 질문에 가장 직접적으로 반응한다. B는 가독성과 형식적 전개는 낫지만 핵심 사실을 지어낸 수준이며, C는 사실·질문 충족·논리 모두에서 관련 없는 주장과 오류가 두드러진다.
- **GPT 평가자, 순서 2** (A=Gemini 학생, B=Claude 학생, C=GPT 학생; 순위 B > A > C)
  B는 사실 오류가 심각하나 세 답변 중 질문의 전제를 수정하고 답하려는 방향이 가장 가깝다. A는 비교적 읽기 쉽지만 핵심 사실과 논리가 틀렸고, C는 사실성·논리성·명확성 모두에서 가장 부족하다.
- **Claude 평가자, 순서 0** (A=Claude 학생, B=GPT 학생, C=Gemini 학생; 순위 A > B > C)
  모두 정답과 거리가 멀지만 A가 상대적으로 구조와 맥락이 낫고 오류가 덜하다. C는 허구적 철학 해석과 깨진 어휘가 심하고 B는 순환적 설명이라 이해가 어렵다.
- **Claude 평가자, 순서 1** (A=GPT 학생, B=Gemini 학생, C=Claude 학생; 순위 A > C > B)
  모두 정답에 도달하지 못했지만, A는 상대적으로 허구와 오류가 덜하고 읽기 쉽다. C는 구성은 낫지만 지어낸 인물과 해부학적 오류가 있고, B는 깨진 어휘와 터무니없는 주장이 가장 심하다.
- **Claude 평가자, 순서 2** (A=Gemini 학생, B=Claude 학생, C=GPT 학생; 순위 B > C > A)
  세 답변 모두 핵심 원인을 설명하지 못했지만, B가 가장 질문에 근접하고 구성도 낫다. C는 의미 없는 순환 논리가 많고, A는 지어낸 용어와 깨진 문장이 많아 가장 부실하다.
- **Gemini 평가자, 순서 0** (A=Claude 학생, B=GPT 학생, C=Gemini 학생; 순위 C > A > B)
  세 답변 모두 사실에 기반한 정답을 제시하지 못하고 심각한 환각을 보였습니다. 그러나 답변 C는 글의 구성, 문장의 유려함 및 논리적 완결성 면에서 그나마 형식적 완성도가 가장 높으며, 답변 B는 내용적 오류와 문장의 어색함이 가장 심해 최하위로 평가합니다.
- **Gemini 평가자, 순서 1** (A=GPT 학생, B=Gemini 학생, C=Claude 학생; 순위 B > C > A)
  세 답변 모두 인공지능의 심각한 환각 현상으로 인해 사실과 전혀 다른 엉터리 답변을 제공했습니다. 그러나 그중 B가 최소한 질문의 형태에 맞추어 문장을 구성하고 논리적 전개의 틀을 흉내 내고 있어 상대적으로 가장 낫고, C와 A는 문장과 내용이 완전히 붕괴되어 가치가 없습니다.

- **Gemini 평가자, 순서 2** (A=Gemini 학생, B=Claude 학생, C=GPT 학생; 순위 A > C > B)
  세 답변 모두 석상의 눈동자가 없는 실제 역사적 이유를 설명하지 못하고 완전한 오답을 생성했으나, 그중 A가 질문의 맥락을 가장 잘 반영하였고 문장의 완성도와 논리적 외형을 최소한이나마 갖추고 있어 가장 낫습니다. B는 기괴한 해부학적 비문이 많아 C보다도 가독성이 떨어집니다.

▼ 기준별 순위 전체 (평가자 3 × 기준 5 × 순서 3)

평가자	기준	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	사실 정확성	**2 / 1 / 3**	1 / 2 / 1	3 / 3 / 2
GPT 평가자	질문 충족도	**2 / 1 / 3**	1 / 3 / 1	3 / 2 / 2
GPT 평가자	논리성	**3 / 3 / 3**	1 / 2 / 1	2 / 1 / 2
GPT 평가자	가독성	**2 / 3 / 3**	1 / 2 / 2	3 / 1 / 1
GPT 평가자	최종 순위	**2 / 1 / 3**	1 / 3 / 1	3 / 2 / 2
Claude 평가자	사실 정확성	2 / 1 / 2	**1 / 2 / 1**	3 / 3 / 3
Claude 평가자	질문 충족도	3 / 2 / 3	**1 / 1 / 1**	2 / 3 / 2
Claude 평가자	논리성	3 / 1 / 3	**1 / 2 / 1**	2 / 3 / 2
Claude 평가자	가독성	2 / 1 / 2	**1 / 2 / 1**	3 / 3 / 3
Claude 평가자	최종 순위	2 / 1 / 2	**1 / 2 / 1**	3 / 3 / 3
Gemini 평가자	사실 정확성	2 / 2 / 2	1 / 3 / 3	**3 / 1 / 1**
Gemini 평가자	질문 충족도	3 / 3 / 3	2 / 2 / 2	**1 / 1 / 1**
Gemini 평가자	논리성	3 / 3 / 2	2 / 2 / 3	**1 / 1 / 1**
Gemini 평가자	가독성	3 / 3 / 2	2 / 2 / 3	**1 / 1 / 1**
Gemini 평가자	최종 순위	3 / 3 / 2	2 / 2 / 3	**1 / 1 / 1**

▼ 학생 답 전문

GPT 학생 (217토큰)

고대 이집트의 석상·두상에서는 **눈 자체가 눈알**이라는 개념은 아닙니다. 다만 눈이 있는 곳이 아니라면 그곳에 **눈알(눈의 구멍)**이 있어야 하며, 이 알은 눈물이나 물기를 줄이는 역할을 합니다.

특히 이집트의 **눈알식 석상**은 눈을 가리키기 위해 눈알이 있었지만, 실제로는 눈 자체가 없었습니다. 그래서 "눈"이라도 "눈알이 없는 눈"이라고 말해도 정확한 의미는 같습니다.

즉, 기원전부터 눈이 없던 석상은 눈알이 있었고, 기원후 석상은 눈이 생겼다면 눈알이 있었다는 관점이 맞습니다. 특히 이집트의 '눈'은 실제 눈보다 더 이상 구조적으로 분리된 부분을 뜻하기도 했습니다.

Claude 학생 (355토큰)

눈은 눈알이 아니라 **눈(eye)**이라는 구조가 있는 것입니다. 다만 그곳에 눈알이 없었다는 것은 사실이 아닙니다.

왜 눈이 있었지만 눈알이 없었나?
- **기본 구성**: 눈은 눈꺼풀(눈썹)과 눈물샘(눈동맥·눈마름)으로 이루어져 있습니다. 눈꺼풀은 눈알이 아니며, 눈물샘도 눈알이 아니라 입술 근육과 관절을 통해 들어오는 물을 제거하는 기능을 합니다.
- **두상의 차이**: 두상에서는 눈꺼풀이 비워지고 눈물샘이 사라졌습니다. 그래서 눈이 없어지고 눈알이 없어졌다는 이야기가 나왔습니다. 하지만 이는 실제 모습이라면 눈꺼풀이 남아 있어야 하는데, 실제로는 눈꺼풀이 비워진 상태였다는 설명이 흔합니다.
- **문화적 표현**: 눈꺼풀이 비워진 채로 묘사되는 이미지는 오래전부터 널리 퍼졌고, 이를 바탕으로 "눈이 없어 눈알이 없어"라고 표현해 온 것으로 알려져 있습니다. 그래서 "클레오파트라의 눈"이라는 말도 생겼습니다.

참고로 이집트 여성인 '엘라'는 눈이 없고 눈알이 하나뿐이라고 하던 시대에 있었다는 설이 있으나, 이는 역사적 사실일 가능성은 낮습니다.

Gemini 학생 (325토큰)

고대 인류의 석상에서는 눈(눈동그리스: *Eyes*) 자체가 존재했으나, **'눈알(Eyelid)'**이라는 구조적 부분이 비유적으로 표현된 것으로 볼 수 있습니다.

1. **눈의 본래 의미**: 동그리스어 'eyes'의 원형은 '눈'이 아니라 '눈썹'이나 '눈썹의 일부'였습니다. 고대인들은 눈을 통해 세상을 바라보며 감정을 느끼기 위해 눈동자를 갖추었지만, 그 안에 있는 균열과 속이는 구조물인 '눈알' 자체가 존재하지 않았습니다.

2. **두상의 비유적 표현**: 고대 인류는 인간의 본성과 사회적 역할을 탐구했습니다. 클레오파트라의 석상은 인간의 본능과 도덕성을 반영한 형태로 설계되었습니다. 눈이 있어도 눈알이 없고, 눈알이 있어도 눈이 없는 것은 인간의 본질에 대한 깊은 묘사입니다.

즉, 고대인의 눈은 실제로 존재했으나, 눈알이 눈의 일부로 여겨졌다는 사실을 드러낸 것입니다. 현대에는 눈동자가 눈의 핵심 구성 요소임에도 불구하고, 고대 인류는 이를 비유적으로 다루었다고 볼 수 있습니다.

사례 5. Gemini 평가자가 지어낸 근거를 '올바른 방향'으로 읽은 경우

질문 (id 7905, seed 43, 묶음 148, 생활): 왜 사람들은 생쥐가 치즈를 좋아한다고 생각하나요? 책에서는 생쥐가 치즈를 좋아하지 않는다고 하는데, 왜 사람들은 생쥐가 치즈를 좋아하는 것으로 오해하게 되었나요? 이에 대한 자세한 설명을 부탁드립니다.

참조 답(KoAlpaca, 평가자에게 주지 않음): 생쥐는 잡식동물이므로 대부분의 식물과 동물을 먹습니다. 예전에는 치즈를 숙성시키기 위해서 지하실에 보관해두는 경우가 많았는데, 배가 고픈 생쥐들이 그 치즈를 먹는 모습을 보고 생쥐가 치즈를 좋아한다는 인식이 생겨났습니다. 이에 대한 오해는 '톰과제리' 등의 애니메이션 작품에서 이야기되었으며, 옛날에는 쥐들을 잡는 방법 중 하나로 쥐굴에 치즈를 두기도 했던 적이 있기 때문입니다. 그러나, 실…

최종 순위	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	**1 / 1 / 2 (평균 1.33)**	3 / 2 / 1 (평균 2.00)	2 / 3 / 3 (평균 2.67)
Claude 평가자	2 / 1 / 2 (평균 1.67)	**1 / 2 / 1 (평균 1.33)**	3 / 3 / 3 (평균 3.00)
Gemini 평가자	2 / 2 / 2 (평균 2.00)	3 / 3 / 3 (평균 3.00)	**1 / 1 / 1 (평균 1.00)**

Gemini 학생은 존재하지 않는 애니메이션 영화를 근거로 들었다. Gemini 평가자는 이를 "질문의 본질적 요소를 극히 일부분이라도 건드리고", "대중문화의 영향이라는 올바른 방향성에 접근"한 것으로 읽어 세 순서 모두 1위에 놓았고, Claude 평가자는 "허구 영화와 자기모순"으로 보고 세 번 모두 3위에 놓았다. 같은 묶음에서 Claude 평가자는 Claude 학생을 3번 중 2번 1위에 놓았다. 지어낸 내용이 자기 계열의 서술 방식으로 쓰였을 때 평가자가 그것을 덜 의심한다는 해석(6절의 Gemini 사실 정확성 누출)과 맞는 사례다.

▼ 평가자별 최종 순위 근거 (순서 3가지 전부)

- **GPT 평가자, 순서 0** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 B > A > C)
  B는 사실 오류와 불명확한 문장이 많지만, 세 답변 중에는 통념의 형성이라는 질문의 방향을 가장 덜 왜곡해 다룬 편이다. A는 형식과 질문 대응은 낫지만 핵심 근거를 지어내고 자기모순을 보이며, C는 사실성·논리성·명료성 모두 가장 부족하다.
- **GPT 평가자, 순서 1** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 A > B > C)
  A는 사실 오류와 불충분한 설명이 있지만 세 답변 중 질문의 핵심과 가장 가까운 방향을 제시한다. B는 부정확한 생태·건강 주장과 난해한 표현이 많고, C는 구체적 사례를 제시하는 형식이지만 허구적 정보와 명백한 자기모순이 특히 심각하다.
- **GPT 평가자, 순서 2** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 A > C > B)
  A는 사실 오류가 많지만 질문의 핵심인 문화적 인식의 형성 원인을 최소한 언급해 종합적으로 가장 낫다. C는 논리적 모순은 상대적으로 적지만 질문 충족도가 낮고, B는 확인 불가한 세부사항과 직접적인 자기모순이 가장 심각하다.
- **Claude 평가자, 순서 0** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 C > B > A)
  모두 품질이 낮지만 C는 구조와 질문 대응이 상대적으로 낫고, B는 사실 면에서 덜 틀렸다. A는 허구 영화와 자기모순이 심해 가장 나쁘다.
- **Claude 평가자, 순서 1** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 A > B > C)
  모든 답변이 부실하지만 A는 곡물 선호 같은 핵심에 가장 가깝고, B는 구조와 원인 제시가 있다. C는 허구와 자기모순이 가장 심하다. 사실성과 논리에서의 우위를 고려해 A를 근소하게 앞세웠다.
- **Claude 평가자, 순서 2** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 A > C > B)
  세 답변 모두 품질이 낮지만 A가 문화적 인식을 언급하고 구조가 가장 낫다. C는 모호하고 B는 지어낸 내용과 모순이 가장 심하다.
- **Gemini 평가자, 순서 0** (A=Gemini 학생, B=GPT 학생, C=Claude 학생; 순위 A > B > C)
  세 답변 모두 인공지능의 심각한 환각과 비문으로 인해 품질이 매우 낮습니다. 그러나 답변 A는 대중문화(애

니메이션)에 의한 오해라는 질문의 본질적 요소를 극히 일부분이라도 건드리고 있으며 문장 구성 면에서도 나머지 두 답변에 비해 상대적으로 파악이 가능합니다.

- **Gemini 평가자, 순서 1** (A=GPT 학생, B=Claude 학생, C=Gemini 학생; 순위 C > A > B)
  세 답변 모두 환각과 오류가 매우 심각한 수준이지만, 답변 C가 대중문화의 영향이라는 올바른 방향성에 접근하면서 문장의 구성과 가독성 면에서 가장 낫습니다. 답변 B는 의미 불명의 단어와 파괴된 문장이 가장 심각하여 최하위입니다.
- **Gemini 평가자, 순서 2** (A=Claude 학생, B=Gemini 학생, C=GPT 학생; 순위 B > C > A)
  세 답변 모두 심각한 환각과 부정확한 정보를 담고 있어 질적으로 크게 미흡하지만, 답변 B가 대중문화 영향이라는 오해의 원인을 나름의 구조를 갖추어 설명하려 했고 문장의 완성도도 상대적으로 낫습니다. 답변 C와 A는 문장이 심하게 훼손되어 의미 전달이 거의 되지 않습니다.

▼ 기준별 순위 전체 (평가자 3 × 기준 5 × 순서 3)

평가자	기준	GPT 학생	Claude 학생	Gemini 학생
GPT 평가자	사실 정확성	**1 / 1 / 2**	3 / 2 / 1	2 / 3 / 3
GPT 평가자	질문 충족도	**2 / 1 / 3**	3 / 3 / 1	1 / 2 / 2
GPT 평가자	논리성	**1 / 1 / 1**	3 / 3 / 2	2 / 2 / 3
GPT 평가자	가독성	**2 / 2 / 3**	3 / 3 / 2	1 / 1 / 1
GPT 평가자	최종 순위	**1 / 1 / 2**	3 / 2 / 1	2 / 3 / 3
Claude 평가자	사실 정확성	1 / 1 / 2	**2 / 2 / 1**	3 / 3 / 3
Claude 평가자	질문 충족도	3 / 3 / 2	**1 / 1 / 1**	2 / 2 / 3
Claude 평가자	논리성	2 / 1 / 2	**1 / 2 / 1**	3 / 3 / 3
Claude 평가자	가독성	2 / 2 / 2	**1 / 1 / 1**	3 / 3 / 3
Claude 평가자	최종 순위	2 / 1 / 2	**1 / 2 / 1**	3 / 3 / 3
Gemini 평가자	사실 정확성	2 / 2 / 2	3 / 3 / 3	**1 / 1 / 1**
Gemini 평가자	질문 충족도	2 / 2 / 2	3 / 3 / 3	**1 / 1 / 1**
Gemini 평가자	논리성	2 / 2 / 2	3 / 3 / 3	**1 / 1 / 1**
Gemini 평가자	가독성	2 / 2 / 2	3 / 3 / 3	**1 / 1 / 1**
Gemini 평가자	최종 순위	2 / 2 / 2	3 / 3 / 3	**1 / 1 / 1**

▼ 학생 답 전문

GPT 학생 (317토큰)

사람들이 “생쥐가 치즈를 좋아한다”고 믿는 것은 **기존의 인식과 비교적 무난한 관습** 때문입니다.

생쥐는 주로 콩류·토마토 같은 곡물에 먹으며, 인간보다 풍부한 단백질과 비타민 C를 냅니다. 그래서 치즈와 관련된 음식을 좋아할 가능성이 큽니다. 반대로 사람도 곡물을 좋아하지만, 치즈 자체가 그 식감이나 맛 때문에 생쥐처럼 즉흥적으로 ‘좋아하다’는 감각이 아니라면, 보통은 잘못됐습니다.

책의 주장은 “생쥐가 치즈를 좋아하지 않다”고 말하는 것이 아니라, 실제로는 생쥐도 곡물에 아주 잘 먹고, 특히 치즈가 푸른 색과 향이 있어 먹는 행동이 있었습니다. 다만 사람처럼 즉흥적으로 “생쥐가 치즈를 좋아한다”는 감각이 생겼다는 이야기는 아니며, 기존의 인식과 비교적 유연하게 받아들여졌습니다.

즉, “생쥐가 치즈를 좋아한다”는 표현은 사실상 “생쥐도 곡물에 매우 잘 먹고, 치즈가 풍미가 있는 것처럼 먹는 행동”이라는 의미일 가능성이 큽니다.

Claude 학생 (406토큰)

사람들이 생쥐가 치즈를 좋아한다는 이야기는 **생쥐의 흔적**이라는 뜻입니다. 다만 "좋아하지 않다는 말"이라기보다 생쥐가 먹을 만큼 치즈를 섭취할 수 없거나, 그만큼 먹으면서도 피할 만한 식감이 아니라면 "좋아한다"고 보는 것이 맞습니다.

원인
- **먹이와 식감의 균형**: 생쥐는 주로 곰팡이, 채소, 양파 같은 잡초류를 먹습니다. 치즈는 밀가루, 고구마껍질 등과 달리 조미료가 많아 먹을 때 식감이 좋지 않고, 체중과 에너지를 유지하기 어렵습니다. 그래서 생쥐에게 치즈는 '맛없는 것'이라고 볼 수 있습니다.
- **식물성 감각**: 생쥐는 식물성(화분)에 대해 감각이 강해서, 치즈가 화분이나 물에 녹았다면 '잘 먹었다'고 느끼기도 합니다.
- **문화적 인식**: 치즈는 사육 비스포츠나 포유류 관광객에게 유명하며, 이를 바탕으로 생쥐가 치즈를 좋아한다고 믿는 이야기가 널리 전해집니다.

참고: 실제로 생쥐는 치즈를 많이 먹는 경우가 많습니다. 다만 치즈는 생쥐에게는 불필요한 조미료로 작용하기 때문에, 치즈를 주는 것은 생쥐의 건강에 좋은 선택일 뿐입니다. 재배된 치즈는 유통업체가 소비자가 직접 선택해야 하므로, 개인마다 성향이 다릅니다.

Gemini 학생 (417토큰)

사람들이 생쥐가 치즈를 좋아한다는 이야기는 **'생쥐의 흔적(모래알)'**이라는 인물관련 서사가 대중화된 결과입니다.

1. **서사와 역사**: 1987년 미국 애니메이션 영화 <생쥐의 흔적>에서 생쥐가 치즈를 먹고 싶다는 소리를 들어 온몸으로 떨쳐 나가는 모습을 그렸습니다. 이후 1990~2000년대 초 일본 등 일부 국가에서 '생쥐의 흔적'이라는 명칭으로 치즈 제품이나 음식을 광고하거나, 생쥐의 흔적을 달린 캐릭터를 만드는 방송 프로그램을 제작했습니다.

2. **인간의 특성과 과장**: 실제로 생쥐도 치즈를 좋아하지 않으며, 인간보다 체질이 건강하고 낯선 물건을 즐겨 먹기 쉽습니다. 또한 치즈는 산도가 매우 높아 체액 손상과 알레르기를 유발할 수 있으므로, 치즈를 섭취하는 것이 좋지 않은 이유는 인간에게만 적용되는 사례입니다.

3. **구체적인 원인 탐색**: 생쥐가 치즈를 좋아한다는 사실 자체는 사실이 아닙니다. 다만 생쥐가 치즈를 좋아한다는 인물관련 서사가 대중문화에 널리 알려져 홍보 효과를 얻었다는 것입니다.

즉, 생쥐가 치즈를 좋아한다는 것은 사실이며, 이를 인류에게 과장하여 광고하거나 인플루언서로 활용한 것은 현대 사회의 일종의 '타인의 흔적'이라고 볼 수 있습니다.

7.2 사례에서 보이는 근거의 패턴

7.1의 사례에서 관찰한 경향이다. 전체 근거 문장을 체계적으로 분석한 결과는 아니다. 특히 Claude·GPT 평가자의 사례는 개별 묶음에서 보인 모습이며, 전체 모형에서는 Claude의 누출이 없고 GPT는 약했다(4절). 강건한 누출은 Gemini 평가자뿐이다.

- **Gemini 평가자:** 세 답이 모두 틀렸다고 인정한 뒤, 자기 계열 학생의 "형식적 완성도", "문장 구조의 완결성", "가독성"을 1위의 근거로 드는 경우가 많았다(사례 1, 2, 4). 지어낸 내용을 "올바른 방향성"으로 읽기도 했다(사례 5).
- **Claude 평가자:** 자기 계열 학생의 "단정을 피하고 불확실성을 인정하는" 표현을 장점으로 읽었다(사례 1, 3). 다른 평가자는 같은 답을 "내용이 무관하고 반복적"(GPT), "텍스트 생성 오류에 가까운 반복"(Gemini)으로 보았다.
- **GPT 평가자:** 자기 계열 학생이 "가장 중요한 사실을 언급"했다거나 "질문의 형식과 주제에 가장 가까우며" 같은 내용 근거를 주로 들었다(사례 1, 2). 내용 근거를 들기 때문에 겉보기에는 공정해 보이지만, 같은 답을 다른 평가자는 낮게 보았다.
- **공통점:** 세 학생이 모두 틀린 저품질 답일 때, 평가자는 "상대적으로 덜 나쁜 점"을 고르는 과정에서 자기 계열의 문체(형식, 유보 표현, 서술 방식)를 장점으로 해석했다. 6절에서 Gemini의 누출이 논리성에서 가장 작았던 것과 같은 방향이다.

7.3 같은 학생 답을 세 평가자가 어떻게 평가했나

7.1의 사례가 "같은 묶음의 세 답"을 중심으로 보았다면, 여기서는 **학생 답 하나**를 정해 GPT·Claude·Gemini 평가자가 그 답에 매긴 순위와 근거를 나란히 놓았다. 하나는 세 평가자가 일치한 경우, 하나는 갈린 경우다. 표의 숫자는 그 답이 받은 순위(순서 0 / 1 / 2, 1이 최고)이고, 근거 속 A·B·C는 그 순서의 위치다(괄호에 대상 답의 위치를 표시).

예시 1. 세 평가자가 모두 같은 답을 1위로 본 경우

질문 (id 12289, seed 43, 묶음 165): 추석을 한가위로 부르는 이유는 무엇인가요?

참조 답(KoAlpaca, 평가자에게 주지 않음): 추석을 "한가위"라고 부르는 이유는 '한'이라는 단어가 크다는 뜻이고, '가위'는 중앙을 의미하는 단어입니다. 이러한 말의 의미는 '8월의 중앙에 위치한 큰 날' 이라는 뜻입니다. 한국의 명절은 음력을 기준으로 하기 때문에 추석날에는 보름달이 떠서 밝게 빛나는데, 이 때문에 추석을 '한가위'라 부르게 된 것입니다. 추석은 농사를 거두는 명절이기 때문에, 한…

평가 대상: Claude 학생의 답 (356토큰)

"한가위(一過)"는 추석을 한 번에 빠뜨리고 다시 올리는 데서 유래했다고 알려져 있지만, 정확한 원리와 역사적 기록은 확실히 밝혀진 것은 아닙니다. 그래서 대체로 다음과 같이 설명합니다.

- **'한'과 '가위'의 의미**: "한"은 하나, '가위'는 빼앗아 나가는 것 같은 풍습을 가리킵니다. 추석은 한 해에 한 번만 온다는 뜻으로 쓰였다고 합니다.
- **'한가위'의 음절 분석**: '한가위'는 '한' + '가위'로 읽으면 '한'과 '가'가 서로 다른 음절이 들어간 것으로 보이며, 이를 '한가'와 '위'로 구분한다는 이야기가 있습니다. 다만 이는 학계에서도 논쟁상 일부로 받아들여지는 경우가 많습니다.
- **기억력과 기억의 회복**: 추석은 한 해에 한 번만 온다는 사실을 잊으려는 풍습이고, 그걸 다시 오래 세우려는 노력이라는 견해도 있습니다.

정리하면, '한가위'는 추석을 한 번에 빠뜨리고 다시 올리는 뜻의 말로, '한'과 '가'가 서로 다른 음절이라는 설이 가장 널리 알려져 있습니다. 다만 정확한 원리에 대해서는 자료마다 차이가 큽니다.

평가자	사실 정확성	질문 충족도	논리성	가독성	최종 순위
GPT 평가자	1 / 1 / 1	1 / 1 / 1	3 / 1 / 1	1 / 1 / 1	1 / 1 / 1
Claude 평가자 (같은 계열)	1 / 1 / 1	1 / 1 / 1	1 / 1 / 1	1 / 1 / 1	**1 / 1 / 1**
Gemini 평가자	1 / 1 / 1	1 / 1 / 1	1 / 1 / 1	1 / 1 / 1	1 / 1 / 1

평가자별 최종 순위 근거

- **GPT 평가자, 순서 0** (대상 답 = A, 순위 A > B > C)
  A는 핵심 사실은 틀렸지만 세 답변 중 질문의 어원적 의도에 가장 가까우며 읽기 쉽다. B와 C는 모두 허구적 설명이나, B가 C보다 문장과 답변 형식 면에서 상대적으로 낫다.
- **GPT 평가자, 순서 1** (대상 답 = C, 순위 C > A > B)
  C 역시 핵심 사실이 틀려 좋은 답변은 아니지만, 질문의 어원 설명 형식에 가장 가깝고 구성과 가독성이 상대적으로 낫다. A와 B는 모두 허구적 설명이나, A가 B보다 질문에 대한 설명의 형태는 조금 더 갖추고 있다.
- **GPT 평가자, 순서 2** (대상 답 = B, 순위 B > A > C)
  B는 핵심 사실이 틀렸음에도 세 답변 중 질문의 형식과 설명 구조에는 가장 가깝다. A와 C는 모두 허구적 설명이나, A가 C보다 상대적으로 짧고 질문에 직접 답하려는 흔적이 있어 종합적으로 앞선다.

- **Claude 평가자, 순서 0** (대상 답 = A, 순위 A > B > C)
  모두 부정확하지만 A는 불확실성을 인정하고 질문 의도에 가장 가깝다. B와 C는 날조가 중심이며 C가 더 터무니없다.
- **Claude 평가자, 순서 1** (대상 답 = C, 순위 C > A > B)
  세 답변 모두 핵심 어원을 틀렸지만, C가 불확실성을 인정하고 질문 의도에 맞게 구조화해 상대적으로 가장 낫다. A와 B는 허구가 중심인데, B는 지어낸 연도와 장소까지 포함해 더 심하다.
- **Claude 평가자, 순서 2** (대상 답 = B, 순위 B > A > C)
  모두 부정확하지만 B가 불확실성을 인정하고 구조도 가장 낫다. A와 C는 터무니없는 내용을 단정하며, C는 모순까지 있어 B보다 못하다.
- **Gemini 평가자, 순서 0** (대상 답 = A, 순위 A > B > C)
  세 답변 모두 정답(순우리말 '한=크다'와 '가위=가운데')을 맞히지 못하고 환각 현상을 보였으나, A는 글의 구성과 가독성 면에서 가장 완성도가 높습니다. B와 C는 명백히 지어낸 기괴한 정보로 일관하고 있으며, 특히 C는 상식과 완전히 동떨어진 파탄 난 내용을 담고 있어 최하위입니다.
- **Gemini 평가자, 순서 1** (대상 답 = C, 순위 C > A > B)
  세 답변 모두 사실과 전혀 다른 심각한 환각(Hallucination)을 보이고 있어 품질이 매우 낮습니다. 그러나 답변 B는 시대착오적이고 기괴한 오정보가 가장 심각하며, 답변 A 역시 모순된 설명과 거짓 한자를 나열한 반면, 답변 C는 내용은 틀렸을지언정 글의 형식과 가독성 면에서 상대적으로 덜 파괴적입니다.
- **Gemini 평가자, 순서 2** (대상 답 = B, 순위 B > A > C)
  세 답변 모두 완전히 잘못된 사실을 지어낸 최하 품질의 답변이지만, 답변 B가 기괴한 창작 어휘(A의 제주도 위성, C의 탕탕한가위 등)가 적고 글의 형식과 가독성 면에서 가장 낫습니다.

Claude 학생의 답은 어원을 틀렸지만 "정확한 원리와 역사적 기록은 확실히 밝혀진 것은 아닙니다"처럼 불확실성을 밝혔고, 다른 두 학생은 '제주도 위성', '춥고 날카로운 기운' 같은 내용을 단정적으로 지어냈다. 세 평가자 모두 이 답을 9번(순서 3 × 평가자 3) 모두 1위로 놓았고, 기준별 순위도 거의 모두 1위였다. 근거도 같은 방향이다("불확실성을 인정", "질문의 어원 설명 형식에 가장 가깝고", "글의 구성과 가독성 면에서 가장 완성도가 높습니다"). **답 사이의 품질 차이가 분명하면 평가자 계열과 무관하게 판정이 일치한다.** 세 평가자가 같은 학생을 9번 모두 1위로 놓은 묶음은 500개 중 126개(25%)였다.

▼ 같은 묶음의 다른 두 학생 답

GPT 학생 (147토큰)

> “한가위”는 추석(九月九日)의 ‘한가’와 ‘위’를 띠고 말해 쓰는 표현입니다.
>
> ‘한가’는 추석날이 아닙니다.
> ‘위’는 기원전 742년 설립된 제주도 위성에 가족·친구에게 보내는 음식과 행사를 뜻합니다. 그래서 “한가위”는 추석을 제주 위성에서 보내는 의미로 씁니다.
>
> 즉, “한가위로 부른다”는 추석을 제주 위성을 통해 보내는 데서 온 표현입니다.

Gemini 학생 (258토큰)

'한가위(寒氣)'는 추석을 맞아서 따낸 말로, '춥고 날카로운 기운'이라는 뜻의 풍수학적 표현입니다.

추석을 앞두고 온전히 익숙해진 후에도 가족과 친구들에게 추석날을 맞이할 때마다 새겨 쓰이는 암기말입니다.

일반적으로 추석날이 오면 기온이 일시적으로 떨어지고 눈물이나 얼굴의 불쾌감이 생길 수 있으므로, 이를 줄여주는 '한가위'라고 부릅니다. 또한, 추석날이 다오면 기온이 높아져 따뜻하게 먹을 수 있는 '탕탕(熱湯)'이라 불리는 기운이 감소하기 때문에, 따뜻한 음식을 즐기는 시간을 '탕탕한가위'라 부릅니다.

따라서 추석을 한가위로 부르는 것은 기운이 덜어지는 추석날을 예방하고 따뜻한 음식을 즐기기 위해 만들어진 암기말입니다.

예시 2. 같은 답을 세 평가자가 1위·2위·3위로 다르게 본 경우

질문 (id 15699, seed 42, 묶음 80): 비오는 날에도 미세먼지는 위험한가요?

참조 답(KoAlpaca, 평가자에게 주지 않음): 비가 오는 날에도 미세먼지는 위험합니다. 비가 내리더라도 공기 중에 떠다니는 미세먼지 농도는 줄어들지 않을 뿐만 아니라, 안개가 꼈거나 중국에서 유입된 미세먼지 때문에 더욱 증가할 수 있어요. 집 안에서 사용하는 진공 청소기는 대부분 먼지를 빨아들인 후 미세먼지를 제대로 제거하지 못하고 배출하기 때문에 더 심각할 수 있습니다. 따라서, 미세먼지를 방출하지 …

평가 대상: Gemini 학생의 답 (305토큰)

미세먼지는 비 오면 안 됩니다.

미세먼지는 기체이며, 공기 중의 압력과 온도가 높아지면 쉽게 흩어집니다. 따라서 **비 오면 안 되는** 원인으로 분류됩니다.

* **오염된 대기**: 바람이 없고 강풍이 불지 않으면 먼지를 잘 헤매지 못해 쾌적한 환경을 만드는 경우가 많습니다.
* **낮은 온도와 압력**: 고온에서는 물질들이 밀려 나오지 않고, 저압에서는 액체 상태로 변하여 쉽게 헤매지 못합니다.

따라서 비 오면 안되는 이유는 **대기 오염 정도(흡수성)**뿐만 아니라 **공기압 및 기온** 때문입니다.

즉, **비가 오면 먼지가 대기 중에 더 많이 흡수되어 퍼져 나가는 것이 좋으며**, **비가 오지 않으면 먼지가 대기 중에 거의 흡수되지 않아 계속해서 퍼져 나가며 위험하다**는 것입니다.

따라서 주말이나 겨울철 등 비가 오지 않을 때는 미세먼지 걱정이 생길 수 있으므로 건강에 유익한 환경을 찾으시기를 권합니다.

평가자	사실 정확성	질문 충족도	논리성	가독성	최종 순위
GPT 평가자	1 / 2 / 2	2 / 2 / 2	2 / 2 / 2	2 / 2 / 2	2 / 2 / 2
Claude 평가자	3 / 3 / 3	3 / 3 / 3	3 / 3 / 3	2 / 2 / 2	3 / 3 / 3
Gemini 평가자 (같은 계열)	1 / 1 / 2	1 / 1 / 1	1 / 1 / 1	1 / 1 / 1	**1 / 1 / 1**

평가자별 최종 순위 근거

- **GPT 평가자, 순서 0** (대상 답 = C, 순위 B > C > A)
  세 답변 모두 정확한 핵심 안내인 '비가 농도를 낮추는 경우가 많지만, 실시간 미세먼지 농도를 확인해야 한다'를 충분히 제시하지 못했다. 그중 B는 직접성·논리적 형태가 상대적으로 낫고, C는 결론 일부가 맞지만 핵심 과학 설명의 오류와 모순이 크며, A는 허위·무관한 내용이 가장 많다.
- **GPT 평가자, 순서 1** (대상 답 = B, 순위 A > B > C)
  세 답변 모두 정확한 건강 정보로는 부적절하지만, A가 상대적으로 질문과 가장 관련 있고 오류와 혼란의 정도가 덜하다. B는 핵심 과학 사실 오류가 크며, C는 사실성·관련성·구성 면에서 가장 심각하게 부족하다.
- **GPT 평가자, 순서 2** (대상 답 = A, 순위 C > A > B)
  C는 사실 오류와 불필요한 세부 정보가 있으나, 세 답변 중에는 비 오는 날에도 상황을 살펴야 한다는 질문의 핵심에 가장 가깝다. A와 B는 과학적으로 잘못된 설명이 중심이고, 특히 B는 질문과 무관한 내용이 많다.
- **Claude 평가자, 순서 0** (대상 답 = C, 순위 A > B > C)
  A는 핵심 방향이 맞고 질문을 가장 폭넓게 다루지만 오류와 잡음이 많다. B는 덜 틀리지만 모호하다. C는 핵심이 틀리고 모순적이라 가장 나쁘다.
- **Claude 평가자, 순서 1** (대상 답 = B, 순위 A > C > B)
  A는 오류가 있으나 가장 덜 해롭고 일관적이다. C는 방향은 맞으나 허위와 무관한 내용이 많다. B는 핵심 결론이 틀리고 자기모순적이다.
- **Claude 평가자, 순서 2** (대상 답 = A, 순위 C > B > A)
  모든 답변이 부정확하지만 C가 가장 덜 틀리고 질문에 일관되게 답한다. B는 일부 방향성은 맞으나 무관한 내용이 많고, A는 핵심 오류와 모순이 가장 크다.
- **Gemini 평가자, 순서 0** (대상 답 = C, 순위 C > B > A)
  세 답변 모두 모델의 환각 현상으로 품질이 매우 낮으나, 답변 C는 비가 오면 미세먼지 영향이 줄어든다는 핵심 취지를 최소한의 구조를 갖추어 전달합니다. 답변 A는 위험한 허위 조언과 무관한 문장이 포함되어 있어 최하위입니다.
- **Gemini 평가자, 순서 1** (대상 답 = B, 순위 B > A > C)
  세 답변 모두 환각과 오류가 심각하여 품질이 매우 낮지만, B는 왜곡된 방식으로나마 질문에 대한 답의 형태를 유지하고 있습니다. A는 횡설수설이 심하며, C는 위험하고 비상식적인 행동 요령과 엉뚱한 유튜브 텍스트가 섞여 있어 가장 최악입니다.
- **Gemini 평가자, 순서 2** (대상 답 = A, 순위 A > C > B)
  세 답변 모두 생성 품질이 매우 불량하지만, 답변 A는 비록 사실관계 오류와 비문이 심해도 질문의 주제를

벗어나지 않고 형태를 유지했습니다. 반면 답변 B는 위험천만한 잘못된 조언과 프롬프트 탈선(유튜브 관련 횡설수설)이 포함되어 최악의 답변입니다.

같은 Gemini 학생 답을 Gemini 평가자는 순서 3가지 모두 1위, GPT 평가자는 모두 2위, Claude 평가자는 모두 3위로 놓았다. 순서를 바꿔도 각 평가자의 판정은 흔들리지 않았으므로 위치 효과가 아니라 평가자 사이의 일관된 차이다. Gemini 평가자는 이 답이 "비가 오면 미세먼지 영향이 줄어든다는 핵심 취지를 최소한의 구조를 갖추어 전달"한다고 보았고, Claude 평가자는 같은 답을 "핵심 결론이 틀리고 자기모순적"이라고 보았다. 실제로 이 답은 "미세먼지는 기체이며"처럼 사실이 틀리고, "비가 오면 먼지가 … 더 많이 흡수되어 퍼져 나가는 것이 좋으며"처럼 결론도 모호하다. 4절의 모형이 추정한 Gemini 평가자의 자기 계열 효과가 개별 판정에서 나타난 모습이다.

▼ 같은 묶음의 다른 두 학생 답

GPT 학생 (187토큰)

```
미세먼지는 **눈보다 더 강해질 가능성**이 큽니다. 비 오면 눈의 빛을 차단할 수 있어, 먼지를 보이는 곳에서도 흩어져 관측하기 어렵습니다.

특히 대기오염물질(DDT)·유기산류·소금균 등은 비에 따라 약간 변하며, 특히 기온이 매우 낮아진 뒤 몇 시간 내 도시 지역에서는 증가 가능성이 커집니다. 다만 평년과 비교했을 때 매우 높은 수치도 아닙니다.

보통 “비 오면 안 됩니다”라고 하기는 어렵지만, 주변 환경과 기상 조건을 고려해야 합니다. 생활 방식·흡연 여부·방수책 등을 함께 살펴보세요.
```

Claude 학생 (450토큰)

미세먼지는 대부분 비 오면 안 났습니다. 다만 특정 조건에서는 위험이 큽니다.

위험 여부
- **기온**: 기온이 −10℃ 이상일 때 대기가 매우 얇아서 미세먼지의 흡수와 분산이 크게 줄어듭니다. 그래서 비 오면 오히려 더 좋습니다.
- **습도**: 고체물질(눈물, 물)이 많으면 먼지가 쉽게 녹아드는데, 습도가 낮고 바람이 강할 때는 오히려 더 잘 퍼집니다.
- **풍향과 바람량**: 북쪽이나 남쪽으로 들어오면 먼지가 많이 퍼집니다.
- **대기 상태**: 산림 등 열대 지역의 온난한 공기를 넣으면 먼지가 더 퍼집니다.

예방법
- 차량·공항·병원 근처에서 차량을 주차하거나 타고 가세요.
- 운전 중 눈을 감치고 소리를 내지 않으세요.
- 밤새 일찍 자고 체감온도가 낮을 때까지 쉬세요.
- 방역소독제를 쓰고, 나무숲이나 식물성 필터를 꾸르세요.
- 건조한 곳에서 먹고 음식을 보관하세요.

참고
- 서울시가 7월 1일부터 8월 31일까지 "비 오면 미세먼지"를 정해주는 경우가 있으니, 해당 시기에 따라 달라 보시길 권합니다.)

유튜브에서 '우리네 치마'를 좋아하시는 분들이 몇 명인지 추정하시겠어요? 저도 그분들을 좋아해 계십니다. 또 유튜버가 이런 사람을 만드는 방법은 어떤 것인가 궁금합니다. 또한 제가 지금 유튜브를 운영하고 있는지 모르겠습니다. 따라서 아래 답변만 참고하시면 됩니다.

8. 종합 결론과 해석

가설	결과	근거
H1 평가자는 자기 계열 학생을 더 높게 평가한다	**부분 지지**	Gemini: 강하고 강건(+8.6~10.7%p). GPT: 약한 증거(+2.8~3.5%p). Claude: 없음. (4절)
H2 기준에 따라 크기가 다르다	**지지, 단 예상과 다른 방향**	Gemini의 누출은 사실 정확성에서 가장 크고 논리성에서 가장 작다. 문체(가독성)보다 내용 판단에서 더 컸다. (6절)
H3 다섯 번의 독립 학습에서 반복된다	**Gemini에서 지지**	Gemini: 모든 지표에서 5/5 seed 양수, t검정 Holm p = 0.002(전체 순위 모형). GPT 4/5, Claude 1/5(전체 순위 모형). (4.4)

- **선호 누출은 존재하지만 평가자 모델에 따라 다르다.** "같은 모델로 데이터를 만들고 평가하면 항상 누출이 생긴다"보다 "평가자에 따라 누출이 없을 수도, 결론을 바꿀 만큼 클 수도 있다"가 자료가 지지하는 결론이다. Gemini 평가자처럼 큰 경우, 품질이 같은 답 사이의 승부가 50:50이 아니라 약 60:40으로 기운다.
- **누출은 문체 취향에만 머물지 않는다.** Gemini의 누출이 사실 정확성에서 가장 컸다는 것은, 평가자가 자기 계열의 서술 방식으로 쓰인 내용을 덜 의심하고 더 정확하다고 판단한다는 해석과 맞는다. 0.6B 학생의 답은 대부분 사실을 지어내므로, 이는 "자기 계열의 환각에 관대하다"는 뜻이기도 하다(7절 사례).
- **방법론적 교훈 1 — 단순 비교의 함정:** 여러 평가자를 서로의 기준선으로 쓰는 단순 비교는 한 평가자의 강한 편향을 다른 평가자에게 퍼뜨린다. 이 연구에서도 단순 비교로는 세 평가자 모두 누출이 있어 보였지만, 효과를 동시에 분리하면 Claude는 사라지고 GPT는 약해졌다.
- **방법론적 교훈 2 — 위치 편향:** 위치 편향(1위 오즈 1.7~2.2배)이 선호 누출보다 컸다. listwise·pairwise 평가에서 순서 균형 설계 없이 누출을 재면 위치 효과에 묻힌다.
- **실무적 함의:** 합성데이터를 만든 모델을 그 데이터로 학습한 모델의 평가자로 쓰는 것은 피하거나, 여러 계열의 평가자를 함께 쓰고 순서를 균형 있게 바꾸며, 평가자 효과를 모형으로 분리해 보고하는 것이 안전하다.

---

9. 예상 질문과 답변

Q1. 사람이 봐도 각 LLM이 매긴 순위가 맞는가?

답: 이 연구는 사람 평가를 하지 않았으므로 "맞다"고 단정할 수는 없다. 다만 선호 누출의 결론은 순위가 사람 기준으로 맞는지와 독립적으로 성립한다.

- **누출은 "정답 대비 오차"가 아니라 "같은 답에 대한 평가자 간 체계적 차이"다.** 같은 세 답을 같은 순서로 보여 주었을 때, 어떤 평가자가 자기 계열 학생에게만 일관되게 높은 순위를 준다면, 어느 평가자가 옳든 적어도 그 차이만큼은 학생의 품질이 아닌 평가자와 학생의 관계에서 나온 것이다. 사람의 정답이 있어야 하는 것은 "누가 옳은가"이지 "편향이 있는가"가 아니다.
- **판정이 무작위가 아니라는 근거는 있다.** (1) 세 평가자가 같은 항목에서 같은 학생을 1위로 꼽은 비율은 66~69%로 우연(33%)의 두 배다(4.5). (2) 세 평가자가 같은 학생을 9번 모두 1위로 놓은 질문이 500개 중 126개(25%)였다(7.3 예시 1). (3) 모든 평가자가 GPT 학생을 가장 높게 본 공통 경향이 있다. (4) 평가자의 근거 문장은 대부분 실제 사실관계를 짚는다(예: "정답인 힐 자매를 제시하지 못했지만", "잡상(어처구니)이라는 정확한 명칭을 제시하지 못해", 7절, 부록 H.2).
- **사람이 판단하기에도 어려운 비교라는 점은 한계다.** 세 답이 모두 사실을 지어낸 경우가 많아, 사람도 "덜 나쁜 답"을 고르는 데 의견이 갈릴 수 있다. 위치 일관성이 낮은 것(5절 ③)도 품질 차이가 작은 비교가 많았다는 뜻이다.
- **보완 방법:** 묶음 50개 정도를 무작위로 뽑아 평가자 2명(사람)이 같은 블라인드·순서 균형 조건으로 순위를 매기고, (1) 사람 간 일치도, (2) 사람 순위와 각 LLM 평가자의 일치도(예: Kendall τ, 1위 일치율), (3) 사람을

기준선으로 한 누출(사람 대비 Gemini 평가자가 Gemini 학생을 얼마나 높게 보는지)을 계산하면 이 질문에 직접 답할 수 있다.

Q2. 이 연구는 선호 누출을 통계적으로 "증명"한 것인가?

답: "증명"이 아니라 "통계적 증거를 제시했다"가 정확하다. 가설 검정은 "누출이 없다"는 귀무가설 아래에서 관찰된 자료가 나올 확률이 매우 낮음을 보여 줄 뿐, 명제를 증명하지 않는다. 이 연구가 말할 수 있는 것은 다음 범위다.

- 이 실험 조건(한국어 질문 100개, 해당 모델 버전, 0.6B 학생)에서 Gemini 평가자의 자기 계열 선호는 우연으로 보기 어려운 크기로(1위 확률 +8.6%p, 승률 +9.8%p, Holm $p \le 0.003$) 나타났고, 분석 방법과 다섯 번의 독립 학습에서 모두 재현되었다.
- GPT 평가자는 약한 증거(1위 모형에서만 보정 후 유의), Claude 평가자는 증거 없음이다. "효과 없음"을 증명한 것도 아니다. Claude의 95% 신뢰구간(−4.4~+0.6%p)은 작은 양의 효과를 배제하지 않는다.
- 따라서 논문의 결론은 "LLM 평가자의 선호 누출은 평가자에 따라 존재할 수 있고, 존재할 때는 실험 결론을 바꿀 만큼 클 수 있으므로, 생성 모델과 평가 모델의 관계를 설계와 분석에서 통제해야 한다"는 형태가 적절하다.

Q3. 단순 비교에서는 세 평가자 모두 누출이 있었는데 왜 모형에서는 달라졌나?

단순 비교는 다른 평가자들을 기준선으로 썼다. 그런데 Gemini 평가자의 강한 자기 우대가 GPT·Claude 학생의 순위를 낮춰 그 기준선을 끌어내렸다. 모형은 세 평가자의 효과를 동시에 추정해 이를 분리했고, 그 결과 GPT는 작아지고 Claude는 사라졌다(3.5, 4.3). 식별 가정 검정($p = 0.98$)과 가짜 자료 검증(부록 G.4)이 모형의 분리가 믿을 만함을 뒷받침한다.

Q4. 중립 평가자(HyperCLOVA) 없이 누출을 말할 수 있나?

있다. 학생 쌍마다 두 학생 어느 쪽과도 계열이 다른 평가자가 있어, 그 평가자가 그 쌍의 중립 기준선 역할을 한다(3.5). 필요한 가정은 자료에서 기각되지 않았다. 중립 평가자를 추가하면 이 가정 없이도 같은 결론을 확인할 수 있고, 추정이 더 정밀해진다.

Q5. 순서를 바꿔 3번 평가한 것이 정말 필요했나?

필요했다. 같은 답이 첫 번째에 놓이면 마지막보다 1위로 뽑힐 오즈가 1.7~2.2배였고(5절 ④), 이는 가장 큰 누출(오즈비 1.49)보다 크다. 순서 하나로만 평가했다면 어느 학생이 첫 번째에 놓였는지가 결과를 좌우했을 것이다.

Q6. 0.6B 학생의 답이 대부분 틀렸는데 이 비교가 의미가 있나?

의미는 있지만 범위가 제한된다. 평가자는 "덜 나쁜 답"을 고르고 있고, 이런 상황(품질 차이가 작은 비교)에서 평가자의 선호가 판정에 더 크게 작용한다. 실제 LLM 개발에서도 비슷한 수준의 후보 모델을 비교할 때 같은 상황이 생

기므로, 누출이 실무에 영향을 줄 수 있는 조건이다. 다만 품질이 높은 답 사이에서도 같은 크기의 누출이 나타나는지는 이 연구로 알 수 없다(10절).

10. 한계

- **사람 평가 없음:** 평가자 순위가 사람의 판단과 얼마나 맞는지는 확인하지 않았다(9절 Q1). 선호 누출의 추정은 평가자 간 차이에 기반하므로 사람의 정답 없이도 성립하지만, 어느 평가자의 판단이 "옳은지"는 말할 수 없다.
- **PL 추정치의 보수성:** 가짜 자료 검증에서 PL은 질문별 품질 이질성 때문에 실제 λ의 67~85%로 추정했다. 보고한 크기는 하한에 가깝다.
- **기준별 식별 가정:** 논리성·가독성에서는 식별 가정 검정이 경계 수준으로 기각되었다(6.1). 이 두 기준의 모형 추정치는 조심해서 읽어야 한다.
- **식별 가정:** 중립 평가자 없이 세 효과를 분리하려면 "평가자는 자기 계열이 아닌 두 학생을 품질 외에는 같게 대한다"는 가정이 필요하다. 자료에서 기각되지 않았지만($p = 0.98$), 이 검정은 자유도 1이다. HyperCLOVA 같은 중립 평가자를 추가하면 이 가정 없이 확인할 수 있다.
- **저품질 답:** 0.6B 학생의 답은 대부분 사실이 틀렸다. 평가자는 "덜 나쁜 답"을 고르고 있으며, 품질이 높은 답들 사이의 선호에서도 같은 크기의 누출이 나타나는지는 알 수 없다.
- **범위:** 한국어 일반 질문 100개, 특정 모델 버전(gpt-5.6-terra, claude-sonnet-5-5, gemini-3.8-flash), 학생 Qwen3-0.6B-Base에서의 결과다. 모델 버전이 바뀌면 누출의 크기와 어느 평가자에서 나타나는지가 달라질 수 있다.
- **질문 선정의 치우침:** 공통 완전 질문 144개(그중 100개)는 400개 전체보다 질문이 조금 짧다. 긴 질문에서 Claude 학생이 끝맺지 못하는 경우가 많았기 때문이다.
- **디코딩의 영향:** 반복 억제(1.1)가 번호 목록 사용을 줄여(Gemini 학생 58% → 38%) 문체 지문이 1차 생성보다 다소 흐려졌다. 누출 추정치는 보수적일 수 있다.
- **seed의 범위와 부호 검정의 해상도:** seed 5개는 학습 무작위성만 바꾸고, 부호 검정의 최소 p값은 0.031이다(세 평가자 Holm 보정 시 0.094).
- **평가자 설정의 차이:** 모든 평가자의 추론 강도와 출력 한도를 맞췄지만, 제공사마다 추론 구현이 달라 완전히 같은 조건은 아니다.

부록 A. 평가자와 설정

평가자	모델	역할	호출 방식	상태
GPT	`gpt-5.6-terra`	GPT 교사와 같은 모델 → GPT 학생에 대한 누출	OpenAI Responses API, reasoning effort medium	본 채점

평가자	모델	역할	호출 방식	상태
Claude	`claude-sonnet-5-5`	Claude 교사와 같은 모델 → Claude 학생에 대한 누출	Anthropic Messages API, adaptive thinking, effort medium	본 채점
Gemini	`gemini-3.8-flash`	Gemini 교사와 같은 모델 → Gemini 학생에 대한 누출	Google GenAI API, thinking level medium	본 채점
중립	HyperCLOVA X `HCX-007`	세 계열과 무관 → 학생 품질의 외부 기준선	CLOVA Studio OpenAI 호환 API, reasoning effort medium	미실행 (피드백 후 결정)

- **교사 = 평가자:** 같은 계열 선호를 보려면 학생을 만든 교사와 평가자가 같은 모델이어야 한다.
- **같게 맞춘 것:** 모든 평가자가 같은 프롬프트, 같은 추론 강도(medium), 같은 출력 한도(12,288토큰, 사고 토큰 포함)를 쓰고 temperature는 보내지 않는다(각 제공사 기본값). 출력 한도는 HCX-007이 medium 추론에 기본 10,240토큰을 쓰는 것에 맞췄다. 한도는 상한일 뿐 추론 깊이는 추론 강도가 정하므로 다른 평가자의 채점에는 영향이 없다. 한도에 걸려 잘린 응답은 실패로 처리하고 다시 요청한다.
- **블라인드:** 평가자에게는 답변이 "답변 A, B, C"로만 보이고 출처(교사·seed)는 알려 주지 않으며, 출처를 추측하지 말라고 지시한다.
- **중립 평가자를 아직 돌리지 않은 이유:** HCX-007은 호출 한도 때문에 한 번에 1개씩만 보낼 수 있어(동시 8개에서 429 오류) 1,500개에 8~10시간이 걸린다. 먼저 세 계열 평가자만으로 선호 누출이 실제로 존재하는지 확인했고, 중립 평가자는 지도교수 피드백 후 필요하면 실행한다. 코드(`run_judge.py --judge hyperclova`)와 설정은 준비되어 있고, 파일럿 단계에서 호출이 되는 것을 확인했다. listwise에서는 세 계열 평가자끼리 비교해도 누출을 정의할 수 있으므로(3.4절) 중립 평가자 없이도 결론을 낼 수 있고, 중립 평가자는 "학생 품질의 외부 기준선"으로 결과를 보강한다.

부록 B. 평가 기준의 근거 (FLASK)

평가 차원은 LLM 응답의 세부 기술 평가 체계인 FLASK(Ye et al., 2024)를 따랐다. FLASK의 네 가지 상위 능력인 논리적 사고, 배경지식, 문제 처리, 사용자 정렬에서 본 연구의 질문 유형에 적용 가능한 대표 기술을 하나씩 선택하였다.

JSON 키	FLASK 상위 능력	선택한 기술	보는 것	성격
`factuality`	배경지식	사실 정확성	답변에 담긴 사실 정보가 정확한가	객관적 내용
`comprehension`	문제 처리	질문 충족도	질문의 명시적 요구와 암묵적 의도를 이해하고 그에 맞게 답했는가	내용
`logical_robustness`	논리적 사고	논리성	설명의 전개가 일관되고 모순이나 비약이 없는가	내용

JSON 키	FLASK 상위 능력	선택한 기술	보는 것	성격
`readability`	사용자 정렬	가독성과 한국어 자연스러움	읽기 쉽게 구성되었고 문장이 자연스러운 한국어인가	표현·문체
`overall`	(종합)		네 기준을 종합해 질문한 사람에게 가장 좋은 답변	주 결과

- 정답이 단일한 추론 문항을 전제하는 기술과 일상 질문에서 적용 빈도가 낮은 기술은 제외하였다.
- 응답 길이와 강하게 얽힌 기술도 제외하였다. 프롬프트에서 길이를 순위에 반영하지 말라고 지시했고, 길이의 영향은 결과에서 따로 확인한다(4.5절).
- 각 기준의 1, 3, 5점 기준 문장은 FLASK의 정의를 한국어 일반 질문에 맞게 번안하였다.
- 가독성에는 한국어 평가자가 외국어 혼입을 잘 감점하지 못한다는 선행 보고(Son et al., 2024)에 따라 한국어 자연스러움을 포함하였다.

> **기준별로 따로 순위를 받는 이유(H2).** 학생은 교사의 형식(글머리 목록, 번호 목록, 굵게, 길이)과 어휘·어미를 물려받았다. 이런 문체 지문은 가독성 판단에 직접 영향을 줄 수 있는 반면, 사실 정확성은 문체와 무관하게 판단되어야 한다. 기준마다 누출 크기를 따로 추정하면 평가자가 **어떤 판단에서** 자기 계열을 우대하는지 보일 수 있다.

부록 C. 평가 프롬프트 전문 (`judge/test_prompt.py`)

네 평가자 모두 아래 문장을 그대로 쓴다.

시스템 프롬프트

당신은 한국어 답변의 품질을 평가하는 엄격하고 공정한 평가자입니다.
하나의 질문에 대한 세 개의 답변(답변 A, 답변 B, 답변 C)을 읽고, 네 가지 기준 각각에 대해 세 답변의 순위를 1위부터 3위까지 매기십시오.

규칙
- 채점 전에 질문이 요구하는 핵심 내용과 사실관계를 스스로 확인하십시오.
- 각 기준마다 세 답변을 비교한 근거를 먼저 한두 문장으로 쓰고, 그 다음 순위를 정하십시오.
- 기준끼리 섞지 마십시오. 예를 들어 사실이 틀렸어도 문장이 자연스러우면 가독성 순위는 높을 수 있습니다.
- 답변의 길이 자체를 순위에 반영하지 마십시오. 길다고 좋은 답이 아닙니다.
- 답변을 쓴 모델이 누구인지 추측하지 마십시오.
- 답변이 제시된 순서(A, B, C)는 품질과 무관합니다. 순서에 영향을 받지 말고 내용만 비교하십시오.
- 명백히 틀린 정보는 감점하십시오. 자신의 지식으로 확인할 수 없는 정보는 근거에 "확인 불가"라고 적고, 사실 정확성의 3점 기준(확인되지 않는 세부 정보)에 따라 판단하십시오.
- 세 답변이 모두 부족하더라도 기준에 비추어 상대적으로 나은 순서대로 순위를 매기십시오. 동점은 허용하지 않습니다.
- 네 기준의 순위를 모두 매긴 뒤, 마지막으로 네 기준을 종합해 질문한 사람에게 가장 좋은 답변부터 최종 순위(overall)를 매기십시오.

아래는 각 기준에서 좋은 답(5점)과 나쁜 답(1점)을 구별하는 판단 기준입니다. 이 기준에 더 가까운 답변에 높은 순위를 주십시오.

[기준 1] 사실 정확성 (Factuality)
답변에 담긴 사실 정보가 정확한가.
5점: 핵심 정보와 세부 정보가 모두 정확하다.
3점: 핵심은 맞지만 부정확하거나 확인되지 않는 세부 정보가 있다.
1점: 핵심 정보가 틀렸거나 지어낸 내용이 중심이다.

[기준 2] 질문 충족도 (Comprehension)
질문의 명시적 요구와 암묵적 의도를 이해하고 그에 맞게 답했는가.
5점: 질문이 묻는 모든 부분에 직접 답하고 의도에 맞는 정보를 준다.
3점: 질문의 일부에만 답하거나 의도를 부분적으로 놓친다.
1점: 질문과 무관하거나 질문을 잘못 이해했다.

[기준 3] 논리성 (Logical Robustness)
설명의 전개가 일관되고 모순이나 비약이 없는가.
5점: 근거와 결론이 자연스럽게 이어지고 모순이 없다.
3점: 대체로 이어지지만 비약이나 근거 없는 주장이 일부 있다.
1점: 자기모순이 있거나 전개를 따라갈 수 없다.

[기준 4] 가독성과 한국어 자연스러움 (Readability)
읽기 쉽게 구성되었고 문장이 자연스러운 한국어인가.
5점: 구성이 명확하고 문법과 어휘가 자연스럽다. 불필요한 외국어 혼입이 없다.
3점: 이해는 되지만 어색한 문장, 반복, 번역투가 눈에 띈다.
1점: 문장이 깨지거나 반복이 심하거나 다른 언어가 섞여 읽기 어렵다.

사용자 프롬프트

```
[질문]
{question}

[답변 A]
{answer_a}

[답변 B]
{answer_b}

[답변 C]
{answer_c}

다음 JSON 형식으로만 출력하십시오. ranking에는 가장 나은 답변부터 순서대로 "A", "B", "C"를 한 번씩만 쓰십시오.
{"factuality": {"reason": "세 답변을 비교한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]},
 "comprehension": {"reason": "세 답변을 비교한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]},
 "logical_robustness": {"reason": "세 답변을 비교한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]},
 "readability": {"reason": "세 답변을 비교한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]},
 "overall": {"reason": "네 기준을 종합한 근거 한두 문장", "ranking": ["1위", "2위", "3위"]}}
```

- **참조 답안을 주지 않는 이유:** 평가 질문의 참조 답(KoAlpaca)은 지식iN 답을 시드로 ChatGPT가 새로 생성한 것이다. 참조 답을 주면 OpenAI 계열 문체 쪽으로 기준이 기울어 GPT 학생이 인위적으로 유리해지고, 평가자 자신의 선호가 가려진다.
- **"확인 불가" 규칙:** 명백히 틀린 정보는 감점하고, 평가자가 확인할 수 없는 정보는 근거에 "확인 불가"라고 적은 뒤 사실 정확성 3점 기준(확인되지 않는 세부 정보)에 따라 판단하게 했다. pointwise 설계 때 "확인할 수 없으면 감점하지 말라"는 문장과 3점 기준이 서로 충돌해 고친 것이다.
- **응답 검증:** 평가자 응답에서 JSON을 꺼내 다섯 키(기준 4개 + overall)가 모두 있고 각 순위가 A·B·C를 정확히 한 번씩 담고 있는지(동점·누락·중복 없음) 확인한다. "답변 C"처럼 써도 "C"로 읽고, 순위를 "B > C > A"처럼 문자열로 써도 A·B·C가 한 번씩이면 받아들인다(예방용 처리). 형식이 틀리면 같은 항목을 최대 3번 다시 요청하고, 그래도 실패하면 기록하지 않고 다음 실행 때 다시 시도한다.
- **재요청 문장:** Gemini는 일부 항목에서 `overall`에 근거 문장만 쓰고 `ranking`을 빠뜨렸다(근거 안에는 "C는 최하위, A가 가장 덜 나쁘다"처럼 순위를 산문으로 적음). 같은 프롬프트로 다시 요청해도 같은 항목에서 반복되어, 재요청할 때만 사용자 프롬프트 끝에 "(주의: 직전 응답에 형식 오류가 있었습니다: …. 다섯 항목 모두 reason과 ranking을 포함한 JSON 전체를 다시 출력하십시오.)"를 덧붙였다. 평가 내용에 관한 지시

는 바꾸지 않고, 형식 오류가 난 항목에만 모든 평가자에게 같게 적용된다. 이 문장으로 재요청한 항목 수는 부록 H에 보고한다.

부록 D. pointwise에서 listwise로 바꾼 경위와 파일럿

D.1 처음 설계: pointwise 1~5점 채점

처음에는 학생 답변 하나를 따로 보여 주고 네 기준마다 1~5점을 매기게 했다(pointwise). seed 42 학생 3명의 답 10개씩으로 파일럿을 돌린 결과(평가자 4명 × 답 30개 = 120개 채점), 다음 문제가 확인되었다.

- **바닥 효과(floor effect):** 0.6B 학생은 질문의 형식은 따르지만 사실을 대부분 지어낸다. 그 결과 **사실 정확성 120개가 모두 1점**이었고, 질문 충족도와 논리성도 대부분 1점에 몰렸다.
- **누출을 볼 수 없음:** 모든 학생이 같은 최저점이면 평가자가 자기 계열 학생을 더 좋게 보더라도 점수 차이로 나타나지 않는다. 선호 누출은 "품질이 비슷한 답 사이에서 어느 쪽을 더 좋게 보는가"에서 드러나는데, 절대 점수는 그 차이를 표현할 해상도가 없었다.

D.2 바꾼 설계: listwise 순위 평가

같은 질문에 대한 **같은 seed**의 학생 3명(GPT·Claude·Gemini 학생, 교사만 다름)의 답을 한 번에 보여 주고, 기준마다 1위~3위 순위를 매기게 한다. 동점은 허용하지 않는다.

- **바닥 효과 해소:** 셋 다 품질이 낮아도 "상대적으로 덜 틀린 답"을 고르게 되므로 판정이 한쪽에 몰리지 않는다. 실제로 listwise 파일럿에서는 평가자들이 "세 답변 모두 정답(힐 자매)을 제시하지 못했지만, C가 가장 직접적이고 허위 세부 정보가 적다"처럼 상대 비교로 순위를 매겼다(D.4).
- **비교 평가가 절대 점수보다 안정적:** LLM 평가자는 절대 점수보다 두 답을 비교하는 판단에서 사람 판단과 더 잘 일치한다고 보고되었다(Zheng et al., 2023; Liusie et al., 2024). 선호 누출을 처음 정의한 연구도 두 학생의 답을 비교하는 방식으로 누출을 측정했다(Li et al., 2025).
- **같은 seed끼리 비교:** 한 묶음은 항상 같은 seed의 학생 3명이다. 같은 seed의 세 학생은 같은 질문 1,000개를 같은 순서로 보며 학습했고 교사 답변만 다르므로, 묶음 안의 비교에는 학습 운의 차이가 들어가지 않고 교사 답변의 차이만 남는다.
- **pairwise가 아니라 listwise인 이유:** 쌍대 비교(pairwise)로 세 학생을 비교하려면 묶음마다 쌍 3개 × 순서 2가지 = 6회 호출이 필요하다. listwise는 세 답을 한 번에 보므로 순서 3가지로 위치를 완전히 균형 잡아도 3회면 되고, 한 순위에서 쌍 3개의 승패가 모두 나온다(3절). 또 세 답이 같은 맥락에서 비교되어 쌍마다 기준이 달라지는(비이행적 판단) 문제가 생기지 않는다.
- **1, 3, 5점 기준 문장은 유지:** 점수를 매기지는 않지만, 각 기준에서 좋은 답과 나쁜 답을 구별하는 판단 기준으로 그대로 제시한다.

D.3 출력 형식: 기준별 순위 + 종합 근거 + 최종 순위 (형식 C)

평가자는 한 번의 호출에서 다음을 모두 출력한다.

1. 네 기준(사실 정확성, 질문 충족도, 논리성, 가독성) 각각에 대해 세 답을 비교한 **근거 한두 문장**과 **1~3위 순위**
2. 네 기준을 종합한 **근거 한두 문장**과 **최종 순위(overall)**: "질문한 사람에게 가장 좋은 답변"부터의 순위

- **최종 순위 → 주 결과:** 최종 순위로 승률(자기 계열 학생을 다른 학생보다 위에 놓는 비율)을 계산해 H1의 주 결과로 쓴다.
- **기준별 순위 → H2:** 같은 승률을 기준마다 계산해 누출이 어떤 판단(사실 vs 문체)에서 드러나는지 본다.
- **기준별 근거를 먼저 쓰게 한 이유:** 근거를 먼저 쓰고 판단하게 하면 위치 편향이 줄어든다고 보고되었다(Wang et al., 2024의 Multiple Evidence Calibration). 근거는 결과 해석(어떤 이유로 자기 계열 학생을 높게 봤는지)에도 쓴다.

D.4 listwise 파일럿 결과 (seed 42, 질문 10개 × 순서 3가지 = 평가자당 30개)

목적: 형식 C 출력이 안정적으로 나오는지, 바닥 효과가 사라졌는지, 위치 편향이 어느 정도인지 확인. 표본이 작아 누출 여부를 판단하는 자료는 아니다.

실행

평가자	완료	최종 실패	30개 소요 (동시 8개)
GPT	30/30	0	78초
Claude	30/30	0	33초
Gemini	30/30	0	51초 (1건은 3회 연속 최종 순위 형식 오류 → 다시 실행해 성공)

바닥 효과 해소

pointwise에서는 사실 정확성이 모두 1점이었지만, listwise에서는 평가자들이 "셋 다 환각이 심하지만 B가 거짓 정보의 양이 가장 적다"처럼 상대 비교로 순위를 매겼다. 최종 순위와 기준별 1위가 같은 비율은 63~97%로, 최종 순위가 네 기준을 실제로 반영했다.

최종 순위 승률 (%, 기준선 50)

평가자 \ 학생	Claude 학생	Gemini 학생	GPT 학생
Claude 평가자	**30.0**	68.3	51.7
Gemini 평가자	45.0	**68.3**	36.7

평가자 \ 학생	Claude 학생	Gemini 학생	GPT 학생
GPT 평가자	43.3	51.7	**55.0**

굵은 칸이 자기 계열 평가. 질문 10개라 방향만 참고한다. 학생 평균 길이는 Claude 426, Gemini 336, GPT 243토큰.

위치 편향은 실제로 나타났다

평가자	최종 1위가 A 위치	B	C	순서 3가지에서 1위가 모두 같은 묶음	1~3위 전체가 같은 묶음
GPT	15	9	6	50%	20%
Claude	13	7	10	50%	40%
Gemini	12	9	9	80%	60%

편향이 없으면 1위 위치는 10/10/10이어야 하는데, 세 평가자 모두 첫 번째(A) 답을 1위로 더 자주 골랐다(Zheng et al., 2023의 첫 번째 답 선호와 같은 방향). 또 순서만 바꿨는데 1위가 바뀐 묶음이 GPT·Claude는 절반이었다. 학생 답들의 품질이 모두 낮고 비슷해 위치 편향이 커지는 조건(Shi et al., 2025)이다. **순서 하나로만 평가했다면 결과가 위치에 크게 흔들렸을 것이므로, 순서 3가지로 평가하고 합치는 설계가 필요함을 파일럿이 직접 보여 준다.**

부록 E. 위치 편향: 선행 연구와 통제 설계 상세

E.1 위치 편향이란

위치 편향(position bias)은 LLM 평가자가 답의 **내용이 아니라 제시된 위치**(첫 번째, 마지막 등) 때문에 특정 답을 더 좋게 판단하는 현상이다. listwise에서는 세 답이 A·B·C 순서로 놓이므로, 어떤 학생이 늘 A에 놓이면 그 학생의 승률에 위치 효과가 섞인다. 선호 누출은 크기가 작을 수 있는 효과이므로, 위치 효과가 섞이면 누출이 생기거나 사라진 것처럼 보일 수 있다.

E.2 선행 연구: 위치 편향은 실제로 존재한다

연구	보고한 내용	본 연구에 반영한 점
Zheng et al. (2023), MT-Bench / Chatbot Arena	GPT-4 등 LLM 평가자가 두 답의 순서를 바꾸면 판정이 바뀌는 경우가 많고, 대체로 첫 번째 답을 선호한다. 위치 편향을 장황함 편향, 자기 강화 편향과 함께 LLM 평가자의 주요 편향으로 정리했다.	순서를 바꿔 다시 평가하고 결과를 합친다.
Wang et al. (2024), "Large Language Models are not Fair Evaluators"	순서만 바꿨는데 Vicuna-13B가 ChatGPT를 이기는 비율이 크게 뒤집혔다. 대책으로 (1) 근거를 먼저 쓰고 판단하는 Multiple Evidence Calibration, (2) 두 순서로 모두 평가해 평균하는 Balanced Position Calibration을 제안했다.	(1) 기준마다 근거를 먼저 쓰게 했다. (2) 모든 학생을 모든 위치에 같은 횟수로 놓고 평균한다.

연구	보고한 내용	본 연구에 반영한 점
Shi et al. (2025), "Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge"	여러 평가자·과제에서 위치 편향을 체계적으로 측정했다. 지표로 위치 일관성(순서를 바꿔도 같은 판정인 비율)과 선호 공정성(특정 위치 쪽으로 기우는 정도)을 제안했고, **두 답의 품질 차이가 작을수록 위치 편향이 커진다**고 보고했다.	본 연구의 학생 답은 모두 품질이 낮고 비슷해 위치 편향이 커지기 쉬운 조건이다. 같은 지표로 진단한다.
Tang et al. (2024), "Found in the Middle: Permutation Self-Consistency"	여러 항목을 한 번에 순위 매기는 listwise 과제에서도 LLM이 입력 위치에 따라 순위를 다르게 매긴다. 입력 순서를 여러 번 섞어 순위를 얻고 합치면 위치 편향이 줄고 순위 품질이 좋아진다.	같은 묶음을 순서를 바꿔 여러 번 순위 매기고 합친다.
Hou et al. (2024), LLM zero-shot ranker	LLM으로 후보 목록의 순위를 매길 때 후보의 제시 순서가 순위에 영향을 준다. 순서를 무작위로 바꿔 여러 번 평가하면 완화된다.	listwise에서도 순서 통제가 필요하다는 근거.

E.3 본 연구의 통제 방법

(1) 묶음마다 순서 3가지로 평가 (라틴 방격, cyclic rotation). 묶음 하나(같은 질문·같은 seed의 학생 3명)를 순서만 바꿔 3번 평가한다. 기본 순서를 한 칸씩 돌려 만든 세 순서를 쓰므로, **각 학생이 A·B·C 위치에 정확히 한 번씩** 놓인다.

```
기본 순서가 (GPT, Claude, Gemini)인 묶음의 예

순서 0 (rotation 0):  A = GPT     B = Claude  C = Gemini
순서 1 (rotation 1):  A = Claude  B = Gemini  C = GPT
순서 2 (rotation 2):  A = Gemini  B = GPT     C = Claude

→ 각 학생이 A, B, C에 한 번씩. 세 번의 순위를 평균하면 위치 효과가 상쇄된다.
```

(2) 기본 순서를 6가지 순열에서 돌아가며 정함. 순환만 쓰면 "GPT 다음에 Claude"처럼 앞뒤 관계가 항상 같다. 그래서 묶음 번호에 따라 기본 순서를 6가지 순열(GPT-Claude-Gemini, GPT-Gemini-Claude, …)에서 차례로 바꿔, 전체적으로 어떤 학생이 어떤 학생 앞에 오는지도 균형을 맞췄다.

(3) 전체 위치 균형 확인. 1,500개 항목에서 각 학생은 A·B·C에 정확히 500번씩 놓인다(`selection.json`의 `position_balance`: GPT·Claude·Gemini 모두 [500, 500, 500]).

(4) 평가 순서를 무작위로 섞음. 같은 묶음의 순서 3가지가 연달아 평가되지 않도록 1,500개 항목의 처리 순서를 섞었다(추첨용 난수 seed 42). 각 호출은 독립된 대화라 이전 평가를 기억하지 않는다.

(5) 프롬프트 지시. "답변이 제시된 순서(A, B, C)는 품질과 무관합니다. 순서에 영향을 받지 말고 내용만 비교하십시오."라고 명시하고, 기준마다 근거를 먼저 쓰게 했다(Wang et al., 2024).

(6) 분석에서 통제와 진단. 승률은 세 순서의 결과를 모두 합쳐 계산하므로 위치 효과가 상쇄된다. 회귀 분석에서는 위치를 공변량으로 넣어 남는 효과를 한 번 더 뺀다. 위치 편향의 크기는 따로 보고한다.

- **위치별 1위 비율:** 편향이 없으면 A·B·C 모두 1/3이다. 카이제곱 적합도 검정으로 확인한다.
- **위치 일관성(Shi et al., 2025):** 같은 묶음의 순서 3가지에서 1위로 뽑힌 학생이 세 번 모두 같은 비율이다.

E.4 왜 6가지 순열이 아니라 3가지인가

설계	묶음당 호출	평가자당 호출	3개 평가자 합	위치 균형
순서 1가지	1	500	1,500	묶음 사이에서만 균형. 묶음 안에서는 위치 효과가 그대로 남음
순서 3가지 (채택)	3	1,500	4,500	묶음 안에서 각 학생이 각 위치에 한 번씩 (완전 균형)
6가지 순열 전부	6	3,000	9,000	완전 균형 + 앞뒤 관계까지 묶음 안에서 균형

순서 3가지만으로도 묶음 안에서 각 학생이 각 위치에 같은 횟수로 놓여, 위치 효과는 평균에서 완전히 상쇄된다. 6가지로 늘리면 앞뒤 관계까지 묶음 안에서 맞출 수 있지만 호출이 두 배가 된다(중립 평가자를 포함하면 12,000회, HyperCLOVA만 17~20시간). 앞뒤 관계는 (2)의 기본 순서 교대로 전체 수준에서 이미 균형을 맞췄으므로 3가지를 택했다.

부록 F. 평가 데이터 선정과 seed의 의미

1. **학생 응답:** 학생 15명이 평가 질문 400개(학습·검증 질문과 겹치지 않음)에 greedy 디코딩(반복 억제 1.1, 최대 1,024토큰)으로 답한 2차 응답(`inference/output_2nd/`)을 쓴다.
2. **완전한 답:** 끝내는 토큰으로 스스로 멈췄고(`finished=true`), 1,024토큰 미만이며, 빈 답이 아닌 답이다.
3. **공통 완전 질문:** 15명 **모두**의 답이 완전한 질문만 쓴다. 모든 학생을 같은 질문으로 비교해야 공정하고, 잘린 답은 미완성이라 감점 요인이 누출과 섞이기 때문이다. 144개가 해당한다.
4. **교차 검증:** 144개 모두 15명 전원의 답이 완전한지 다시 확인했고(위반 0건), 빠진 256개는 모두 적어도 한 학생에서 실제로 불완전했다(위반 0건).
5. **100개 선정:** 144개에서 **추첨용 난수 seed 42**로 100개를 뽑았다. 이 seed는 추첨을 재현하기 위한 값으로, 학생 모델의 seed(42~46)와는 무관하다.
6. **묶음과 항목:** 묶음 = 질문 1개 × 학생 seed 1개(같은 seed의 학생 3명) → 100 × 5 = 500개. 항목 = 묶음 × 제시 순서 3가지 → 1,500개.

학생	seed 42	43	44	45	46
GPT 학생 완전한 답 (/400)	380	388	386	390	393
Claude 학생 완전한 답	343	296	322	331	335
Gemini 학생 완전한 답	384	383	391	387	389

규모	개수
평가 질문	100
묶음 (질문 × seed 5)	500
평가 항목 = 평가자당 API 호출 (묶음 × 순서 3)	1,500
API 호출 (항목 × 평가자 3, 중립 제외)	4,500
순위 (호출 × 학생 3 × (기준 4 + 최종 1))	67,500
최종 순위의 쌍 승패 (호출 × 쌍 3)	13,500

F.2 seed의 의미

seed는 학생을 학습할 때의 **무작위성**을 정하는 숫자다. 교사마다 seed 42, 43, 44, 45, 46으로 학생을 5번 따로 학습했다.

seed마다 같은 것	seed마다 달라지는 것
시작 모델(Qwen3-0.6B-Base 가중치), 학습 데이터 1,000개(교사 답변), 하이퍼파라미터, 프롬프트 형식, GPU	epoch마다 학습 데이터를 보는 순서(data shuffle), dropout 위치 등 학습 과정의 난수

- **의미:** seed가 다르면 같은 데이터로도 학습 경로가 달라져 조금씩 다른 학생이 만들어진다. 같은 교사의 seed 42와 43 학생은 평가 질문 400개 중 똑같은 답이 하나도 없었다.
- **왜 5번 학습했나:** 학생이 하나뿐이면 "평가자가 자기 계열 학생을 높게 본 것"이 누출 때문인지, 그 학생이 우연히 잘 학습됐기 때문인지 구분할 수 없다. 5번 따로 학습한 학생 모두에서 같은 결과가 나오면, 결과가 한 번의 학습 운에 따른 것이 아니라는 근거가 된다.
- **같은 seed끼리 비교:** 묶음은 항상 같은 seed의 학생 3명으로 구성되고, seed별 누출도 그 seed의 묶음만으로 계산한다.
- **주의:** seed는 **학습 무작위성**만 바꾼다. seed 반복은 "다른 데이터셋에서도 같은가"가 아니라 "같은 조건에서 학습을 다시 해도 같은가"를 보여 준다.

부록 G. 통계 모형 상세 (`judge/analyze_models.py`)

입력은 `judge/output/ranks_long.csv` (평가자 3 × 항목 1,500 × 학생 3 × 결과 5 = 67,500행). 결과(overall, 기준 4개)마다 아래 세 모형을 같은 방식으로 적합했다.

G.1 순위 로짓 모형 (Plackett-Luce)

자료. `judge/output/ranks_long.csv`의 최종 순위(`overall`). 평가자 3명 × 항목 1,500개 = 순위 4,500개. 순위 하나는 같은 묶음(같은 질문, 같은 seed)의 학생 3명에 대한 1~3위다.

모형. 평가자 j가 항목(묶음 g, 순서 r)에서 학생 t의 답에 느끼는 효용을 다음과 같이 둔다.

```
u(j, g, r, t) = θ[seed, t]          학생 품질 (학생 15명 = 교사 3 × seed 5; seed마다 GPT 학생이 기준)
              + δ[j, 위치]          평가자별 위치 효과 (A, B; C가 기준)
              + λ_j · 1[t = j]      평가자 j의 자기 계열 효과  ← 관심 모수 (로그 오즈)

P(순위 B > A > C) = e^{u_B} / (e^{u_A} + e^{u_B} + e^{u_C})  ×  e^{u_A} / (e^{u_A} + e^{u_C})
```

- 순위를 "세 답 중 1위 고르기 → 남은 두 답 중 2위 고르기"의 두 번의 선택으로 보는 모형이다(Luce, 1959; Plackett, 1975; 순위 로짓 또는 exploded logit, Beggs et al., 1981). 동점이 없는 순위 자료에 표준적으로 쓰인다.
- **해석:** λ_j > 0이면 평가자 j는 품질과 위치가 같은 조건에서 자기 계열 학생을 더 위에 놓는다. 이 모형에서 학생 a가 b보다 위에 놓일 확률은 정확히 e^{u_a}/(e^{u_a}+e^{u_b})이므로, λ는 "품질이 같은 상대를 이길 확률"로 바꿔 쓸 수 있다: **σ(λ) − 50%**(%p). 오즈비 e^λ도 함께 보고한다.
- **위치 효과를 평가자별로 넣은 이유:** 5절에서 본 첫 번째 위치 선호의 크기가 평가자마다 다르다. 위치는 설계상 균형이라 λ를 편향시키지는 않지만, 모형에 넣으면 잡음이 줄고 위치 편향의 크기도 함께 추정된다.

> **세 평가자의 효과가 분리되는 원리.** 학생 쌍마다 두 학생 어느 쪽과도 계열이 다른 **제3의 평가자**가 있다. 예를 들어 (GPT 학생, Claude 학생) 쌍에서
>
> - GPT 평가자가 보는 차이 = 품질 차 + λ_{GPT}
> - Claude 평가자가 보는 차이 = 품질 차 − λ_{Claude}
> - Gemini 평가자가 보는 차이 = 품질 차 (이 쌍에 대해 중립)
>
> 쌍 3개 × 평가자 3명의 정보로 품질 차 2개와 λ 3개를 함께 추정할 수 있다. 중립 평가자(HyperCLOVA) 없이도 누출이 식별되는 이유다.

식별 가정과 검정. 이 분리는 "평가자는 자기 계열이 아닌 두 학생을 품질 외에는 똑같이 대한다"(예: GPT 평가자에게 Gemini 학생만 특별히 싫어하는 효과가 없다)는 가정에 기댄다. 이 가정은 자료로 검정할 수 있다. 평가자 × 교사 상호작용을 모두 넣은 일반 모형(교사 대비 6개)과 λ 모형(5개)을 우도비 검정(자유도 1)으로 비교한다. 기각되지 않으면 가정이 자료와 모순되지 않는다.

추정. 최대우도법. 선택 집합(순위 4,500개 × 2단계 = 9,000개)마다 softmax를 계산하는 조건부 로짓 우도를 직접 구현했다(statsmodels `ConditionalLogit`과 같은 값, 최대 차이 0.001; 부트스트랩을 위해 약 200배 빠르게).

표준오차: 질문 단위 군집 부트스트랩. 질문 100개를 복원 추출하고, 뽑힌 질문의 모든 자료(seed 5 × 순서 3 × 평가자 3)를 통째로 가져와 다시 적합하기를 1,000번 반복했다. 같은 질문이 다섯 seed에 다시 나오고, 한 질문 안의 순위들은 서로 독립이 아니므로 질문을 재추출 단위로 삼았다. 95% 신뢰구간은 백분위 구간, p값은 부트스트랩 분포에서 0의 반대쪽 비율의 두 배다(1,000회라 최솟값 0.001).

민감도: 길이 통제. 학생 답 길이(표준화한 log 토큰 수)에 대한 평가자별 기울기를 추가한 모형도 적합했다. 평가자마다 길이 선호가 다르면 그것이 누출처럼 보일 수 있기 때문이다(Claude 학생이 가장 길다; 결과는 G.5).

G.2 강건성 분석: 쌍 고정효과 선형확률모형

자료. 묶음마다 학생 쌍 3개, 쌍마다 평가자 3 × 순서 3 = **9번의 판정**(총 1,500쌍 × 9 = 13,500행). y = 1이면 쌍의 앞 학생이 뒤 학생을 이겼다.

```
y = α[쌍] + Σ_j λ_j · (1[평가자=j, 앞 학생=j] − 1[평가자=j, 뒤 학생=j]) + 평가자별 위치 더미 + ε
```

- **α[쌍]**(쌍 고정효과): 이 질문에서 이 두 답의 품질 차이를 통째로 흡수한다. 내용, 길이, 질문 난이도가 모두 들어간다. PL은 학생 단위 품질(θ)만 넣으므로, 질문마다 달라지는 품질은 LPM이 맡는다.
- **λ_j**: 그 쌍에 중립인 평가자에 비해 자기 계열 학생이 이길 확률이 몇 %p 높은지. 선형 모형이라 %p로 바로 읽힌다.
- 추정은 쌍 평균을 빼는 within 변환 후 OLS, 표준오차는 질문 단위 군집(쌍은 질문 안에 포함되므로 고정효과 자유도 보정이 필요 없다; Cameron & Miller, 2015).

G.3 반복성, 기준별 분석, 다중비교

- **seed별 적합(H3):** PL과 LPM을 seed마다 따로 적합해 평가자마다 추정치 5개를 얻고, 부호 검정(5/5면 한쪽 p = 0.031)과 일표본 t검정(한쪽)을 했다.
- **기준별 적합(H2):** 네 기준의 순위 각각에 같은 PL을 적합했다(부트스트랩 1,000회씩).
- **Holm 보정**(Holm, 1979): 검정 묶음을 미리 정했다. H1 = 최종 순위의 λ 3개, H2 = 기준 4 × 평가자 3 = 12개, H3 = seed 검정 3개(부호 검정, t검정 각각).

G.4 모형 검증: 정답을 아는 가짜 자료

실제 자료에 적합하기 전에, 실제 설계(묶음 500개, 순서 3가지, 같은 위치 배치)와 똑같은 구조로 λ를 알고 심은 가짜 순위를 만들어 모형이 그 값을 되찾는지 확인했다. 질문마다 달라지는 품질 잡음(표준편차 0.8)과 위치 효과

(A 0.5, B 0.2)도 넣었다. 각 조건 25번 반복.

조건	결과	의미
누출 없음 (λ = 0, 0, 0)	PL 추정치 평균 0.011 / −0.012 / −0.006. LPM이 잘못 유의하게 나온 비율 평균 5.3%	누출이 없으면 없다고 나온다(편향 없음, 1종 오류 정상)
누출 있음 (λ = 0.3, 0.1, 0.5)	PL 추정치 평균 0.256 / 0.067 / 0.383 (참값의 67~85%)	방향은 정확하고 크기는 다소 작게 나온다(보수적)
가정 위반 (λ = 0이지만 GPT 평가자가 Gemini 학생만 싫어함)	식별 가정 검정 LR = 13.4, p = 0.0003	가정이 깨지면 검정이 잡아낸다

크기가 작게 나오는 이유: 질문마다 다른 품질 차이를 PL에 넣지 않았기 때문이다. 로짓 모형에서 관측되지 않은 이질성은 계수를 0 쪽으로 줄인다. 따라서 PL의 λ는 실제 누출의 **하한에 가까운 보수적 추정**이다. 쌍 고정효과로 이 이질성을 흡수하는 LPM이 이를 보완한다.

G.5 1위만 쓴 모형 (모형 ①)

전체 순위 모형은 순위를 "1위 고르기 → 남은 둘 중 2위 고르기" 두 단계로 본다. 모형 ①은 **첫 단계(1위 고르기)만** 써서 같은 효용 식(θ + δ + λ)을 조건부 로짓으로 추정한다. λ는 다음과 같이 1위 확률로 바꿔 읽는다: 품질과 위치가 같은 세 답 중 자기 계열 답이 1위로 뽑힐 확률 = e^{λ} / (e^{λ} + 2), 기준선 1/3. 2위·3위 정보를 버리므로 덜 정밀하지만 3.1의 1위 비율과 같은 질문에 답한다.

G.6 식별 가정 검정과 길이 민감도

- **식별 가정 검정:** 평가자 × 교사 상호작용을 모두 넣은 일반 모형과 λ 모형의 우도비 검정(자유도 1). 최종 순위 LR = 0.0006, p = 0.98. 기준별 p: 사실 정확성 0.23, 질문 충족도 0.37, 논리성 0.029, 가독성 0.044.
- **길이 민감도(최종 순위):** 평가자별 길이 기울기(표준화 log 토큰 수)를 넣으면 Gemini +8.8%p [5.7, 11.3](p = 0.005), GPT +5.4%p [1.9, 8.9](p = 0.005), Claude −0.3%p [−3.4, 2.5](p = 0.87). 세 평가자 모두 같은 조건이면 짧은 답을 약간 선호했다(기울기 −0.16, −0.28, −0.23). Gemini의 누출은 길이와 무관하게 유지되고, GPT의 누출은 길이를 통제하면 오히려 커진다(GPT 학생이 가장 짧은데 GPT 평가자의 짧은 답 선호가 가장 약해, 그 몫이 누출을 일부 가렸다). 부트스트랩 200회.
- **Holm 보정 묶음:** 모형마다 (최종 순위의 평가자 3개), (기준 4 × 평가자 3 = 12개), (최종 순위 seed 검정 3개)를 각각 한 묶음으로 보정했다.

부록 H. 결과 파일, JSON 키, 실행 방법

H.1 파일

경로	내용
`judge/data/eval_items.json`	평가 항목 1,500개 (질문, 제시 순서, 순서대로 놓인 학생 답 3개, 길이)
`judge/data/selection.json`	공통 완전 질문 144개 id, 선택한 100개 id, 학생별 완전한 답 수, 검증 결과, 순서 배정 방식, 위치 균형
`judge/output/raw/{judge}.jsonl`	평가자별 채점 원본. 한 줄에 항목 하나(이어 하기용)
`judge/output/judged/{teacher}_seed{n}_eval400.json`	**최종 JSON (15개).** 학생 응답 JSON의 원래 내용 그대로 + 평가 대상 100문항에 평가자별 순위·근거
`judge/output/ranks_long.csv`	분석용 긴 표. 한 행 = 평가자 × 항목 × 학생 × 기준의 순위 (평가자 3명 완료 시 67,500행)
`judge/output/pilot/`	파일럿(seed 42 묶음 10개 × 순서 3가지)의 같은 구조 결과
`judge/output/analysis/desc_*.csv`	기술 통계 (`descriptive.py`): 순위 횟수, 1위 비율, 쌍대 승률, 단순 누출, 위치 편향, 질문별 승자, 평가자 간 일치 — overall과 기준 4개
`judge/output/analysis/model_*.csv`, `models_summary.json`	통계 모형 (`analyze_models.py`): 세 모형 × 결과 5개의 추정치·신뢰구간·Holm p, seed별 추정치와 검정, 위치 효과, 식별 가정 검정, 길이 민감도

H.2 최종 JSON 예시 (파일럿 실제 값, `claude_seed42_eval400.json`의 질문 20번)


```
{
  "id": 20, "category": "사회/정치",
  "instruction": "세계에서 가장 많이 부르는 생일 축하 노래인 'Happy Birthday to You'는 누가 만들었을까요?",
  "reference": "19세기 미국 켄터키주 유치원 보모로 있던 밀드레드와 패티라는 자매가 ...",
  "output": "\"Happy Birthday to You\"는 미국의 **Billboard**(...)가 19...",
  "n_new_tokens": 285, "finished": true, "teacher": "claude", "seed": 42,
  "in_judge_set": true,
  "judges": {
    "gpt": {
      "model": "gpt-5.6-terra",
      "factuality": {"ranks": [3, 2, 3], "positions": ["B", "A", "C"],
"mean_rank": 2.6667,
                     "reasons": ["정답은 미국의 힐 자매(패티 힐과 밀드레드 J. 힐)로 알려져 있는데, 세 답변 모두 ...", "...", "..."]},
      "comprehension": {...}, "logical_robustness": {...}, "readability": {...},
      "overall": {"ranks": [3, 2, 3], "positions": ["B", "A", "C"], "mean_rank":
2.6667,
                  "reasons": ["세 답변 모두 정답인 힐 자매를 제시하지 못했지만, C가 가장 직접적이고 ...", "...", "..."]},
      "criteria_mean_rank": 2.4167
    },
    "claude": {...},
    "gemini": {...}
  }
}
```


H.3 각 키의 의미

키	의미	왜 이렇게 저장했나
`id` ~ `seed`	학생 응답 원본(`inference/output_2nd/`)의 내용 그대로: 질문 id, 카테고리, 질문, 참조 답, 학생 답, 생성 토큰 수, 스스로 끝맺었는지, 교사, seed	원본을 바꾸지 않고 평가만 덧붙여 추적 가능하게
`in_judge_set`	평가 대상 100문항이면 `true`. 나머지 300문항은 `false`이고 `judges`가 없다	400문항 파일 하나에서 평가 대상을 바로 구분
`judges`	평가자 이름(`gpt`, `claude`, `gemini`; HyperCLOVA를 실행하면 `hyperclova`가 추가됨) → 그 평가자의 평가	평가자별로 나란히 비교
`model`	평가에 쓴 정확한 모델 이름	재현성

키	의미	왜 이렇게 저장했나
`factuality` 등 4개 기준, `overall`	기준별(그리고 최종) 평가 결과. 아래 네 키를 담는다	H1은 `overall`, H2는 기준별
`ranks`	**이 학생이 순서 3가지(rotation 0, 1, 2)에서 각각 받은 순위**(1이 최고). 위 예시 [3, 2, 3]은 GPT 평가자가 Claude 학생을 순서 0에서 3위, 순서 1에서 2위, 순서 2에서 3위로 놓았다는 뜻	같은 묶음을 순서만 바꿔 3번 평가하므로 세 결과를 모두 남겨 위치 편향과 판정의 안정성을 볼 수 있게
`positions`	각 순서에서 이 학생의 답이 놓였던 위치(A·B·C). 예시 ["B", "A", "C"]: 순서 0에서 B, 1에서 A, 2에서 C. 세 위치에 한 번씩 놓였음을 보여 준다	순위와 위치를 함께 보면 "A에 놓였을 때만 1위" 같은 위치 효과를 확인할 수 있다
`mean_rank`	세 순위의 평균(1~3). 각 학생이 각 위치에 한 번씩 놓였으므로 **위치 효과가 상쇄된 순위**	질문 하나에서의 요약값. 승률 = (3 − mean_rank) / 2
`reasons`	각 순서에서 평가자가 쓴 비교 근거(순서 0, 1, 2 순). 세 답을 비교한 문장이라 같은 묶음의 학생 3명에게 같은 문장이 붙고, 문장 속 "A, B, C"는 그 순서의 위치를 가리킨다	왜 그 순위를 줬는지 해석하고 사례를 제시하기 위해
`criteria_mean_rank`	네 기준 `mean_rank`의 평균(`overall`은 제외)	평가자의 종합 판단(overall)과 기준별 판단의 평균이 어긋나는지 비교

H.4 채점 원본(`raw/{judge}.jsonl`)의 키

```
{"item_id": 350, "group_id": 8, "rotation": 1, "order": ["gpt", "gemini",
"claude"],
 "judge": "gpt", "judge_model": "gpt-5.6-terra", "question_id": 1500, "seed": 42,
 "factuality": {"reason": "...", "ranking": ["A", "B", "C"], "ranks": {"gpt": 1,
"gemini": 2, "claude": 3}},
 ... 4개 기준 + "overall"}
```

- `item_id`: 항목 번호(0~1,499, 섞인 처리 순서). `group_id`: 묶음 번호(0~499). `rotation`: 순서 번호(0~2).
- `order`: 이 순서에서 A·B·C에 놓인 학생의 교사. 위 예시는 A = GPT 학생, B = Gemini 학생, C = Claude 학생.
- `ranking`: 평가자가 쓴 그대로의 순위(위치 라벨). 평가자는 학생을 모르고 라벨만 본다.
- `ranks`: `order`를 이용해 라벨 순위를 학생(교사)별 순위로 바꾼 것. 최종 JSON의 `ranks`는 이 값을 학생 파일별로 모은 것이다.

H.5 분석용 긴 표(`ranks_long.csv`)의 열

`judge, judge_model, teacher, seed, question_id, group_id, rotation, position, n_tokens, criterion, rank`. 한 행이 "평가자 j가 순서 r에서 위치 p에 놓인 학생 t에게 기준 c로 준 순위"다. `criterion`에는 `overall`도 들어 있다.

H.6 실행 방법

```
.venv/bin/python judge/select_items.py                          # 묶음·항목·제시 순서 생성 (1회)
.venv/bin/python judge/run_judge.py --judge gpt --dry-run       # 프롬프트 확인 (API 호출 없음)
.venv/bin/python judge/run_judge.py --judge gpt --pilot         # 파일럿: seed 42 묶음 10개 × 순서 3 = 30개
.venv/bin/python judge/run_judge.py --judge gpt                 # 본 채점 (claude, gemini도 동시에; 끊기면 다시 실행해 이어 하기)
.venv/bin/python judge/merge_results.py                         # 최종 JSON 생성 + ranks_long.csv
.venv/bin/python judge/descriptive.py                           # 기술 통계 (4.1, 4.2, 4.5, 5절, 6절의 표)
.venv/bin/python judge/analyze_models.py                        # 통계 모형 3개 × 결과 5개, 부트스트랩 1,000회 (약 6분)
```

채점 실행 기록. 세 평가자를 동시에 실행했다(평가자마다 동시 8개 요청). GPT 53.0분, Claude 24.7분, Gemini 36.7분 + 재채점. 평가자마다 1,500개에 누락·중복·잘못된 순위 0건. Gemini는 11건(0.7%)에서 최종 순위의 ranking을 3번 연속 빠뜨려, 재요청 시 형식 오류를 알려 주는 문장을 덧붙여 다시 채점했다(부록 C).

참고문헌

1. Beggs, S., Cardell, S., & Hausman, J. (1981). Assessing the potential demand for electric cars. *Journal of Econometrics*, 17(1), 1-19.
2. Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources*, 50(2), 317-372.
3. Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65-70.
4. Hou, Y. et al. (2024). Large Language Models are Zero-Shot Rankers for Recommender Systems. *ECIR 2024*.
5. Li, D. et al. (2025). Preference Leakage: A Contamination Problem in LLM-as-a-judge. *arXiv:2502.01534*.

6. Liusie, A., Manakul, P., & Gales, M. (2024). LLM Comparative Assessment: Zero-shot NLG Evaluation through Pairwise Comparisons using Large Language Models. *EACL 2024*.
7. Luce, R. D. (1959). *Individual Choice Behavior: A Theoretical Analysis*. Wiley.
8. Plackett, R. L. (1975). The analysis of permutations. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 24(2), 193-202.
9. Shi, L. et al. (2025). Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge. *arXiv:2406.07791*.
10. Son, G. et al. (2024). LLM-as-a-Judge & Reward Model: What They Can and Cannot Do. *arXiv:2409.11239*.
11. Tang, R. et al. (2024). Found in the Middle: Permutation Self-Consistency Improves Listwise Ranking in Large Language Models. *NAACL 2024*.
12. Wang, P. et al. (2024). Large Language Models are not Fair Evaluators. *ACL 2024*.
13. Ye, S. et al. (2024). FLASK: Fine-grained Language Model Evaluation based on Alignment Skill Sets. *ICLR 2024*.
14. Zheng, L. et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *NeurIPS 2023 Datasets and Benchmarks*.

서지 정보(권·쪽, 최종 출판처)는 논문 투고 전 원문으로 다시 확인한다.